第 2 章　常用统计理论介绍

2.1　常用概率分布

2.1.1　常用概率分布的定义

设 X 为一随机变量，对任意实数 x，定义

$$F(x)=P(X\le x)$$

为 X 的**分布函数**。根据随机变量取值的特点，随机变量分为离散型和连续型两种。

若 X 为离散随机变量，其可能的取值为 $x_1,x_2,\cdots,x_n,\cdots$，称 $P(X=x_i),\ i=1,2,\cdots,n,\cdots$ 为 X 的**概率函数**（也称为**分布列**）。定义 $E(X)=\sum_i x_iP(X=x_i)$（若存在）为 X 的**数学期望**（也称**均值**）。

若随机变量 X 的分布函数可以表示为一个非负函数 $f(x)$ 的积分，即 $F(x)=\int_{-\infty}^{x}f(x)dx$，则称 X 为连续型随机变量，称 $f(x)$ 为 X 的**概率密度函数**（简称密度函数）。定义 $E(X)=\int_{-\infty}^{+\infty}f(x)dx$（若存在）为 X 的数学期望。

定义 $\mathrm{var}(X)=E\left\{\left[X-E(X)\right]^2\right\}$（若存在）为随机变量 X 的**方差**。

这里介绍几个常用的离散型和连续型分布。

1. 二项分布

若随机变量 X 的概率函数为

$$P(X=k)=C_n^k p^k(1-p)^{n-k},\quad k=0,1,\cdots,n,\quad 0<p<1,$$

则称 X 服从**二项分布**，记为 $X\sim B(n,\ p)$．其期望 $E(X)=np$，方差 $\mathrm{var}(X)=np(1-p)$.

这样一个实例就对应了一个二项分布，在 n 次独立重复试验中，若每次试验仅有两个结果，记为事件 A 和 $\overline{A}$（A 的对立事件），设 A 发生的概率为 p，n 次试验中 A 发生的次数为 X，则 $X\sim B(n,\ p)$.

2. 泊松分布

若随机变量 X 的概率函数为

$$P(X=k)=\frac{\lambda^k e^{-\lambda}}{k!},\quad k=0,1,2,\cdots,\quad \lambda>0,$$

则称 X 服从参数为 λ 的**泊松分布**，记为 $X\sim P(\lambda)$. 其期望 $E(X)=\lambda$，方差 $\mathrm{var}(X)=\lambda$.

在生物学、医学、工业统计、保险科学及公用事业的排队等问题中， 泊松分布是常见的。例如纺织厂生产的一批布匹上的疵点个数、电话总机在一段时间内收到的呼唤次数等都服从泊松分布。

3. 离散均匀分布

若随机变量 X 的概率函数为

$$P(X=x_i)=\frac{1}{n},\quad i=1,2,\cdots n,$$

则称 X 服从**离散的均匀分布**.

4. 连续均匀分布

若随机变量 X 的概率密度函数为

$$f(x)=\begin{cases}\dfrac{1}{b-a}, & a\le x\le b,\\ 0, & 其它.\end{cases}$$

则称 X 服从区间 $[a,\ b]$ 上的**连续均匀分布**，记为 $X\sim U(a,b)$．其期望 $E(X)=\dfrac{a+b}{2}$，方差 $\mathrm{var}(X)=\dfrac{(b-a)^2}{12}$．

通常四舍五入取整所产生的误差服从 $(-0.5,\ 0.5)$ 上的均匀分布。在没指明分布的情况下，我们常说的随机数是指 $[0,\ 1]$ 上的均匀分布随机数。

5. 指数分布

若随机变量 X 的概率密度函数为

$$f(x)=\begin{cases}\dfrac{1}{\lambda}e^{-\frac{x}{\lambda}}, & x>0,\\ 0, & x\le 0.\end{cases}$$

其中 $\lambda>0$ 为参数，则称 X 服从**指数分布**，记为 $X\sim Exp(\lambda)$．其期望 $E(X)=\lambda$，方差 $\mathrm{var}(X)=\lambda^2$．

某些元件或设备的寿命服从指数分布。例如无线电元件的寿命 、电力设备的寿命、动物的寿命等都服从指数分布。

6. 正态分布

若随机变量 X 的概率密度函数为

$$f(x)=\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-\mu)^2}{2\sigma^2}},\quad -\infty<x<+\infty,$$

其中 $\sigma>0,\ \mu$ 为分布的参数，则称 X 服从**正态分布**，记为 $X\sim N(\mu,\ \sigma^2)$．其期望 $E(X)=\mu$，方差 $\mathrm{var}(X)=\sigma^2$．特别地，当 $\mu=0,\ \sigma=1$ 时，称 X 服从标准正态分布，记为 $X\sim N(0,\ 1)$．

正态分布是最重要最为常见的一种分布，自然界中的很多随机现象都对应着正态分布，例如考试成绩近似服从正态分布，人的身高、体重、产品的尺寸等均近似服从正态分布。

正态分布具有以下几个重要特征：

（1）密度函数关于 $x=\mu$ 对称，呈现出中间高，两边低的现象，在 $x=\mu$ 处取得最大值，如图 2-1 所示。

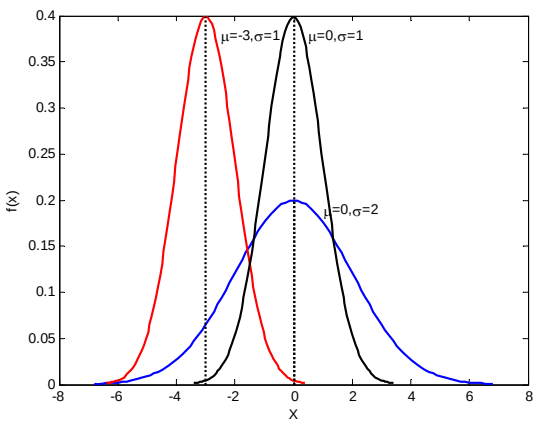

图 2-1　正态分布密度函数图

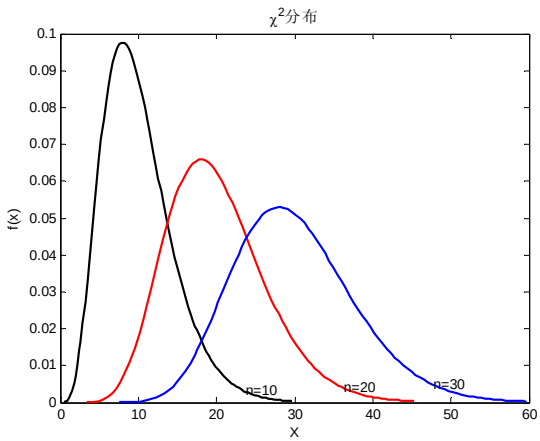

图 2-2　卡方分布密度函数图

（2）当 μ 的取值变动时，密度函数图像沿 x 轴平移，当 σ 的取值变大或变小时，密度函数图像变得

平缓或陡峭。

（3）若 $X \sim N(\mu,\ \sigma^2)$，则

$$X^* = \frac{X-\mu}{\sigma} \sim N(0,\ 1), \quad F(x) = \Phi\left(\frac{x-\mu}{\sigma}\right).$$

这里 $F(x)$ 为 X 的分布函数，$\Phi(x)$ 为标准正态分布的分布函数，在一般的概率论与数理统计课本中都提供 $\Phi(x)$ 的函数值表。

7. χ^2（卡方）分布

设随机变量 $X_1, X_2, \cdots, X_k$ 相互独立，且均服从 $N(0,\ 1)$ 分布，则称随机变量 $\chi^2 = \sum_{i=1}^{k} X_i^2$ 所服从的分布是自由度为 k 的 **χ^2 分布**，记作 $\chi^2 \sim \chi^2(k)$. 卡方分布的密度函数图像如图 2-2 所示。

8. t 分布

设随机变量 X 与 Y 相互独立，X 服从 $N(0,1)$ 分布，Y 服从自由度为 k 的 χ^2 分布，则称随机变量 $t = \frac{X}{\sqrt{Y/k}}$ 所服从的分布是自由度为 k 的 **t 分布**，记作 $t \sim t(k)$. t 分布的密度函数图像如图 2-3 所示。

9. F 分布

设随机变量 X 与 Y 相互独立，分别服从自由度为 k_1 与 k_2 的 χ^2 分布，则称随机变量 $F = \frac{X/k_1}{Y/k_2}$ 所服从的分布是自由度为 (k_1, k_2) 的 **F 分布**，记作 $F \sim F(k_1, k_2)$. 其中 k_1 称为第一自由度，k_2 称为第二自由度。F 分布的密度函数图像如图 2-4 所示。

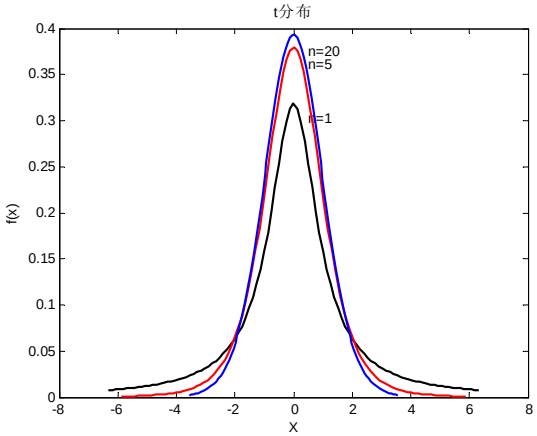

图 2-3 t 分布密度函数图

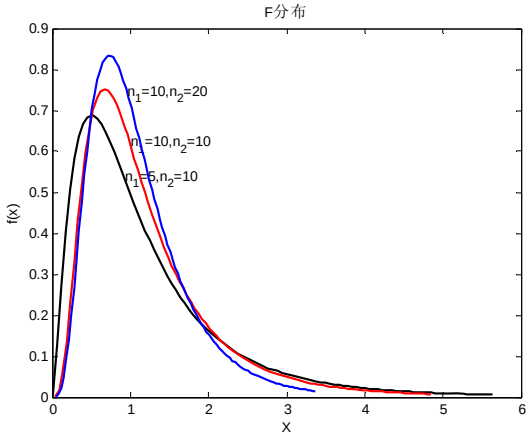

图 2-4 F 分布密度函数图

2.1.2 密度、分布和逆概率分布函数值的计算

MATLAB 统计工具箱中有这样一系列函数，函数名以 pdf 三个字符结尾的函数用来计算常见连续分布的密度函数值或离散分布的概率函数值，函数名以 cdf 三个字符结尾的函数用来计算常见分布的分布函数值，函数名以 inv 三个字符结尾的函数用来计算常见分布的逆概率分布函数值，函数名以 rnd 三个字符结尾的函数用来生成常见分布的随机数，函数名以 fit 三个字符结尾的函数用来求常见分布的参数的最大似然估计和置信区间，函数名以 stat 四个字符结尾的函数用来计算常见分布的期望和方差，函数名以 like 四个字符结尾的函数用来计算常见分布的负对数似然函数值。

MATLAB 中提到的常见分布如表 2-1 所示

表 2-1　常见分布列表

离散分布	连续分布		
二项分布（bino）	正态分布（norm）	t 分布（t）	威布尔分布（wbl）
负二项分布（nbin）	对数正态分布（logn）	非中心 t 分布（nct）	瑞利分布（rayl）
几何分布（geo）	多元正态分布（mvn）	多元 t 分布（mvt）	极值分布（ev）
超几何分布（hyge）	连续均匀分布（unif）	F 分布（F）	广义极值分布（gev）
泊松分布（poiss）	指数分布（exp）	非中心 F 分布（ncf）	广义 Pareto 分布（gp）
离散均匀分布（unid）	卡方分布（chi2）	β 分布（beta）	
多项分布（mn）	非中心卡方分布（ncx2）	Γ 分布（gam）	

在表 2-1 中列出的一些常见分布名英文缩写的后面分别加上 pdf，cdf，inv，就可得到常见分布的密度、分布和逆概率分布函数值的计算函数，如表 2-2 所示。

表 2-2　常见分布的密度、分布和逆概率分布函数值的计算函数

密度函数		分布函数		逆概率分布函数	
函数名	调用方式	函数名	调用方式	函数名	调用方式
betapdf	Y = betapdf(X,A,B)	betacdf	p = betacdf(X,A,B)	betainv	X = betainv(P,A,B)
binopdf	Y = binopdf(X,N,P)	binocdf	Y = binocdf(X,N,P)	binoinv	X = binoinv(Y,N,P)
chi2pdf	Y = chi2pdf(X,V)	chi2cdf	P = chi2cdf(X,V)	chi2inv	X = chi2inv(P,V)
evpdf	Y = evpdf(X,mu,sigma)	evcdf	P = evcdf(X,mu,sigma)	evinv	X = evinv(P,mu,sigma)
exppdf	Y = exppdf(X,mu)	expcdf	P = expcdf(X,mu)	expinv	X = expinv(P,mu)
fpdf	Y = fpdf(X,V1,V2)	fcdf	P = fcdf(X,V1,V2)	finv	X = finv(P,V1,V2)
gampdf	Y = gampdf(X,A,B)	gamcdf	gamcdf(X,A,B)	gaminv	X = gaminv(P,A,B)
geopdf	Y = geopdf(X,P)	geocdf	Y = geocdf(X,P)	geoinv	X = geoinv(Y,P)
gevpdf	Y = gevpdf(X,K,sigma,mu)	gevcdf	P = gevcdf(X,K,sigma,mu)	gevinv	X = gevinv(P,K,sigma,mu)
gppdf	P = gppdf(X,K,sigma,theta)	gpcdf	P = gpcdf(X,K,sigma,theta)	gpinv	X = gpinv(P,K,sigma,theta)
hygepdf	Y = hygepdf(X,M,K,N)	hygecdf	hygecdf(X,M,K,N)	hygeinv	hygeinv(P,M,K,N)
lognpdf	Y = lognpdf(X,mu,sigma)	logncdf	P = logncdf(X,mu,sigma)	logninv	X = logninv(P,mu,sigma)
mnpdf	Y = mnpdf(X,PROB)				
mvnpdf	y = mvnpdf(X) y = mvnpdf(X,MU) y = mvnpdf(X,MU,SIGMA)	mvncdf	y = mvncdf(X) y = mvncdf(X,mu,SIGMA) y = mvncdf(xl,xu,mu,SIGMA)		
mvtpdf	y = mvtpdf(X,C,df)	mvtcdf	y = mvtcdf(X,C,DF) y = mvtcdf(xl,xu,C,DF)		
nbinpdf	Y = nbinpdf(X,R,P)	nbincdf	Y = nbincdf(X,R,P)	nbininv	X = nbininv(Y,R,P)
ncfpdf	Y = ncfpdf(X,NU1,NU2,DELTA)	ncfcdf	P = ncfcdf(X,NU1,NU2,DELTA)	ncfinv	X = ncfinv(P,NU1,NU2,DELTA)
nctpdf	Y = nctpdf(X,V,DELTA)	nctcdf	P = nctcdf(X,NU,DELTA)	nctinv	X = nctinv(P,NU,DELTA)
ncx2pdf	Y = ncx2pdf(X,V,DELTA)	ncx2cdf	P = ncx2cdf(X,V,DELTA)	ncx2inv	X = ncx2inv(P,V,DELTA)
normpdf	Y = normpdf(X,mu,sigma)	normcdf	P = normcdf(X,mu,sigma)	norminv	X = norminv(P,mu,sigma)
poisspdf	Y = poisspdf(X,lambda)	poisscdf	P = poisscdf(X,lambda)	poissinv	X = poissinv(P,lambda)
raylpdf	Y = raylpdf(X,B)	raylcdf	P = raylcdf(X,B)	raylinv	X = raylinv(P,B)
tpdf	Y = tpdf(X,V)	tcdf	P = tcdf(X,V)	tinv	X = tinv(P,V)
unidpdf	Y = unidpdf(X,N)	unidcdf	P = unidcdf(X,N)	unidinv	X = unidinv(P,N)
unifpdf	Y = unifpdf(X,A,B)	unifcdf	P = unifcdf(X,A,B)	unifinv	X = unifinv(P,A,B)
wblpdf	Y = wblpdf(X,A,B)	wblcdf	P = wblcdf(X,A,B)	wblinv	X = wblinv(P,A,B)

公　用	调用方式	公　用	调用方式	公　用	调用方式
pdf	Y = pdf(name,X,A) Y = pdf(name,X,A,B) Y = pdf(name,X,A,B,C)	cdf	Y = cdf(name,X,A) Y = cdf(name,X,A,B) Y = cdf(name,X,A,B,C)	icdf	Y = icdf(name,X,A) Y = icdf(name,X,A,B) Y = icdf(name,X,A,B,C)

如表 2-2 所示，MATLAB 中还提供了 pdf、cdf 和 icdf 三个公共函数，它们分别通过调用表 2-2 中的其他函数来计算常见分布的密度、分布和逆概率分布函数值。表 2-2 中的部分函数有多种调用方式，表中只列了一种。另外限于篇幅没有对各个函数的调用方式作出说明，读者可以参考下例。

【例 2.1】求均值为 1.2345，标准差（方差的算术平方根）为 6 的正态分布在 $x = 0,1,2,\cdots,10$ 处的密度函数值与分布函数值。

```
>> x = 0:10;     %产生一个向量
>> Y = normpdf(x, 1.2345, 6)     %求密度函数值

Y =

    0.0651 0.0664 0.0660 0.0637 0.0598 0.0546 0.0485 0.0419 0.0352 0.0288 0.0229

>> P = normcdf(x, 1.2345, 6)     %求分布函数值

P =

    0.4185 0.4844 0.5508 0.6157 0.6776 0.7349 0.7865 0.8317 0.8703 0.9022 0.9280
```

【例 2.2】求标准正态分布、t 分布、χ^2 分布和 F 分布的上侧分位数。

（1）标准正态分布的上侧 0.05 分位数 $u_{0.05}$；

（2）自由度为 50 的 t 分布的上侧 0.05 分位数 $t_{0.05}(50)$；

（3）自由度为 8 的 χ^2 分布的上侧 0.025 分位数 $\chi^2_{0.025}(8)$；

（4）第一自由度为 7，第二自由度为 13 的 F 分布的上侧 0.01 分位数 $F_{0.01}(7,\ 13)$；

（5）第一自由度为 13，第二自由度为 7 的 F 分布的上侧 0.99 分位数 $F_{0.99}(13,\ 7)$.

这里先对上侧分位数的概念作一点说明，设随机变量 $\chi^2 \sim \chi^2(n)$，对于给定的 $0 < \alpha < 1$，称满足 $P(\chi^2 \geq \chi^2_\alpha) = \alpha$ 的数 χ^2_α 为 $\chi^2(n)$ 分布的**上侧 α 分位数**。其他分布的上侧分位数的定义与之类似。利用逆概率分布函数可以求上侧分位数，例 2.2 的程序及结果如下。

```
>> u = norminv(1-0.05, 0, 1)

u =

    1.6449

>> t = tinv(1-0.05, 50)

t =

    1.6759

>> chi2 = chi2inv(1-0.025, 8)

chi2 =

   17.5345
```

```
>> f1 = finv(1-0.01, 7, 13)

f1 =

    4.4410

>> f2 = finv(1-0.99, 13, 7)

f2 =

    0.2252
```

从上面的结果可以验证 F 分布的分位数满足的性质：$F_{\alpha}(k_1,\ k_2)=\dfrac{1}{F_{1-\alpha}(k_2,\ k_1)}$.

2.2　统计量与统计图

2.2.1　总体与样本

在研究实际问题的时候，我们往往研究有关对象的某一项或几项数量指标，例如研究我国某地区经济发展水平，就需要考察一些数量指标：人均 GDP、人均能源消费、农村人口比重、人口预期寿命、新生婴儿死亡率、识字率等。为此，需要对该地区所有人进行调查（统计上称为**试验**），对每个人调查得到的数据就是一个观察值，称为**个体**。考虑到实际调查的难度，这显然是不太现实的，通常是抽取一部分人进行调查，这种方法在统计中就叫做**抽样**。这里把试验的全部可能的观察值称为**总体**，如果只研究一项数量指标，这个总体就是一元总体，多项数量指标对应的是多元总体。包含有限个个体的总体是有限总体，否则称为无限总体，对于无限总体，也只能通过抽样来研究。把从总体中抽取的若干个体称为**样本**，样本包含的个体数称为**样本容量**。前面提到的例子中的总体就是该地区所有人对应的观察值，这是一个有限多元总体。

因为总体中每一个个体是随机试验的一个观察值，它是一个随机变量 X 的值，因此我们用随机变量 X 表示总体，相应的把从总体中抽取的容量为 n 的样本用随机变量 $X_1,X_2,\cdots,X_n$ 表示，$x_1,x_2,\cdots,x_n$ 表示样本观测值。抽样应使得 $X_1,X_2,\cdots,X_n$ 相互独立（通俗地讲就是互相之间没有任何关系），并与总体 X 具有相同的分布，这样才能用样本去推断总体。

2.2.2　常用统计量

在用样本推断总体时，通常需要构造一些样本函数，把不含任何未知参数的样本函数称为**统计量**，之所以不含未知参数，是因为在推断总体时，能用的只有样本的信息。常用统计量有以下几种。

1．样本均值（mean）：$\bar{X}=\dfrac{1}{n}\sum\limits_{i=1}^{n}X_i$.

2．样本方差（var）：$S^2=\dfrac{1}{n-1}\sum\limits_{i=1}^{n}(X_i-\bar{X})^2$.

3．样本标准差（std）：$S=\sqrt{\dfrac{1}{n-1}\sum\limits_{i=1}^{n}(X_i-\bar{X})^2}$.

4．样本 k 阶原点矩：$A_k=\dfrac{1}{n}\sum\limits_{i=1}^{n}X_i^k$.

5．样本 k 阶中心矩（moment）：$B_k = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^k$.

6．次序统计量：称 $X_{(i)}$ 为第 i 次序统计量，$X_{(i)}$ 的取值为样本观测值从小到大排序后的第 i 个值。

7．样本极差（range）：$\mathrm{Range}(X_1, X_2, \cdots, X_n) = X_{(n)} - X_{(1)}$.

8．样本 p 分位数（prctile）：$m_p = \begin{cases} X_{([np+1])}, & 若np不是整数 \\ \frac{1}{2}\left(X_{(np)} + X_{(np+1)}\right), & 若np是整数 \end{cases}$，其中 $[np+1]$ 表示不超过 $np+1$ 的整数。特别的，样本 0.5 分位数又称为**样本中位数**。

9．众数（mode）：样本观测值中出现次数最多（或频率最大）的数。

10．变异系数：样本标准差与样本均值的比值 $S/\bar{X}$.

11．样本偏度（skewness）：$\gamma_1 = \frac{B_3}{B_2^{1.5}}$，其中 B_k 为样本 k 阶中心矩。

12．样本峰度（kurtosis）：$\gamma_2 = \frac{B_4}{B_2^2}$.

注意： 上面各统计量名称后面的括号中给出的就是MATLAB中自带的求该统计量观测值的函数，在后面的章节中会以案例的形式给出各函数的调用方法。

2.2.3 常用统计图

用图形能比较直观的反映数据所包含的规律，下面介绍几个常用的统计图。

1. 直方图（hist/hist3）

在观察数据所服从的分布时，直方图是非常简洁实用的。做直方图的步骤如下：

（1）将样本观测值从小到大排序得 $x_{(1)} \le x_{(2)} \le \cdots \le x_{(l)}$.

（2）适当选取略小于 $x_{(1)}$ 的数 a 与略大于 $x_{(l)}$ 的数 b，将区间 $(a,\ b)$ 随意分为 k 个不相交的小区间，记第 i 个小区间为 I_i，其长度为 h_i .

（3）把样本观测值逐个分到各区间内，并计算样本观测值落在各区间内的频数 n_i 及频率 $f_i = \frac{n_i}{n}$.

（4）在 x 轴上截取各区间，并以各区间为底，以 n_i 为高作小矩形，就得到**频数直方图**，若以 $\frac{f_i}{h_i}$ 为高作小矩形，就得到**频率直方图**。

MATLAB 中绘制频数直方图的函数是 hist 和 hist3（二元变量的三维直方图）。

2. 经验分布函数图（cdfplot，ecdf）

根据直方图的作法，可以得到样本频率分布表如表 2-3 所示。

表 2-3 样本频率分布表

观测值	$x_{(1)}$	$x_{(2)}$	$\cdots$	$x_{(l)}$	总　计
频数	n_1	n_2	$\cdots$	n_l	n
频率	f_1	f_2	$\cdots$	f_l	1

称函数

$$F_n(x)=\begin{cases}0, & x<x_{(1)},\\ \sum_{k=1}^{i} f_k, & x_{(i)}\le x<x_{(i+1)},\quad i=1,2,\cdots,l-1\\ 1, & x\ge x_{(l)},\end{cases}$$

为**样本分布函数**（或**经验分布函数**）。经验分布函数图是阶梯状图，反映了样本观测数据的分布情况。对于经验分布函数，格里汶科（Glivenko）证明了下面的定理。

定理 2.1（格里汶科定理）　设总体 X 的分布函数为 $F(x)$，经验分布函数为 $F_n(x)$，记

$$D_n=\sup_{-\infty<x<+\infty}|F_n(x)-F(x)|$$

则有

$$P\left\{\lim_{n\to\infty}D_n=0\right\}=1.$$

该定理可以这样理解，当样本容量 n 相当大时，经验分布函数是总体分布函数的一个良好的近似。

MATLAB 中绘制经验分布函数图的函数是 cdfplot 和 ecdf.

3. 箱线图（boxplot）

箱线图的做法如下：

（1）画一个箱子，其左侧线为样本 0.25 分位数位置，其右侧线为样本 0.75 分位数位置，在样本中位数（即 0.5 分位数）位置上画一条竖线，画在箱子内。这个箱子包含了样本中 50%的数据。

（2）在箱子左右两侧各引出一条水平线，左侧线画至样本最小值，右侧线画至样本最大值，这样每条线段包含了样本 25%的数据。

以上两步得到的图形就是样本数据的水平**箱线图**，当然箱线图也可以作成竖直的形式。从箱线图上能大概看出样本数据的分布情况。MATLAB 中绘制箱线图的函数是 boxplot.

4. 正态概率图（normplot，probplot）

正态概率图用于正态分布的检验，实际上就是纵坐标经过变换后的正态分布的分布函数图，正常情况下，正态分布的分布函数曲线是一条 S 形曲线，而在正态概率图上描绘的则是一条直线。

如果采用手工绘制正态概率图的话，可以在正态概率纸上描绘，正态概率纸上有根据正态分布构造的坐标系，其横坐标是均匀的，纵坐标是不均匀的，以保证正态分布的分布函数图形是一条直线。

MATLAB 统计工具箱中提供了 normplot 函数，用来绘制正态概率图，每一个样本观测值对应图上一个“+”号，图上给出了一条红色的参考线（点划线），若图中的“+”号都集中在这条参考线附近，说明样本观测数据近似服从正态分布，偏离参考线的“+”号越多，说明样本观测数据越不服从正态分布。MATLAB 统计工具箱中还提供了 probplot 函数，用来绘制指定分布的概率图。

5. p-p 图

p-p 图用来检验样本观测数据是否服从指定的分布，是样本经验分布函数与指定分布的分布函数的关系曲线图。通常情况下，一个坐标轴表示样本经验分布，另一个坐标轴表示指定分布的分布函数。每一个样本观测数据对应图上的一个“+”号，图中有一条参考直线，若图中的“+”号都集中在这条参考线附近，说明样本观测数据近似服从指定分布，偏离参考线的“+”号越多，说明样本观测数据越不服从指定分布。

MATLAB 中没有提供绘制 p-p 图的函数。

6. q-q 图（qqplot）

q-q 图也可用来检验样本观测数据是否服从指定的分布，是样本分位数与指定分布的分位数的关系曲线图。通常情况下，一个坐标轴表示样本分位数，另一个坐标轴表示指定分布的分位数。每一个样本观测数据对应图上的一个“+”号，图中有一条参考直线，若图中的“+”号都集中在这条参考线附近，说明样本观测数据近似服从指定分布，偏离参考线的“+”号越多，说明样本观测数据越不服从指定分布。

MATLAB 统计工具箱中提供了 qqplot 函数，用来绘制 q-q 图。qqplot 函数不仅可以绘制一个样本的 q-q 图，用来检验样本是否服从指定分布，还可以绘制两个样本的 q-q 图，检验两个样本是否服从相同的分布。

2.3 参数估计

总体分布中通常含有参数，在实际问题中这些参数往往是未知的，需要用样本观测数据进行估计，若估计出具体的值，就称为**点估计**，若在一定概率水平下估计出一个区间，就称为**区间估计**。

2.3.1 点估计

通常情况下，参数的点估计有**矩估计**和**最大似然估计**两种。

1. 矩估计

总体的各阶中心矩和原点矩是总体分布中参数的函数，而样本的各阶中心矩和原点矩是样本的函数，样本矩不含有未知参数，通过它们相等可以建立方程组，从而解得总体分布中的参数，这种方法称为矩估计。

设总体 X 的分布中含有 m 个未知参数 $\theta_1,\theta_2,\cdots,\theta_m$，用 $\mu_k=E(X^k)$ 表示总体的 k 阶原点矩，它是 $\theta_1,\theta_2,\cdots,\theta_m$ 的函数，用 $A_k=\frac{1}{n}\sum_{i=1}^{n}X_i^k$ 表示样本的 k 阶原点矩，列方程组 $\mu_i=A_i,\ i=1,\cdots,m$ 解得参数的矩估计，记为 $\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_m$.

2. 最大似然估计

举一个通俗的例子说明什么是最大似然估计，射击技术平庸的我和一个经验丰富的猎人一同在密林里打猎，前面蹿出一只野兔，只听一声枪响，野兔倒下，请问野兔最可能是被谁击中的？我想几乎所有的人都会认为是猎人击中的野兔，因为猎人击中野兔的概率要比我击中的概率大得多，大家不会去选择发生概率比较小的情况。最大似然估计的原理与之类似，我们通过抽样得到一组样本观测值 $x_1,x_2,\cdots,x_n$，也就是说事件 $X_1=x_1,\ X_2=x_2\ ,\cdots,\ X_n=x_n$ 发生了，为什么是这个事件发生而不是别的事件发生呢？因为这个事件发生的概率最大，换句话说，让 $P(X_1=x_1,\ X_2=x_2\ ,\cdots,\ X_n=x_n)$ 达到最大，即可求得总体分布中参数的估计值，因为这个概率是总体分布中参数的函数。

对于离散总体 X，设其概率函数为 $p(x;\ \theta)$，其中 θ 是未知参数，$X_1,X_2,\cdots,X_n$ 为样本，令

$$L(\theta)=P(X_1=x_1,\ X_2=x_2\ ,\cdots,\ X_n=x_n)=\prod_{i=1}^{n}p(x_i;\ \theta)$$

称 $L(\theta)$ 为样本的**似然函数**，通常 $L(\theta)$ 为单峰函数，其最大值在极大值点处取得，由 $\frac{dL(\theta)}{d\theta}=0$ 可求得 θ 的最大似然估计。遗憾的是，因为求导过于复杂，这样行不通，转而考虑在单调性不变的情况下作对数变换得**对数似然函数**

$$\ln L(\theta)=\sum_{i=1}^{n}\ln p(x_i;\ \theta).$$

$\ln L(\theta)$ 与 $L(\theta)$ 的最大值点相同，再由 $\frac{d\ln L(\theta)}{d\theta}=0$ 即可求得 θ 的最大似然估计。

对于连续总体 X，设其密度函数为 $f(x;\ \theta)$，其中 θ 是未知参数，$X_1,X_2,\cdots,X_n$ 为样本，此时 $P(X_1=x_1,\ X_2=x_2\ ,\cdots,\ X_n=x_n)=0$，考虑概率

$$P(x_1\le X_1\le x_1+\Delta x_1,\ \cdots,\ x_n\le X_n\le x_n+\Delta x_n)\approx\prod_{i=1}^{n}f(x_i;\ \theta)\Delta x_i$$

令 $L(\theta)=\prod_{i=1}^{n} f(x_i;\ \theta)$ 为似然函数，下面的过程与离散总体情形相同。

若总体分布中有多个未知参数，只需对数似然函数对每个未知参数求偏导，令其等于 0，解方程组即可得到每个未知参数的最大似然估计。

2.3.2　区间估计

设 $\theta\in\Theta$ 为总体 X 分布中的未知参数，$X_1,X_2,\cdots,X_n$ 为样本，对给定的 $0<\alpha<1$，构造统计量 $\hat{\theta}_L=\hat{\theta}_L(X_1,X_2,\cdots,X_n)$ 和 $\hat{\theta}_U=\hat{\theta}_U(X_1,X_2,\cdots,X_n)$，使得对任意 $\theta\in\Theta$ 有

$$P(\hat{\theta}_L<\theta<\hat{\theta}_U)=1-\alpha$$

称 $(\hat{\theta}_L,\ \hat{\theta}_U)$ 为参数 θ 的置信水平为 $1-\alpha$ 的**置信区间**，$\hat{\theta}_L$ 为**置信下限**，$\hat{\theta}_U$ 为**置信上限**。

置信水平 $1-\alpha$ 反映了区间的可靠性，区间长度 $\hat{\theta}_U-\hat{\theta}_L$ 反映了估计的精确度，可靠性和精确度是互相矛盾的，通常的做法是在取定置信水平的情况下尽量使区间长度达到最短。

需要注意的是，一旦进行抽样，按照定义中构造统计量的方法，就可用样本观测数据得到一个区间，这个区间可能包含真实的 θ 值，也可能不包含。如果我们抽取 100 个样本，注意说的是样本数，不是样本容量，用这 100 个样本可以得到 100 个区间，这 100 个区间中大概有 $100(1-\alpha)$ 个区间包含 θ 的真实的取值。如图 2-5 所示，从标准正态分布总体中进行 100 次抽样，每次抽取容量为 50 的样本，求得总体均值 μ 的 100 个置信水平为 0.95 的置信区间，用这 100 个区间画出 100 条线段，可以看到只有 5 条线段（红色虚线）不过 0 点。

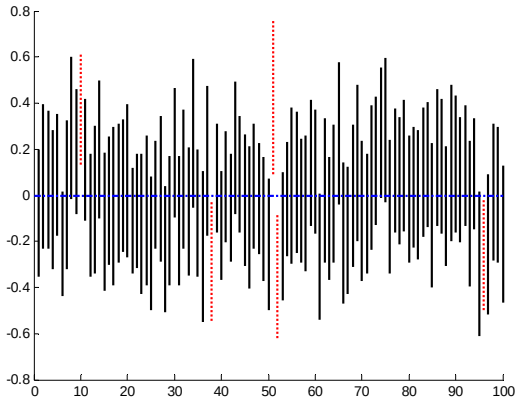

图 2-5　置信区间示意图

求置信区间的常用方法为**枢轴量法**，就是构造一个关于 θ 和样本的函数，记为 $G(\theta)$，$G(\theta)$ 的分布已知并且不依赖于 θ，根据 $G(\theta)$ 的分布，求一个尽可能短的区间 $(g_1,\ g_2)$，使

$$P(g_1<G(\theta)<g_2)=1-\alpha$$

解不等式 $g_1<G(\theta)<g_2$ 得出 θ 的区间即可。

按照这种方法求得单个正态总体均值 μ 的置信水平为 $1-\alpha$ 的置信区间如表 2-4 所示

表 2-4　单个正态总体均值 μ 的置信水平为 $1-\alpha$ 的置信区间

情　形	枢轴量	枢轴量的分布	μ 的置信区间
σ 已知	$\dfrac{\bar{X}-\mu}{\sigma/\sqrt{n}}$	$N(0,\ 1)$	$\left(\bar{X}-\dfrac{\sigma u_{\alpha/2}}{\sqrt{n}},\ \bar{X}+\dfrac{\sigma u_{\alpha/2}}{\sqrt{n}}\right)$

σ 未知	$\dfrac{\bar{X}-\mu}{S/\sqrt{n}}$	$t(n-1)$	$\left(\bar{X}-\dfrac{St_{\alpha/2}(n-1)}{\sqrt{n}},\ \bar{X}+\dfrac{St_{\alpha/2}(n-1)}{\sqrt{n}}\right)$

当总体均值 μ 未知时，单个正态总体标准差 σ 的置信水平为 $1-\alpha$ 的置信区间为

$$\left(\sqrt{\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)}},\ \sqrt{\frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)}}\right).$$

【例 2.3】从某厂生产的滚珠中随机抽取 10 个，测得滚珠的直径（单位：mm）如下：

15.14　14.81　15.11　15.26　15.08　15.17　15.12　14.95　15.05　14.87 .

若滚珠直径服从正态分布 $N(\mu,\sigma^2)$，其中 μ,σ 未知，求 μ,σ 的最大似然估计和置信水平为 90%的置信区间。

MATLAB 统计工具箱中的 normfit 函数用来根据样本观测值求正态总体均值 μ 和标准差 σ 的最大似然估计和置信区间，对于本例，可如下调用：

```
% 定义样本观测值向量
>> x = [15.14  14.81  15.11  15.26  15.08  15.17  15.12  14.95  15.05  14.87];
% 调用 normfit 函数求正态总体参数的最大似然估计和置信区间
% 返回总体均值的最大似然估计 muhat 和 90%置信区间 muci，
% 还返回总体标准差的最大似然估计 sigmahat 和 90%置信区间 sigmaci
>> [muhat,sigmahat,muci,sigmaci] = normfit(x,0.1)

muhat =

   15.0560

sigmahat =

    0.1397

muci =

   14.9750
   15.1370

sigmaci =

    0.1019
    0.2298
```

上面调用 normfit 函数时，它的第 1 个输入是样本观测值向量 x，第 2 个输入是 $\alpha=1-0.9=0.1$. 得到总体均值 μ 的最大似然估计为 $\hat{\mu}=15.0560$，总体标准差 σ 的最大似然估计为 $\hat{\sigma}=0.1397$，总体均值 μ 的 90%置信区间为 $[14.9750,\ 15.1370]$，总体标准差 σ 的 90%置信区间为 $[0.1019,\ 0.2298]$.

2.4　总体参数的检验

2.4.1　假设检验基本概念

相信大家都有过买菜或买水果的经历，比如买 10 斤苹果，我们买到的实际份量可能不是整 10 斤，有可能多一点，有可能少一点，造成这种现象的原因有两种，一种是抽样造成的随机误差，另一种是水果店老板的秤不准，如何检验老板的秤是否准呢？这实际上就是一个假设检验问题。

买 10 斤苹果，设水果店老板给出的实际份量为 X，通常 $X \sim N(\mu, \sigma^2)$，在该水果店买 n 次苹果（每次买 10 斤），相当于从总体 X 中抽取了容量为 n 的样本，记为 $X_1, X_2, \cdots, X_n$，并记样本均值为 $\bar{X}$，样本标准差为 S. 下面结合几个基本概念来阐述上面提出的问题。

1. 原假设与对立假设

作出假设

$$H_0: \mu = \mu_0 = 10, \qquad H_1: \mu \neq \mu_0.$$

这是截然相反的两个结论，分别称为**原假设** H_0 和**对立假设** H_1，对立假设又称为**备择假设**。若老板的秤准，可认为 H_0 成立，否则认为 H_1 成立，我们需要从样本观测值中寻找证据来支持其中的一个结论。

2. 检验统计量

采用类似于反证法的思想，假定 H_0 成立，此时 $|\bar{X} - \mu_0|$ 的值不应该太大，反过来说，如果 $|\bar{X} - \mu_0|$ 的实际计算值比较大，超出了某个临界值，我们就有理由认为前面的假设出了问题，就可以拒绝原假设 H_0.

这个临界值如何确定呢？显然不能凭个人主观来确定，应该从 $\bar{X} - \mu_0$ 的分布的分位数上去考虑，进而从 $\dfrac{\bar{X} - \mu_0}{S/\sqrt{n}}$ 的分布的分位数上去考虑。令 $t = \dfrac{\bar{X} - \mu_0}{S/\sqrt{n}}$，称 t 为**检验统计量**，可知 $t \overset{H_0\text{成立}}{\sim} t(n-1)$。

取 $t(n-1)$ 分布的上侧 0.025 分位数 $t_{0.025}(n-1)$，我们来看看当 $\left|\dfrac{\bar{X} - \mu_0}{S/\sqrt{n}}\right| \geq t_{0.025}(n-1)$ 发生时，拒绝 H_0 是否合理. 注意到 H_0 成立时 $P\left(\left|\dfrac{\bar{X} - \mu_0}{S/\sqrt{n}}\right| \geq t_{0.025}(n-1)\right) = 0.05$，这说明事件 $\left\{\left|\dfrac{\bar{X} - \mu_0}{S/\sqrt{n}}\right| \geq t_{0.025}(n-1)\right\}$ 发生的概率只有 0.05，可以认为是一个小概率事件（通常认为概率不超过 0.05 的事件即为小概率事件），而小概率事件在一次试验（抽样）中是不可能发生的，再次注意到小概率事件是在 H_0 成立假设下导出的，那我们就有理由拒绝 H_0 了。

3. 假设检验的显著性水平

更一般的，用 α 表示小概率，则当 $|t| = \left|\dfrac{\bar{X} - \mu_0}{S/\sqrt{n}}\right| \geq t_{\alpha/2}(n-1)$ 时拒绝 H_0. α 一般取 0.05 或 0.01，称 α 为假设检验的**显著性水平**。

4. 假设检验的拒绝域

令 $W = \left\{(X_1, X_2, \cdots, X_n) \middle| \ |t| \geq t_{\alpha/2}(n-1)\right\}$，由前面的推导可知当样本观测值落入 W 内时，在显著性水平 α 下应拒绝原假设 H_0，称 W 为假设检验的**拒绝域**。

5. 假设检验的 p 值

令 $p = P(|t| \geq |t\text{的观测值}|)$，注意到 $P(|t| \geq t_{\alpha/2}(n-1)) = \alpha$，可以看出当 $p \leq \alpha$ 时，$|t\text{的观测值}| \geq t_{\alpha/2}(n-1)$，此时应拒绝原假设 H_0，反之当 $p > \alpha$ 时，应接受原假设 H_0. 称 p 为假设检验的 ***p* 值**，需要注意的是对不同的假设检验问题，p 值的定义可能不同，但接受或拒绝的规则没变。

6. 假设检验可能犯的两类错误

假设检验可能会犯两类错误，第一类错误是本来 H_0 正确，却由于抽样的原因拒绝了 H_0，这类错误又称为“**拒真**”错误，犯第一类错误的概率小于或等于显著性水平 α；第二类错误是本来 H_0 不正确，却由于抽样的原因接受了 H_0，这类错误又称为“**取伪**”错误。

7. 双侧假设检验与单侧假设检验

设检验统计量为T，拒绝域形如$\{T \ge T_1, 或 T \le T_2\}$的假设检验称为**双侧假设检验**，拒绝域形如$\{T \ge T_1\}$或$\{T \le T_2\}$的假设检验称为**单侧假设检验**。

8. 假设检验的一般步骤

（1）根据实际问题写出原假设H_0与对立假设H_1；

（2）选取适当的统计量，并在原假设H_0成立的条件下确定该统计量的分布；

（3）根据问题的实际情况，选取合适的显著性水平α，并根据统计量的分布查出临界值，从而确定拒绝域；

（4）根据样本观测值计算出统计量的观测值，通过与临界值比较，作出拒绝或接受H_0的判断。

2.4.2 正态总体均值的检验

1. 单个正态总体均值的检验

设总体$X \sim N(\mu,\ \sigma^2)$，$X_1, X_2, \cdots, X_n$为取自X的样本，记样本均值为$\overline{X}$，样本标准差为S. 考虑如下假设检验：

$$H_0: \mu = \mu_0, \qquad H_1: \mu \ne \mu_0,$$
$$H_0: \mu \ge \mu_0, \qquad H_1: \mu < \mu_0,$$
$$H_0: \mu \le \mu_0, \qquad H_1: \mu > \mu_0.$$

当总体标准差σ已知时，构造检验统计量

$$u = \frac{\overline{X} - \mu_0}{\sigma / \sqrt{n}} \overset{\mu=\mu_0}{\sim} N(0,\ 1).$$

σ未知时，构造检验统计量

$$t = \frac{\overline{X} - \mu_0}{S / \sqrt{n}} \overset{\mu=\mu_0}{\sim} t(n-1).$$

拒绝域如表 2-5 所示。

表 2-5 单个正态总体均值的检验

原假设H_0	对立假设H_1	拒绝域	
		σ已知	σ未知
$H_0: \mu = \mu_0$	$H_1: \mu \ne \mu_0$	$\lvert u \rvert \ge u_{\alpha/2}$	$\lvert t \rvert \ge t_{\alpha/2}(n-1)$
$H_0: \mu \ge \mu_0$	$H_1: \mu < \mu_0$	$u \le -u_\alpha$	$t \le -t_\alpha(n-1)$
$H_0: \mu \le \mu_0$	$H_1: \mu > \mu_0$	$u \ge u_\alpha$	$t \ge t_\alpha(n-1)$

【例 2.4】某切割机正常工作时，切割的金属棒的长度服从正态分布$N(100, 4)$. 从该切割机切割的一批金属棒中随机抽取 15 根，测得它们的长度（单位：mm）如下：

97 102 105 112 99 103 102 94 100 95 105 98 102 100 103.

假设总体方差不变，试检验该切割机工作是否正常，即总体均值是否等于 100mm？取显著性水平$\alpha = 0.05$.

分析：这是总体标准差已知时的单个正态总体均值的检验，根据题目要求可写出如下假设：

$$H_0: \mu = \mu_0 = 100, \qquad H_1: \mu \ne \mu_0 .$$

MATLAB 统计工具箱中的 ztest 函数用来作总体标准差已知时的单个正态总体均值的检验，对于本例，可如下调用：

```
% 定义样本观测值向量
```

```
>> x = [97  102  105  112  99  103  102  94  100  95  105  98  102  100  103];
% 调用 ztest 函数作总体均值的双侧检验，
% 返回变量 h，检验的 p 值，均值的置信区间 muci，检验统计量的观测值 zval
>> [h,p,muci,zval] = ztest(x,100,2,0.05)

h =                    % h = 1 时拒绝原假设，h = 0 时，接受原假设

     1

p =

    0.0282

muci =

  100.1212  102.1455

zval =

    2.1947
```

在上述命令中，ztest 函数的 4 个输入分别为样本观测值向量 x、原假设中的 μ_0、总体标准差 σ 和显著性水平 α（默认的显著性水平为 0.05），ztest 函数的 4 个输出分别为变量 h、检验的 p 值 p、总体均值 μ 的置信水平为 $1-\alpha$ 的置信区间 muci 和检验统计量的观测值 zval。当 h = 0 或 $\mathrm{p} > \alpha$ 时，接受原假设 H_0；当 $\mathrm{h} = 1$ 或 $\mathrm{p} \le \alpha$ 时，拒绝原假设 H_0.

由于 ztest 函数返回的检验的 p 值 p = 0.0282 < 0.05，所以在显著性水平 $\alpha = 0.05$ 下拒绝原假设 $H_0: \mu = \mu_0 = 100$，认为该切割机工作不正常。注意到 ztest 函数返回的总体均值的置信水平为 95%的置信区间为 $[100.1212, 102.1455]$，它的两个置信限均大于 100，因此还需作如下的检验：

$$H_0: \mu \le \mu_0 = 100, \qquad H_1: \mu > \mu_0 .$$

```
% 定义样本观测值向量
>> x = [97  102  105  112  99  103  102  94  100  95  105  98  102  100  103];
% 调用 ztest 函数作总体均值的单侧检验，
% 返回变量 h，检验的 p 值，均值的置信区间 muci，检验统计量的观测值 zval
>> [h,p,muci,zval] = ztest(x,100,2,0.05,'right')

h =                    % h = 1 时拒绝原假设，h = 0 时，接受原假设

     1

p =

    0.0141

muci =

  100.2839       Inf

zval =

    2.1947
```

在上述命令中，ztest 函数的前 4 个输入分别为样本观测值向量 x、原假设中的 μ_0、总体标准差 σ 和

显著性水平α（默认的显著性水平为 0.05）。ztest 函数的第 5 个输入 'right' 用来指定对立假设的形式为$H_1:\mu>\mu_0$，若把 'right' 改为 'left'，则表示对立假设为$H_1:\mu<\mu_0$. 由于 ztest 函数返回的检验的 p 值 p = 0.0141 < 0.05，所以在显著性水平$\alpha=0.05$下拒绝原假设$H_0:\mu\le\mu_0=100$，认为总体均值大于 100.

【例 2.5】化肥厂用自动包装机包装化肥，某日测得 9 包化肥的质量（单位：kg）如下：

49.4　50.5　50.7　51.7　49.8　47.9　49.2　51.4　48.9

设每包化肥的质量服从正态分布，是否可以认为每包化肥的平均质量为 50kg？取显著性水平$\alpha=0.05$.

分析：这是总体标准差未知时的单个正态总体均值的检验，根据题目要求可写出如下假设:

$$H_0:\mu=\mu_0=50,\qquad H_1:\mu\ne\mu_0\ .$$

MATLAB 统计工具箱中的 ttest 函数用来作总体标准差未知时的正态总体均值的检验，对于本例，可如下调用：

```
% 定义样本观测值向量
>> x = [49.4  50.5  50.7  51.7  49.8  47.9  49.2  51.4  48.9];
% 调用 ttest 函数作总体均值的双侧检验，
% 返回变量 h，检验的 p 值，均值的置信区间 muci，结构体变量 stats
>> [h,p,muci,stats] = ttest(x,50,0.05)

h =

     0

p =

    0.8961

muci =

   48.9943   50.8945

stats =

    tstat: -0.1348    % t 检验统计量的观测值
       df: 8          % t 检验统计量的自由度
       sd: 1.2360     % 样本标准差
```

在上述命令中，ttest 函数的 3 个输入分别为样本观测值向量 x、原假设中的μ_0和显著性水平α（默认的显著性水平为 0.05），ttest 函数的 4 个输出分别为变量 h、检验的 p 值 p、总体均值μ的置信水平为$1-\alpha$的置信区间 muci 和结构体变量 stats（其字段及说明见命令中的注释）。当 h = 0 或$\mathrm{p}>\alpha$时，接受原假设H_0；当 h = 1 或$\mathrm{p}\le\alpha$时，拒绝原假设H_0.

由于 ttest 函数返回的检验的 p 值 p = 0.8961 > 0.05，所以在显著性水平$\alpha=0.05$下接受原假设$H_0:\mu=\mu_0=50$，认为每包化肥的平均质量为 50kg .

2. 两个正态总体均值的比较检验

设总体$X\sim N(\mu_2,\ \sigma_1^2)$，$X_1,X_2,\cdots,X_{n_1}$为取自$X$的样本，记样本均值为$\overline{X}$，样本标准差为$S_1$；总体$Y\sim N(\mu_2,\ \sigma_2^2)$，$Y_1,Y_2,\cdots,Y_{n_2}$为取自$Y$的样本，记样本均值为$\overline{Y}$，样本标准差为$S_2$. 两样本独立，考虑如下假设检验：

$$H_0:\mu_1=\mu_2,\qquad H_1:\mu_1\ne\mu_2,$$
$$H_0:\mu_1\ge\mu_2,\qquad H_1:\mu_1<\mu_2,$$
$$H_0:\mu_1\le\mu_2,\qquad H_1:\mu_1>\mu_2.$$

当 σ_1，σ_2 已知时，构造检验统计量

$$u=\frac{\bar{X}-\bar{Y}}{\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}}\overset{\mu_1=\mu_2}{\sim}N(0,\ 1).$$

当 $\sigma_1=\sigma_2$ 未知时，检验统计量

$$t=\frac{\bar{X}-\bar{Y}}{S_w\sqrt{\frac{1}{n_1}+\frac{1}{n_2}}}\overset{\mu_1=\mu_2}{\sim}t(n_1+n_2-2).$$

其中

$$S_w=\sqrt{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}.$$

相应的拒绝域如表 2-6 所示。

表 2-6　两个正态总体均值的检验

原假设 H_0	对立假设 H_1	拒绝域	
		σ 已知	σ 未知
$H_0:\mu_1=\mu_2$	$H_1:\mu_1\neq\mu_2$	$\lvert u\rvert\geq u_{\alpha/2}$	$\lvert t\rvert\geq t_{\alpha/2}(n_1+n_2-2)$
$H_0:\mu_1\geq\mu_2$	$H_1:\mu_1<\mu_2$	$u\leq -u_\alpha$	$t\leq -t_\alpha(n_1+n_2-2)$
$H_0:\mu_1\leq\mu_2$	$H_1:\mu_1>\mu_2$	$u\geq u_\alpha$	$t\geq t_\alpha(n_1+n_2-2)$

【例 2.6】甲、乙两台机床加工同一种产品，从这两台机床加工的产品中随机抽取若干件，测得产品直径（单位：mm）为：

甲机床：20.1, 20.0, 19.3, 20.6, 20.2, 19.9, 20.0, 19.9, 19.1, 19.9 .

乙机床：18.6, 19.1, 20.0, 20.0, 20.0, 19.7, 19.9, 19.6, 20.2 .

设甲、乙两机床加工的产品的直径分别服从正态分布 $N(\mu_1,\sigma_1^2)$ 和 $N(\mu_2,\sigma_2^2)$，试比较甲、乙两台机床加工的产品的直径是否有显著差异？取显著性水平 $\alpha=0.05$.

分析：这是总体标准差未知时的两个正态总体均值的比较检验，根据题目要求可写出如下假设：

$$H_0:\mu_1=\mu_2,\qquad H_1:\mu_1\neq\mu_2\ .$$

MATLAB 统计工具箱中的 ttest2 函数用来作总体标准差未知时的两个正态总体均值的比较检验，对于本例，可如下调用：

```
% 定义甲机床对应的样本观测值向量
>> x = [20.1,  20.0,  19.3,  20.6,  20.2,  19.9,  20.0,  19.9,  19.1,  19.9];
% 定义乙机床对应的样本观测值向量
>> y = [18.6,  19.1,  20.0,  20.0,  20.0,  19.7,  19.9,  19.6,  20.2];
>> alpha = 0.05;    % 显著性水平为 0.05
>> tail = 'both';    % 尾部类型为双侧
>> vartype = 'equal';    % 方差类型为等方差
% 调用 ttest2 函数作两个正态总体均值的比较检验，
% 返回变量 h，检验的 p 值，均值差的置信区间 muci，结构体变量 stats
>> [h,p,muci,stats] = ttest2(x,y,alpha,tail,vartype)

h =

     0
```

```
p =

    0.3191

muci =

   -0.2346    0.6791

stats =
    tstat: 1.0263    % t 检验统计量的观测值
       df: 17        % t 检验统计量的自由度
       sd: 0.4713    % 样本的联合标准差（双侧检验）或样本的标准差向量（单侧检验）
```

在上述命令中，ttest2 函数的 5 个输入分别为样本观测值向量 x、样本观测值向量 y、显著性水平α（默认的显著性水平为 0.05）、尾部类型变量 tail 和方差类型变量 vartype. 其中尾部类型变量 tail 用来指定对立假设H_1的形式，它的可能取值为字符串 'both'、'right' 和 'left'，对应的对立假设分别为$H_1:\mu_1\neq\mu_2$（双侧检验）、$H_1:\mu_1>\mu_2$（右尾检验）和$H_1:\mu_1<\mu_2$（左尾检验）。方差类型变量 vartype 用来指定两总体方差是否相等，它的可能取值为字符串 'equal' 和 'unequal'，分别表示等方差和异方差。ttest2 函数的 4 个输出分别为变量 h、检验的p值 p、总体均值之差$\mu_1-\mu_2$的置信水平为$1-\alpha$的置信区间 muci 和结构体变量 stats（其字段及说明见命令中的注释）。当 h = 0 或$\mathrm{p}>\alpha$时，接受原假设H_0；当 h = 1 或$\mathrm{p}\le\alpha$时，拒绝原假设H_0.

上面假定两个总体的方差相同并未知，调用 ttest2 函数进行了两正态总体均值的比较检验，返回的检验的p值 p = 0.3191 > 0.05，所以在显著性水平$\alpha=0.05$下接受原假设$H_0:\mu_1=\mu_2$，认为甲、乙两台机床加工的产品的直径没有显著差异。

3. 成对数据的比较检验（t检验）

对于两个正态总体均值的比较检验，可能出现以下两种情况：

（1）当σ_1,σ_2未知并且$\sigma_1\neq\sigma_2$，但$n_1=n_2=n$；

（2）样本$X_1,X_2,\cdots,X_{n_1}$与$Y_1,Y_2,\cdots,Y_{n_2}$不独立。

在这两种情况下考虑两个正态总体均值的比较检验，就是所谓的成对（配对）数据的比较检验。

令$D=X-Y\sim N(\mu_d,\ \sigma_d^2)$，则两个正态总体均值的比较检验就成了单个正态总体均值的检验

$$H_0:\mu_d=\mu_0=0,\qquad H_1:\mu\neq\mu_0,$$
$$H_0:\mu_d\ge\mu_0=0,\qquad H_1:\mu<\mu_0,$$
$$H_0:\mu_d\le\mu_0=0,\qquad H_1:\mu>\mu_0.$$

此时样本为$D_i=X_i-Y_i,\ i=1,2,\cdots,n$. 这里$\sigma_d$通常是未知的，按照单个正态总体均值的检验中$\sigma$未知的情况构造$t$检验统计量即可，这里不再赘述。

2.4.3 正态总体方差的检验

1. 单个正态总体方差的检验

设总体$X\sim N(\mu,\ \sigma^2)$，μ,σ均未知，$X_1,X_2,\cdots,X_n$为取自X的样本，记样本均值为$\overline{X}$，样本标准差为S. 考虑如下假设检验：

$$H_0:\sigma^2=\sigma_0^2,\qquad H_1:\sigma^2\neq\sigma_0^2,$$
$$H_0:\sigma^2\ge\sigma_0^2,\qquad H_1:\sigma^2<\sigma_0^2,$$
$$H_0:\sigma^2\le\sigma_0^2,\qquad H_1:\sigma^2>\sigma_0^2.$$

构造检验统计量

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \overset{\sigma^2=\sigma_0^2}{\sim} \chi^2(n-1).$$

相应的拒绝域如表 2-7 所示。

表 2-7 单个正态总体方差的检验

原假设 H_0	对立假设 H_1	拒绝域（μ 未知）
$H_0:\sigma^2=\sigma_0^2$	$H_1:\sigma^2\neq\sigma_0^2$	$\chi^2\geq\chi^2_{\alpha/2}(n-1)$ 或 $\chi^2\leq\chi^2_{1-\alpha/2}(n-1)$
$H_0:\sigma^2\geq\sigma_0^2$	$H_1:\sigma^2<\sigma_0^2$	$\chi^2\leq\chi^2_{1-\alpha}(n-1)$
$H_0:\sigma^2\leq\sigma_0^2$	$H_1:\sigma^2>\sigma_0^2$	$\chi^2\geq\chi^2_{\alpha}(n-1)$

【例 2.7】根据例 2.5 中的样本观测数据检验每包化肥的质量的方差是否等于 1.5？取显著性水平 $\alpha=0.05$.

分析：这是总体均值未知时的单个正态总体方差的检验，根据题目要求可写出如下假设:

$$H_0:\sigma^2=\sigma_0^2=1.5,\qquad H_1:\sigma^2\neq\sigma_0^2\ .$$

MATLAB 统计工具箱中的 vartest 函数用来作总体均值未知时的单个正态总体方差的检验，对于本例，可如下调用：

```
% 定义样本观测值向量
>> x = [49.4  50.5  50.7  51.7  49.8  47.9  49.2  51.4  48.9];
>> var0 = 1.5;     % 原假设中的常数
>> alpha = 0.05;     % 显著性水平为 0.05
>> tail = 'both';     % 尾部类型为双侧
% 调用 vartest 函数作单个正态总体方差的双侧检验，
% 返回变量 h，检验的 p 值，方差的置信区间 varci，结构体变量 stats
>> [h,p,varci,stats] = vartest(x,var0,alpha,tail)

h =

     0

p =

    0.8383

varci =

    0.6970    5.6072

stats =

    chisqstat: 8.1481     % 卡方检验统计量的观测值
           df: 8          % 卡方检验统计量的自由度
```

在上述命令中，vartest 函数的 4 个输入分别为样本观测值向量 x、原假设中的 σ_0^2、显著性水平 α（默认的显著性水平为 0.05）和尾部类型变量 tail. 其中尾部类型变量 tail 用来指定对立假设 H_1 的形式，它的可能取值为字符串 'both'、'right' 和 'left'，对应的对立假设分别为 $H_1:\sigma^2\neq\sigma_0^2$（双侧检验）、$H_1:\sigma^2>\sigma_0^2$（右尾检验）和 $H_1:\sigma^2<\sigma_0^2$（左尾检验）。vartest 函数的 4 个输出分别为变量 h、检验的

p 值 p、总体方差 σ^2 的置信水平为 $1-\alpha$ 的置信区间 varci 和结构体变量 stats（其字段及说明见命令中的注释）。当 h = 0 或 $p > \alpha$ 时，接受原假设 H_0；当 h = 1 或 $p \le \alpha$ 时，拒绝原假设 H_0.

由于 vartest 函数返回的检验的 p 值 p = 0.8383 > 0.05，所以在显著性水平 $\alpha = 0.05$ 下接受原假设 $H_0: \sigma^2 = \sigma_0^2 = 1.5$，认为每包化肥的质量的方差等于 1.5 .

2. 两个正态总体方差的比较检验

设总体 $X \sim N(\mu_2,\ \sigma_1^2)$，$\mu_1$ 未知，$X_1, X_2, \cdots, X_{n_1}$ 为取自 X 的样本，记样本均值为 $\overline{X}$，样本标准差为 S_1；总体 $Y \sim N(\mu_2,\ \sigma_2^2)$，$\mu_2$ 未知，$Y_1, Y_2, \cdots, Y_{n_2}$ 为取自 Y 的样本，记样本均值为 $\overline{Y}$，样本标准差为 S_2. 两样本独立。考虑如下假设检验：

$$H_0: \sigma_1^2 = \sigma_2^2, \qquad H_1: \sigma_1^2 \ne \sigma_2^2,$$
$$H_0: \sigma_1^2 \ge \sigma_2^2, \qquad H_1: \sigma_1^2 < \sigma_2^2,$$
$$H_0: \sigma_1^2 \le \sigma_2^2, \qquad H_1: \sigma_1^2 > \sigma_2^2.$$

构造检验统计量

$$F = \frac{S_1^2}{S_2^2} \overset{\sigma_1^2=\sigma_2^2}{\sim} F(n_1 - 1,\ n_2 - 1),$$

相应的拒绝域如表 2-8 所示。

表 2-8 两个正态总体方差的比较检验

原假设 H_0	对立假设 H_1	拒绝域（μ_1, μ_2 未知）
$H_0: \sigma_1^2 = \sigma_2^2$	$H_1: \sigma_1^2 \ne \sigma_2^2$	$F \ge F_{\alpha/2}(n_1-1, n_2-1)$ 或 $F \le F_{1-\alpha/2}(n_1-1, n_2-1)$
$H_0: \sigma_1^2 \ge \sigma_2^2$	$H_1: \sigma_1^2 < \sigma_2^2$	$F \le F_{1-\alpha}(n_1-1, n_2-1)$
$H_0: \sigma_1^2 \le \sigma_2^2$	$H_1: \sigma_1^2 > \sigma_2^2$	$F \ge F_{\alpha}(n_1-1, n_2-1)$

【例 2.8】根据例 2.6 中的样本观测数据检验甲、乙两台机床加工的产品的直径的方差是否相等？取显著性水平 $\alpha = 0.05$.

分析：这是总体均值未知时的两个正态总体方差的比较检验，根据题目要求可写出如下假设:

$$H_0: \sigma_1^2 = \sigma_2^2, \qquad H_1: \sigma_1^2 \ne \sigma_2^2 .$$

MATLAB 统计工具箱中的 vartest2 函数用来作总体均值未知时的两个正态总体方差的比较检验，对于本例，可如下调用：

```
% 定义甲机床对应的样本观测值向量
>> x = [20.1,  20.0,  19.3,  20.6,  20.2,  19.9,  20.0,  19.9,  19.1,  19.9];
% 定义乙机床对应的样本观测值向量
>> y = [18.6,  19.1,  20.0,  20.0,  20.0,  19.7,  19.9,  19.6,  20.2];
>> alpha = 0.05;    % 显著性水平为 0.05
>> tail = 'both';    % 尾部类型为双侧
% 调用 vartest2 函数作两个正态总体方差的比较检验，
% 返回变量 h，检验的 p 值，方差之比的置信区间 varci，结构体变量 stats
>> [h,p,varci,stats] = vartest2(x,y,alpha,tail)

h =

     0

p =
```

```
        0.5798

    varci =

        0.1567    2.8001

    stats =

        fstat: 0.6826     % F 检验统计量的观测值
          df1: 9          % F 检验统计量的分子自由度
          df2: 8          % F 检验统计量的分母自由度
```

在上述命令中，vartest2 函数的 4 个输入分别为样本观测值向量 x、样本观测值向量 y、显著性水平 α（默认的显著性水平为 0.05）和尾部类型变量 tail. 其中尾部类型变量 tail 用来指定对立假设 H_1 的形式，它的可能取值为字符串 'both'、'right' 和 'left'，对应的对立假设分别为 $H_1:\sigma_1^2 \neq \sigma_2^2$（双侧检验）、$H_1:\sigma_1^2 > \sigma_2^2$（右尾检验）和 $H_1:\sigma_1^2 < \sigma_2^2$（左尾检验）。vartest2 函数的 4 个输出分别为变量 h、检验的 p 值 p、总体方差之比 σ_1^2/σ_2^2 的置信水平为 $1-\alpha$ 的置信区间 varci 和结构体变量 stats（其字段及说明见命令中的注释）。当 h = 0 或 $\mathrm{p} > \alpha$ 时，接受原假设 H_0；当 h = 1 或 $\mathrm{p} \le \alpha$ 时，拒绝原假设 H_0.

由于 vartest2 函数返回的检验的 p 值 p = 0.5798 > 0.05，所以在显著性水平 $\alpha = 0.05$ 下接受原假设 $H_0:\sigma_1^2 = \sigma_2^2$，认为甲、乙两台机床加工的产品的直径的方差相等。

2.4.4　非正态总体均值的检验

前面讨论了正态总体参数的检验，在实际问题中，我们还会遇到非正态总体，甚至是离散总体的参数的假设检验问题。设总体 X 为非正态总体，总体均值为 $E(X)=\mu$，方差 $\mathrm{var}(X)=\sigma^2$ 存在（通常未知），从总体 X 中抽取容量足够大的样本 $X_1, X_2, \cdots, X_n$，考虑假设检验 $H_0:\mu=\mu_0$，　$H_1:\mu \neq \mu_0$. 这样的假设检验问题会用到中心极限定理。

1. 中心极限定理

◆ 林德伯格（Lindeberg）—列维（Levy）中心极限定理

设相互独立的随机变量序列 $X_1, X_2, \cdots, X_n, \cdots$ 有相同的分布，且 $E(X_i)=\mu$，$\mathrm{var}(X_i)=\sigma^2>0$，$i=1,2,\cdots,n,\cdots$ 则对于任意实数 x，有

$$\lim_{n\to\infty} P\left\{\frac{\sum_{i=1}^{n} X_i - n\mu}{\sqrt{n}\sigma} \le x\right\} = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt .$$

此定理说明了当 n 足够大时，$\dfrac{\sum_{i=1}^{n} X_i - n\mu}{\sqrt{n}\sigma}$ 近似服从标准正态分布。

◆ 德莫佛（De Movire）—拉普拉斯（Laplace）中心极限定理

设在独立试验序列中，事件 A 发生的概率为 p $(0<p<1)$，随机变量 Y_n 表示事件 A 在 n 次试验中发生的次数。则对任意实数 x，有

$$\lim_{n\to\infty} P\left\{\frac{Y_n - np}{\sqrt{np(1-p)}} \le x\right\} = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt.$$

此定理说明当n足够大时，$\dfrac{Y_n - np}{\sqrt{np(1-p)}}$近似服从标准正态分布。

2. 非正态总体均值的检验

由中心极限定理可知，当样本容量n足够大时，近似地有

$$\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \sim N(0,\ 1).$$

通常σ未知，令$S^* = \sqrt{\dfrac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2}$作为$\sigma$的估计，构造检验统计量

$$u = \frac{\bar{X}-\mu_0}{S^*/\sqrt{n}} \underset{H_0\text{成立}}{\overset{\text{近似}}{\sim}} N(0,\ 1).$$

可得拒绝域为$|u| \geq u_{\alpha/2}$.

2.5 总体分布的检验

对于一个实际问题，总体的分布函数形式一般是未知的，因此首先应根据样本对总体分布作出推断，便于进一步的统计分析。设$(X_1, X_2, \cdots, X_n)$是从分布为$F(x)$的总体中抽取的样本，希望检验假设

$$H_0: F(x) = F_0(x;\theta), \qquad H_1: F(x) \neq F_0(x;\theta). \tag{2.1}$$

其中$F_0(x;\theta)$为一个指定的分布，θ是参数向量。若$\theta = \theta_0$已知，即总体分布为完全确定的某个特殊分布，此时称为**简单假设**；否则若θ部分或完全未知，即$F_0(x;\theta)$形式上确定，但含有未知参数，此时称为**复合假设**。

一般来说，理论和实际没有绝对的符合或不符合，于是设想提出一个能反映实际数据$x_1, x_2, \cdots, x_n$与理论分布$F_0(x;\theta)$偏离的量$\Delta(x_1, x_2, \cdots, x_n; F_0)$，如果$\Delta$超过某个临界值$\Delta_\alpha$，则认为理论分布与数据$x_1, x_2, \cdots, x_n$不符，因而拒绝$H_0$. 这个$\Delta$就称为**拟合优度**（Goodness of Fit），这种检验称为**拟合优度检验**（Goodness of Fit Test）。

分布的拟合优度检验无论在理论上还是在应用上都是统计学的一个重要分支，这方面的研究一直受到关注，检验方法也有很多，本节主要介绍人们所熟知的χ^2检验、K-S 检验（Kolmogorov-Smirnov test）.

2.5.1 χ^2拟合优度检验

1. 简单假设检验问题

先考虑简单假设检验问题

$$H_0: F(x) = F_0(x;\theta_0), \qquad H_1: F(x) \neq F_0(x;\theta_0). \tag{2.2}$$

其中θ_0为已知参数。

为此选取$r-1$个实数$-\infty < t_1 < t_2 < \cdots < t_{r-1} < +\infty$，将总体$X$的一切可能取值的集合分为$r$个区间，用$n_i$表示样本观测值落入第$i$个区间$(t_{i-1}, t_i]$（这里设$t_0 = -\infty,\ t_r = +\infty$）的**观测频数**（Observed Frequency）. 在H_0成立情况下，由理论分布$F_0(x;\theta_0)$可以求出总体X在第i个区间上取值的概率

$$p_i = F_0(t_i;\theta_0) - F_0(t_{i-1};\theta_0), \quad i = 1, 2, \cdots, r.$$

显然$\sum_{i=1}^{r} p_i = 1$，另外区间的划分应使得$0 < p_i < 1$（否则可重新改变分点）。称np_i为样本落入第i个区间的**理论频数**（Theoretic Frequency）.

构造统计量

$$\chi^2=\sum_{i=1}^{r}\frac{(n_i-np_i)^2}{np_i}. \tag{2.3}$$

它表示观测频数 n_i 与理论频数 np_i 的相对差异的总和。按照大数定律，在 H_0 为真时，频率 n_i/n 与概率 p_i 的差异不会太大，因此当 χ^2 的观测值大于某个临界值时，应拒绝原假设 H_0. 为写出拒绝域的表达形式，下面先介绍 K.Pearson 于 1900 年证明的一个定理。

定理 2.2（Pearson 定理） 当(2.2)式中的原假设 H_0 为真时，由(2.3)式定义的统计量 χ^2 的极限分布是自由度为 $r-1$ 的 χ^2 分布。

以上定理的证明从略。由 Pearson 定理可知，当样本容量 n 充分大时，对于给定的显著性水平 α，检验的拒绝域为

$$W=\left\{\chi^2\ge\chi_\alpha^2(r-1)\right\}.$$

2. 复合假设检验问题

现在考虑由(2.1)式确定的复合假设检验问题。设理论分布 $F_0(x;\theta)$ 中含有 s 个未知参数，即 θ 可以写成向量的形式 $\theta=\left(\theta_1,\theta_2,\cdots,\theta_s\right)$。此时不能直接用理论分布计算理论概率 p_i 和理论频数 np_i，自然也就不能直接应用(2.3)式构造的统计量。20 世纪 20 年代初，R.A.Fisher 等推广了 Pearson 定理，用最大似然估计量 $\hat{\theta}$ 代替未知参数 θ，并计算 p_i 的估计值

$$\hat{p}_i=F_0(t_i;\hat{\theta})-F_0(t_{i-1};\hat{\theta}),\quad i=1,2,\cdots,r.$$

其中 $\hat{\theta}=\left(\hat{\theta}_1,\hat{\theta}_2,\cdots,\hat{\theta}_s\right)$ 是 s 维参数向量 θ 的最大似然估计，将 $\hat{p}_i$ 代入(2.3)式得到

$$\chi^2=\sum_{i=1}^{r}\frac{(n_i-n\hat{p}_i)^2}{n\hat{p}_i}. \tag{2.4}$$

当样本容量 n 充分大时，由(2.4)式构造的统计量近似地服从自由度为 $r-s-1$ 的 χ^2 分布，从而检验的拒绝域为

$$W=\left\{\chi^2\ge\chi_\alpha^2(r-s-1)\right\}.$$

在具体应用 χ^2 统计量进行拟合优度检验时，应注意以下几个问题。

（1）样本容量 n 应比较大。

（2）理论概率 p_i 或理论频数 np_i 的值不能太小，一般应有 $np_i\ge5$，否则可以将理论频数小于 5 的区间并入邻近区间。

（3）对离散型总体，样本的分组是自然的。对连续型总体，样本的分组可能失去某些信息。组分得多一些，因此而带来的损失就越小，但落在各组内的数据个数减少了，这将导致 χ^2 的精确分布与其极限分布的偏离增大，因此在考虑组数时要注意到这两方面的因素。

（4）对于简单假设情况，即理论分布完全已知时，H.B.Mann 和 A.Wald 于 1942 年曾指出，在分区间时，使各区间有相同的概率是有利的。

2.5.2 Kolmogorov-Smirnov 检验

1. Kolmogorov 检验

设 $(X_1,X_2,\cdots,X_n)$ 是从分布函数为 $F(x)$ 的总体中抽取的样本，$F_n(x)$ 表示相应的经验分布函数，令

$$D_n=\sup_{-\infty<x<+\infty}|F_n(x)-F(x)|. \tag{2.5}$$

关于 D_n 的精确分布和极限分布有以下定理。

定理 2.3 设总体分布函数 $F(x)$ 是连续的，则有

$$P\left\{D_n \le z+\frac{1}{2^n}\right\}=\begin{cases}0, & z<0\\ \int_{\frac{1}{2n}-z}^{\frac{1}{2n}+z}\int_{\frac{3}{2n}-z}^{\frac{3}{2n}+z}\cdots\int_{\frac{2n-1}{2n}-z}^{\frac{2n-1}{2n}+z} f(y_1,y_2,\cdots y_n)dy_1dy_2\cdots dy_n, & 0\le z<\frac{2n-1}{2n}.\\ 1, & \frac{2n-1}{2n}\le z\end{cases} \tag{2.6}$$

其中 $f(y_1,y_2,\cdots y_n)$ 是总体为 $U(0,1)$ 分布的次序统计量 $X_{(1)}\le X_{(2)}\le\cdots\le X_{(n)}$ 的联合分布密度函数，

$$f(y_1,y_2,\cdots y_n)=\begin{cases}n!, & 0<y_1<\cdots<y_n<1\\ 0, & \text{其他}\end{cases}.$$

A.N. Kolmogorov 于 1933 年证明了下面的著名定理。

定理 2.4 设总体分布函数是连续的，则有

$$\lim_{n\to\infty}P\left\{\sqrt{n}D_n\le z\right\}=L(z),\ z>0. \tag{2.7}$$

其中

$$L(z)=\sum_{k=-\infty}^{+\infty}(-1)^k e^{-2k^2z^2}. \tag{2.8}$$

以上两个定理的证明从略。这两个定理提供了分布函数拟合检验的重要方法。对双边假设检验问题

$$H_0: F(x)=F_0(x;\theta_0),\qquad H_1: F(x)\ne F_0(x;\theta_0).$$

其中 θ_0 为已知参数，可用 D_n 作为检验统计量。在原假设 H_0 成立时，以上两个定理分别给出了 D_n 的精确分布和极限分布。当 H_0 不成立时，D_n 有偏大的趋势，因此对给定的显著性水平 α，检验的拒绝域为

$$W=\left\{D_n>D_{n,\alpha}\right\}.$$

其中 $D_{n,\alpha}$ 是统计量 D_n 的分布的上侧 α 分位数。对于较大的 n，可利用 D_n 的极限分布，此时检验的拒绝域为

$$W=\left\{D_n>D_\alpha\right\}.$$

其中 D_α 是统计量 D_n 的极限分布的上侧 α 分位数。

在应用 Kolmogorov 检验时，应注意以下几个问题。

（1）Kolmogorov 检验只适用于简单假设情况，即要求理论分布是完全已知的，不含有任何未知参数。如果总体的理论分布中含有未知参数 θ，企图由样本得到 θ 的估计量 $\hat{\theta}$，然后计算

$$\Delta=\sup_{-\infty<x<+\infty}|F_n(x)-F_0(x;\hat{\theta})|.$$

然而，此时 Δ 的极限分布已经不是(2.7)式了。实际上，Δ 的极限分布与 $F_0(x;\theta)$ 有关，而不是分布自由的。但如果分布中仅含有未知的位置参数和尺度参数时，可用最大似然估计来代替未知参数，用 Monte-Carlo 方法求 Δ 的分位数。对某些常用的分布，如正态分布、指数分布等，已有人完成了这方面的工作。例如 H.W.Lilliefors 于 1967 年给出了 $F_0(x;\theta)$ 为正态分布时的 Δ 分布的分位数，称为 **Lilliefors 检验**。

（2）与 χ^2 检验比较，Kolmogorov 检验的灵敏度较高，即对给定的显著性水平 α 和同样大小的样本，Kolmogorov 检验比 χ^2 检验的功效高。

（3）D_n 值是完全确定的，不像 χ^2 检验那样有人为的影响，即 χ^2 统计量的观测值随分组方法的不同而不同。

2. Smirnov 检验

在许多实际问题中，要求比较两个总体的分布是否相同。对这种两个总体分布函数的比较检验问题，N.V. Smirnov 利用经验分布函数给出了与 Kolmogorov 检验类似的统计量。

设 $(X_1, X_2, \cdots, X_{n_1})$ 是从分布函数为 $F(x)$ 的总体中抽取的样本，$(Y_1, Y_2, \cdots, Y_{n_2})$ 是从分布函数为 $G(x)$ 的总体中抽取的样本，并假定这两个样本是相互独立的，考虑如下的双边假设检验问题。

$$H_0: F(x) = G(x), \qquad H_1: F(x) \neq G(x). \tag{2.9}$$

设 $F_{n_1}(x)$ 和 $G_{n_2}(x)$ 分别为这两个样本对应的经验分布函数，考虑统计量

$$D_{n_1,n_2} = \sup_{-\infty<x<+\infty} |F_{n_1}(x) - G_{n_2}(x)|$$

的精确分布和极限分布，有以下定理。

定理 2.5　若原假设 H_0 成立，并且 $F(x)$ 是连续的，则有

$$P\left\{D_{n,n} \le z\right\} = \begin{cases} 0, & z < \dfrac{1}{n} \\ \displaystyle\sum_{k=-\left[\frac{n}{c}\right]}^{\left[\frac{n}{c}\right]} (-1)^k \frac{C_{2n}^{n-kc}}{C_{2n}^{n}}, & \dfrac{1}{n} \le z < 1. \\ 1, & 1 \le z \end{cases}$$

其中 $c = -[-zn]$，$[x]$ 表示不超过 x 的最大整数。

定理 2.6　若原假设 H_0 成立，并且 $F(x)$ 是连续的，则有

$$\lim_{\substack{n_1\to\infty \\ n_2\to\infty}} P\left\{\sqrt{n} D_{n_1,n_2} \le z\right\} = \begin{cases} L(z), & z > 0 \\ 0, & z \le 0 \end{cases}$$

其中 $n = \dfrac{n_1 n_2}{n_1 + n_2}$，$L(x)$ 由 (2.8) 式给定。

以上两个定理的证明从略。这两个定理提供了比较两个总体的分布函数是否相等的重要方法。对于(2.9)式对应的双边假设检验问题，可得拒绝域为

$$W = \left\{D_{n_1,n_2} > D_{n_1,n_2,\alpha}\right\}.$$

其中 $D_{n_1,n_2,\alpha}$ 是统计量 D_{n_1,n_2} 的分布（或极限分布）的上侧 α 分位数。

2.6　方差分析

方差分析是英国统计学家 R.A.Fisher 于 20 世纪 20 年代提出的一种统计方法，它有着非常广泛的应用。具体来说，在生产实践和科学研究中，经常要研究生产条件或试验条件的改变对产品的质量和产量有无影响。如在农业生产中，需要考虑品种、施肥量、种植密度等因素对农作物收获量的影响；又如某产品在不同的地区、不同的时期，采用不同的销售方式，其销售量是否有差异。在诸影响因素中哪些因素是主要的，哪些因素是次要的，以及主要因素处于何种状态时，才能使农作物的产量和产品的销售量达到一个较高的水平，这就是方差分析所要解决的问题。本节主要介绍单因素方差分析和双因素方差分析的基本理论。

2.6.1　单因素方差分析

【例 2.9】某饮料生产企业研制出一种新型饮料。饮料的颜色共有四种，分别为橘黄色、粉色、绿色和无色透明。这四种饮料的营养含量、味道、价格、包装等可能影响销售量的因素全部相同。现从地理位置相似、经营规模相仿的五家超级市场上收集了同一时期该饮料的销售情况数据，如表 2-9 所示。试分析饮料的颜色对销售量是否产生影响。

表 2-9　四种颜色的饮料的销售量（单位：千瓶）

超市编号	无色饮料销售量	粉色饮料销售量	橘黄色饮料销售量	绿色饮料销售量
1	26.5	31.2	27.9	30.8
2	28.7	28.3	25.1	29.6
3	25.1	30.8	28.5	32.4
4	29.1	27.9	24.2	31.7
5	27.2	29.6	26.5	32.8

欲检验饮料的颜色对销售量是否有影响，饮料的颜色称为**因素**（或**因子**），饮料的销售量称为**试验指标**。用 A 表示饮料的颜色，则因素 A 有四个**水平**：无色、粉色、橘黄色和绿色，分别用 A_1, A_2, A_3, A_4 表示。可认为因素 A 的第 i 个水平 A_i $(i=1,2,3,4)$ 所对应的饮料销售量是来自同一个总体的样本，这里就有 4 个总体和 4 个独立的样本，通常假定这些总体服从方差相同的正态分布。记 μ_1, μ_2, μ_3, μ_4 分别表示 4 个总体的总体均值，则分析饮料的颜色对销售量是否产生影响就相当于作如下假设检验。

$$H_0: \mu_1=\mu_2=\mu_3=\mu_4, \qquad H_1: \mu_1,\mu_2,\mu_3,\mu_4 \text{ 不全相等.}$$

1. 单因素方差分析的数学模型

这里将例 2.9 进行抽象，给出单因素方差分析问题的数学模型。设因素 A 有 k 个水平，对应试验指标的 k 个总体，记为 π_1, π_2, $\cdots$, π_k，它们的分布为

$$\pi_i \sim N(\mu_i,\ \sigma^2), \quad i=1,2,\cdots,k.$$

今从这 k 个总体中各自独立地抽取一个样本，取自 π_i 的样本记为 $X_{i1},X_{i2},\cdots,X_{in_i}$，$i=1,2,\cdots,k$. 列表如表 2-10 所示。

表 2-10　单因素方差分析的样本数据

组　别	样　本	样本均值	样本方差
π_1	$X_{11},X_{12},\cdots,X_{1n_1}$	$\bar{X}_1$	S_1^2
π_2	$X_{21},X_{22},\cdots,X_{2n_2}$	$\bar{X}_2$	S_2^2
$\vdots$	$\vdots$	$\vdots$	$\vdots$
π_k	$X_{k1},X_{k2},\cdots,X_{kn_k}$	$\bar{X}_k$	S_k^2

其中

$$\bar{X}_i=\frac{1}{n_i}\sum_{j=1}^{n_i}X_{ij}, \quad S_i^2=\frac{1}{n_i-1}\sum_{j=1}^{n_i}(X_{ij}-\bar{X}_i)^2, \quad i=1,2,\cdots,k.$$

单因素方差分析的数学模型为

$$\begin{cases} X_{ij}=\mu_i+\varepsilon_{ij} \\ \varepsilon_{ij} \overset{iid}{\sim} N(0,\sigma^2) \end{cases}, \quad i=1,\cdots,k, \quad j=1,\cdots,n_i. \tag{2.10}$$

其中 iid 表示独立同分布。欲检验因素 A 对试验指标有无显著影响，相当于检验

$$H_0: \mu_1=\mu_2=\cdots=\mu_k, \qquad H_1: \mu_1,\mu_2,\cdots,\mu_k \text{ 不全相等.} \tag{2.11}$$

原假设 H_0 成立表示因素 A 对试验指标无显著影响。令

$$\mu=\frac{1}{k}\sum_{i=1}^{k}\mu_i, \quad \alpha_i=\mu_i-\mu, \quad i=1,2,\cdots,k.$$

则(2.10)式可改写为

$$\begin{cases} X_{ij} = \mu + \alpha_i + \varepsilon_{ij} \\ \varepsilon_{ij} \overset{iid}{\sim} N(0,\sigma^2) \\ \alpha_1 + \alpha_2 + \cdots + \alpha_k = 0 \end{cases}, \quad i = 1,\cdots,k, \quad j = 1,\cdots,n_i. \tag{2.12}$$

(2.11)式等价于

$$H_0 : \alpha_1 = \alpha_2 = \cdots = \alpha_k = 0, \qquad H_1 : \text{至少存在一个}\alpha_i \neq 0$$

这里的 α_i $(i = 1,2,\cdots,k)$ 称为因素 A 的第 i 个水平所引起的**效应**，可以看成 A_i 对总平均 μ 的“贡献”大小。若 $\alpha_i > 0$，称 A_i 的效应为正，若 $\alpha_i < 0$，称 A_i 的效应为负。

2. 单因素方差分析的原理

作(2.11)式的假设检验，应从分析样本数据的差异入手，数据的差异可分为系统偏差和随机误差，来自不同总体样本数据之间的差异称为**系统偏差**，来自同一总体样本数据之间的差异称为**随机误差**。从例 2.9 可以看出，同一种颜色的饮料在 5 家超市的销售量是不一样的，由于超市是随机抽取的，并且地理位置相似、经营规模相仿，可以不考虑超市的因素，所以数据的这种差异为随机误差。不同颜色饮料的销售量也是不一样的，这种差异除了抽样所造成的随机误差外，主要还是系统偏差。

样本数据之间的差异通常用离差平方和（样本观测数据与总均值的差的平方和）来表示，方差分析就是将样本数据的**总的离差平方和**分解为两部分，一部分为因素所造成的离差平方和，即系统偏差，又称为**组间离差平方和**；另一部分为随机因素所造成的离差平方和，即随机误差，又称为**组内离差平方和**。然后根据两部分平方和构造检验统计量，推导统计量所服从的分布，最后写出拒绝域。直观上可以这样理解：若总离差平方和中主要是组间离差平方和，组内离差平方和所占比重非常小，则可认为各组数据之间的差异是显著的，即因素对试验指标的影响是显著的；若总离差平方和中主要是组内离差平方和，组间离差平方和所占比重非常小，则可认为因素对试验指标的影响是不显著的。

3. 离差平方和及自由度的分解

从模型(2.12)式可以看出

$$X_{ij} - \mu = \alpha_i + \varepsilon_{ij}, \quad i = 1,\cdots,k, \quad j = 1,\cdots,n_i. \tag{2.13}$$

上式左边表示每一个样本观测数据与总均值的偏差，这个偏差被分成两部分，其中 α_i 表示由因素 A 的不同水平所引起的系统偏差，ε_{ij} 表示随机误差。令

$$n = \sum_{i=1}^{k} n_i, \quad \bar{X} = \frac{1}{n}\sum_{i=1}^{k}\sum_{j=1}^{n_i} X_{ij} = \frac{1}{n}\sum_{i=1}^{k} n_i \bar{X}_i$$

用 $\bar{X}$ 作为 μ 的估计，$\bar{X}_i - \bar{X}$ 作为 α_i 的估计，$X_{ij} - \bar{X}_i$ 作为 ε_{ij} 的估计，则(2.13)式变为

$$X_{ij} - \bar{X} = \bar{X}_i - \bar{X} + X_{ij} - \bar{X}_i, \quad i = 1,\cdots,k, \quad j = 1,\cdots,n_i.$$

记 SS_T 表示总离差平方和，则

$$\begin{aligned} SS_T &= \sum_{i=1}^{k}\sum_{j=1}^{n_i}\left(X_{ij} - \bar{X}\right)^2 = \sum_{i=1}^{k}\sum_{j=1}^{n_i}\left(\bar{X}_i - \bar{X} + X_{ij} - \bar{X}_i\right)^2 \\ &= \sum_{i=1}^{k} n_i\left(\bar{X}_i - \bar{X}\right)^2 + \sum_{i=1}^{k}\sum_{j=1}^{n_i}\left(X_{ij} - \bar{X}_i\right)^2. \end{aligned}$$

令

$$SS_A = \sum_{i=1}^{k} n_i\left(\bar{X}_i - \bar{X}\right)^2, \qquad SS_E = \sum_{i=1}^{k}\sum_{j=1}^{n_i}\left(X_{ij} - \bar{X}_i\right)^2.$$

可以看出，SS_A 为因素 A 所造成的离差平方和，称为**组间离差平方和**，SS_E 为随机因素所造成的离差平方和，称为**组内离差平方和**。这样就有如下平方和分解式

$$SS_T = SS_A + SS_E.$$

为了构造检验统计量并推导其分布，引入如下定理。

定理 2.7 在以上记号下，对于模型(2.12)式，有以下结论成立。

- $\dfrac{SS_E}{\sigma^2} \sim \chi^2(n-k)$；
- 原假设 H_0 成立时，$\dfrac{SS_A}{\sigma^2} \sim \chi^2(k-1)$, $\dfrac{SS_T}{\sigma^2} \sim \chi^2(n-1)$，$SS_E$ 与 SS_A 相互独立。

对于(2.11)式的假设检验，构造检验统计量

$$F = \frac{SS_A/(k-1)}{SS_E/(n-k)} = \frac{MS_A}{MS_E}.$$

其中 $MS_A = SS_A/(k-1)$ 称为**组间均方离差平方和**，$MS_E = SS_E/(n-k)$ 称为**组内均方离差平方和**。由定理 2.7 可知，当原假设 H_0 成立时，

$$F = \frac{SS_A/(k-1)}{SS_E/(n-k)} = \frac{MS_A}{MS_E} \sim F(k-1,\ n-k).$$

直观上可以看出，当统计量 F 的观测值大于某个临界值时，应拒绝原假设 H_0，所以对于给定的显著性水平 α，拒绝域为

$$W = \{F \ge F_\alpha(k-1,\ n-k)\}.$$

其中 $F_\alpha(k-1,\ n-k)$ 为 $F(k-1,\ n-k)$ 分布的上侧 α 分位数。

4. 单因素方差分析表

根据以上过程列出单因素方差分析表，如表 2-11 所示。

表 2-11 单因素方差分析表

方差来源	离差平方和	自由度	均方离差	F 值	临界值 F_α
组间	SS_A	$k-1$	$MS_A = SS_A/(k-1)$	$F = MS_A/MS_E$	$F_\alpha(k-1,\ n-k)$
组内	SS_E	$n-k$	$MS_E = SS_E/(n-k)$		
总计	SS_T	$n-1$			

方差分析表很直观地展现了方差分析的过程，通过对比 F 值与临界值 $F_\alpha(k-1,\ n-k)$ 的大小，作出最后的结论。也可以将表格最后一列的临界值换成检验的 p 值，其中 $p = P\{F \ge F\text{的观测值}\}$。对于给定的显著性水平 α，当 $p \le \alpha$ 时，应拒绝原假设 H_0，即认为因素 A 对试验指标有显著影响，并且 p 值越小，显著性越强；当 $p > \alpha$ 时，应接受原假设 H_0，即认为因素 A 对试验指标无显著影响。

例 2.9 所对应的方差分析表如表 2-12 所示。

表 2-12 饮料销售量的单因素方差分析表

方差来源	平方和	自由度	均方	F 值	临界值 $F_{0.05}(3,16)$	p 值
组间	76.8455	3	25.6152	10.49	3.2389	0.0005
组内	39.084	16	2.4428			
总计	115.9295	19				

由于 F 值大于临界值 $F_{0.05}(3,16)$ 或 $p = 0.0005 < 0.05$，所以在显著性水平 $\alpha = 0.05$ 下拒绝原假设 H_0，即认为饮料的颜色对销售量有显著影响。

5. 多重比较检验

如果 F 检验的结论是拒绝原假设，仅说明 k 个均值间有显著差异，即 $\mu_1,\mu_2,\cdots,\mu_k$ 不全相等，但究竟是哪些均值不等呢？这就需要作进一步的分析，所用的方法就是**多重比较**（Multiple Comparisons），它是通过对 k 个总体均值进行配对比较来进一步检验究竟哪些均值之间存在显著差异。

多重比较的方法有很多，这里仅介绍最小显著差数法（LSD 法）和最小显著极差法（LSR 法），最小显著极差法又包括新复极差检验法和 q 检验法。

（1）最小显著差数法（LSD 法）

最小显著差数法的实质是两个均值比较的 t 检验。检验的方法是在 F 检验显著的前提下，先计算出显著性水平为 α 的最小显著差数 LSD_α（实际上就是一个临界值），将两个样本均值差的绝对值 $|\overline{x}_i-\overline{x}_j|$ 与 LSD_α 进行比较，若 $|\overline{x}_i-\overline{x}_j|\ \geq LSD_\alpha$，则在显著性水平 α 下认为两个总体均值差异显著，否则，差异不显著。最小显著差数 LSD_α 的计算公式如下

$$LSD_\alpha = t_a(df_e)S_{\overline{x}_i-\overline{x}_j}\quad ,$$

$$S_{\overline{x}_i-\overline{x}_j}=\sqrt{\frac{MS_E}{n_i}+\frac{MS_E}{n_j}}.$$

其中 df_e 为组内离差平方和的自由度，$t_a(df_e)$ 是自由度为 df_e 的 t 分布的上侧 $\alpha/2$ 分位数。

（2）新复极差检验法

此法又称为邓肯（Duncan）法，由邓肯于 1955 年提出，简称 SSR 法，它是建立在 t 化极差分布上的一种检验方法。将两个样本均值差的绝对值 $|\overline{x}_i-\overline{x}_j|$ 与最小显著极差 $LSR_\alpha(P)$ 进行比较，若 $|\overline{x}_i-\overline{x}_j|\ \geq LSR_\alpha(P)$，则在显著性水平 α 下认为两个总体均值差异显著，否则，认为差异不显著。$LSR_\alpha(P)$ 的计算公式如下

$$LSR_\alpha(P)=SSR_\alpha(P,df_e)S_{\overline{X}}\ ,$$

$$S_{\overline{X}}=\begin{cases}\sqrt{\dfrac{MS_E}{r}}, & n_i=n_j=r\\[2ex] \sqrt{\dfrac{MS_E}{2}\left(\dfrac{1}{n_i}+\dfrac{1}{n_j}\right)}, & n_i\neq n_j\end{cases}.$$

其中 P（$2\leq P\leq k$）为相比较的两样本均值间秩次距，例如，当最大均值与次大均值相比较时，$P=2$，当最大均值与第 3 大均值相比较时，$P=3$，依次类推。对于给定的显著性水平 α，$SSR_\alpha(P,df_e)$ 的值通过查 SSR_α 值表得到。

q 检验法与新复极差检验法类似，其区别就在于计算最小显著极差 $LSR_\alpha(P)$ 时，不是查 SSR_α 值表，而是查 q_α 值表。

2.6.2　双因素方差分析

在例 2.9 中，我们只考虑了饮料颜色对销售量的影响，若还考虑不同超市对销售量的影响，这就是一个双因素方差分析问题，本节介绍双因素试验的方差分析。

设因素 A 有 p 个不同的水平 $A_1,A_2,\cdots,A_p$，因素 B 有 q 个不同的水平 $B_1,B_2,\cdots,B_q$，每种水平组合 $\left(A_i,\ B_j\right)$ 下的试验结果看作是取自正态总体 $N(\mu_{ij},\ \sigma^2)$ 的一个样本。为了后面表述的需要，先引入以下记号，记

$$\mu=\frac{1}{pq}\sum_{i=1}^{p}\sum_{j=1}^{q}\mu_{ij}\ ,$$

$$\mu_{i\cdot}=\frac{1}{q}\sum_{j=1}^{q}\mu_{ij},\ \alpha_i=\mu_{i\cdot}-\mu,\ \ i=1,2\cdots,p\ , \tag{2.14}$$

$$\mu_{\cdot j}=\frac{1}{p}\sum_{i=1}^{p}\mu_{ij},\ \beta_j=\mu_{\cdot j}-\mu,\ \ j=1,2\cdots,q\ .$$

(2.14) 式中的 α_i 表示因素 A 的第 i 个水平 A_i 的效应，β_j 表示因素 B 的第 j 个水平 B_j 的效应，它们满足

$$\sum_{i=1}^{p}\alpha_i=0,\ \ \sum_{j=1}^{q}\beta_j=0.$$

下面分别讨论以下两种情况：

（1）$\mu_{ij}=\mu+\alpha_i+\beta_j$，即每种水平组合 $\left(A_i,\ B_j\right)$ 下的总体均值 μ_{ij} 可看成是总平均 μ 与各因素水平效应 α_i,β_j 的简单迭加。若仅仅为了研究因素 A,B 对试验指标的影响是否显著，对每种水平组合 $\left(A_i,\ B_j\right)$ 只需各作一次试验，结果记为 X_{ij}，试验误差为 ε_{ij}，则

$$\begin{cases}X_{ij}=\mu+\alpha_i+\beta_j+\varepsilon_{ij},\\ \varepsilon_{ij}\overset{iid}{\sim}N(0,\sigma^2),\\ \sum_{i=1}^{p}\alpha_i=0,\ \sum_{j=1}^{q}\beta_j=0,\end{cases}\qquad (i=1,2,\cdots,p\ ;\ j=1,2,\cdots,q) \tag{2.15}$$

(2.15) 式称为**无交互作用的二因素方差分析**（Analysis of Variance without Interaction）模型。

（2）$\mu_{ij}\neq\mu+\alpha_i+\beta_j$，记

$$\delta_{ij}=\mu_{ij}-\mu-\alpha_i-\beta_j,\ i=1,2,\cdots,p\ ,\ j=1,2,\cdots,q.$$

δ_{ij} 表示 A_i,B_j 对试验结果的某种联合影响，称为 A_i,B_j 的**交互效应**，它们满足

$$\begin{cases}\sum_{i=1}^{p}\delta_{ij}=0,\ \ j=1,2,\cdots,q,\\ \sum_{j=1}^{q}\delta_{ij}=0,\ \ i=1,2,\cdots,p.\end{cases}$$

为研究交互效应的影响是否显著，一般对每种水平组合 $\left(A_i,\ B_j\right)$ 至少要作 $r\ (r\geq 2)$ 次试验，所得结果记为 $X_{ijk}\ \left(i=1,2,\cdots,p\ ,\ j=1,2,\cdots,q,\ k=1,2,\cdots,r\right)$，每次试验误差为 ε_{ijk}，则

$$\begin{cases}X_{ijk}=\mu+\alpha_i+\beta_j+\delta_{ij}+\varepsilon_{ijk},\\ \varepsilon_{ijk}\overset{iid}{\sim}N(0,\sigma^2),\\ \sum_{i=1}^{p}\alpha_i=0,\ \sum_{j=1}^{q}\beta_j=0,\\ \sum_{i=1}^{p}\delta_{ij}=0,\ \ \sum_{j=1}^{q}\delta_{ij}=0,\end{cases}\qquad (i=1,\cdots,p\ ;\ j=1,\cdots,q;\ k=1,\cdots,r). \tag{2.16}$$

(2.16) 式称为**有交互作用的二因素方差分析**（Analysis of Variance with Interaction）模型。

1. *无交互作用的方差分析*

由(2.14)式可知，检验因素 A 对试验指标的影响是否显著，等价于检验假设

$$H_{0A}:\alpha_1=\alpha_2=\cdots=\alpha_p=0,\qquad H_{1A}:\text{至少存在一个}\alpha_i\neq 0. \tag{2.17}$$

类似地，检验因素 B 对试验指标的影响是否显著，等价于检验假设

$$H_{0B}:\beta_1=\beta_2=\cdots=\beta_q=0,\qquad H_{1B}:\text{至少存在一个}\beta_j\neq 0. \tag{2.18}$$

（1）平方和分解

和单因素方差分析一样，用平方和分解的思想给出以上检验的统计量。记

$$\bar{X}=\frac{1}{pq}\sum_{i=1}^{p}\sum_{j=1}^{q}X_{ij}\ ,\ \bar{X}_{i\cdot}=\frac{1}{q}\sum_{j=1}^{q}X_{ij}\ ,i=1,\cdots,p,\ \ \bar{X}_{\cdot j}=\frac{1}{p}\sum_{j=1}^{p}X_{ij}\ ,j=1,\cdots,q.$$

由(2.15)式可知

$$X_{ij}-\mu=\alpha_i+\beta_j+\varepsilon_{ij},\ \ i=1,2,\cdots,p\ ,\ j=1,2,\cdots,q.$$

用 $\bar{X}$ 作为 μ 的估计，$\bar{X}_{i\cdot}$ 作为 $\mu_{i\cdot}$ 的估计，$\bar{X}_{\cdot j}$ 作为 $\mu_{\cdot j}$ 的估计，则有

$$X_{ij}-\bar{X}=\left(\bar{X}_{i\cdot}-\bar{X}\right)+\left(\bar{X}_{\cdot j}-\bar{X}\right)+\left(X_{ij}-\bar{X}_{i\cdot}-\bar{X}_{\cdot j}+\bar{X}\right),\ \ i=1,2,\cdots,p\ ,\ j=1,2,\cdots,q.$$

记 SS_T 表示总离差平方和，则

$$\begin{aligned}SS_T&=\sum_{i=1}^{p}\sum_{j=1}^{q}\left(X_{ij}-\bar{X}\right)^2=\sum_{i=1}^{p}\sum_{j=1}^{q}\left[\left(\bar{X}_{i\cdot}-\bar{X}\right)+\left(\bar{X}_{\cdot j}-\bar{X}\right)+\left(X_{ij}-\bar{X}_{i\cdot}-\bar{X}_{\cdot j}+\bar{X}\right)\right]^2\\&=q\sum_{i=1}^{p}\left(\bar{X}_{i\cdot}-\bar{X}\right)^2+p\sum_{j=1}^{q}\left(\bar{X}_{\cdot j}-\bar{X}\right)^2+\sum_{i=1}^{p}\sum_{j=1}^{q}\left(X_{ij}-\bar{X}_{i\cdot}-\bar{X}_{\cdot j}+\bar{X}\right)^2\\&=SS_A+SS_B+SS_E.\end{aligned} \tag{2.19}$$

其中

$$SS_A=q\sum_{i=1}^{p}\left(\bar{X}_{i\cdot}-\bar{X}\right)^2,\quad SS_B=p\sum_{j=1}^{q}\left(\bar{X}_{\cdot j}-\bar{X}\right)^2,\quad SS_E=\sum_{i=1}^{p}\sum_{j=1}^{q}\left(X_{ij}-\bar{X}_{i\cdot}-\bar{X}_{\cdot j}+\bar{X}\right)^2. \tag{2.20}$$

SS_A 为因素 A 所造成的离差平方和，SS_B 为因素 B 所造成的离差平方和，SS_E 为随机因素所造成的离差平方和。关于这几个平方和，有如下定理。

定理 2.8 在以上记号下，对于模型(2.15)式，有以下结论成立。

- $\dfrac{SS_E}{\sigma^2}\sim\chi^2\left((p-1)(q-1)\right)$；
- H_{0A} 成立时，$\dfrac{SS_A}{\sigma^2}\sim\chi^2(p-1)$ ，SS_E 与 SS_A 相互独立；
- H_{0B} 成立时，$\dfrac{SS_B}{\sigma^2}\sim\chi^2(q-1)$ ，SS_E 与 SS_B 相互独立。

（2）检验的统计量和拒绝域

对于(2.17)和(2.18)式的假设检验，分别构造检验统计量

$$F_A=\frac{SS_A/(p-1)}{SS_E/\left((p-1)(q-1)\right)}=\frac{MS_A}{MS_E},$$

$$F_B=\frac{SS_B/(q-1)}{SS_E/\left((p-1)(q-1)\right)}=\frac{MS_B}{MS_E}.$$

其中

$$MS_A=SS_A/(p-1),\ \ MS_B=SS_B/(q-1),\ \ MS_E=SS_E/\left((p-1)(q-1)\right).$$

则由定理 2.8 可知，在原假设 H_{0A} 和 H_{0B} 分别成立时，有

$$F_A\sim F\left(p-1,\ (p-1)(q-1)\right),\quad F_B\sim F\left(q-1,\ (p-1)(q-1)\right).$$

对于给定的显著性水平 α，H_{0A} 和 H_{0B} 对应的拒绝域分别为

$$W_A=\left\{F_A\geq F_\alpha\left(p-1,\ (p-1)(q-1)\right)\right\},$$

$$W_B=\left\{F_B\geq F_\alpha\left(q-1,\ (p-1)(q-1)\right)\right\}.$$

（3）无交互效应双因素方差分析表

根据以上过程列出无交互效应双因素方差分析表，如表 2-13 所示。

表 2-13 无交互效应双因素方差分析表

方差来源	平方和	自由度	均方离差	F 值	临界值 F_α
因素 A	SS_A	$p-1$	$MS_A=SS_A/(p-1)$	$F_A=MS_A/MS_E$	$F_\alpha(p-1,(p-1)(q-1))$
因素 B	SS_B	$q-1$	$MS_B=SS_B/(q-1)$	$F_B=MS_B/MS_E$	$F_\alpha(q-1,(p-1)(q-1))$
误差	SS_E	$(p-1)(q-1)$	$MS_E=\dfrac{SS_E}{(p-1)(q-1)}$		
总计	SS_T	$pq-1$			

2. 有交互作用的方差分析

对于有交互作用的二因素方差分析，除了要检验(2.17)和(2.18)式的假设外，还要检验假设

$$H_{0A\times B}:\delta_{ij}=0,\qquad H_{1A\times B}:\text{至少存在一个}\delta_{ij}\neq 0,\ \ i=1,2,\cdots,p\ ,\ j=1,2,\cdots,q. \tag{2.21}$$

（1）平方和分解

为检验这些假设，仍考虑平方和分解，记

$$\bar{X}=\frac{1}{pqr}\sum_{i=1}^{p}\sum_{j=1}^{q}\sum_{k=1}^{r}X_{ijk},\ \ \bar{X}_{ij\cdot}=\frac{1}{r}\sum_{k=1}^{r}X_{ijk},$$

$$\bar{X}_{i\cdot\cdot}=\frac{1}{qr}\sum_{j=1}^{q}\sum_{k=1}^{r}X_{ijk}=\frac{1}{q}\sum_{j=1}^{q}\bar{X}_{ij\cdot}\ ,$$

$$\bar{X}_{\cdot j\cdot}=\frac{1}{pr}\sum_{i=1}^{p}\sum_{k=1}^{r}X_{ijk}=\frac{1}{p}\sum_{i=1}^{p}\bar{X}_{ij\cdot}\ .$$

则

$$X_{ijk}-\bar{X}=(\bar{X}_{i\cdot\cdot}-\bar{X})+(\bar{X}_{\cdot j\cdot}-\bar{X})+(\bar{X}_{ij\cdot}-\bar{X}_{i\cdot\cdot}-\bar{X}_{\cdot j\cdot}+\bar{X})+(X_{ijk}-\bar{X}_{ij\cdot}).$$

总离差平方和 SS_T 可作如下分解

$$\begin{aligned}SS_T&=\sum_{i=1}^{p}\sum_{j=1}^{q}\sum_{k=1}^{r}(X_{ijk}-\bar{X})^2\\&=qr\sum_{i=1}^{p}(\bar{X}_{i\cdot\cdot}-\bar{X})^2+pr\sum_{j=1}^{q}(\bar{X}_{\cdot j\cdot}-\bar{X})^2+r\sum_{i=1}^{p}\sum_{j=1}^{q}(\bar{X}_{ij\cdot}-\bar{X}_{i\cdot\cdot}-\bar{X}_{\cdot j\cdot}+\bar{X})^2+\sum_{i=1}^{p}\sum_{j=1}^{q}\sum_{k=1}^{r}(X_{ijk}-\bar{X}_{ij\cdot})^2.\\&=SS_A+SS_B+SS_{A\times B}+SS_E\end{aligned}$$

其中

$$SS_A=qr\sum_{i=1}^{p}(\bar{X}_{i\cdot\cdot}-\bar{X})^2,\quad SS_B=pr\sum_{j=1}^{q}(\bar{X}_{\cdot j\cdot}-\bar{X})^2,$$

$$SS_{A\times B}=r\sum_{i=1}^{p}\sum_{j=1}^{q}(\bar{X}_{ij\cdot}-\bar{X}_{i\cdot\cdot}-\bar{X}_{\cdot j\cdot}+\bar{X})^2,\ \ SS_E=\sum_{i=1}^{p}\sum_{j=1}^{q}\sum_{k=1}^{r}(X_{ijk}-\bar{X}_{ij\cdot})^2.$$

SS_A 为因素 A 所造成的离差平方和，SS_B 为因素 B 所造成的离差平方和，$SS_{A\times B}$ 为因素 A,B 的交互效应所造成的离差平方和，SS_E 为随机因素所造成的离差平方和。关于这几个平方和，有如下定理。

定理 2.9 在以上记号下，对于模型(2.16)式，有以下结论成立。

- $\dfrac{SS_E}{\sigma^2} \sim \chi^2\left(pq(r-1)\right)$；
- H_{0A}成立时，$\dfrac{SS_A}{\sigma^2} \sim \chi^2(p-1)$ ，SS_E与SS_A相互独立；
- H_{0B}成立时，$\dfrac{SS_B}{\sigma^2} \sim \chi^2(q-1)$ ，SS_E与SS_B相互独立；
- $H_{0A\times B}$成立时，$\dfrac{SS_{A\times B}}{\sigma^2} \sim \chi^2\left((p-1)(q-1)\right)$ ，SS_E与$SS_{A\times B}$相互独立。

（2）检验的统计量和拒绝域

对于(2.17) 、(2.18) 和(2.21)式的假设检验，分别构造检验统计量

$$F_A = \frac{SS_A/(p-1)}{SS_E/\left(pq(r-1)\right)} = \frac{MS_A}{MS_E},$$

$$F_B = \frac{SS_B/(q-1)}{SS_E/\left(pq(r-1)\right)} = \frac{MS_B}{MS_E},$$

$$F_{A\times B} = \frac{SS_{A\times B}/\left((p-1)(q-1)\right)}{SS_E/\left(pq(r-1)\right)} = \frac{MS_{A\times B}}{MS_E},$$

其中

$$MS_A = SS_A/(p-1),\ MS_B = SS_B/(q-1),\ MS_{A\times B} = SS_{A\times B}/\left((p-1)(q-1)\right),\ MS_E = SS_E/\left(pq(r-1)\right).$$

则由定理 2.8 可知，在原假设H_{0A}、H_{0B}和$H_{0A\times B}$分别成立时，有

$$F_A \sim F\left(p-1,\ pq(r-1)\right),\quad F_B \sim F\left(q-1,\ pq(r-1)\right),\quad F_{A\times B} \sim F\left((p-1)(q-1),\ pq(r-1)\right).$$

对于给定的显著性水平α，H_{0A}、H_{0B}和$H_{0A\times B}$对应的拒绝域分别为

$$W_A = \left\{F_A \ge F_\alpha\left(p-1,\ pq(r-1)\right)\right\},$$

$$W_B = \left\{F_B \ge F_\alpha\left(q-1,\ pq(r-1)\right)\right\},$$

$$W_{A\times B} = \left\{F_{A\times B} \ge F_\alpha\left((p-1)(q-1),\ pq(r-1)\right)\right\},$$

（3）有交互效应双因素方差分析表

根据以上过程列出有交互效应双因素方差分析表，如表 2-14 所示。

表 2-14 有交互效应双因素方差分析表

方差来源	平方和	自由度	均方离差	F 值	临界值
因素 A	SS_A	$p-1$	$MS_A = SS_A/(p-1)$	$F_A = MS_A/MS_E$	$F_{A\alpha}$
因素 B	SS_B	$q-1$	$MS_B = SS_B/(q-1)$	$F_B = MS_B/MS_E$	$F_{B\alpha}$
$A\times B$	$SS_{A\times B}$	$(p-1)(q-1)$	$MS_{A\times B} = SS_{A\times B}/(p-1)(q-1)$	$F_{A\times B} = MS_{A\times B}/MS_E$	$F_{A\times B\alpha}$
误差	SS_E	$pq(r-1)$	$MS_E = SS_E/\left(pq(r-1)\right)$		
总计	SS_T	$pqr-1$			

2.7 回归分析

在自然科学、工程技术和经济活动等各种领域，经常需要研究某些变量之间的关系。一般来说，变量之间的关系分为两种，一种是确定性的**函数关系**，另一种是不确定性关系。例如物体作匀速（速度为v）直线运动时，路程s和时间t之间有确定的函数关系$s = v\cdot t$. 又如人的身高和体重之间存在某种关

系，对此我们普遍有这样的认识，身高较高的人，平均说来，体重会比较重，但是身高相同的人体重却未必相同，也就是说身高和体重之间的关系是一种不确定性关系，在控制身高的同时，体重是随机的。变量间的这种不确定性关系又称为**相关关系**，变量间存在相关关系的例子还有很多，如父亲的身高和成年儿子的身高之间的关系，粮食的产量与施肥量之间的关系，商品的广告费和销售额之间的关系等。回归分析是研究变量之间相关关系的数学工具，本节介绍回归分析的基本理论。

2.7.1 一元线性回归分析

1. 一元线性回归模型

设有两个变量 x 和 y，其中 x 是可以精确测量或控制的非随机变量，y 是随机变量，假定随机变量 y 与可控变量 x 之间存在线性相关关系，建立 y 与 x 的数学模型如下：

$$\begin{cases} y = a + bx + \varepsilon \ , \\ \varepsilon \sim N(0, \sigma^2) \ . \end{cases} \tag{2.22}$$

其中未知参数 a, b 和 σ^2 都不依赖于 x. 称(2.22)式为 y 关于 x 的**一元线性回归模型**，其中 b 称为**回归系数**。

由一元线性回归模型可知，当 x 固定时，$y \sim N(a + bx, \sigma^2)$，令 $\mu(x) = E(y \mid x) = a + bx$，它是 x 固定时随机变量 y 的数学期望。直线 $\mathcal{Y} = \mu(x) = a + bx$ 近似表示了 y 与 x 的线性相关关系，称 $\mu(x)$ 为 y 关于 x 的**回归函数**，称 $\mathcal{Y} = \mu(x) = a + bx$ 为 y 关于 x 的**理论回归方程**。

2. 参数的最小二乘估计

对 x, y 作 n 次独立的观测，得到观测数据 $(x_i, y_i),\ i = 1, 2, \cdots, n$. 根据(2.22)式可得

$$\begin{cases} y_i = a + bx_i + \varepsilon_i \ , \\ \varepsilon_i \overset{iid}{\sim} N(0, \sigma^2) \ , \ i = 1, 2, \cdots, n \ . \end{cases}$$

其中 iid 表示独立同分布。令

$$Q(a, b) = \sum_{i=1}^{n} \varepsilon_i^2 = \sum_{i=1}^{n} \left(y_i - (a + bx_i) \right)^2,$$

二元函数 $Q(a, b)$ 的最小值点 $(\hat{a}, \hat{b})$ 称为 a, b 的最小二乘估计，通过解下面方程组求得

$$\begin{cases} \dfrac{\partial Q}{\partial a} = -2\sum_{i=1}^{n} \left(y_i - (a + bx_i) \right) = 0 \\ \dfrac{\partial Q}{\partial b} = -2\sum_{i=1}^{n} \left(y_i - (a + bx_i) \right) x_i = 0 \end{cases} \Rightarrow \begin{cases} na + n\overline{x}b = n\overline{y} \ , \\ n\overline{x}a + \left(\sum_{i=1}^{n} x_i^{\ 2} \right) b = \sum_{i=1}^{n} x_i y_i \ . \end{cases} \tag{2.23}$$

其中

$$\overline{x} = \frac{1}{n} \sum_{i=1}^{n} x_i \ , \quad \overline{y} = \frac{1}{n} \sum_{i=1}^{n} y_i \ .$$

当方程组(2.23)的系数矩阵的行列式

$$D = \begin{vmatrix} n & n\overline{x} \\ n\overline{x} & \sum_{i=1}^{n} x_i^{\ 2} \end{vmatrix} = n(\sum_{i=1}^{n} x_i^{\ 2} - n\overline{x}^2) = n\sum_{i=1}^{n} (x_i - \overline{x})^2 \neq 0,$$

可以解得

$$\hat{a} = \overline{y} - \hat{b}\overline{x}, \quad \hat{b} = l_{xy} / l_{xx} \ . \tag{2.24}$$

其中

$$l_{xx}=\sum_{i=1}^{n}(x_i-\overline{x})^2=\sum_{i=1}^{n}x_i^2-n\overline{x}^2,\quad l_{xy}=\sum_{i=1}^{n}(x_i-\overline{x})(y_i-\overline{y})=\sum_{i=1}^{n}x_iy_i-n\overline{x}\,\overline{y}\ .$$

将 $\hat{a},\hat{b}$ 代入理论回归方程可得 $\hat{y}=\hat{a}+\hat{b}x$，称之为 y 关于 x 的**经验回归方程**。由于

$$\hat{y}=\hat{a}+\hat{b}x=\overline{y}-\hat{b}\overline{x}+\hat{b}x=\overline{y}+\hat{b}(x-\overline{x})\ ,$$

可知 y 关于 x 的经验回归直线一定过点 $(\overline{x},\overline{y})$. 可以证明估计量 $\hat{a},\hat{b}$ 服从以下分布：

$$\hat{a}\sim N\left(a,\ \left(\frac{1}{n}+\frac{\overline{x}^2}{l_{xx}}\right)\sigma^2\right),\quad \hat{b}\sim N\left(b,\ \frac{\sigma^2}{l_{xx}}\right)\ . \tag{2.25}$$

从而可知 $\hat{a},\hat{b}$ 分别是 a,b 的无偏估计。

3. σ^2 的估计

记 $\hat{y}_i=\hat{a}+\hat{b}x_i$，称 $y_i-\hat{y}_i$ 为 x_i 处的**残差**，它是 ε_i 的估计。令

$$Q_e=\sum_{i=1}^{n}(y_i-\hat{y}_i)^2=\sum_{i=1}^{n}(y_i-\hat{a}-\hat{b}x_i)^2\ ,$$

称 Q_e 为**残差平方和**（或**剩余平方和**）。对 Q_e 进行整理可得

$$\begin{aligned}Q_e&=\sum_{i=1}^{n}[y_i-\overline{y}-\hat{b}(x_i-\overline{x})]^2=\sum_{i=1}^{n}(y_i-\overline{y})^2-2\hat{b}\sum_{i=1}^{n}(x_i-\overline{x})(y_i-\overline{y})+\hat{b}^2\sum_{i=1}^{n}(x_i-\overline{x})^2\\&=\sum_{i=1}^{n}(y_i-\overline{y})^2-\hat{b}^2\sum_{i=1}^{n}(x_i-\overline{x})^2=l_{yy}-\hat{b}^2l_{xx}\ .\end{aligned} \tag{2.26}$$

其中 $l_{yy}=\sum_{i=1}^{n}(y_i-\overline{y})^2$. 根据(2.25)式中 $\hat{b}$ 的分布可以求得 $E(Q_e)=(n-2)\sigma^2$，从而可得 σ^2 的一个无偏估计为 $\hat{\sigma}^2=Q_e/(n-2)$. 对于 $\hat{\sigma}^2$，还有以下结论成立。

定理 2.10　对于一元线性回归模型(2.22)式，有

$$\frac{(n-2)\hat{\sigma}^2}{\sigma^2}=\frac{Q_e}{\sigma^2}\sim\chi^2(n-2)\ ,$$

并且 Q_e 分别与 $\hat{a},\hat{b}$ 相互独立。

4. 回归方程的显著性检验

对于变量 y 和 x 的任意 n 对观测值 (x_i,y_i)，只要 $x_1,x_2,\cdots,x_n$ 不全相等，则无论变量 y 和 x 之间是否存在线性相关关系，都可根据上面介绍的方法求得一个线性回归方程 $\hat{y}=\hat{a}+\hat{b}x$. 显然，只有当变量 y 和 x 之间存在线性相关关系时，这样的线性回归方程才是有意义的。为了使求得的线性回归方程真正有意义，就需要检验变量 y 和 x 之间是否存在显著的线性相关关系。若 y 和 x 之间存在显著的线性相关关系，则回归模型(2.22)式中的 b 不应为 0，因为若 $b=0$，则 $\mu(x)=E(y\,|\,x)$ 就不依赖于 x 了。因此需要检验假设

$$H_0:b=0,\qquad H_1:b\neq 0. \tag{2.27}$$

（1）t 检验

由于

$$\hat{b}\sim N\left(b,\ \frac{\sigma^2}{l_{xx}}\right),\quad \frac{(n-2)\hat{\sigma}^2}{\sigma^2}=\frac{Q_e}{\sigma^2}\sim\chi^2(n-2)\ ,$$

并且 $\hat{b}$ 与 Q_e 相互独立，故有

$$\frac{\hat{b}-b}{\sqrt{\sigma^2/l_{xx}}}\Bigg/\sqrt{\frac{(n-2)\hat{\sigma}^2}{\sigma^2}\Big/(n-2)}=\frac{\hat{b}-b}{\hat{\sigma}}\sqrt{l_{xx}}\sim t(n-2). \tag{2.28}$$

当原假设 H_0 成立时，检验统计量

$$t=\frac{\hat{b}}{\hat{\sigma}}\sqrt{l_{xx}}\sim t(n-2). \tag{2.29}$$

对于给定的显著性水平 α，可得 H_0 的拒绝域为

$$|t|=\frac{|\hat{b}|}{\hat{\sigma}}\sqrt{l_{xx}}\geq t_{\alpha/2}(n-2)\ .$$

当原假设 H_0 被拒绝时，认为回归效果是显著的，即认为 y 和 x 之间的线性相关关系是显著的。

（2）F 检验

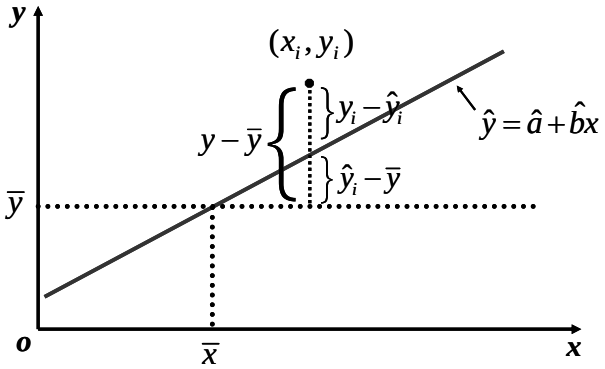

图 2-6 离差分解示意图

如图 2-6 所示，每个观测点 (x_i, y_i) 处的 y_i 与均值 $\bar{y}$ 的离差 $y_i-\bar{y}$ 被分解为两部分，即

$$y_i-\bar{y}=y_i-\hat{y}_i+\hat{y}_i-\bar{y}\ ,$$

于是总离差平方和可作如下分解

$$\begin{aligned}SS_T&=\sum_{i=1}^{n}(y_i-\bar{y})^2=\sum_{i=1}^{n}(y_i-\hat{y}_i+\hat{y}_i-\bar{y})^2\\&=\sum_{i=1}^{n}(y_i-\hat{y}_i)^2+\sum_{i=1}^{n}(\hat{y}_i-\bar{y})^2+2\sum_{i=1}^{n}(y_i-\hat{y}_i)(\hat{y}_i-\bar{y})\ .\end{aligned}$$

可以证明 $2\sum_{i=1}^{n}(y_i-\hat{y}_i)(\hat{y}_i-\bar{y})=0$. 令

$$SS_E=\sum_{i=1}^{n}(y_i-\hat{y}_i)^2,\quad SS_R=\sum_{i=1}^{n}(\hat{y}_i-\bar{y})^2\ ,$$

则有

$$SS_T=SS_E+SS_R\ . \tag{2.30}$$

这里的 SS_T 为总离差平方和，它被分解为两部分。其中 SS_R 是估计值 $\hat{y}_i$ 的离差平方和，反映了 y 的总变差中由于 y 与 x 之间的线性关系所引起的 y 的变差，称为**回归平方和**。SS_E 就是前文中的 Q_E，称为**残差平方和**（或**剩余平方和**），它反映了 y 的总变差中不能由回归直线来解释的变差。由图 2-6 可以看出，若总离差平方和 SS_T 中主要是回归平方和 SS_R，残差平方和 SS_E 所占比重非常小，则说明观测数据的散点基本集中在回归直线附近，进一步说明 y 和 x 之间存在显著的线性相关关系，因此可以根据 SS_R 和 SS_E 构造检验统计量，检验 y 和 x 之间的线性相关关系是否显著。为此，下面先给出一个定理。

定理 2.11 对于一元线性回归模型(2.22)式，有

- $\dfrac{SS_E}{\sigma^2}\sim\chi^2(n-2)$；

- 当原假设 H_0 成立时，$\dfrac{SS_R}{\sigma^2} \sim \chi^2(1)$，并且 SS_E 和 SS_R 相互独立。

对于(2.27)式的假设检验，构造检验统计量

$$F = \frac{SS_R/1}{SS_E/(n-2)} \ , \tag{2.31}$$

由定理 2.11 可知，当原假设 H_0 成立时

$$F = \frac{SS_R/1}{SS_E/(n-2)} \sim F(1, n-2) \ .$$

对于给定的显著性水平 α，可得 H_0 的拒绝域为

$$F \geq F_\alpha(1,\ n-2) \ .$$

当原假设 H_0 被拒绝时，同样认为 y 和 x 之间的线性相关关系是显著的。

根据以上 F 检验过程列出一元线性回归的方差分析表，如表 2-15 所示。

表 2-15 一元线性回归的方差分析表

方差来源	平方和	自由度	均方	F 值	临界值 F_α	p 值
回归	SS_R	1	$MS_R = SS_R/1$	$F = MS_R / MS_E$	$F_\alpha(1, n-2)$	$P\{F \geq F_{观}\}$
剩余	SS_E	$n-2$	$MS_E = SS_E/(n-2)$			
总计	SS_T	$n-1$				

由(2.26)、(2.29)和(2.31)式可知

$$t^2 = \frac{\hat{b}^2 l_{xx}}{\hat{\sigma}^2} = \frac{l_{yy} - Q_e}{Q_e/(n-2)} = \frac{SS_T - SS_E}{SS_E/(n-2)} = \frac{SS_R}{SS_E/(n-2)} = F \ .$$

故对于一元线性回归分析，t 检验和 F 检验是完全等价的。大部分统计软件都采用 F 检验，并且很多统计软件中还会给出一个被称为**判定系数**（coefficient of determination）的量，用来描述 y 和 x 之间的线性相关的程度。判定系数的定义如下：

$$R^2 = \frac{SS_R}{SS_T} = \frac{\sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \ . \tag{2.32}$$

实际上判定系数 R^2 就是回归平方和在总离差平方和中的比例，可知 $R^2 \in [0,1]$，R^2 越接近于 1，说明回归方程所能解释的因变量的变差部分越大，则 y 和 x 之间的线性相关程度也就越高。实际上，容易验证

$$R = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}} \ ,$$

这里的 R 正是 y 与 x 的样本相关系数，并且 t 检验统计量、F 检验统计量和判定系数 R^2 之间有如下关系：

$$t^2 = F = \frac{(n-2)R^2}{1-R^2} \ .$$

5. 回归系数 b 的置信区间

当 y 和 x 之间的线性相关关系显著时，通常需要对回归系数 b 作区间估计. 由(2.28)式可得 b 的置信

水平为$1-\alpha$的置信区间为

$$\left(\hat{b}-\frac{\hat{\sigma}t_{\alpha/2}(n-2)}{\sqrt{l_{xx}}},\ \hat{b}+\frac{\hat{\sigma}t_{\alpha/2}(n-2)}{\sqrt{l_{xx}}}\right). \tag{2.33}$$

6. y 的均值 $E(y\mid x)=a+bx$ 的点估计和区间估计

当自变量 x 取某一指定值 x_0 时，由(2.22)式可知，相应的因变量 $y_0\sim N(a+bx_0,\sigma^2)$，$y_0$ 的均值 $a+bx_0$ 的点估计为 $\hat{y}_0=\hat{a}+\hat{b}x_0$．可以证明

$$\frac{\hat{y}_0-(a+bx_0)}{\hat{\sigma}\sqrt{\frac{1}{n}+\frac{(x_0-\overline{x})^2}{l_{xx}}}}\sim t(n-2)\ .$$

于是可得 y_0 的均值 $a+bx_0$ 的置信水平为$1-\alpha$的置信区间为

$$\left(\hat{y}_0-t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{\frac{1}{n}+\frac{(x_0-\overline{x})^2}{l_{xx}}},\ \hat{y}_0+t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{\frac{1}{n}+\frac{(x_0-\overline{x})^2}{l_{xx}}}\right). \tag{2.34}$$

7. y 的观测值的点预测和区间预测

对于自变量 x 的某一指定值 x_0，还可以对 x_0 处 y 的观测值 $y_0=a+bx_0+\varepsilon_0$ 进行点预测和区间预测。由于随机误差 ε_0 的值无法预测，就用 x_0 处的经验回归函数值 $\hat{y}_0=\hat{a}+\hat{b}x_0$ 作为 $y_0=a+bx_0+\varepsilon_0$ 的点预测。可以证明

$$\frac{\hat{y}_0-y_0}{\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(x_0-\overline{x})^2}{l_{xx}}}}\sim t(n-2)\ .$$

于是可得 y_0 的置信水平为$1-\alpha$的预测区间为

$$\left(\hat{y}_0-t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(x_0-\overline{x})^2}{l_{xx}}},\ \hat{y}_0+t_{\alpha/2}(n-2)\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(x_0-\overline{x})^2}{l_{xx}}}\right). \tag{2.35}$$

将(2.34)式和(2.35)式加以对比可知，在相同置信水平下，y_0 的均值 $a+bx_0$ 的置信区间比 y_0 的预测区间要短，这是因为 y_0 比 y_0 的均值多了一个随机项 ε_0．另外，当 $x_0=\overline{x}$ 时，y_0 的均值 $a+bx_0$ 的置信区间和 y_0 的预测区间的长度均达到最短；当 x_0 逐渐远离 $\overline{x}$ 时，置信区间和预测区间的长度逐渐增大。

2.7.2 多重线性回归分析

1. 多重线性回归（Multiple linear regression）模型

设随机变量 y 与 p 个可控变量 $x_1,x_2,\cdots,x_p$ 之间存在线性相关关系，建立 y 与 $x_1,x_2,\cdots,x_p$ 的数学模型如下：

$$\begin{cases} y=b_0+b_1x_1+b_2x_2+\cdots+b_px_p+\varepsilon\ , \\ \varepsilon\sim N(0,\sigma^2)\ . \end{cases} \tag{2.36}$$

其中未知参数 $b_0,b_1,\cdots,b_p$ 和 σ^2 都不依赖于 $x_1,x_2,\cdots,x_p$．称(2.36)式为 y 关于 $x_1,x_2,\cdots,x_p$ 的 ***p* 重线性回归模型**，其中 $b_1,b_2,\cdots,b_p$ 称为**回归系数**。

类似于一元线性回归，称 $\boldsymbol{y}=E(y\mid x_1,\cdots,x_p)=b_0+b_1x_1+b_2x_2+\cdots+b_px_p$ 为 y 关于 $x_1,\cdots,x_p$ 的理论回归方程。

2. 参数的最小二乘估计

对 $x_1,x_2,\cdots,x_p$ 和 y 作 n 次独立的观测，得到观测数据 $(x_{i1},x_{i2},\cdots,x_{ip};y_i)$，$i=1,2,\cdots,n$．根据(2.36)式可得

$$\begin{cases} y_i=b_0+b_1x_{i1}+b_2x_{i2}+\cdots+b_px_{ip}+\varepsilon_i\ , \\ \varepsilon_i\overset{iid}{\sim}N(0,\sigma^2)\ ,\ i=1,2,\cdots,n\ . \end{cases}$$

令

$$Q(b_0,b_1,\cdots,b_p)=\sum_{i=1}^{n}\varepsilon_i^2=\sum_{i=1}^{n}\left(y_i-(b_0+b_1x_{i1}+b_2x_{i2}+\cdots+b_px_{ip})\right)^2,$$

求 $p+1$ 元函数 $Q(b_0,b_1,\cdots,b_p)$ 的最小值点 $(\hat{b}_0,\hat{b}_1,\cdots,\hat{b}_p)$，即得未知参数 $b_0,b_1,\cdots,b_p$ 的最小二乘估计。

求 Q 分别关于 $b_0,b_1,\cdots,b_p$ 的偏导数，并令其等于 0，列方程组如下

$$\begin{cases} \dfrac{\partial Q}{\partial b_0}=-2\sum\limits_{i=1}^{n}(y_i-b_0-b_1x_{i1}-b_2x_{i2}-\cdots-b_px_{ip})=0\ , \\ \dfrac{\partial Q}{\partial b_k}=-2\sum\limits_{i=1}^{n}(y_i-b_0-b_1x_{i1}-b_2x_{i2}-\cdots-b_px_{ip})x_{ik}=0,\ \ k=1,2,\cdots,p. \end{cases}$$

整理得

$$\begin{cases} nb_0+b_1\sum\limits_{i=1}^{n}x_{i1}+b_2\sum\limits_{i=1}^{n}x_{i2}+\cdots+b_p\sum\limits_{i=1}^{n}x_{ip}=\sum\limits_{i=1}^{n}y_i\ , \\ b_0\sum\limits_{i=1}^{n}x_{ik}+b_1\sum\limits_{i=1}^{n}x_{ik}x_{i1}+\cdots+b_p\sum\limits_{i=1}^{n}x_{ik}x_{ip}=\sum\limits_{i=1}^{n}x_{ik}y_i,\ \ k=1,2,\cdots,p. \end{cases} \tag{2.37}$$

(2.37)式称为**正规方程组**。令

$$\boldsymbol{X}=\begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix},\quad \boldsymbol{Y}=\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix},\quad \boldsymbol{B}=\begin{pmatrix} b_0 \\ b_1 \\ \vdots \\ b_p \end{pmatrix}.$$

则(2.37)式的矩阵形式为

$$\boldsymbol{X}'\boldsymbol{X}\boldsymbol{B}=\boldsymbol{X}'\boldsymbol{Y}\ . \tag{2.38}$$

这里的 $\boldsymbol{X}$ 称为**设计矩阵**，当矩阵 $\boldsymbol{X}'\boldsymbol{X}$ 可逆时，由(2.38)式解得未知参数 $b_0,b_1,\cdots,b_p$ 的最小二乘估计为

$$\hat{\boldsymbol{B}}=\begin{pmatrix} \hat{b}_0 \\ \hat{b}_1 \\ \vdots \\ \hat{b}_p \end{pmatrix}=(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{Y}. \tag{2.39}$$

可以证明

$$\hat{\boldsymbol{B}}\sim N_{p+1}(\boldsymbol{B},\ \sigma^2(\boldsymbol{X}'\boldsymbol{X})^{-1}),$$

$$\hat{b}_i\sim N(b_i,\sigma^2c_{ii}),\ \ i=1,2,\cdots,p.$$

其中 c_{ii} 为矩阵 $(\boldsymbol{X}'\boldsymbol{X})^{-1}$ 的对角线上的第 $i+1$ 个元素。从而 $E(\hat{\boldsymbol{B}})=\boldsymbol{B}$，即 $\hat{\boldsymbol{B}}$ 是 $\boldsymbol{B}$ 的无偏估计。将 $\hat{\boldsymbol{B}}$ 代入理论回归方程可得 y 关于 $x_1,\cdots,x_p$ 的经验回归方程 $\hat{y}=\hat{b}_0+\hat{b}_1x_1+\hat{b}_2x_2+\cdots+\hat{b}_px_p$．

3. σ^2 的估计

类似于一元线性回归分析，变量 y 的观测值的离差平方和也有如(2.30)式所示的分解，其中残差平方

和

$$SS_E=\sum_{i=1}^{n}(y_i-\hat{y}_i)^2=\sum_{i=1}^{n}(y_i-\hat{b}_0-\hat{b}_1x_{i1}-\hat{b}_2x_{i2}-\cdots-\hat{b}_px_{ip})^2\ ,$$

可以证明 $\hat{\sigma}^2=SS_E/(n-p-1)$ 是 σ^2 的一个无偏估计，并且 $\hat{\sigma}^2$ 与 $\hat{\boldsymbol{B}}$ 相互独立。

4. 回归方程的显著性检验

为了使求得的 p 重线性回归方程真正有意义，需要检验变量 y 和 $x_1,x_2,\cdots,x_p$ 之间是否存在显著的线性相关关系。若 y 和 $x_1,x_2,\cdots,x_p$ 之间存在显著的线性相关关系，则回归模型(2.36)式中的回归系数 $b_1,b_2,\cdots,b_p$ 不应全为 0，因为若 $b_1=b_2=\cdots=b_p=0$，则 $E(y\mid x_1,\cdots,x_p)$ 就不依赖于 $x_1,x_2,\cdots,x_p$ 了。因此需要检验假设

$$H_0:b_1=b_2=\cdots=b_p=0,\qquad H_1:b_i\text{不全为 0，}\ i=1,2,\cdots,p. \tag{2.40}$$

为了构造检验统计量并确定其分布，下面引入一个定理。

定理 2.12 对于 p 重线性回归模型(2.36)式，有以下结论成立

- $\dfrac{SS_E}{\sigma^2}\sim\chi^2(n-p-1)$；
- 当原假设 H_0 成立时，$\dfrac{SS_R}{\sigma^2}\sim\chi^2(p)$，并且 SS_E 和 SS_R 相互独立。

这里采用 F 检验，构造检验统计量

$$F=\frac{SS_R/p}{SS_E/(n-p-1)}\ , \tag{2.41}$$

由定理 2.12 可知，当原假设 H_0 成立时

$$F=\frac{SS_R/p}{SS_E/(n-p-1)}\sim F(p,n-p-1)\ .$$

对于给定的显著性水平 α，可得 H_0 的拒绝域为

$$F\ge F_\alpha(p,\ n-p-1)\ .$$

当原假设 H_0 被拒绝时，认为回归方程整体上是显著的，即认为 y 与 $x_1,x_2,\cdots,x_p$ 之间的线性相关关系是显著的，但是这并不表示 y 与每一个 x_i 之间的线性相关关系都是显著的。

根据以上 F 检验过程列出 p 重线性回归的方差分析表，如表 2-16 所示。

表 2-16　p 重线性回归的方差分析表

方差来源	平方和	自由度	均方	F 值	临界值 F_α	p 值
回归	SS_R	p	$MS_R=\dfrac{SS_R}{p}$	$F=\dfrac{MS_R}{MS_E}$	$F_\alpha(p,n-p-1)$	$P\{F\ge F_{观}\}$
剩余	SS_E	$n-p-1$	$MS_E=\dfrac{SS_E}{n-p-1}$			
总计	SS_T	$n-1$				

5. 回归系数的显著性检验

当 F 检验拒绝了(2.40)式中的原假设 H_0，即回归方程整体上显著时，还需要对方程中的每一项进行检验，以确定 y 与哪些变量之间的线性相关关系是显著的，为此，进行如下的假设检验：

$$H_{0i}:b_i=0,\qquad H_{1i}:b_i\ne 0. \tag{2.42}$$

这里的 $i=1,2,\cdots,p$． 当(2.42)式中的原假设 H_{0i} 被拒绝时，说明 y 与 x_i 之间的线性相关关系是显著的，

也就是说回归方程中 x_i 项是不可缺少的。

由于

$$\hat{b}_i \sim N(b_i, \sigma^2 c_{ii}), \qquad \frac{(n-p-1)\hat{\sigma}^2}{\sigma^2} = \frac{SS_E}{\sigma^2} \sim \chi^2(n-p-1),$$

并且 $\hat{\sigma}^2$ 与 $\hat{b}_i$ 相互独立，于是

$$\frac{\hat{b}_i - b_i}{\hat{\sigma}\sqrt{c_{ii}}} \sim t(n-p-1).$$

当(2.42)式中的原假设 H_{0i} 成立时，检验统计量

$$T_i = \frac{\hat{b}_i}{\hat{\sigma}\sqrt{c_{ii}}} \sim t(n-p-1).$$

对于给定的显著性水平 α，可得 H_{0i} 的拒绝域为

$$|T_i| = \frac{|\hat{b}_i|}{\hat{\sigma}\sqrt{c_{ii}}} \geq t_{\alpha/2}(n-p-1)\ .$$

6. “最优”回归方程的选择

在很多实际问题中，因变量 y 通常受到许多因素的影响，如果把所有可能产生影响的因素全部考虑进去，所建立起来的回归方程却不一定是最好的。首先由于自变量过多，使用不便，而且在回归方程中引入无意义变量，会使 $\hat{\sigma}^2$ 增大，降低预测的精确性及回归方程的稳定性。但是另一方面，通常希望回归方程中包含的变量尽可能多一些，特别是对 y 有显著影响的自变量，如此能使回归平方和 SS_R 增大，残差平方和 SS_E 减小，一般也能使 $\hat{\sigma}^2$ 减小，从而提高预测的精度。因此，为了建立一个“最优”的回归方程，如何选择自变量是个重要问题。我们希望最优的回归方程中包含所有对 y 有显著影响的自变量，不包含对 y 影响不显著的自变量。下面介绍 4 种常用的选优方法。

（1）全部比较法

全部比较法是从所有可能的自变量组合构成的回归方程中挑选最优者，用这种方法总可以找一个“最优”回归方程，但是当自变量个数较多时，这种方法的计算量非常巨大，例如有 p 个自变量，就需要建立 $C_p^1 + C_p^2 + \cdots + C_p^p = 2^p - 1$ 个回归方程。对一个实际问题而言，这种方法有时是不实用的。

（2）只出不进法

只出不进法是从包含全部自变量的回归方程中逐个剔除不显著的自变量，直到回归方程中所包含的自变量全部都是显著的为止。当所考虑的自变量不多，特别是不显著的自变量不多时，这种方法是可行的；当自变量较大，尤其是不显著的自变量较多时，计算量仍然较大，因为每剔除一个自变量后都要重新计算回归系数。

（3）只进不出法

只进不出法是从一个自变量开始，把显著的自变量逐个引入回归方程，直到余下的自变量均不显著，没有变量还能再引入方程为止。只进不出法虽然计算量少些，但它有严重的缺点。虽然刚引入的那个自变量是显著的，但是由于自变量之间可能有相关关系，所以在引入新的变量后，有可能使已经在回归方程中的自变量变得不显著，因此不一定能得到“最优”回归方程。

（4）逐步回归法

逐步回归法是（2）和（3）相综合的一种方法，它根据自变量对因变量 y 的影响大小，将它们逐个引入回归方程，影响最显著的变量先引入回归方程，在引入一个变量的同时，对已引入的自变量逐个检验，将不显著的变量再从回归方程中剔除，最不显著的变量先被剔除，直到再也不能向回归方程中引入新的变量，同时也不能从回归方程中剔除任何一个变量为止。如此操作就保证了最终得到的回归方程是“最优”的。

2.7.3 非线性回归分析

在很多实际问题中，变量之间的相关关系可能不是线性的，就不能用线性回归方程来描述它们之间的相关关系，此时需要建立变量之间的非线性回归方程。对于大多数非线性回归问题，可以通过变量代换的方式把非线性回归化为线性回归。对于不能线性化的非线性回归，通常的做法是利用迭代算法求回归方程中参数的估计值。本节简要介绍一元非线性回归分析的线性化方法。

1. 可线性化的一元非线性回归

若变量 y 和 x 之间存在非线性相关关系，可根据 y 和 x 的散点图的形状选择适当的非线性函数 $y=f(x;b_1,\cdots,b_k)$ 作为 y 关于 x 的非线性回归方程，其中 $b_1,\cdots,b_k$ 是待估计的参数。下面列举一些常用的能够线性化的一元非线性函数，并给出线性化变换的变量代换公式，如表 2-17 所示。

表 2-17 可线性化的非线性函数

非线性函数	变量代换公式	变换后的线性方程
$\frac{1}{y}=a+\frac{b}{x}$（双曲线函数）	$u=\frac{1}{x},\ v=\frac{1}{y}$	$v=a+bu$
$y=ax^b$（幂函数）	$u=\ln x,\ v=\ln y$	$v=\ln a+bu$
$y=a+b\ln x$（对数函数）	$u=\ln x,\ v=y$	$v=a+bu$
$y=ae^{bx}$（指数函数）	$u=x,\ v=\ln y$	$v=\ln a+bu$
$y=ae^{b/x}$（负指数函数）	$u=\frac{1}{x},\ v=\ln y$	$v=\ln a+bu$
$y=\frac{1}{a+be^{-x}}$（logistic 曲线函数）	$u=e^{-x},\ v=\frac{1}{y}$	$v=a+bu$

以上非线性函数的图形如图 2-7 至图 2-12 所示。

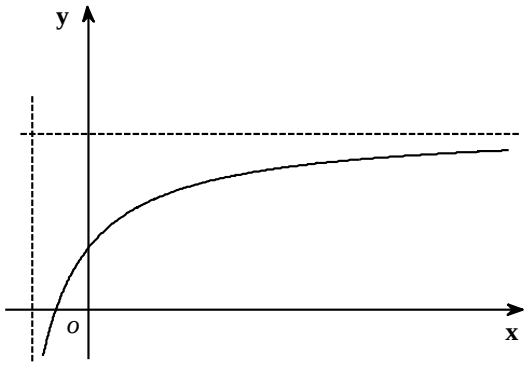

(1) $b>0$

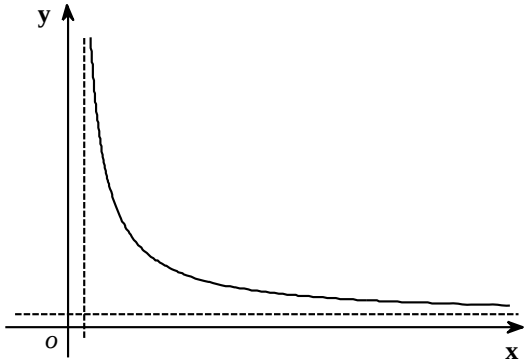

(2) $b<0$

图 2-7 双曲线函数图形（$1/y=a+b/x$）

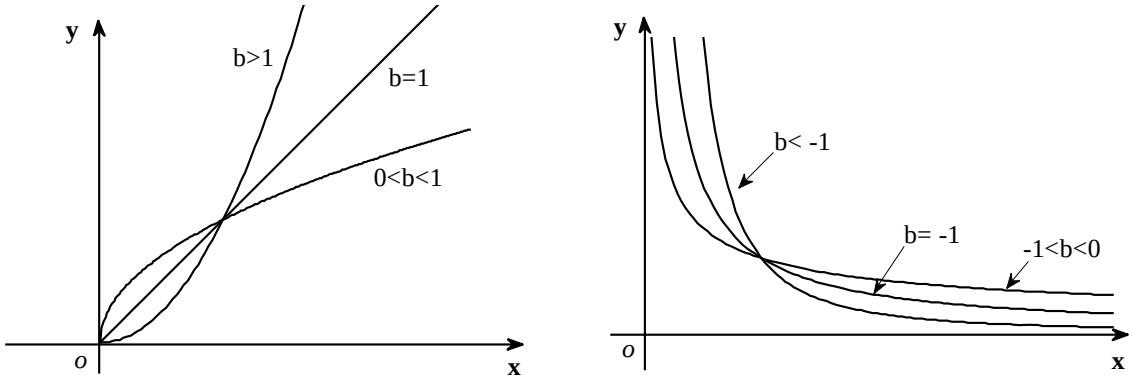

(1) $b > 0$　　(2) $b < 0$

图 2-8　幂函数图形（$y = ax^b$）

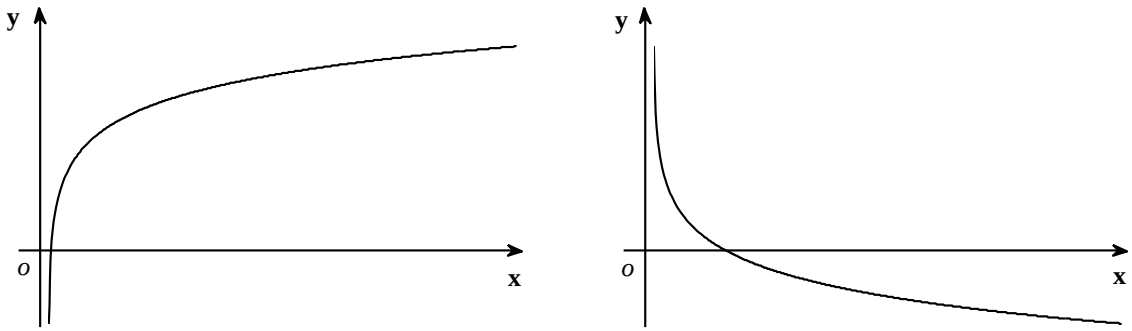

(1) $b > 0$　　(2) $b < 0$

图 2-9　对数函数图形（$y = a + b\ln x$）

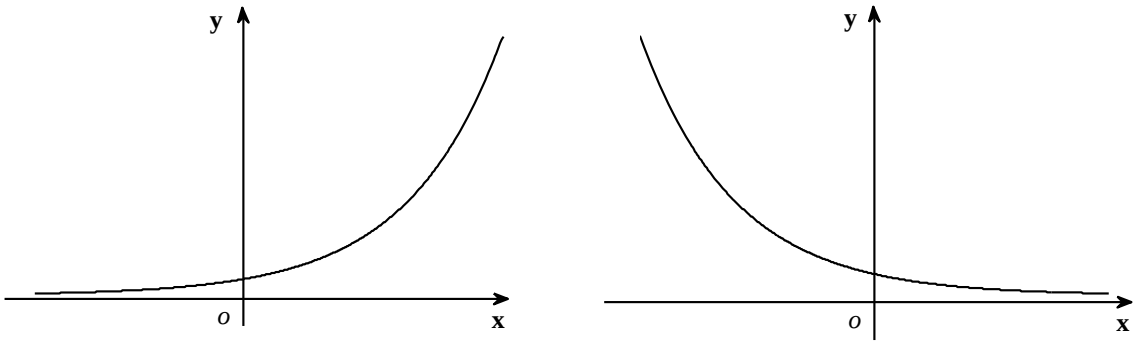

(1) $b > 0$　　(2) $b < 0$

图 2-10　指数函数图形（$y = ae^{bx}$）

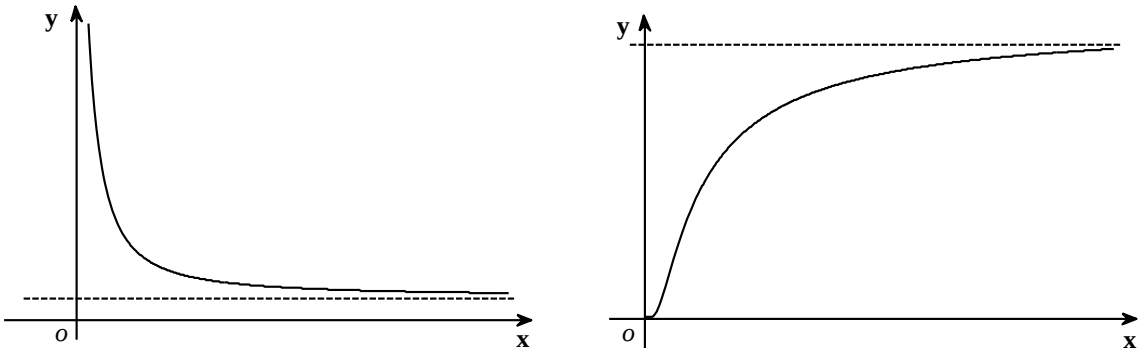

(1) $b > 0$　　(2) $b < 0$

图 2-11 负指数函数图形（ $y = ae^{b/x}$ ）

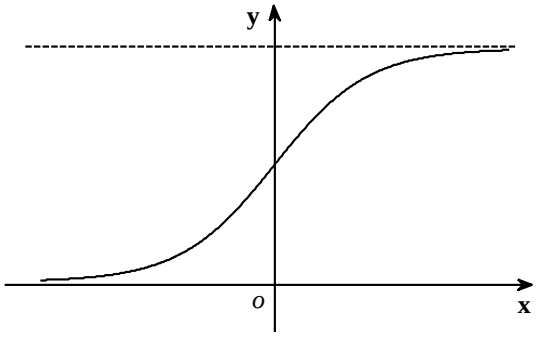

图 2-12 logistic 曲线（ $y = 1/(a + be^{-x})$ ）

2. 多项式回归

若随机变量 y 和可控变量 x 之间的回归模型为

$$\begin{cases} y = b_0 + b_1 x + b_2 x^2 + \cdots + b_p x^p + \varepsilon , \\ \varepsilon \sim N(0, \sigma^2) . \end{cases} \tag{2.43}$$

其中未知参数 $b_0, b_1, \cdots, b_p$ 和 σ^2 都不依赖于 $x_1, x_2, \cdots, x_p$ ，则回归函数 $E(y \mid x) = b_0 + b_1 x + \cdots + b_p x^p$ 为 p 次多项式。称模型(2.43)为**多项式回归模型**。若令 $X_i = x^i,\ i = 1, 2, \cdots, p$ ，则多项式回归模型就转化为多重线性回归模型

$$\begin{cases} y = b_0 + b_1 X_1 + b_2 X_2 + \cdots + b_p X_p + \varepsilon , \\ \varepsilon \sim N(0, \sigma^2) . \end{cases}$$