第9章 回归分析

Lianghai Xiao

https://github.com/styluck/mlb

- 一元线性回归分析
- 一元非线性回归分析
- 多重回归分析

一元线性回归

- 一元线性回归（Univariate Linear Regression）是一种统计学方法，用于研究两个变量之间的线性关系。在这种模型中，有一个因变量（通常表示为Y）和一个自变量（通常表示为X），我们假设自变量X的变化会以线性方式影响因变量Y的变化。

一元线性回归

- 一元线性回归模型的基本形式是:

$$Y = \beta_0 + \beta_1 X + \epsilon$$

其中:

- Y 是因变量，也就是我们想要预测的变量。
- X 是自变量，也就是用来预测因变量的变量。
- β_0 是截距项，表示当自变量X为0时因变量Y的预期值。
- β_1 是斜率系数，表示自变量X每变化一个单位，因变量Y预期会变化的量。
- ϵ 是误差项，表示模型未能解释的随机变异。

一元线性回归

1. **模型设定**：确定因变量和自变量，并假设它们之间存在线性关系。
2. **参数估计**：使用最小二乘法等统计技术来估计模型参数 β_0 和 β_1 。
3. **模型评估**：通过R平方（决定系数）、残差分析、ANOVA表等方法来评估模型的拟合优度和统计显著性。
4. **预测和解释**：利用估计得到的模型进行预测，并解释自变量和因变量之间的关系。

最小二乘法

- 最小二乘法（Least Squares Method）是一种数学优化技术，用于在一元线性回归中估计模型参数（截距项 β_0 和斜率系数β_1），目的是最小化模型预测值与实际观测值之间的差异的平方和。

最小二乘法

1. **构建残差平方和**：对于给定的数据集 $\{(x_i, y_i)\}$，其中 $i = 1, 2, \ldots, n$，计算每个观测值的预测残差（实际观测值与模型预测值之间的差异），然后计算这些残差的平方和（RSS）：
   $RSS = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$
   其中，$\hat{y}_i$ 是模型对 y_i 的预测值。

最小二乘法

2. **参数估计**：通过最小化残差平方和来求解参数 β_0 和 β_1。这通常涉及到对 β_0 和 β_1 进行偏导，并将导数设置为零，从而得到正规方程（Normal Equations）：

$$\frac{\partial RSS}{\partial \beta_0} = 0$$

$$\frac{\partial RSS}{\partial \beta_1} = 0$$

解这组方程可以得到 β_0 和 β_1 的估计值。

最小二乘法

3. **求解正规方程**：正规方程是两个方程的联立方程组，解这个方程组可以得到 β_0 和 β_1 的闭合形式解。
4. **模型评估**：使用估计得到的参数来评估模型的拟合优度，例如计算决定系数 R^2，它表示模型解释的变异占总变异的比例。

最小二乘法

- **优点：**
- **无偏性**：在一定条件下，最小二乘估计是无偏的，即长期平均下，估计值等于真实值。
- **最小方差性：**在所有无偏估计中，最小二乘估计是具有最小方差的（高斯-马尔可夫定理）。
- **计算简便：**对于线性模型，最小二乘法提供了参数的闭合形式解，计算过程相对简单。

最小二乘法

- **局限性：**
- **正态性假设：**在经典线性回归模型中，最小二乘法的有效性依赖于误差项的正态性假设。
- **异方差性：**如果误差项不满足同方差性假设，最小二乘估计可能不是最优的。
- **异常值敏感性：**最小二乘法对异常值较为敏感，异常值可能会对估计结果产生较大影响。

R平方（R-squared）

- R平方（R-squared），也称为决定系数（Coefficient of Determination），是统计学中用于衡量回归模型拟合优度的一个指标。它表示模型解释的变异占总变异的比例，用于评估模型对数据的解释能力。
- 对于一元线性回归模型，R平方可以通过以下公式计算：

R平方（R-squared）

- 对于一元线性回归模型，R平方可以通过以下公式计算：
  - $R^2 = 1 - \frac{SSR}{SST}$
- 其中：
- SSR 是残差平方和（Residual Sum of Squares），即实际观测值与模型预测值之间差异的平方和。
- SST 是总平方和（Total Sum of Squares），即实际观测值与观测值均值之间差异的平方和。

R平方的局限

- **不适用于非线性模型：**R平方是为线性模型设计的，对于非线性模型，R平方可能不是一个合适的拟合优度指标。
- 模**型选择：**在模型选择时，不应仅依赖R平方，因为它不考虑模型的复杂度。在有多个模型可选时，可以使用调整R平方（Adjusted R-squared）来考虑自由度的影响。
- **过拟合风险：**模型的R平方值可能会因为模型中自变量的增加而提高，即使这些变量对因变量的解释没有实质性帮助，这可能导致过拟合。

调整R平方

- 调整R平方（Adjusted R-squared）是R平方的一个变体，用于多元线性回归模型中，它对自变量的数量进行了惩罚，以防止过拟合。调整R平方通过考虑模型中自变量的数量和样本大小来调整R平方的值，从而提供了一个更为公正的模型拟合优度的度量。

调整R平方

- 调整R平方的计算公式如下：

$$\text{Adjusted } R^2 = 1 - (1 - R^2)\frac{n-1}{n-k-1}$$

其中：

- R^2 是未调整的决定系数。
- n 是样本大小（即观测值的数量）。
- k 是模型中自变量的数量。

调整R平方的特点

- **惩罚项**：调整R平方通过分母中的$(n-k-1)$ 项对自变量的数量进行惩罚。当添加更多的自变量时，如果这些变量没有提供额外的解释能力，调整R平方可能会下降。
- **模型选择**：调整R平方是一个有用的指标，用于在包含不同数量自变量的模型之间进行选择。它倾向于选择那些既不过拟合也不欠拟合的模型。
- **更保守的估计**：与未调整的R平方相比，调整R平方提供了一个更保守的模型拟合优度估计。

调整R平方

- **不适用于一元回归**：调整R平方主要用于多元回归模型。在一元回归中，调整R平方的值与未调整的R平方相同，因为没有其他自变量需要惩罚。

t检验

1.计算t统计量：使用样本数据计算t值，

$$t = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$$

其中，$\bar{X}$是样本均值，μ_0 是总体均值，s 是样本标准差，$\sqrt{n}$是样本大小。

1.确定自由度：自由度（df）通常是样本大小减1（n-1）。

2.查找t分布表：根据自由度和显著性水平（如0.05），在t分布表中查找临界t值。

3.作出决策：如果计算出的t值大于临界t值，则拒绝原假设，认为样本均值与总体均值存在显著差异。

t检验

- 回归分析中的t检验（t-test）是一种统计检验，用于评估单个回归系数是否显著不同于零。这种检验提供了一种方法来确定模型中每个自变量对因变量是否有统计上显著的影响。t检验基于回归系数的估计值和其标准误差来进行。
- 计算t统计量的公式如下：

$$t = \frac{\hat{\beta} - \beta_0}{SE(\hat{\beta})}$$

其中，$\hat{\beta}$ 是估计的回归系数，β_0 是零假设下的系数值（通常为0）

$SE(\hat{\beta})$ 是估计系数的标准误差。

t检验

- **正态性假设**：t检验的有效性依赖于残差服从正态分布的假设。
- **独立性假设**：残差之间应该是独立的，否则t检验的结果可能不准确。
- **异方差性**：如果残差不满足同方差性假设，可能需要使用异方差性稳健的标准误差来进行t检验。

F检验

- F检验（F-test）是一种统计检验，用于比较两组或多组数据的方差是否存在显著差异。
- F检验的基本思想是通过比较数据组内和组间的方差来判断各组之间是否存在显著的差异。
- 计算方法：
- 计算组内方差（每个组内数据与组均值的差的平方和的平均值）和组间方差（两组均值与总体均值的差的平方和的平均值）。
- F统计量是组间方差与组内方差之比，计算公式如下：
  - F = 组间方差 / 组内方差

F检验

- 在回归分析中，F统计量（F-statistic）用于检验模型中的所有回归系数是否同时等于零，即用于检验模型中至少有一个预测变量对因变量有统计显著的影响。F统计量是模型中解释变量（自变量）整体重要性的度量，它是模型中解释变量的方差与未解释变量的方差之比。
- **模型整体显著性检验**：F统计量用于检验整个回归模型的显著性，而不仅仅是单个自变量。
- **方差分析（ANOVA）**：在线性回归的方差分析表中，F统计量通常用于检验模型的整体效应。

F检验的假设

- **正态性假设**：F统计量的分布假设包括残差的正态性。
- **方差齐性**：F统计量的有效性依赖于残差具有恒定的方差（方差齐性）。
- **多重共线性**：如果模型中的自变量之间存在多重共线性，可能会影响F统计量的解释。

F检验

- 对于线性回归模型，F统计量的计算公式如下：
- $F = \frac{MSR}{MSE}$
- 其中：
- MSR（Mean Square Regression）是回归平方和除以其自由度，也称为回归均方，表示模型解释的方差部分。
- MSE（Mean Square Error）是残差平方和除以其自由度，也称为误差均方，表示模型未能解释的方差部分。

F检验

- MSR和MSE的计算方法如下：
  - $MSR = \frac{SSR}{df_{reg}}$
  - $MSE = \frac{SSE}{df_{res}}$

SSR（Sum of Squares Regression）是回归平方和，表示由于模型中的自变量而解释的因变量的总变异。

SSE（Sum of Squares Error）是残差平方和，表示模型未能解释的因变量的总变异。

df_{reg} 是回归的自由度，通常是自变量的个数。

df_{res} 是残差的自由度，通常是观测值的个数减去自变量个数再减1。

F统计量的解释：

- **F值**：F统计量的值越大，表明模型中的自变量对因变量的解释能力越强，模型的整体显著性越高。
- **显著性**：通过比较计算得到的F值与F分布的临界值，可以判断模型中至少有一个自变量对因变量有显著影响。如果F值大于临界值，通常在显著性水平（如0.05）下，我们拒绝原假设（所有回归系数等于零），认为模型是显著的。

线性回归模型的假设

- **线性假定：**即回归模型的形式是线性的。这意味着因变量Y可以表示为自变量X的线性组合，加上一个误差项
- **误差正态性假定：**回归模型中的误差项ε服从正态分布。这个假定对于小样本尤其重要，因为它影响到回归系数的估计和假设检验的有效性。
- **误差方差齐次性假定：**所有观测值的误差项具有恒定的方差，即方差不随自变量的变化而变化。
- **误差独立性假定：**模型中的误差项之间是相互独立的，即一个观测值的误差不影响其他观测值的误差。

回归诊断

- 回归诊断（Regression Diagnostics）是统计学中用于评估回归模型是否满足其基本假设和是否适合数据集的一系列方法和图形技术。回归诊断的主要目的是检查模型是否正确指定，是否存在任何违反标准线性回归模型假设的问题。
- **主要内容包括：**
- **异常值和强影响点检测**
- **残差分析：**包括模型线性诊断、误差正态性诊断、误差方差齐性诊断和误差独立性诊断
- **多重共线性诊断**

异常值和强影响点检测

- 异常点是指那些与其他观测值相比显著偏离的点。它们可能由于测量错误、数据录入错误或其他原因而与数据集中的其他观测值不一致。异常点可以是高异常值（High Outliers）或低异常值（Low Outliers），具体取决于它们是在变量的高值区域还是低值区域偏离。
- 强影响点是指那些对回归模型估计有显著影响的点。这些点不仅偏离其他观测值，而且对回归系数的估计有较大影响。强影响点不一定是异常值，它们可能是真实的观测值，但由于其特殊的值（如自变量的极端值）而对模型产生较大影响。

异常值和强影响点检测

- **识别**：可以使用Cook’s距离、DFITS（Difference in Fit with the ith case deleted）等统计量来识别可能的异常值和影响点。
- **处理**：处理这些点的方法包括删除、替换、变换数据或使用稳健的回归方法。在决定如何处理之前，应该仔细考虑这些点的成因和对分析的影响。

残差分析

- 在理想情况下，残差应该随机分布，没有明显的模式，这表明模型已经捕捉了数据中的所有系统性信息。
- 通过残差分析可以检验回归模型的基本假设是否得到满足，如残差的正态性、方差齐性、独立性等。
- 残差图：绘制残差与拟合值、杠杆值或其他变量的图表，以检查残差的分布情况和潜在的模式。

残差分析

- 正态性检验：检验残差是否近似正态分布，可以使用Q-Q图（Quantile-Quantile Plot）或Shapiro-Wilk检验等方法。

- 方差齐性检验：检验残差的方差是否恒定，即是否存在异方差性。可以使用Breusch-Pagan检验、White检验等统计方法。

多重共线性检验

- 检验模型中自变量之间是否存在高度相关性，可以使用方差膨胀因子（Variance Inflation Factor, VIF）或条件指数（Condition Index）等方法。

Box-Cox变换

- Box-Cox变换是一种统计学中的数据转换方法，由George Box和David Cox在1964年提出。它用于改善数据的正态性质，使数据更接近正态分布，从而满足某些统计模型（如线性回归模型）的正态性假设。

对于原始数据 $y_i > 0$，Box-Cox变换的一般形式为：

$$y_i^{(\lambda)} = \frac{y_i^{\lambda} - 1}{\lambda} \quad \text{for} \quad \lambda \neq 0$$

当 $\lambda = 0$ 时，变换简化为对数变换：

$$y_i^{(0)} = \ln(y_i)$$

Box-Cox变换

- **Box-Cox变换的目的：**

1. **正态性**：数据的分布明显偏斜，不满足正态分布的假设。Box-Cox变换使数据分布更接近正态分布，提高某些统计测试的有效性。
2. **方差齐性**：数据的方差随均值的增加而增加，即存在异方差性。Box-Cox变换可以减少或消除数据的异方差性问题。
3. **线性关系**：需要使用线性模型，但原始数据的分布特性不适宜直接应用。Box-Cox变换有时可以揭示变量间的线性关系，改善回归分析的效果。

Box-Cox变换

- 变换参数 λ 的值通常通过最大似然估计来确定，也可以通过图形方法或者信息准则（如赤池信息准则AIC）来选择。

稳健回归

- 稳健回归（Robust Regression）是一种旨在减少异常值和极端观测值对回归分析影响的统计方法。与传统的最小二乘回归（OLS）相比，稳健回归对数据中的噪声和异常值更为鲁棒，能够提供更加可靠的回归系数估计。
- 稳健回归在处理具有异常值、噪声或其他非理想特征的数据时非常有用。它广泛应用于经济学、生物统计学、环境科学等领域，尤其是在数据质量不确定或存在潜在异常值的情况下。

稳健回归

1. **对异常值的鲁棒性**：稳健回归通过使用不同的损失函数或估计方法，减少了异常值对回归系数估计的影响。
2. **减小影响**：稳健回归方法可以减小单个或少数异常观测值对整个模型的影响，使得模型更加稳定。
3. **多种方法**：稳健回归有多种实现方式，包括但不限于Huber估计、M-估计、S-估计和R-估计等。

一元非线性回归

- 与一元线性回归不同，非线性回归模型的假设是变量之间存在非线性关系，即因变量Y与自变量X之间的关系不能简单地用直线来描述。
- 一元非线性回归模型的一般形式是：

$$Y = f(X, \beta_0, \beta_1, ..., \beta_k) + \epsilon$$

- 一元非线性回归的参数估计：
- 参数估计通常通过最小化残差平方和来进行，但由于模型是非线性的，这可能需要使用数值优化方法，如梯度下降、牛顿法等。

多元线性回归

- 多元线性回归模型的一般形式是

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_n X_n + \epsilon$$

- **多重共线性**：在多元线性回归中，如果自变量之间存在高度相关性，可能会导致多重共线性问题，影响模型的稳定性和系数的解释。
- **正态性假设**：多元线性回归的误差项应服从正态分布，这影响到回归系数的估计和假设检验的有效性。
- **异方差性**：误差项应具有恒定的方差，如果存在异方差性，可能需要使用加权最小二乘法或其他方法来调整模型。

多重共线性检验

- 检验模型中自变量之间是否存在高度相关性，可以使用方差膨胀因子（Variance Inflation Factor, VIF）或条件指数（Condition Index）等方法。

基于方差膨胀因子的多重共线性诊断

- VIF的计算方法：
- 对于每个自变量Xi，VIF的计算公式为：
- $$VIF_i = \frac{1}{1-R_i^2}$$
- 其中，R_i^2是自变量Xi对其余自变量进行回归分析时的决定系数（R-squared）。VIF实际上是自变量Xi的方差与在不存在共线性时的方差之比。

基于方差膨胀因子的多重共线性诊断

- R_i^2接近1，VIF接近无穷大；R_i^2接近0，VIF接近1

- **VIF值小于5**：表明自变量之间的共线性较弱。
- **VIF值介于5和10之间：**表明存在中等程度共线性。
- **VIF值大于10**：通常认为存在严重的多重共线性问题，这可能会导致回归系数的估计不稳定，并且可能影响模型的预测能力。

基于方差膨胀因子的多重共线性诊断

- **处理方法：**

1. **删除变量**：如果某个自变量的VIF值很高，可以考虑从模型中删除这个变量。
2. **变量转换**：对自变量进行转换，如对数、平方根或差分，以减少变量间的相关性。
3. **增加样本量**：有时增加样本量可以减轻共线性问题。
4. 使用**逐步回归**、**岭回归**或**主成分回归**等方法来选择重要的变量或转换变量。

多元多项式回归

- 扩展了多元线性回归模型，允许自变量的高次项和交互项出现在模型中。这种方法适用于探索自变量与因变量之间的非线性关系。
- 多元多项式回归模型的一般形式是

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_n X_n + \beta_{n+1} X_1^2 + \beta_{n+2} X_1 X_2 + \ldots + \beta_{2n} X_n^2 + \epsilon$$

1. **非线性建模**：通过包括高次项和交互项，多元多项式回归能够捕捉自变量与因变量之间的非线性关系。
2. **模型灵活性**：多元多项式回归提供了一种灵活的建模方式，可以根据数据的特点选择包含哪些高次项和交互项。
3. **过拟合风险**：由于模型的复杂性，多元多项式回归可能面临过拟合的风险，特别是在样本量较小的情况下。

逐步回归

- 逐步回归（Stepwise Regression）是一种变量选择方法，用于构建线性回归模型时确定最佳的自变量集合。
- 因变量y通常受到许多因素的影响，回归方程却不一定是最好的。回归方程引入无意义的变量，会使得误差方差的估计值变大，降低预测的精确性以及回归方程的稳定性。
- 逐步回归通过逐步添加或删除自变量的方式，尝试找出对因变量有显著预测能力的自变量集合。
- 逐步回归的目的是在模型的复杂度和预测能力之间寻找一个平衡点。

逐步回归

1.向前选择（只进不出，Forward Selection）：

1. 从没有任何自变量的模型开始。
2. 逐步添加对模型贡献最大的自变量，通常是使得模型的统计显著性提高最多的变量。
3. 在每一步，都会考虑尚未进入模型的所有自变量，选择最显著的一个加入模型。

2.向后消除（只出不进，Backward Elimination）：

1. 从包含所有候选自变量的模型开始。
2. 逐步删除对模型贡献最小的自变量，即统计上最不显著的变量。
3. 在每一步，都会考虑已经进入模型的所有自变量，移除最不显著的一个。

3.逐步选择（Stepwise Selection）：

1. 结合了向前选择和向后消除的特点。
2. 在每一步中，算法都可能添加一个新的自变量或从模型中删除一个现有的自变量。

逐步回归

1. **模型拟合**：使用逐步回归算法拟合模型，这通常涉及到计算每个自变量的统计显著性，如t检验的p值。
2. **变量进入**：选择最显著的自变量加入模型，或者移除最不显著的自变量。
3. **迭代过程**：重复上述步骤，直到没有其他变量可以显著提高模型的性能，或者达到预设的停止条件。
4. **模型评估**：评估最终模型的性能，包括其统计显著性和预测能力。

逐步回归

- **逐步回归的优点：**
  - **自动化**：逐步回归提供了一种自动化的变量选择方法。
  - **模型简化**：可以帮助识别和构建一个更简洁且有预测能力的模型。
- **逐步回归的缺点：**
  - **数据挖掘**：可能会因为过度拟合而捕捉到数据中的随机噪声。
  - **稳定性**：逐步回归的结果可能对数据集非常敏感，不同的样本可能导致不同的模型。
  - **多重比较问题**：由于进行多次统计检验，可能会增加第一类错误（假阳性）的风险。

岭回归Ridge Regression和Lasso回归

- 一般来说，回归问题是一个函数拟合的过程，那么我们希望模型不要太复杂，否则很容易发生过拟合现象，所以我们要加入正则化项，而不同的正则化项就产生了不同的回归方法，其中以Ridge Regression (岭回归）和Lasso最为经典，前者是加入了L2正则化项，后者加入的是L1正则化项。

向量的范数

- $\|\alpha\|_1$ 被称为向量的L1范数， $\|\alpha\|_2$ 被称为向量的L2范数

$$\|\alpha\|_1 = \sum_{i=1}^{d} |a_i|$$

$$\|\alpha\|_2 = \sqrt{\sum_{i=1}^{d} a_i^2}$$

岭回归Ridge Regression和Lasso回归

- 相比于普通线性回归，Ridge Regression加入了L2正则化项，Lasso加入了L1正则化项，故它们的目标函数如下：

$$\text{Lasso}: \boldsymbol{\beta}^* = \text{argmin}_{\boldsymbol{\beta}} \frac{1}{\text{n}} \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta}\|_2^2 + \lambda\|\boldsymbol{\beta}\|_1$$

$$\text{Ridge Regression}: \boldsymbol{\beta}^* = \text{argmin}_{\boldsymbol{\beta}} \frac{1}{\text{n}} \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{\beta}\|_2^2 + \lambda\|\boldsymbol{\beta}\|_2^2$$

岭回归

- 岭回归模型有一个等价的优化问题，即考虑一个带有约束的线性回归问题，其中约束条件是将系数向量β 限制在一个半径为t的超球内部，即下面这个模型是与原问题等价的：

$$\beta^* = \mathrm{argmin}_\beta \ \frac{1}{\mathrm{n}} \|\boldsymbol{y} - \boldsymbol{X}\beta\|_2^2$$

$$\mathrm{s.t.} \ \|\beta\|_2^2 \leq \mathrm{t}$$

Lasso回归

- 同理地，Lasso也有一个带约束形式的等价优化模型：

$$\beta^* = \mathrm{argmin}_\beta \ \frac{1}{\mathrm{n}} \|\boldsymbol{y} - \boldsymbol{X}\beta\|_2^2$$

$$\mathrm{s.t.} \ \|\beta\|_1 \leq \mathrm{t}$$