第10章聚类分析

LianghaiXiao

https://github.com/styluck/mlb

分类和聚类

- 分类（Classification）和聚类（Clustering）是数据挖掘和机器学习中两种常见的数据分析技术，它们存在一些关键的区别：
- **目的：**
- **分类**：是一种监督学习任务，目的是通过分析训练数据集中的已知类别，建立一个模型，然后用这个模型预测新数据点的类别。
- **聚类**：是一种无监督学习任务，目的是将数据集中的样本根据相似性分组，使得同一组内的样本尽可能相似，而不同组之间的样本尽可能不同。

分类和聚类

- **数据：**
- **分类：**需要预先标注好的训练数据，即每个样本都有一个已知的类别标签。
- **聚类：**不需要预先标注的标签，算法自行发现数据中的结构，形成簇。
- **应用：**
- **分类**：适用于需要预测或分类的场景，如垃圾邮件检测、疾病诊断、手写数字识别等。
- **聚类**：适用于探索性数据分析，如市场细分、社交网络分析、图像分割等。

聚类

- 聚类分析（ClusterAnalysis）是一种探索性的数据分析技术，用于将数据集中的对象（通常称为“样本”或“观测值”）根据它们的相似性或距离划分成若干个由相似对象组成的子集或“簇（Clusters）。
- 聚类分析不需要对分类的数目和结构作出预先假定。
- 聚类分析属于无监督学习（UnsupervisedLearning），因为它不需要预先标记的数据来指导学习过程。

Q型聚类：

- 也称为样本聚类（SampleClustering）或硬聚类（HardClustering）。
- 目的是将数据集中的个体（样本）根据它们的相似性分组成多个簇，每个样本只属于一个簇，簇与簇之间没有交集。
- 常用于根据样本的特征进行分组，以便发现数据集中的潜在模式或结构。
- 确定聚类数目是Q型聚类的第一步，可以使用肘部法则、轮廓系数等方法来确定。
- 相似度计算和聚类算法选择（如K-means、层次聚类等）是关键步骤。
- 结果评估通常涉及到比较聚类结果与实际分类或观察到的模式。

R型聚类

- 也称为变量聚类（VariableClustering）或属性聚类。
- 目的是将数据集中的特征（变量或属性）根据它们的相似性分组，以减少特征数量并发现关键特征。
- 通过将相似的特征归为同一组，可以揭示数据中的潜在关系，有助于数据降维和特征选择。
- 特征选择、相似度计算和聚类算法选择（同样可以采用K-means、层次聚类等）是R型聚类的关键步骤。
- 结果评估则通过比较聚类结果与实际知识、业务逻辑等，来确定聚类的有效性。

Q型聚类和R型聚类的区别

- **Q型聚类**：
- 关注的是数据集中的样本（或称为观测、个体）之间的相似性，并将相似的样本分组成簇。
- 每个样本只属于一个簇，属于“硬”聚类，即簇与簇之间是互斥的。

- **R型聚类**：
- 关注的是数据集中的变量（或称为特征、属性）之间的相似性，并将相似的变量分组成簇。
- 允许变量属于多个簇，每个簇的隶属度不同，属于“软”聚类，即簇与簇之间可能有交集。

变量类型

- **定量变量（QuantitativeVariables）**
  - 连续变量：可以在某个范围内取任意值，如身高、体重、温度等。
  - 离散变量：只能取特定的值，如孩子的数量、车辆数、缺陷数等。

- **定性变量（QualitativeVariables）**
  - 名称变量（NominalVariables）：表示分类的变量，如性别、种族、品牌、血型等。
  - 序数变量（OrdinalVariables）：表示有顺序关系的分类变量，如教育水平、满意度评分（非常不满意、不满意、中立、满意、非常满意）等。

距离

- 距离度量是用来评估数据点之间相似性或差异性的一种方法。
- 选择合适的距离度量对于聚类结果的质量和解释性至关重要。常用的距离有：
  - 欧式距离（EuclideanDistance）
  - 曼哈顿距离（ManhattanDistance）
  - 闵可夫斯基距离（MinkowskiDistance）
  - 马氏距离（MahalanobisDistance）
  - 汉明距离（HammingDistance）
  - 兰氏距离（Lance-WilliamsDistance）

欧氏距离（EuclideanDistance）

定义为两点之间的直线距离，在二维空间中，如果两点的坐标分别为 (x_1, y_1) 和 (x_2, y_2)，那么它们之间的欧氏距离 d 计算公式为： $d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$

推广到多维空间，两点 $\mathbf{x}$ 和 $\mathbf{y}$ 之间的欧氏距离为：

$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$

曼哈顿距离（ManhattanDistance）

- 也称为城市街区距离，因为在城市中，出租车通常只能沿着街道行驶，所以这个距离度量反映了出租车行驶的最短路径。计算两点在坐标轴上的绝对轴距总和

$$d(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^{n} |x_i - y_i|$$

闵可夫斯基距离（MinkowskiDistance）

是欧氏距离和曼哈顿距离的一般形式，可以表示为：

$d(\mathbf{x},\mathbf{y}) = \left(\sum_{i=1}^{n} |x_i - y_i|^p\right)^{\frac{1}{p}}$ 其中 p 是一个参数，当 $p = 1$ 时，闵可夫斯基距离就是曼哈顿距离；当 $p = 2$ 时，就是欧氏距离。

马氏距离（MahalanobisDistance）

考虑数据集的统计特性，使用数据的均值和协方差矩阵来衡量一个点到一个分布的距离。如果 $\mathbf{x}$ 是一个点，μ 是均值向量，Σ 是协方差矩阵，那么马氏距离 d 为： $d(\mathbf{x}) = \sqrt{(\mathbf{x}-\mu)^T\Sigma^{-1}(\mathbf{x}-\mu)}$

汉明距离（HammingDistance）

- 比较两个等长字符串之间的差异，计算不同位置的字符差异次数。在信息论中，一个汉明距离为1表示一个比特的错误。

余弦相似度（CosineSimilarity）

通过计算两个向量的夹角余弦值来评估它们的相似度，对于两个非零向量 $\mathbf{x}$ 和 $\mathbf{y}$，余弦相似度 s 定义为： $s(\mathbf{x}, \mathbf{y}) = \frac{\mathbf{x} \cdot \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|} = \frac{\sum_{i=1}^{n} x_i y_i}{\sqrt{\sum_{i=1}^{n} x_i^2} \sqrt{\sum_{i=1}^{n} y_i^2}}$

相关系数（CorrelationCoefficient）

- 最常用的相关系数是皮尔逊相关系数（PearsonCorrelationCoefficient），计算公式为：

$$r = \frac{\sum_{i=1}^{n}(X_i - X)(Y_i - Y)}{\sqrt{\sum_{i=1}^{n}(X_i - \bar{X})^2}\sqrt{\sum_{i=1}^{n}(Y_i - \bar{Y})^2}}$$

系统聚类法

- 系统聚类法（HierarchicalClustering），又称为层次聚类法，是聚类分析中的一种方法。它不需要事先指定聚类的数量，而是生成一个由层次结构组成的聚类树（Dendrogram），通过这个树可以决定聚类的数量和聚类的层次。
- 系统聚类法属于Q型聚类，因为在系统聚类法中，每个样本（观测值）最终只被分配到一个簇中，而不是多个簇，这符合Q型聚类的特征。

系统聚类法

- 系统聚类法通过构建一个层次的聚类树（Dendrogram）来组织样本，这个树状结构展示了样本之间的相似性或距离。在树的底部，每个样本自己的簇，随着向上移动到树的顶端，样本簇逐渐合并，直到所有样本合并成一个大簇。

系统聚类法

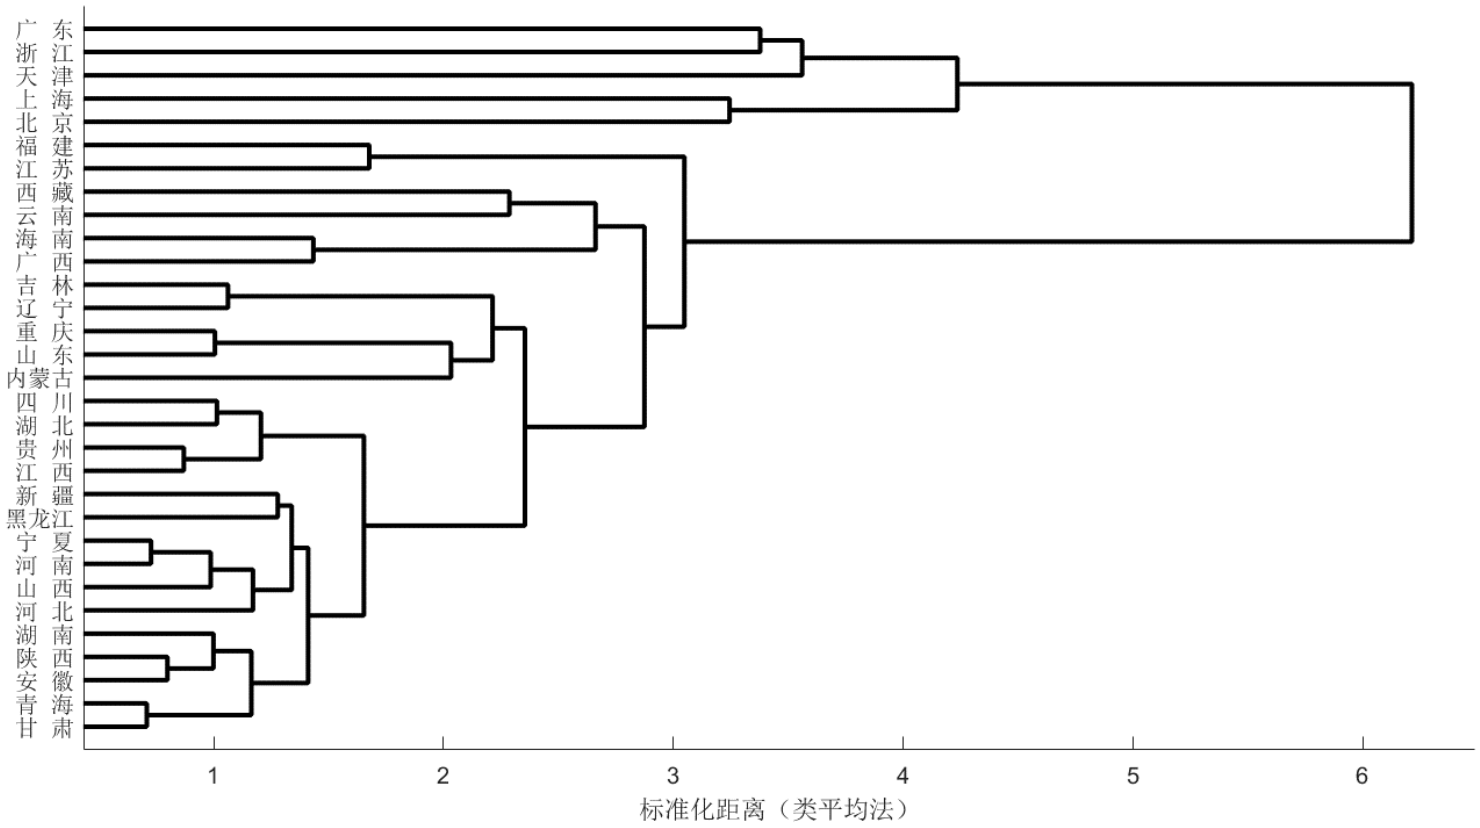
广东
浙江
天津
上海
北京
福建
江苏
西藏
云南
海南
广西
吉林
辽宁
重庆
山东
内蒙古
四川
湖北
贵州
江西
新疆
黑龙江
宁夏
河南
山西
河北
湖南
陕西
安徽
青海
甘肃
1
2
3
4
5
6
标准化距离（类平均法）

系统聚类法

- 在系统聚类法中，簇的合并通常基于以下距离度量方法之一：
- **最短距离法（SingleLinkage）**： 根据两个簇中最近的成员之间的距离来合并簇。
- **最长距离法（CompleteLinkage）**： 根据两个簇中最远成员之间的距离来合并簇。
- **类平均距离法（AverageLinkage）**： 使用两个簇所有成员之间距离的平均值来合并簇。
- **中心距离法（CentroidLinkage）**： 使用两个簇的质心之间的距离来合并簇。

系统聚类法

- 此外，还有中间距离法、可变距离法、可变类平均法、离差平方和法等
- 采用不同的方法进行聚类，得到的结果可能完全不同

- 推荐使用：最短距离法、最长距离法、类平均法

K-means聚类方法

- K-means聚类法是一种流行的迭代聚类算法，用于将数据分为多个簇，使得簇内的点尽可能相似，而簇间的点尽可能不同。这种方法属于Q型聚类（硬聚类），因为每个数据点最终只属于一个簇。

K-means聚类方法

- K-means聚类法的基本步骤如下：

1.初始化：选择一个初始的簇数目*k*，然后随机选择*k*个数据点作为初始的簇中心（质心）。

2.分配：对于数据集中的每个点，计算它与每个簇中心的距离，并将其分配到最近的簇中心，形成*k*个簇。

3.更新：重新计算每个簇的中心，通常是簇内所有点的均值。

4.迭代：重复步骤2和3，直到满足以下停止条件之一：

1. 簇中心不再显著变化，即连续两次迭代的簇中心变化量小于某个预设的阈值。
2. 达到预设的迭代次数

K-means聚类方法

- 优点:
- 简单、直观，易于理解和实现。
- 计算效率高，适合处理大型数据集。

- 缺点
- 对初始簇中心敏感，可能导致局部最优解。
- 需要预先指定簇的数目k，但在很多情况下这个数目并不明显。
- 对噪声和异常值敏感，可能会影响聚类结果。
- 只能发现球形的簇，对于非球形分布的数据可能不是最佳选择。

模糊C均值聚类法

- 模糊C均值聚类法（Fuzzy C-Means Clustering，简称FCM）是一种软聚类方法，属于R型聚类。与传统的硬聚类方法（如K-means）不同，FCM允许一个数据点以不同的隶属度属于多个簇。这种聚类方法基于模糊逻辑，特别是模糊集合理论。

模糊C均值聚类法

1. **初始化**：选择簇的数目 C，并随机初始化簇中心。
2. **隶属度计算**：对于每个数据点，计算它到每个簇中心的隶属度，隶属度的值介于0和1之间。隶属度越高，表示数据点属于特定簇的可能性越大。
3. **簇中心更新**：根据数据点的隶属度，更新每个簇的中心。
4. **迭代**：重复步骤2和3，直到满足停止条件，如簇中心的变化小于某个阈值或达到预设的迭代次数。
5. **终止**：当满足停止条件后，聚类过程结束。

模糊C均值聚类法

- 优点：
- 能够处理数据点可能属于多个簇的模糊边界情况。

- 缺点：
- 需要预先指定簇的数目C。
- 算法可能对初始簇中心敏感。
- 计算复杂度较高，尤其是在处理大型数据集时。