# 第11章 判别分析

# 判别分析

- 判别分析（Discriminant Analysis）是一种统计方法，用于研究两个或多个已知类别的对象群之间的差异，并通过这些差异来预测新对象的类别。它主要用于分类和预测，尤其是在生物统计学、心理学、市场研究和金融分析等领域。

# 判别分析

- 距离判别
- 贝叶斯判别
- Fisher判别（线性判别分析，LDA）

# 判别分析和聚类分析

- **判别分析**:
- 主要用于已知类别的情况下，通过分析不同类别之间的差异，建立一个或多个判别函数，用于预测新数据点的类别。
- 判别分析通常使用已知类别的数据来训练模型，然后利用这些模型来预测未知类别的数据点。它依赖于统计学中的协方差和均值等参数。
- **聚类分析**:
- 聚类分析旨在将数据集中的点根据相似性分组，形成不同的簇。这些簇内的点相似度高，簇间的点相似度低。
- 聚类分析不依赖于预先标记的类别，而是通过计算数据点之间的相似度（如欧氏距离、曼哈顿距离等）来构建簇。

# 距离判别（Distance Discriminant）

- 距离判别是一种基于距离的分类方法，它根据一个新样本与各个类别的中心点的距离来预测其类别。新样本会被归类为距离最近的类别。
- 这种方法简单直观，适用于类别具有不同均值但相同协方差矩阵的情况。
- 优点：计算简单，易于理解和实现。
- 缺点：它没有考虑到类别内部的方差，可能在类别协方差矩阵不同或类别重叠较多的情况下效果不佳。

# 距离判别（Distance Discriminant）

- 常用的距离判别手段是基于马氏距离，对新样本所属的类别进行判断。
- 两点之间的马氏距离为：
  - $d^2(x,y) = (x-y)^T\Sigma^{-1}(x-y)$
- 新的样本$x$到总体$G$的马氏距离为
  - $d^2(x,G) = (x-\mu)^T\Sigma^{-1}(x-\mu)$

# 马氏距离和等高线

- 马氏距离通过协方差矩阵的逆对数据进行了标准化处理，使得不同尺度和分布的数据可以进行比较。
- 在二维正态分布中，等高线（或等概率线）通常是椭圆形的。马氏距离可以看作是从一个点到分布中心的最短距离，这个距离沿着椭圆的主轴方向。椭圆的形状和方向由协方差矩阵决定。
- 马氏距离的计算可以看作是一种几何变换，它首先通过协方差矩阵的逆变换数据，然后计算变换后空间中的欧氏距离。

# 两总体距离判别

- 设有两个 p 维总体$G_1$ 和 $G_2$, 分布的均值向量分别为 $\mu_1$， $\mu_2$ ， 协方差矩阵分别为 $\Sigma_1 > 0, \Sigma_2 > 0$。现有一未知类别的样品，记为 x, 试判断 x 的归属，则有以下判别规则
- 如果$d(X, G_1) < d(X, G_2)$，则X属于$G_1$;
- 如果$d(X, G_1) > d(X, G_2)$，则X属于$G_2$;
- 如果$d(X, G_1) = d(X, G_2)$，则无法判断X属于哪个总体。

# 贝叶斯判别（Bayes Discriminant）

- 距离判别没有考虑人们对研究对象已有的认知，而这种已有的认知可能会对判别的结果产生影响。贝叶斯（Bayes）判别则用一个先验概率来描述这种已有的认知，然后通过样本来修正先验概率，得到后验概率，最后基于后验概率进行判别。
- 贝叶斯判别基于贝叶斯定理，它考虑了先验概率和数据的概率密度函数（PDF）。在给定一个新样本的情况下，贝叶斯判别会计算该样本属于每个类别的后验概率，并将其归类为具有最高后验概率的类别。

# 贝叶斯判别（Bayes Discriminant）

- 适用于已知类别的概率分布，并且可以处理各种类型的分布，包括正态分布、多项式分布等。
- 优点：提供了一种自然的方式来结合先验知识和数据特征。
- 缺点：在实际应用中，可能需要估计多个类别的概率密度函数，这在数据量较少或分布复杂时可能比较困难。

# 贝叶斯判别（Bayes Discriminant）

- 假设有K个类别$G_1, G_2, \ldots, G_K$，每个类别Gi对应一个条件概率密度函数$f(x|G_i)$，其中x为样本特征向量。
- 给定一个新的样本x，我们需要将其归为某个类别中。根据贝叶斯定理，可以计算出后验概率$P(G_i|x)$，即在已知样本特征向量x的前提下，该样本属于类别Gi的概率。这个后验概率是由类别的先验概率$P(G_i)$和样本x在类别Gi中的条件概率密度$f(x|G_i)$计算得出的，具体公式为$P(G_i|x) = [f(x|G_i) * P(G_i)] / P(x)$，其中P(x)是样本x在所有类别中的边缘概率，可以视为常数。
- 在计算出所有类别的后验概率后，我们将样本x归为后验概率最大的那个类别。即如果$P(G_j|x) > P(G_k|x)$对于所有$k \neq j$，则判定样本x属于类别$G_j$。

# 贝叶斯判别（Bayes Discriminant）

- 由贝叶斯定理，后验概率$P(G_i \mid x)$可由类别Gi的先验概率$P(G_i)$和x的条件概率密度$p(x \mid G_i)$来计算，即：
  - $$P(G_i|x) = \frac{p(x|G_i)P(G_i)}{P(x)} = \frac{p(x|G_i)P(G_i)}{\sum_{i=1}^{k} p(x|G_i)P(G_i)}$$
- 这里$p(x \mid G_i)$也称为似然函数。

# 贝叶斯判别示例

- 对某一地震高发区进行统计，地震以$G_1$类表示，正常以$G_2$类表示统计的时间区间内， 每周发生地震的概率为20%，即$P(G_1)=0.2$，当然$P(G_2)=1-0.2=0.8$ 在任意一周，要判断该地区是否会有地震发生。显然，因为$P(G_2)> P(G_1)$，只能说是正常的可能性大。如要进行判断，只能其它观察现象来实现。通常地震与生物异常反应之间有一定的联系。

# 贝叶斯判别示例

- 若用生物是否有异常反应这一观察现象来对地震进行预测，生物是否异常这一结果以模式x代表，这里x为一维特征，且只有x=“异常”和x=“正常”两种结果。假设根据观测记录，发现这种方法有以下统计结果：
- 地震前一周内出现生物异常反应的概率=0.6，即p(x=异常| G1)=0.6
- 地震前一周内出现生物正常反应的概率=0.4，即p(x=正常| G1)=0.4
- 一周内没有发生地震但也出现了生物异常的概率=0.1，即p(x=异常| G2)=0.1
- 一周内没有发生地震时，生物正常的概率=0.9，即p(x=正常| G2)=0.9
- 　　若某日观察到明显的生物异常反应现象，一周内发生地震的概率为多少，即求P(G1 | x=异常)=？

# 贝叶斯判别示例

# 贝叶斯判别示例

已知：$P(\omega_1)=0.2$，$P(\omega_2)=0.8$，

$p(x=异常|\omega_1)=0.6$，$p(x=正常|\omega_1)=0.4$，

$p(x=异常|\omega_2)=0.1$，$p(x=正常|\omega_2)=0.9$

利用贝叶斯公式，有：

$$
\begin{aligned}
P(\omega_1 \mid x=异常) &= \frac{p(x=异常 \mid \omega_1)P(\omega_1)}{p(x=异常)} \\
&= \frac{p(x=异常 \mid \omega_1)P(\omega_1)}{p(x=异常 \mid \omega_1)P(\omega_1)+p(x=异常 \mid \omega_2)P(\omega_2)} \\
&= \frac{0.6\times 0.2}{0.6\times 0.2+0.1\times 0.8}=0.6
\end{aligned}
$$

似然比：$l_{12}=\dfrac{\mathrm{p}(\mathrm{x}=异常 \mid \omega_1)}{\mathrm{p}(\mathrm{x}=异常 \mid \omega_2)}=\dfrac{0.6}{0.1}=6$

判决阈值：$\theta_{21}=\dfrac{\mathrm{P}(\omega_2)}{\mathrm{P}(\omega_1)}=\dfrac{0.8}{0.2}=4$

# 朴素贝叶斯分类器

- 朴素贝叶斯分类器（Naive Bayes Classifier）是一种基于贝叶斯定理的简单概率分类器，它基于一个非常强的假设：特征之间相互独立。由于这个假设在现实世界中往往不成立，因此被称为“朴素”的。
- 除此之外，朴素贝叶斯模型还假设所有特征变量都是离散变量，如果实际应用场景中存在连续值特征，可以先对其进行分段离散化，再应用朴素贝叶斯模型。
- 尽管如此，朴素贝叶斯分类器在很多实际应用中仍然表现出色，尤其是在文本分类和垃圾邮件过滤等领域。

# 朴素贝叶斯分类器

- **优点：**
- **简单**：朴素贝叶斯算法简单，易于理解和实现。
- **高效**：在特征数量很大时，仍然可以高效计算。
- **适用于大规模数据集**：可以处理非常大的数据集，特别是在使用算法的变体时，如多项式朴素贝叶斯。
- **缺点：**
- **特征独立性假设**：朴素贝叶斯分类器的性能受限于特征之间相互独立的假设，这在现实世界中很少成立。
- **概率估计不准确**：当特征空间很大时，可能会导致概率估计不准确。

# 朴素贝叶斯分类器

- 输入变量，也叫特征变量、自变量，一般用符号 X 表示。
- 输出变量，也叫标签变量、隐变量，一般用符号 Y 表示。
- 模型输入 X ，输出 Y 的期望值或者最大概率值。 不同的算法模型就是对条件概率分布 P(Y|X) 不同的建模方法，利用贝叶斯定理

$$P(Y|X) = \frac{P(X,Y)}{P(X)} = \frac{P(Y)P(X|Y)}{P(X)}$$

- 条件概率 P(Y|X) 可以通过联合概率 P(X,Y) 推断得到，

# 朴素贝叶斯分类器

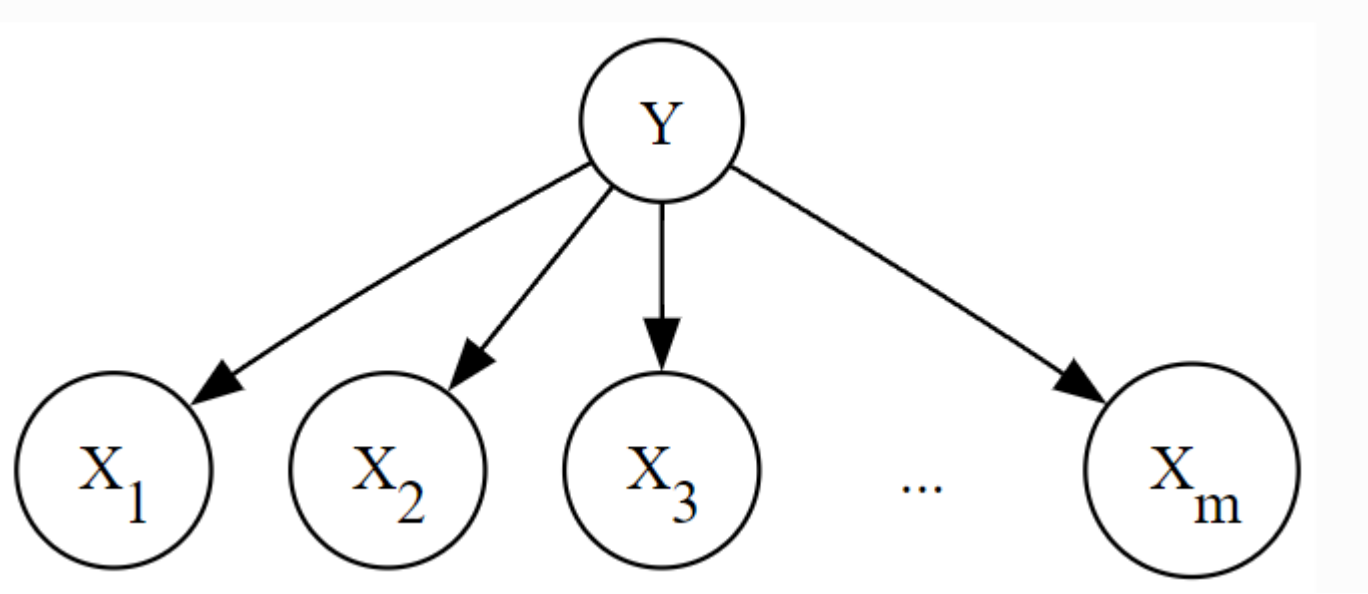

# 朴素贝叶斯分类器

- 根据贝叶斯定理，后验概率 P(Y|X) 可以分解成

$$
\begin{aligned}
P(Y|X) &= \frac{P(X,Y)}{P(X)} \\
&= \frac{P(Y)P(X|Y)}{P(X)} \\
&= \frac{P(Y)\prod_{j=1}^{m} P(X_j|Y)}{P(X)}
\end{aligned}
$$

# 朴素贝叶斯分类器

- 朴素贝叶斯模型中的条件独立性假设，使得每一项 $p(x_j|y;\theta_{xj})$ 都是独立的，其参数可以分别独立的进行估计，这极大的简化了参数估计的复杂度。
- 我们用符号 $\theta_y$ 表示 P(Y) 的参数， $\theta_{xj}$ 表示 $P(X_j|Y)$ 的参数， 并且 $\hat{\theta} = \{\theta_y, \theta_{x1}, \theta_{x2}, \cdots, , \theta_{xm}\}$
- 则

$$P(Y|X;\theta) = \frac{P(Y;\theta_y)\prod_{j=1}^{m} P(X_j|Y;\theta_{xj})}{P(X)}$$

# 朴素贝叶斯分类器

- 有一个标记好的训练数据集，每个样本点都已知其所属的类别。对于每个类别，根据训练数据集估计其先验概率（即该类别在训练数据集中出现的频率）以及给定类别时各个特征的条件概率。
- 使用贝叶斯定理计算新样本点属于每个类别的后验概率:

$$P(C_k|x_1, x_2, ..., x_n) = P(C_k) \prod_{i=1}^{n} P(x_i|C_k)$$

其中，$C_k$ 是第 $k$ 个类别，$x_1, x_2, ..., x_n$ 是特征值，$P(C_k)$ 是类别 $C_k$ 的先验概率，$P(x_i|C_k)$ 是在类别 $C_k$ 下特征 $x_i$ 的条件概率。

- 选择具有最高后验概率的类别作为新样本点的预测类别。

# Fisher判别（Fisher Discriminant）

- Fisher判别（Fisher's Linear Discriminant）是一种统计方法，用于确定两个或多个群体的成员在特征空间中是否可区分。它由罗纳德·费雪（Ronald Fisher）在1936年提出，因此得名。Fisher判别主要用于分类问题，尤其是在监督学习中，用于找到特征空间中的最佳决策边界。
- Fisher判别的核心思想是寻找一个线性组合的特征，使得不同类别的数据在这个组合特征上具有最大的类别间差异（类间散度）和最小的类别内差异（类内散度）。

# Fisher判别（Fisher Discriminant）

- Fisher判别寻找最佳的特征子空间，该子空间能够最大化类别间的分离度（类间方差）和最小化类别内的变异（类内方差）。
- 特别适用于类别具有正态分布，并且所有类别具有相同的协方差矩阵的情况。Fisher判别通常用于二分类问题，但也可以扩展到多分类问题。
- 优点：能够找到最有效的特征来区分不同的类别，对于线性可分的数据效果良好。
- 缺点：对正态分布和相同协方差矩阵的假设可能在实际应用中不总是成立，这可能会影响分类效果。

# Fisher判别（Fisher Discriminant）

- **计算类别均值**：首先，对于每个类别，计算其数据点的均值向量。
- **计算类内散度矩阵（Within-Class Scatter Matrix, $S_{WSW}$）**：这个矩阵是所有类别内数据点的散度矩阵的总和。对于每个类别 $i$，计算其散度矩阵 $S_{W_i}$，然后求和得到 $S_W$。

$$S_{W_i} = \sum_{x_j \in Class_i} (x_j - \mu_i)(x_j - \mu_i)^T$$

$$S_W = \sum_{i=1}^{c} S_{W_i}$$

- 其中，c 是类别的数量，$x_j$是属于第 $i$ 类的某个数据点，$\mu_i$是第$i$类的均值向量。

# Fisher判别（Fisher Discriminant）

- **计算类间散度矩阵（Between-Class Scatter Matrix, S_B*SB*）**：这个矩阵衡量不同类别的均值向量之间的散度。

$$S_B = \sum_{i=1}^{c} N_i(\mu_i - \mu)(\mu_i - \mu)^T$$

- 其中，$N_i$是第 *i* 类的样本数量，*μ* 是所有类别数据点的总体均值向量。
- **求解Fisher判别系数**：为了最大化类别间散度与类别内散度的比率，需要找到一个权向量 *w*，使得$w^T S_W w$ 被最小化的同时$w^T S_B w$ 被最大化。这可以通过求解以下特征值问题来实现：

$$(S_B)w = \lambda(S_W)w$$

其中，$\lambda$ 是特征值，$w$ 是对应的特征向量。理想情况下，我们寻找最大的特征值 $\lambda_{max}$ 及其对应的特征向量 $w_{max}$。

# Fisher判别（Fisher Discriminant）

- **类内散度矩阵（Within-class Scatter Matrix）** $S_W$：是所有类别内数据点到各自类中心的偏差之和的协方差矩阵。
- **类间散度矩阵（Between-class Scatter Matrix）** $S_B$：是所有类别中心向量的协方差矩阵与类别大小的加权和。
- Fisher判别的核心是求解以下广义特征值问题：

$$S_w^{-1} S_b \omega = \lambda \omega$$

- 其中，$\omega$ 是特征向量，$\lambda$ 是特征值。

# Fisher判别（Fisher Discriminant）

- **选择特征向量**：根据得到的广义特征值，选择最大的 $d$ 个特征值对应的特征向量，这些特征向量定义了最佳投影方向，其中 $d$ 是希望降维到的维数，且$d \leq k-1$，$k$ 是类别的总数。
- **构造投影矩阵**：将选定的特征向量作为列向量构成一个矩阵 $W$，这个矩阵就是LDA的投影矩阵。
- **应用投影**：最后，使用投影矩阵 $W$ 将原始数据集中的每个点 $x_i$ 映射到降维后的空间中，得到新的点 $y_i=W^T x_i$。