第12章主成分分析

主成分分析

- 尽管收集和分析大量的多变量数据可以为我们提供宝贵的信息资源，但这同时也加大了数据收集的工作负担。尤为关键的是，数据中变量间的相互关联往往会使得问题的分析变得更加复杂。如果对每个变量单独进行分析，可能会导致分析结果的孤立，无法充分利用数据集中的全部信息。因此，不经考虑地直接减少分析的指标数量，不仅会丢失许多有价值的信息，还可能导致得出错误的结论。
- 主成分分析（PCA）是一种统计方法，用于简化高维数据集的复杂性。它通过识别数据中的模式来减少数据集的维度，同时尽可能保留原始数据的变异性。PCA可以帮助我们了解数据的内在结构，揭示数据中的主要成分。

主成分分析

- 主成分分析常用于以下目的：

1. **降维**：在许多实际应用中，原始数据集可能包含大量特征，但其中许多特征可能是冗余的或高度相关的。PCA可以减少特征的数量，同时保留大部分信息。
2. **可视化**：通过将多维数据映射到较低维度（通常是二维或三维），PCA可以帮助我们更直观地理解数据。
3. **噪声过滤**：PCA可以去除数据中的噪声，因为它只保留最重要的变化模式。
4. **特征工程**：在机器学习中，PCA常用于特征提取，以改善模型的性能。

主成分分析与判别分析

- PCA是一种无监督学习方法，它不依赖于数据的类别标签，旨在找到数据中方差最大的方向，以这些方向作为新的特征空间，从而实现降维。
- LDA是一种有监督学习方法，它利用类别标签信息，寻找一个投影方向，使得同类样本在该方向上的投影尽可能接近，而异类样本的投影尽可能远离。

主成分分析

- PCA的数学定义是：一个正交化线性变换，把数据变换到一个新的坐标系统中，使得这一数据的任何投影的第一大差异性在第一个坐标（称为第一主成分）上，第二大差异性在第二个坐标（第二主成分）上，依次类推。

主成分分析

- 我们如何得到这些包含最大差异性的主成分方向呢?

- 通过计算数据矩阵的协方差矩阵，然后得到协方差矩阵的特征值特征向量，选择特征值最大(即方差最大)的k个特征所对应的特征向量组成的矩阵。这样就可以将数据矩阵转换到新的空间当中，实现数据特征的降维。

- 两种实现方法：基于特征值分解协方差矩阵实现PCA算法、基于SVD分解协方差矩阵实现PCA算法。

特征值分解矩阵原理

- 如果一个向量v是矩阵A的特征向量，将一定可以表示成下面的形式：

$$Av = \lambda v$$

- 其中，λ是特征向量v对应的特征值，一个矩阵的一组特征向量是一组正交向量。
- 对于矩阵A，有一组特征向量v，将这组向量进行正交化单位化，就能得到一组正交单位向量。**特征值分解**，就是将矩阵A分解为如下式：

$$A = Q\Sigma Q^{-1}$$

- 其中，Q是矩阵A的特征向量组成的矩阵，Σ则是一个对角阵，对角线上的元素就是特征值。

SVD分解矩阵原理

- 奇异值分解是一个能适用于任意矩阵的一种分解的方法，对于任意矩阵A总是存在一个奇异值分解：

$$A = U\Sigma V^T$$

- 假设A是一个m*n的矩阵，那么得到的U是一个m*m的方阵，U里面的正交向量被称为左奇异向量。
- Σ是一个m*n的矩阵，Σ除了对角线其它元素都为0，对角线上的元素称为奇异值。
- V^T 是V的转置矩阵，是一个n*n的矩阵，它里面的正交向量被称为右奇异值向量。而且一般来讲，我们会将Σ上的值按从大到小的顺序排列。

主成分分析

- 输入：数据集 $X = \{x_1, x_2, x_3, ..., x_n\}$，需要降到k维。
- 1) 去平均值(即去中心化)，即每一位特征减去各自的平均值。
- 2) 计算协方差矩阵 $\frac{1}{n}XX^T$，这里除或不除样本数量n或n-1,对求出的特征向量没有影响。
- 3) 用特征值分解方法求协方差矩阵 $\frac{1}{n}XX^T$ 的特征值与特征向量。
- 4) 对特征值从大到小排序，选择其中最大的k个。然后将其对应的k个特征向量分别作为行向量组成特征向量矩阵P。
- 5) 将数据转换到k个特征向量构建的新空间中，即Y=PX。

主成分分析

- 定义一个n×m的矩阵,X^T为去平均值（以平均值为中心移动至原点）的数据，其行为数据样本，列为数据类别。则X的奇异值分解为
  - $X = W\Sigma V^T$
- 据此，

$$\begin{aligned} \boldsymbol{Y}^\top &= \boldsymbol{X}^\top \boldsymbol{W} \\ &= \boldsymbol{V}\boldsymbol{\Sigma}^\top \boldsymbol{W}^\top \boldsymbol{W} \\ &= \boldsymbol{V}\boldsymbol{\Sigma}^\top \end{aligned}$$

- 我们可以利用$\mathbf{W}_L$把 **X** 映射到一个只应用前面L个向量的低维空间中去：

$$\mathbf{Y} = \mathbf{W_L}^\top \mathbf{X} = \boldsymbol{\Sigma}_\mathbf{L} \mathbf{V}^\top$$

由主成分重建原始数据

$$
\begin{aligned}
\boldsymbol{Y}^\top &= \boldsymbol{X}^\top \boldsymbol{W} \\
&= \boldsymbol{V}\boldsymbol{\Sigma}^\top \boldsymbol{W}^\top \boldsymbol{W} \\
&= \boldsymbol{V}\boldsymbol{\Sigma}^\top
\end{aligned}
$$

PCA优化目标

- PCA推导有两种主要思路：
  1.最大化数据投影后的的方差（让数据更分散）
  2.最小化投影造成的损失

- 采用第一种思路完成推导过程，下图中旋转的是新坐标轴，每个数据点在改坐标轴上垂直投影，最佳的坐标轴为数据投影后的数据之间距离最大。

PCA优化目标

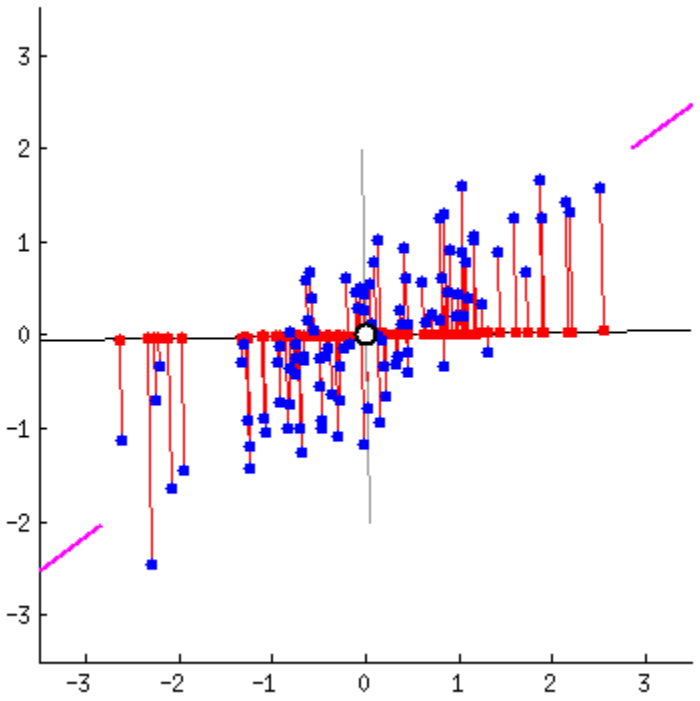

PCA推导

- PCA的目标是找到一组新的正交基 $\{u_1, u_2, \cdots, u_k\}$（从n维下降到k维），使得数据点在该正交基构成的平面上投影后，数据间的距离最大，即数据间的方差最大。
- 如果数据在每个正交基上投影后的方差最大，那么同样满足在正交基所构成的平面上投影距离最大。

PCA推导

- 设正交基 *uj*， 数据点*xi*在该基底上的投影距离为 *xiTuj*， 所以所有数据在该基底上投影的方差 *Jj* 为：

$$J_j = \frac{1}{m}\sum_{i=1}^{m}(x_i^T u_j - x_{center}^T u_j)^2$$

- 由于在数据运算之前对数据 x 进行0均值初始化，上式可写作

$$\begin{aligned} J_j &= \frac{1}{m}\sum_{i=1}^{m}(x_i^T u_j)^2 \\ &= \frac{1}{m}\sum_{i=1}^{m}(u_j^T x_i \cdot x_i^T u_j) = u_j^T \cdot \frac{1}{m}\sum_{i=1}^{m}(x_i x_i^T) \cdot u_j \end{aligned}$$

PCA推导

- 写成矩阵形式，有

$$J_j = \frac{1}{m} u_j^T X X^T u_j$$

- 则优化问题为

$$J_j = u_j^T S u_j$$

$$s.t.\ u_j^T u_j = 1$$

选择降维后的维度K(主成分的个数)

- average squared projection error

$$\frac{1}{m}\sum_{i=1}^{m}\left\|x^{(i)} - x_{approx}^{(i)}\right\|^2$$

- total variation in the data

$$\frac{1}{m}\sum_{i=1}^{m}\left\|x^{(i)}\right\|^2$$

选择降维后的维度K(主成分的个数)

- 选择不同的K值，然后用下面的式子不断计算，选取能够满足下列式子条件的最小K值即可。

$$\frac{\frac{1}{m}\sum_{i=1}^{m}\left\|x^{(i)}-x_{approx}^{(i)}\right\|^2}{\frac{1}{m}\sum_{i=1}^{m}\left\|x^{(i)}\right\|^2}\leq t$$

- 还可以用SVD分解时产生的S矩阵来表示

$$1-\frac{\sum_{i=1}^{k}S_{ii}}{\sum_{i=1}^{n}S_{ii}}\leq t$$

ALS算法

- PCA（主成分分析）中的ALS算法实际上是指交替最小二乘法（Alternating Least Squares），它是一种用于矩阵分解的优化方法，尤其在推荐系统中被广泛应用。
- ALS通常用于处理用户-商品评分矩阵，通过矩阵分解来预测缺失的评分，从而生成个性化推荐。

稀疏PCA

- 稀疏PCA是一种特殊的PCA，它旨在找到一组稀疏的主成分，这意味着每个主成分向量中的非零元素相对很少，从而提高模型的可解释性。
- 在这种情况下，ALS被用于优化一个目标函数，该函数不仅包括数据的方差最大化，还包括一个稀疏性惩罚项来鼓励找到稀疏解。