第13章 因子分析

因子分析简介

- 子分析起源于 20 世纪初, K. 皮尔逊 (Pearson) 和 C. 斯皮尔 曼 (Spearman) 等学者为定义和测定智力所作的努力，主要是 由对心理测量学有兴趣的科学家们培育和发展了因子分析。
- 因子分析常用于对不能直接观测的变量, 例如智力, 音乐能力, 爱国主义, 消费者态度等等, 进行推断, 这类变量称为隐变量.
- **隐变量**（latent variable）是指不能直接观测到的变量，但是可以从一组可观测变量的相关关系中导出。

因子分析简介

- 例如我们知道**虚弱**所表达的状况，但是无法测量。我们认为它 可以通过比如力量、重量、速度、平衡性等其他方面的测量（可 观测变量）来确定. 因此隐变量“虚弱”应该可以通过这些可测量的量来表示.
- 因子分析中称**隐变量为因子** (Factor).
- 个体在一个或多个因子上取值的变化可以影响可观测变量中的 多个变量 (某个变量子集), 从而导致该子集内变量之间高度相 关.

因子分析的分类

- 因子分析常包括探索性因子分析(Exploratory FA) 和验证性因子分析(Confirmatory FA) 两类.
- **探索性因子分析**常用来降维, 降维的方式是试图用少数几个潜 在的, 不可观测的随机变量（因子）来描述原始变量间的协方 差关系. “探索性”是指在没有对可观测变量之间，以及可观 测变量与因子之间的线性关系赋予任何结构，而只指定隐变量 (latent variables) 的个数.
- **验证性因子分析**则常用来研究一个假设的因子模型对一组新的样本拟合程度如何，其允许对模型中的参数进行限制.

EFA vs CFA

Exploratory FA

因子个数未知
载荷模式未知
（例如所有的因子在所有变量）
可以不是可识别的
因子是不相关的

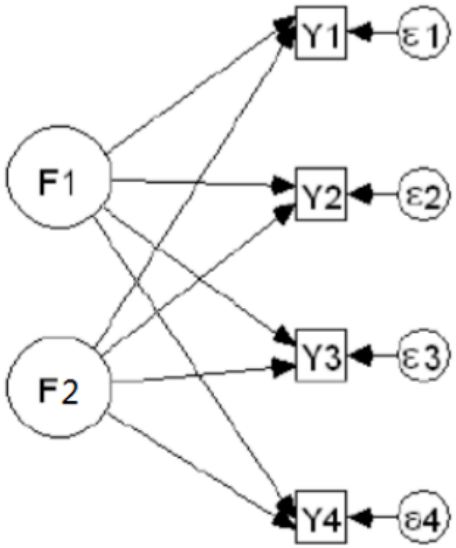

Exploratory FA

Confirmatory FA

因子个数根据理论来设置
载荷模式由理论决定
(e.g. $Y_1 = l_1 F_1 + \epsilon$)
一般是可识别的
因子可以是相关的

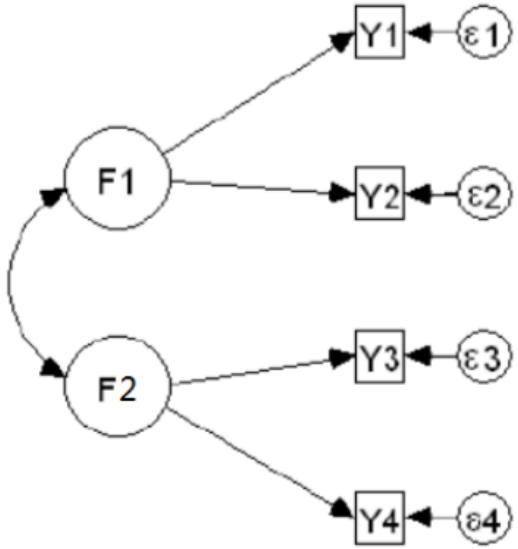

Confirmatory FA

Example: 验证性因子分析

- 一家市场研究公司希望了解消费者如何选择光顾哪家商店

- 随机对光顾每家商店的消费者进行了包含 80(p = 80) 道问题 的问卷调查
- 市场研究人员提出假设 消费者的选择是基于几个潜在的因子: <u>商店人员的友好程度, 消费者服务水平, 商店气氛, 产品种类, 产品质量和一般的价格水平</u>
- 因子分析使用 80 个问题的响应值之间的相关性来决定 80 个变量是否可以分为 6 组, 每组分别反映所假设的一个因子.

正交因子模型

- $X = (X_1, \ldots, X_p)'$ 为 p 维观测变量, 其均值和协方差矩阵分别 为 μ 和 Σ.
- 因子分析模型假定 X 可以表示为 m个公共因子 (common factors) $F_1, \ldots, F_m$ 和 p 个特殊因子 (unique factors) $\epsilon_1, \ldots, \epsilon_p$ 的 线性组合

$$
\begin{aligned}
X_1 - \mu_1 &= l_{11}F_1 + l_{12}F_2 + \cdots + l_{1m}F_m + \epsilon_1 \\
X_2 - \mu_2 &= l_{21}F_1 + l_{22}F_2 + \cdots + l_{2m}F_m + \epsilon_2 \\
&\vdots \\
X_p - \mu_p &= l_{p1}F_1 + l_{p2}F_2 + \cdots + l_{pm}F_m + \epsilon_p
\end{aligned}
$$

- 其中 l_{ij} 称为第 i 个变量在第 j 个因子上的因子负荷 (factor loading).

正交因子模型

- 表达成矩阵形式: $X_{p\times 1} = \mu + L_{p\times m}F + \epsilon$, L 称为因子负荷阵. 上述模型和线性模型形式非常相像, 但是注意右边每个量我们均不能直接观测到, 即公共因子和特殊因子均为随机变量且不能直接观测到. 因此需要假定一些结构才能进行推断.
- 正交因子模型假设包括:

$$(1). \quad E\mathbf{F} = 0, \quad Var(\mathbf{F}) = E(\mathbf{F}\mathbf{F}') = I_m$$

$$(2). \quad E\boldsymbol{\epsilon} = 0, \quad Var(\boldsymbol{\epsilon}) = E(\boldsymbol{\epsilon}\boldsymbol{\epsilon}') = \Psi = diag\{\psi_1, \ldots, \psi_p\}$$

$$(3). \quad cov(\mathbf{F}, \boldsymbol{\epsilon}) = 0$$

正交因子模型

- 在正交因子模型假设下，有

$$Cov(X_i, F_j) = l_{ij},$$

$$\Sigma = Var(\mathbf{X}) = Var(\mathbf{LF} + \boldsymbol{\epsilon}) = \mathbf{LL}' + \Psi$$

$$\sigma_{ii} = Var(X_i) = \sum_{j=1}^{m} l_{ij}^2 + \psi_i := h_i^2 + \psi_i$$

$$\sigma_{ij} = cov(X_i, X_j) = \sum_{k=1}^{m} l_{ik} l_{jk}, i \neq j$$

正交因子模型

- 方差 σ_{ii} 由两部分构成: 由 m 个公共因子贡献的部分,
- h_{2i} , 称为共性或**共性方差**(communality);
- 由公共因子不能解释 (由特 殊因子解释) 的部分称为特殊方差 (uniqueness, specific variance).
- 由协方差结构假设, 正交因子模型假定了 $p(p + 1)/2$ 个方差参数可以通过 $pm + p$ 个参数表达.

因子旋转

- 出于降维的需要，我们常常希望 m 要比 p 小得多, 这样分解式 $\Sigma = LL' + \Psi$ 通常只能近似成立. 一般来说, m 选取得越小, 上述近似效果就越差, 即因子模型拟合得越不理想. 拟合得太差的因子模型是没有什么实际意义的.
- 注意：公共因子 F 和负荷阵 L 不唯一: 对任意正交矩阵 T 有

$$X - \boldsymbol{\mu} = \mathbf{LF} + \epsilon = (\mathbf{LT})(\mathbf{T}'\mathbf{F}) + \boldsymbol{\epsilon} = \mathbf{L}^*\mathbf{F}^* + \boldsymbol{\epsilon}$$

- L^* , F^* 满足正交因子模型的所有假设. 因此因子负荷阵
  - $L^* = LT$ 和 L
- 在解释协方差 Σ 时候是等价的.

因子旋转

- 由正交矩阵的性质, 称正交变换 LT, $T'F$ 为因子旋转. 在合适 的准则下对因子负荷阵 L 进行旋转, 以期得到更易解释的结果.
- 旋转的目的是使每个变量在一个因子上的负荷量尽可能高，而在其他因子上的负荷量尽可能低，这样每个因子代表的含义就更加清晰。

参数估计

- 对可观测变量 X, 假设我们有一组样本: $x_1, \ldots, x_n$
- 由 $\Sigma = LL' + \Psi$ 结构, 需要估计 L 和 Ψ 当 L 和 Ψ 被估计出来后, 使用线性模型理论可得因子 F 的估 计 (称为因子得分).
- 记 S 为样本协方差矩阵, 则 S 为 Σ 的估计. 于是首先我们需要研究 p 个变量之间是否存在足够大的相关以进行因子分析. 如 果 S 的非对角元都约为零, 则特殊因子方差 ψ_i 占控制地位, 因 此此时我们不能识别公共因子.

参数估计

- 常见的估计方法包括
  - 主成分法
  - 迭代主因子法
  - 最大似然法 (假设正态)
- 第一种方法对方差关注更多, 后两种方法关注如何使用公共因 子的波动来描述观测性状之间的相关性.

主成分法(The principal component method)

- 由 Σ 的非负定性, 可以得到正交分解

$$\Sigma = \lambda_1 \mathbf{e}_1 \mathbf{e}_1' + \cdots + \lambda_p \mathbf{e}_p \mathbf{e}_p := \mathbf{e} \Lambda \mathbf{e}'$$

- 其中 $\lambda_1 \geq \cdots \geq \lambda_p \geq 0$ 为特征根, $e_1, \ldots, e_p$ 为相应的特征向量
- 记 $Y = e'(X - \mu)$, 则 Y 为总体主成分，有

$$\mathbf{X} - \boldsymbol{\mu} = \mathbf{e}\mathbf{Y} = \sum_{j=1}^{m} \mathbf{e}_j Y_j + \sum_{j=m+1}^{p} \mathbf{e}_j Y_j$$

$$:= \mathbf{L}\mathbf{F} + \boldsymbol{\epsilon},$$

- 其中 $\mathbf{L} = [\sqrt{\lambda_1}\mathbf{e}_1, \ldots, \sqrt{\lambda_m}\mathbf{e}_m]$, $\mathbf{F} = (Y_1/\sqrt{\lambda_1}, \ldots, Y_m/\sqrt{\lambda_m})'$,
  $\boldsymbol{\epsilon} = \sum_{j=m+1}^{p} \mathbf{e}_j Y_j$.

主成分法

- 可以验证正交因子模型的假设条件 (1) 和 (3) 成立, 但是 (2) 未 必成立.
- 相应地,

$$\Sigma = \mathbf{LL}' + Var(\boldsymbol{\epsilon})$$

- 若特殊因子 ϵ 对协方差的贡献很小, 则 $\Sigma \approx LL'$, 从而对协方 差的一个良好近似为

$$\Sigma \approx \mathbf{LL}' + diag\{\psi_1, \ldots, \psi_p\}$$

- 其中 $\psi_i = \sigma_{ii} - \sum_{j=1}^{m} l_{ij}^2 = \sigma_{ii} - h_i^2, i = 1, \ldots, p.$

主成分法

- 使用样本数据 $x_1, \ldots, x_n$ 估计上述参数. 记 $(\hat{\lambda}_i, \hat{\mathbf{e}}_j), j = 1, \ldots, p$ 为样本协方差矩阵 S 的特征根和特征向量对, 且 $\hat{\lambda}_1 \geq \cdots \geq \hat{\lambda}_p \geq 0$.

- 因子模型的主成分解:

$$\hat{\mathbf{L}} = [\sqrt{\hat{\lambda}_1}\hat{\mathbf{e}}_1, \ldots, \sqrt{\hat{\lambda}_m}\hat{\mathbf{e}}_m],$$

$$\hat{\Psi} = diag(\mathbf{S} - \hat{\mathbf{L}}\hat{\mathbf{L}}') = diag\{\hat{\psi}_1, \ldots, \hat{\psi}_p\}, \hat{\psi}_i = s_{ii} - \sum_{j=1}^{m} \hat{l}_{ij}$$

因子个数 m的确定

- 在一些问题里, 因子个数 m 是事先取定的
- 若 m 不能事先取定, 则可以基于不同 m 下拟合的模型结果来 寻找 “最好” 的 m, 使得:

$$\mathbf{S} - (\hat{\mathbf{L}}\hat{\mathbf{L}}' + \hat{\Psi})$$

- 有较小的非对角元. 类似主成分个数的选择方法, 选择 m 使得

$$\frac{\sum_{i=1}^{m} \hat{\lambda}_i}{\hat{\lambda}_1 + \cdots \hat{\lambda}_p}$$

- 较大.
- 基于相关系数矩阵分析时候, 选择特征根大于 1 的个数.

迭代主因子法(Iterated principal factor method)

- 迭代主因子法是对主成分方法的修正. 我们通过样本相关系数矩阵 R 来说明. 同样的过程也可以用于样本协方差矩阵.
- 由于总体相关系数矩阵 $\rho = LL' + \Psi$, 因此 $\rho - \Psi = LL'$. 对角 元 $\rho_{ii} = h_{2i} + \psi_i = 1$.
- 从而若 Ψ 已知, 则可对 $\rho - \Psi$ 进行矩阵分解得到 L; 有了 L 后 可以由 $\Psi = \rho - LL'$ 得到 Ψ.
- 因此, 使用样本相关系数矩阵 R 代替 ρ, 使用 Ψ 的一个初始估 计代替, 则可以迭代求解 $\hat{\mathbf{L}}, \hat{\Psi}$. 此即为迭代主因子法.

迭代主因子法

- 1.若我们有 ψ_i 的估计 ψ^*_i , 则使用 $1-\psi^*_i = h^{*2}_i$ 代替 $\rho_{ii} = 1$ 后, 得到一个“ 缩减” 的样本相关系数矩阵

$$\mathbf{R}_r = \begin{pmatrix} h_1^{*2} & r_{12} & \cdots & r_{1p} \\ r_{21} & h_2^{*2} & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & h_p^{*2} \end{pmatrix}$$

- 2.对 m 个因子, 类似主成分方法将 R_r 因子化得到

$$\mathbf{R}_r \approx \mathbf{L}_r^* \mathbf{L}_r^{*\prime}$$

- 3.其中 L_r^* 由 R_r 的前 m 个特征根和特征向量构成. 有了 L_r^*后, 更新 Ψ 的估计为 $\Psi^* = diag\{\mathbf{R} - \mathbf{L}_r^* \mathbf{L}_r^{*\prime}\}$
- 重复上面 1-2 步直至满足收敛准则.

迭代主因子法

- 特殊方差 ψ_i(或共性方差 h^2_i) 的常用初始估计有如下几种:

- 取 $\psi_i^* = 1/r^{ii}$, 其中 r^{ii} 为 R^{-1} 的第 i 个对角元, 此时 $h_i^{*2} = 1 - \psi_i^*$ 为 X_i 和其它 $p-1$ 个变量间的样本负相关系数的平方. 这种初始估计方法最常用.

- 取 $h_i^{*2} = \max_{j \neq i} |r_{ij}|$, 此时 $\psi^* = 1 - h_i^{*2}$

- 取 $h_i^{*2} = 1$, 此时 $\psi^* = 0$, 得到的 $\mathbf{L}_r^*$ 为主成分解.

迭代主因子法

- 对主因子法, 需要注意
  - 缩减的相关系数矩阵 $\mathbf{R}_r$ 未必总是正定的, 因此其一些特征根可能是负的
  - 主因子方法的结果对因子个数 m 比较敏感, 不同 m 下得到的结果可能差异较大.
  - 如果 m 太大, 一些共性方差估计 h_i^{*2} 可能会大于 1.

最大似然方法

假定 $\mathbf{F} \sim N_m(0, I_m), \boldsymbol{\epsilon} \sim N_p(0, \Psi)$ 且两者相互独立. 从而 $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \mathbf{L}\mathbf{L}' + \Psi)$.

记 $l(\boldsymbol{\mu}, \mathbf{L}, \Psi)$ 为对数似然函数, 因此

$$
\begin{aligned}
(\hat{\boldsymbol{\mu}}, \hat{\mathbf{L}}, \hat{\Psi}) &= \arg\max l(\boldsymbol{\mu}, \mathbf{L}, \Psi) \\
&= \arg\max \Big\{ -\frac{n}{2} log|\mathbf{L}\mathbf{L}' + \Psi| \\
&\qquad - \frac{1}{2}\sum_{i=1}^{n}(\mathbf{x}_i - \boldsymbol{\mu})'(\mathbf{L}\mathbf{L}' + \Psi)^{-1}(\mathbf{x}_i - \boldsymbol{\mu}) \Big\}
\end{aligned}
$$

最大似然方法

计算得到 $\hat{\boldsymbol{\mu}} = \bar{\mathbf{x}}$, $\hat{\mathbf{L}}, \hat{\Psi}$ 满足

$$\begin{cases} \hat{\Sigma}\hat{\Psi}^{-1}\hat{\mathbf{L}} = \hat{\mathbf{L}}(I_m + \hat{\mathbf{L}}'\hat{\Psi}^{-1}\hat{\mathbf{L}}) \\ \hat{\Psi} = diag(\hat{\Sigma} - \hat{\mathbf{L}}\hat{\mathbf{L}}') \end{cases}$$

其中 $\hat{\Sigma} = \frac{1}{n}\sum_{i=1}^{n}(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})'$.

由于对 $\hat{\mathbf{L}}$ 的解不唯一 (对任意正交阵 T, $\hat{\mathbf{L}}T$ 也满足等式), 因此为了得到唯一解, 常常附加计算上的限制条件

$$\hat{\mathbf{L}}'\hat{\Psi}^{-1}\hat{\mathbf{L}} \text{ 为对角阵}$$

因子旋转

- 前面我们已经看到, 在正交因子模型下， 对因子负荷阵乘以一 个正交矩阵 T 可以得到对协方差矩阵同样的逼近.
- 这意味着, 我们使用 $\hat{\mathbf{L}}$ 或 $\hat{\mathbf{L}}T$ 来估计因子负荷阵都是可以的, 其中 T 为任意正交矩阵.
- 估计的残差矩阵 $\mathbf{S}-\hat{\mathbf{L}}\hat{\mathbf{L}}'-\hat{\Psi}=\mathbf{S}-(\hat{\mathbf{L}}T)(\hat{\mathbf{L}}T)'-\hat{\Psi}$ 保持不变, 而且估计的特殊方差和共性方差均不变.
- 我们希望通过旋转因子来更好对结果进行解释: 使因子负荷的 平方两极分化, 要么接近 0, 要么接近 1.
- 因子旋转方法主要有正交旋转和斜交变换两类.

正交旋转方法 (Orthogonal rotation)

- 正交旋转方法使得旋转后的因子仍然保持独立性. 常用的正交旋转方法包括: varimax, quartimax等.

最大方差旋转法 (varimax)(Kaiser, 1958)

- 直观上使得 p 个变量在每个因子上负荷尽可能分散, 即在 每个因子上的负荷方差最大.
- 该方法简化因子负荷阵的列, 是最常用的因子旋转方法.

记 $\hat{\mathbf{L}}^* = (\hat{l}_{ij}^*)$ 为旋转的因子负荷阵, 令 $l_{ij}^* = \hat{l}_{ij}^*/\hat{h}_i$, 以及

$$V = \sum_{j=1}^{m}\left[\frac{1}{p}\sum_{i=1}^{p}\left\{(l_{ij}^*)^2 - \frac{1}{p}\sum_{i=1}^{p}(l_{ij}^*)^2\right\}^2\right]$$

$$\propto \sum_{j=1}^{m}\left[\text{第}j\text{个因子 (刻度变换后) 载荷平方的方差}\right]$$

从而选择 T, 使得 V 达到最大.

最大四次方法 (quartimax)

- varimax 旋转方法会破坏 “overall” 因子: 每个变量在该 因子上都有高负荷.
- quartimax 旋转目的在于保留 “overall” 因子, 建立其它因子, 使得每个变量在至多一个 (其它) 因 子上有高负荷.
- 最大化

$$V = \sum_{j=1}^{p} \left[\frac{1}{m} \sum_{i=1}^{m} \left\{ (l_{ij}^*)^2 - \frac{1}{m} \sum_{i=1}^{m} (l_{ij}^*)^2 \right\}^2 \right]$$

- 可使得解释每个变量所需的因子最少。该方法简化变量 (因子负荷阵的行)。