

第三章：数据处理及分析

Part 1：描述性统计、分布估计与数据标准化

Lianghai Xiao

<https://github.com/styluck/mlb>

本章结构

Part 1 描述性统计、分布估计与数据标准化

Part 2 方差分析

Part 3 回归分析

数据长什么样？如何比较数据？

学习目标

- 用集中趋势、离散程度和分布形态**描述数据**；
- 根据变量取值范围和生成机制选择**候选分布**；
- 理解矩估计和极大似然估计，并完成基本的**参数拟合与诊断**；
- 正确使用 Z-score、Min-Max、稳健标准化和对数变换；
- 识别并处理异常值，同时说明处理造成的信息损失；
- 在金融面板数据中区分**横截面处理**和**时间序列处理**。

数据准备

本项目的 `dataset` 是“日期 × 股票”的宽表；课堂分析继续保留这一结构。

1. 用 `data_io.load_data` 读取 `close`、`adj_factor`、`total_mv`、`vol`；
2. 复权价格 = `close` × `adj_factor`，逐只股票计算日收益率；
3. 将收益率、总市值和成交量分别保存到字典 `df`；每个值仍是宽表，行是日期，列是股票。

课堂示例保留 2024 年第一季度的数据；本节多数练习取最后一日的股票截面。

贯穿本节的数据

字典 `df` 包含三张宽表：

- `df["return"]`：日收益率；
- `df["total_mv"]`：总市值；
- `df["volume"]`：成交量（来自 `vol`）；
- 每张表的**行是日期、列是股票**。

Tips:

收益率可以为正或负；市值和成交量非负。变量的**取值范围与生成机制**不同，描述和建模方法也会不同。

描述性统计量

描述数据的位置、差异与形态

为什么需要描述性统计？

面对一组原始数据，如何概况其大概情况：

- 数据的典型水平是多少？——**集中趋势**
- 个体之间的差异有多大？——**离散程度**
- 数据的结构是怎样的？——**分布形态**
- 是否存在异常值、缺失值或录入错误？——**数据质量**

描述先于推断

描述性统计把复杂的数据压缩成简要且可理解的信息，也是选择统计模型和数据处理方法的起点。

总体、样本与变量

总体与参数

研究对象的全体称为**总体**。总体均值 μ 、总体方差 σ^2 等固定但通常未知，称为**参数**。

样本与统计量

从总体中观测到的 $x_1, \dots, x_n$ 称为**样本**。样本均值 $\bar{x}$ 、样本方差 s^2 等由样本计算，称为**统计量**。

用样本统计量描述已有数据，并进一步估计未知的总体参数。

集中趋势：数据的“中心”在哪里？

均值 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ 。利用全部观测，但容易受极端值影响。

中位数 排序后位于中间的数。对异常值更稳健，适合偏态数据。

众数 出现次数最多的值。可用于类别变量，也可能不唯一。

如何选择？

对称、无明显异常值时常报告均值；偏态或含异常值时同时报告中位数和四分位数。不能只因“均值常用”就忽略分布形态。

代码练习：快速查看中心位置

```
x = df["return"].iloc[-1].dropna()

mean_ = x.mean()
median_ = x.median()
mode_ = x.mode()           # 可能返回多个众数

print(mean_, median_)
print(mode_.tolist())
print(x.describe())       # count, mean, std, quartiles...
```

先清楚缺失值的处理口径。 Pandas 的统计函数通常自动跳过缺失值，但样本量会随变量变化。

离散程度：数据的分散程度？

$$\text{极差} \quad R = x_{\max} - x_{\min},$$

$$\text{样本方差} \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2,$$

$$\text{样本标准差} \quad s = \sqrt{s^2},$$

$$\text{四分位距} \quad IQR = Q_{0.75} - Q_{0.25},$$

$$\text{变异系数} \quad CV = \frac{s}{\bar{x}}.$$

标准差与原变量单位相同；IQR 只关注中间 50% 的数据，对极端值更稳健。

标准差、IQR 与变异系数如何选？

- **标准差**与均值配套，适合较对称的数据；
- **IQR**与中位数配套，适合偏态或含异常值的数据；
- **CV**消除单位，适合比较不同量纲下的相对波动。

变异系数的使用条件

CV 通常要求变量具有有意义的绝对零点，且均值明显不为零。数据均值接近零时，CV 可能巨大或符号不稳定，不宜使用。（所以不适合对收益率数据使用 CV）

代码练习：离散程度

```
x = df["return"].iloc[-1].dropna()

q1, q3 = x.quantile([0.25, 0.75])
summary = {
    "range": x.max() - x.min(),
    "variance": x.var(ddof=1),
    "std": x.std(ddof=1),
    "iqr": q3 - q1,
}
print(summary)
```


`ddof=1` 对应分母 $n - 1$ 的样本方差；比较结果时必须保持口径一致。

偏度：分布是否对称？

偏度刻画分布的**不对称程度**：

- 偏度 < 0 ：左尾较长；
- 偏度 ≈ 0 ：大致对称；
- 偏度 > 0 ：右尾较长。

右偏分布中常见 “众数 $<$ 中位数 $<$ 均值”；左偏时顺序通常相反。



代码练习：计算偏度并验证图形


```
import matplotlib.pyplot as plt

x = df["total_mv"].iloc[-1].dropna()
x.name = "total_mv"
print("skewness =", x.skew())

x.plot(kind="hist", bins=40, density=True, alpha=0.7)
plt.axvline(x.mean(), color="red", label="mean")
plt.axvline(x.median(), color="green", label="median")
plt.legend()
plt.show()
```

单个偏度数值会压缩大量信息，应与直方图或密度图一起解释。

总市值的分布：最后交易日截面




峰度：尾部是否容易出现极端值？

峰度基于标准化四阶矩：

$$K = \frac{\mathbb{E}[(X - \mu)^4]}{\sigma^4}.$$

较高的峰度通常意味着**尾部更重、极端值更常见**，不应只理解为“峰更尖”。

正态分布普通峰度为 3，**超额峰度**为 $K - 3 = 0$ 。



代码练习：峰度

```
x = df["return"].iloc[-1].dropna()

excess_kurt = x.kurt()      # Pandas: 超额峰度
ordinary_kurt = excess_kurt + 3

print("excess =", excess_kurt)
print("ordinary =", ordinary_kurt)
```

注意：pandas 返回的是超额峰度。

数值摘要不能代替图形

- 直方图：观察整体形态；
- 密度图：平滑展示分布；
- 箱线图：观察中位数、IQR 与异常点；
- Q-Q 图：比较样本分位数与理论分位数；
- 散点图：观察两个变量的关系。

基本原则

“统计量 + 图形” 共同使用。均值和标准差相同的两组数据，形态仍可能完全不同。

练习代码：直方图与箱线图


```
import matplotlib.pyplot as plt

x = df["return"].iloc[-1].dropna()
plot_low, plot_high = x.quantile([0.01, 0.99])
x_plot = x[x.between(plot_low, plot_high)]
fig, axes = plt.subplots(1, 2, figsize=(10, 3.5))

x_plot.plot.hist(bins=40, density=True, ax=axes[0], alpha=0.7)
x_plot.plot.kde(ax=axes[0])
axes[0].set_xlim(plot_low, plot_high)
axes[0].set_title("Histogram + density (1%-99%)")

axes[1].boxplot(x, vert=False)
axes[1].set_title("Boxplot")
plt.tight_layout()
plt.show()
```

收益率的基础探索：最后交易日截面



左图聚焦收益率中间 98%；右图保留全部观测以显示两侧极端值。

常见分布与参数估计

分布不是一条“长得像”的曲线，而是数据生成机制的模型







常见分布

变量范围	常见候选分布	例子
$(-\infty, +\infty)$	正态、Student t	收益率、测量误差
$(0, +\infty)$	对数正态、指数、Gamma	市值、持续时间
$[0, 1]$	Beta、均匀	比例、概率
$[a, b]$	均匀、缩放后的 Beta	有上下界的指标
非负整数	Poisson、负二项	事件次数

支持集

变量范围决定了分布的可能取值，所以不要一上来就假设分布类型。

常见连续分布一览




均匀分布

在区间 $[a, b]$ 内, 等宽区间具有相同概率:

$$f(x) = \frac{1}{b-a}, \quad a \leq x \leq b.$$

区间外密度为 0; 适合表达已知边界、区间内没有位置偏好的情形。




正态分布

$X \sim N(\mu, \sigma^2)$, 密度关于 μ 对称, σ 决定离散程度:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/(2\sigma^2)}.$$


图中的 68%-95% 规律只适用于正态模型。



Student t 分布

$t(\nu)$ 关于 0 对称，自由度 ν 控制尾部厚度。

- ν 较小时尾部更厚；
- $\nu \rightarrow \infty$ 时趋近标准正态；
- 位置和尺度参数可进一步平移、缩放曲线。




对数正态分布


若 $\log X \sim N(\mu, \sigma^2)$, 则 X 服从对数正态分布。

- 只取正值，通常右偏；
- 乘法增长可能产生近似对数正态形态；
- 变量可取负值时不能直接使用。

市值等正值变量可先取对数分析；
变得更对称不代表一定正态。



例子：总市值取对数前后




使用 `total_mv.iloc[-1]` 的全部股票截面；仅对正市值取对数。

指数分布

指数分布常用来描述恒定发生率下的等待时间：

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0, \lambda > 0.$$

速率 λ 越大，等待时间越短；其均值为 $1/\lambda$ 。




Gamma 分布


Gamma 分布只取正值，形状参数 α 与尺度参数 β 控制曲线：

$$f(x) = \frac{x^{\alpha-1} e^{-x/\beta}}{\Gamma(\alpha)\beta^\alpha}, \quad x > 0.$$

当 $\alpha = 1$ 时，它就是速率为 $1/\beta$ 的指数分布。



Beta 分布



$X \in (0, 1)$, $\alpha, \beta > 0$; 改变两个参数, 可得到 U 形、单调、均匀或单峰的密度, 适合连续比例数据。

均匀分布与 Beta 分布

均匀分布 $U(a, b)$

区间 $[a, b]$ 内等可能:

$$f(x) = \frac{1}{b-a}, \quad a \leq x \leq b.$$

适合表达 “只知道上下界、区间内无偏好”。

当观测恰好包含 0 或 1 时, 拟合 Beta 分布要特别处理边界。

Beta 分布 $\text{Beta}(\alpha, \beta)$

定义在 $[0, 1]$, 通过 α, β 表达多种形态。
适合比例、概率和归一化指标。

正态分布与 Student t 分布

正态分布 $N(\mu, \sigma^2)$

对称钟形，由位置参数 μ 和尺度参数 σ 决定。许多独立小扰动相加时，正态近似常有合理性。

Student $t(\nu)$ 分布

同样对称，但尾部比正态更重。自由度 ν 越小，尾部越重； ν 增大时趋近正态。

金融收益率经常出现尖峰和厚尾，因此 t 分布常比正态分布更贴合；这仍需用数据检验。

指数分布与 Gamma 分布

指数分布

描述无记忆事件的等待时间：

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0.$$

只有一个速率参数 λ 。

Gamma 分布

定义在正半轴，由形状参数和尺度参数控制。指数分布是 Gamma 分布的特殊情形。

Gamma 分布更灵活，可用于持续时间、交易间隔和正值偏态变量。

从“候选分布”到“拟合分布”



- 先提出一个或多个有理论依据的候选分布；
- 再用样本估计分布参数；
- 最后检查模型无法解释的偏离，必要时更换模型。

参数估计：矩估计

矩估计法用样本矩去匹配总体矩。

例如 $X \sim N(\mu, \sigma^2)$, 有

$$\mathbb{E}[X] = \mu, \quad \mathbb{E}[(X - \mu)^2] = \sigma^2.$$

用样本对应量替代：

$$\hat{\mu} = \bar{x}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

注意

此处的 $1/n$ 同时是矩估计和正态模型下的极大似然估计；常用的无偏样本方差使用 $1/(n-1)$ 。估计目标不同，公式可能不同。

参数估计：极大似然估计

已知候选密度 $f(x | \theta)$ ，将观测值视为固定，选择最能解释数据的参数：

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} \prod_{i=1}^n f(x_i | \theta) = \arg \max_{\theta} \sum_{i=1}^n \log f(x_i | \theta).$$

- 取对数把乘积变成求和，数值计算更稳定；
- 不同分布对应不同的参数约束；
- 拟合成功只表示找到了基于当前分布假设下的最优参数，**正确与否仍依赖分布假设。**

代码：用 SciPy 估计分布参数

```
from scipy import stats

x = df["return"].iloc[-1].dropna().to_numpy()

# fit 返回极大似然参数；正态为 loc, scale
mu, sigma = stats.norm.fit(x)

# t 分布为 df, loc, scale
nu, loc, scale = stats.t.fit(x)

print("normal:", mu, sigma)
print("t:", nu, loc, scale)
```

scale 是标准差型尺度参数，不是方差。不同分布的返回参数顺序应查阅相应接口。

拟合诊断一：叠加密度曲线

- 画样本直方图或核密度图；
- 在同一坐标轴叠加拟合分布的密度；
- 重点观察中心、偏斜和尾部是否系统偏离。

不能只靠“看起来像”

直方图受分箱宽度影响，样本量较小时尤其不稳定。图形用于发现问题，还需配合 Q-Q 图、统计检验和业务知识。


练习代码：直方图叠加拟合密度

```
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats

x = df["return"].iloc[-1].dropna().to_numpy()
mu, sigma = stats.norm.fit(x)
nu, loc, scale = stats.t.fit(x)
grid = np.linspace(x.min(), x.max(), 400)

plt.hist(x, bins=40, density=True, alpha=0.5)
plt.plot(grid, stats.norm.pdf(grid, mu, sigma),
         linewidth=2, label="fitted normal")
plt.plot(grid, stats.t.pdf(grid, nu, loc, scale),
         linewidth=2, label="fitted t")
plt.legend()
plt.show()
```

收益率的分布拟合





在同一尺度比较直方图、正态拟合与 t 分布拟合，重点检查中心和尾部。


拟合诊断二：Q-Q 图

Q-Q 图比较样本分位数与理论分位数：

- 点接近直线：分布较吻合；
- 两端明显弯曲：尾部不匹配；
- 整体不对称：可能存在偏度差异。




收益率的正态 Q-Q 图



两端偏离参考线，说明正态模型对尾部的刻画存在偏差。

收益率的 t 分布 Q-Q 图



使用同一日收益率截面估计 t 分布参数；与上一页比较点在尾部偏离参考线的程度。

拟合诊断三：统计检验

Jarque–Bera 检验 依据偏度和峰度检验正态性；

Shapiro–Wilk 检验 常用于中小样本的正态性检验；

练习代码：统计检验

```
import numpy as np
from scipy import stats
x = df["return"].iloc[-1].dropna().to_numpy()
jb = stats.jarque_bera(x)
sw_x = x
if len(x) > 5000:
    sw_x = np.random.default_rng(0).choice(x, 5000, replace=False)
sw = stats.shapiro(sw_x)
print("JB statistic, p-value:", jb.statistic, jb.pvalue)
print("SW W, p-value:", sw.statistic, sw.pvalue)
```

检验结果

有效收益率 $n = 5242$ 。

检验	统计量	p 值
Jarque-Bera	12350.9130	≈ 0 (数值下溢)
Shapiro-Wilk	$W = 0.9068$	4.92×10^{-48}

- 两项正态性检验的 p 值远小于 0.05, **拒绝该截面服从正态分布**的假设。
- 直方图显示收益率集中; 正态 Q-Q 图的尾部明显偏离。 t 分布 Q-Q 图的极端分位数仍有偏离, **单一对称 t 分布也未充分刻画该截面**。
- 基本可以排除正态分布假设, 下一步可以进行对 t 分布的正式检验。

数据标准化与异常值处理

改变尺度、改善形态，但不要悄悄改变研究问题

三类操作

操作	主要目的	典型方法
尺度变换	让变量处于可比较尺度	Z-score、Min-Max、稳健标准化
分布变换	缓解偏态、稳定方差	对数、平方根、Box-Cox
异常值处理	降低极端观测的影响	缩尾、截尾、单独建模

名称不要混用

标准化通常改变位置和尺度；对数变换会改变分布形态；缩尾会直接改变部分观测值。三者的统计含义不同。



为什么要标准化？

- 不同变量单位和数量级差异很大，无法直接比较；
- 距离、梯度和正则化对变量尺度敏感；
- 可提高部分数值优化算法的稳定性与收敛速度；
- 便于解释“相对样本均值高出多少个标准差”。

并非所有模型都必须标准化

决策树等模型通常不依赖变量尺度；线性模型中是否标准化也取决于解释目标。处理方法应服务于后续分析。

Z-score 标准化



$z_i = (x_i - \bar{x})/\hat{\sigma}$: 各变量平移、缩放至均值 0、标准差 1。形态不变。



代码：Z-score 标准化

```
x = df["volume"].iloc[-1]
mean_ = x.mean()
std_ = x.std(ddof=0)

df["volume_z"] = (x - mean_) / std_ if std_ > 0 else np.nan
```

- 标准差为零时无法进行 Z-score;
- 训练/测试划分后，只能用**训练集**的均值和标准差变换测试集;
- 保存 $\bar{x}$ 和 s ，否则无法复现或反变换。

Min-Max 归一化



$x'_i = (x_i - x_{\min}) / (x_{\max} - x_{\min})$: 样本映射到 $[0, 1]$, 保留顺序; **端点对异常值敏感。**

代码：Min-Max 及边界检查

```
x = df["volume"].iloc[-1]
x_min, x_max = x.min(), x.max()

if x_max == x_min:
    df["volume_mm"] = np.nan
else:
    df["volume_mm"] = (x - x_min) / (x_max - x_min)
```

新数据可能超出训练集的最小值和最大值，因此变换结果也可能超出 $[0, 1]$ ；这并非计算错误。

稳健标准化：中位数与 IQR

当均值和标准差易受极端值影响时，可用

$$x'_i = \frac{x_i - Q_{0.50}}{Q_{0.75} - Q_{0.25}}.$$

- 中位数替代均值，IQR 替代标准差；
- 对少量极端值更稳健；
- 不会删除异常值，也不会保证结果落在固定区间；
- 当 IQR 为零时同样需要单独处理。

代码：稳健标准化

```
x = df["total_mv"].iloc[-1]
median = x.median()
q1, q3 = x.quantile([0.25, 0.75])
iqr = q3 - q1


if iqr == 0:
    df["total_mv_robust"] = np.nan
else:
    df["total_mv_robust"] = (x - median) / iqr
```

稳健不等于“不受影响”，而是少量极端值对中心和尺度估计的影响更小。

对数变换：压缩右侧长尾

- 压缩较大的正值；
- 常用于市值、成交额等右偏变量；
- 将乘法关系转为加法关系；
- 可减轻异方差，但不保证消除异方差。

对非负且可能为零的数据，常使用 $\log(1 + x)$ 。



代码：先检查取值范围，再取对数

```
import numpy as np

x = df["total_mv"].iloc[-1]
if (x < 0).any():
    raise ValueError("log1p requires x >= 0 in this example")

df["log_total_mv"] = np.log1p(x)
```

解释也随之改变

对数变量的单位不再是原始单位。分析结果应按对数尺度解释，必要时再转换回原尺度。

异常值：为什么异常

异常值可能来自：

- 录入、单位、复权或合并错误；
- 真实但罕见的市场事件；
- 不同群体混合造成的结构差异；
- 数据生成机制本身具有厚尾。

异常 $\neq$ 错误

在金融数据中，极端收益可能是风险信息。异常数据也可能来自于特殊的交易规则。


用 IQR 规则识别异常值

$IQR = Q_{0.75} - Q_{0.25}$, 经验阈值为

$$L = Q_{0.25} - 1.5IQR,$$

$$U = Q_{0.75} + 1.5IQR.$$

区间外观测只标记为潜在异常值。



图下方的百分比仅对应正态分布示意；偏态或厚尾数据的比例会不同。

练习代码：IQR 规则识别异常值

```
x = df["return"].iloc[-1]
q1, q3 = x.quantile([0.25, 0.75])
iqr = q3 - q1
lower = q1 - 1.5 * iqr
upper = q3 + 1.5 * iqr


df["is_outlier"] = (x < lower) | (x > upper)
print(df["is_outlier"].value_counts())
```

缩尾与截尾

缩尾 Winsorize 将超出阈值的数值
替换为边界值，样本
量不变。

截尾 Trim 删除超出阈值的观测，
样本量减少。

两种方法都会改变数据，使用的时
候要慎重考虑。



图片示意缩尾后边界处的堆积；截尾会删除这些阈值外的观测。

练习代码：分位数缩尾与截尾



```
x = df["return"].iloc[-1]
lower, upper = x.quantile([0.01, 0.99])

# 缩尾：保留所有行，只改变极端值
df["return_win"] = x.clip(lower=lower, upper=upper)

# 截尾：保留阈值内的行
mask = x.between(lower, upper) | x.isna()
return_trim = x.loc[mask].copy()
```

不要覆盖原变量；保留原列与处理后的列，才能做稳健性比较。

异常值处理的代价



处理后要重新检查样本边界与残差形态。

- 删除真实极端事件可能低估风险；缩尾会在阈值处制造相同数值；
- 截尾会改变样本构成。

金融面板：横截面还是时间序列？

横截面标准化

在每个交易日内，对不同股票进行标准化。回答“这只股票相对当天其他股票有多高”。常用于因子构造。

时间序列标准化

对每只股票，利用其历史窗口标准化。回答“当前值相对该股票自身历史有多高”。常用于异常监测。

两者研究问题不同，不能只因输出都叫 Z-score 就混为一谈。

代码：两种 Z-score

```
# 同日横截面：比较最后一日的股票
v = df["volume"].iloc[-1]
std_cross = v.std(ddof=0)
df["z_cross"] = (v - v.mean()) / std_cross if std_cross > 0 else np.nan

# 时间序列：每列是一只股票，只用当前日前 20 期
past = df["volume"].shift(1)
mean20 = past.rolling(20, min_periods=20).mean().iloc[-1]
std20 = past.rolling(20, min_periods=20).std(ddof=0).iloc[-1]
df["z_time"] = (v - mean20) / std20.replace(0, np.nan)
```

信息泄漏

- 预测任务中，不能用未来数据计算当前时点的均值、标准差或分位数；
- 训练集和测试集不能分别“各自拟合”后再比较；
- 滚动窗口应确认是否包含当前值，必要时先 `shift(1)`；
- 横截面处理应确认当日数据在真实决策时是否已经可获得。

判断标准

在时间 t 做变换时，只允许使用时间 t 当时已经知道的信息。

从原始变量到可分析变量



1. 明确变量含义、单位、范围与缺失规则;
2. 用数值和图形描述; 提出并检验候选分布;
3. 根据后续任务选择处理方法, 并保存参数与处理日志;
4. 比较处理前后结论, 说明方法的影响。

课堂练习：为三个变量设计处理方案

对 `return`、`total_mv`、`volume` 分别回答：

1. 变量的可能取到的值的范围是什么？应该报告哪些描述性统计量？
2. 哪个候选分布较合理？需要估计哪些参数？
3. 用哪些图形或检验判断拟合质量？
4. 如何对数据进行预处理？

要求：简述理由并提供代码。

本节小结

- 描述分布要同时看**中心、离散、形态和图形**；
- 候选分布来自**支持集与生成机制**，参数拟合之后仍需诊断；
- Z-score 改变位置和尺度，**不会自动产生正态分布**；
- 对数变换、标准化和异常值处理是不同操作；
- 金融数据处理必须明确横截面/时间序列维度，并避免未来信息泄漏；
- 保留原始变量、变换参数和处理日志，才能复现与比较。

Part 1 完成

下一部分：方差分析
