第三章：数据处理及分析

Part 3：回归分析

Lianghai Xiao

https://github.com/styluck/mlb

本章结构

Part 1 描述性统计、分布估计与数据标准化

Part 2 方差分析

Part 3 回归分析

回归分析：研究变量之间的数量关系。

学习目标

- 建立一元与多元线性回归模型，并解释回归系数；
- 理解最小二乘、平方和分解、R^2、F 检验和 t 检验；
- 理解线性回归的基本假设及其对估计和检验的影响；
- 通过残差图和统计检验进行回归诊断；
- 区分稳健标准误、加权最小二乘与变量变换的作用；
- 掌握回归中性化，并用回归系数和相关系数评价 BP 因子。

案例：账面市值比与股票收益

股票的账面市值比与下一交易日收益是否存在关系?

$$BP = \frac{1}{PB} = \frac{\text{公司净资产}}{\text{公司总市值}}.$$

- 在净资产为正时，BP 越高，每元市值对应的账面净资产越多;
- BP 较高的股票，下一交易日的平均收益是否也较高?
- 考虑公司规模后，这种关系是否仍然存在?

上一节用方差分析比较各行业的平均 PB。本节进一步研究估值指标与后续收益之间的数量关系。

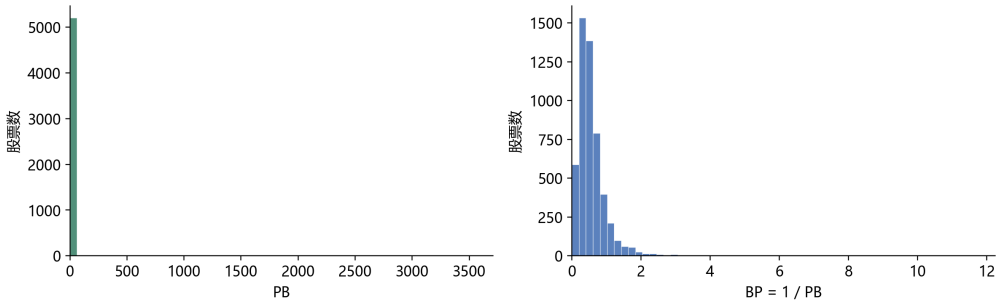
从行业比较到回归分析

- **方差分析**：按行业分组，比较各组的平均水平；
- **一元回归**：研究 BP 变化时，下一交易日收益的平均水平如何变化；
- **多元回归**：同时考虑 BP 与公司规模，分析控制规模后 BP 与收益的关系。

从一元回归到多元回归，可以逐步分析 BP、公司规模与收益之间的关系。

同一交易日的 PB 与 BP 分布

2024-03-28，沪深市场 5,226 只有效股票的 PB 与 BP 分布。



两图均展示原始取值的完整范围，横轴采用线性尺度。PB 的较大值被倒数变换压缩，而接近零的 PB 会产生较大的 BP，因此 BP 仍可能右偏。

线性回归模型

回归方程、回归系数与残差

一元线性回归

一元线性回归用一个解释变量 X 描述因变量 Y 的平均变化规律：

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

β_0 截距。在零条件均值假设下，表示 $X = 0$ 时 Y 的平均水平；

β_1 斜率。X 每增加一个单位，Y 的平均水平改变 β_1 个单位；

ε_i 未被 X 解释的个体差异与随机误差。

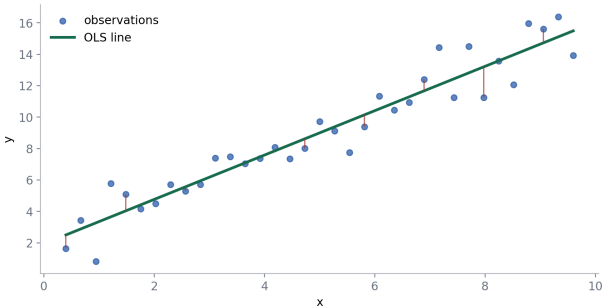
线性回归中的“线性”指对参数线性。加入 X^2 等项，也可以描述曲线关系。若 $X = 0$ 超出样本范围，截距通常不宜作实际解释。

观测值、拟合值与残差

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i,$$
$$e_i = Y_i - \hat{Y}_i.$$

残差是观测值与拟合值之差，即图中沿**纵轴方向的差值**，不是点到回归线的最短距离。

残差是不可观测误差 ε_i 的样本估计。



回归分析的用途

描述关系 分析在给定解释变量时，Y 的平均水平如何变化；

预测 根据解释变量的取值估计新观测的因变量，预测效果需用新样本检验；

因果 分析改变 X 对 Y 的影响，需要研究设计和相应的识别假设。

回归关系的解释

回归系数首先描述变量之间的统计关系。遗漏变量、反向因果和样本选择都可能影响估计，因此统计显著性本身不足以说明因果关系。

最小二乘估计与统计推断

参数估计、拟合优度与假设检验

最小二乘法

选择截距和斜率，使观测值与拟合值之间的残差平方和最小：

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg\min_{\beta_0,\beta_1} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2 .$$

- 每个残差都先平方，正负残差不会相互抵消；
- 残差越大的观测，对目标函数的影响越大；
- 以一个交易日的股票数据为例，估计 BP 与次日收益之间的回归关系。

Python 示例：导入程序包

```python
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm
import statsmodels.formula.api as smf
from scipy import stats
from statsmodels.stats.diagnostic import het_breuschpagan
from statsmodels.stats.outliers_influence import variance_inflation_factor
from data_io.io_framework import load_data
```

Python 示例：读取单日数据

```
date, next_date = "2024-03-28", "2024-03-29"
pb = load_data("pb", date, date).loc[date]
plt.figure()
pb.hist(bins=500)
bp = (1 / pb).rename("bp")
plt.figure()
bp.hist(bins=100)
```

以 2024-03-28 的 BP 为解释变量，以 2024-03-29 的收益率为因变量。收益率的单位为百分比。

Python 示例：整理回归样本

```
price = close * adj
return_next = (100 * (price.loc[next_date] / price.loc[date] - 1)).rename("return_next")
```

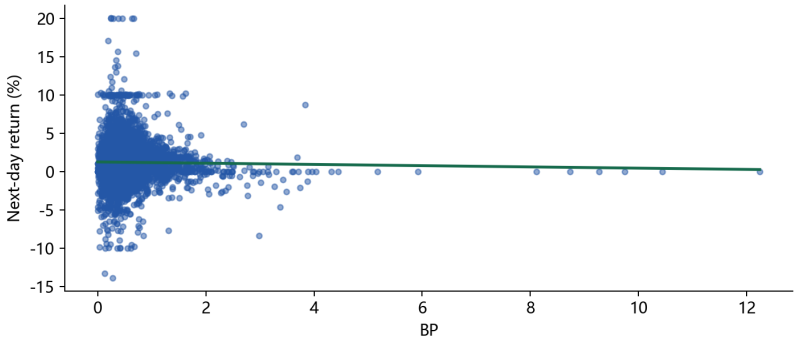
每行对应一只股票。样本包含 BP 为正、BP 与次日收益均无缺失的股票，解释变量采用原始 BP。

Python 示例：一元回归估计

```
single = single.replace([np.inf, -np.inf], np.nan)
simple_cross = single.loc[single.bp > 0].dropna().copy()
```

斜率表示 BP 每增加 1，预测次日收益改变多少个百分点。

案例结果：BP 与下一交易日收益



5226 只股票的一元回归斜率为 -0.081，即 BP 每增加 1，拟合的次日收益下降 0.081 个百分点。散点较为分散，BP 对单日收益的解释程度较低。

多元线性回归

$$Y_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_k X_{ik} + \varepsilon_i.$$

- β_j 是在**其他解释变量保持不变**时，X_j 增加一个单位对应的条件均值变化；
- 类别变量可通过虚拟变量进入模型；
- 加入交互项，可以描述一个变量的斜率如何随另一个变量变化；
- 加入 X^2、$\log X$ 等项可以描述曲线关系，模型对参数仍然是线性的。

矩阵形式

对 n 个观测、k 个解释变量：

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

其中 $\mathbf{X}$ 通常包含一列常数，因此共有 $k+1$ 个参数。

- $\mathbf{y} \in \mathbb{R}^n$；
- $\mathbf{X} \in \mathbb{R}^{n \times (k+1)}$；
- $\boldsymbol{\beta} \in \mathbb{R}^{k+1}$；
- $\boldsymbol{\varepsilon} \in \mathbb{R}^n$。

多元回归的最小二乘解

多元回归同样使残差平方和最小：

$$\hat{\boldsymbol{\beta}} = \arg\min_{\boldsymbol{\beta}} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2.$$

若设计矩阵满列秩，则

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

实际计算通常采用 QR 或 SVD 分解，而不是直接计算矩阵的逆。

Python 示例：构造规模变量

```
simple = smf.ols("return_next ~ bp", data=simple_cross).fit()
print(simple.summary())
```

用总市值的自然对数衡量公司规模。比较一元与多元回归时，均使用 BP、收益和市值完整的股票。

Python 示例：多元回归估计

```
log_mv = np.log(mv.where(mv > 0)).rename("log_mv")
cross = simple_cross.join(log_mv).dropna().copy()

# %% TODO 2: 多元回归
model = smf.ols("return_next ~ bp + log_mv", data=cross).fit()
```

在同一样本上分别估计一元和多元回归，比较加入规模变量前后的 BP 系数。

案例数据：单日回归的样本与变量

因子日期：2024-03-28；收益日期：2024-03-29；有效股票数：5226。

样本范围	股票数
BP、收益与市值均有效的股票	5226

- `bp`：原始账面市值比；
- `log_mv`：当日总市值的自然对数；
- `return_next`：下一交易日复权收盘收益，单位为百分比。

多元回归系数的含义

$$r_{i,t+1} = \beta_0 + \beta_1 BP_{i,t} + \beta_2 \log MV_{i,t} + \varepsilon_i.$$

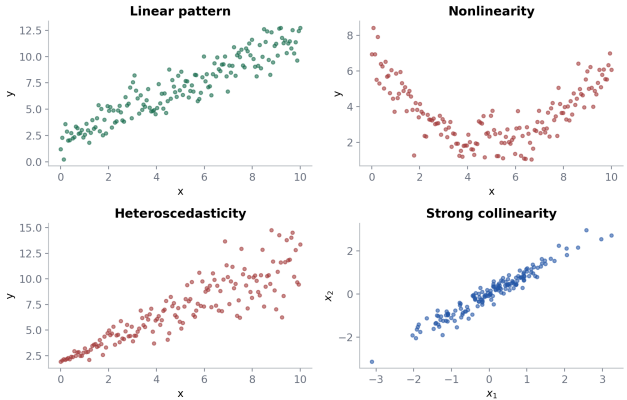
- β_1：市值相同时，BP 增加 1，对应收益改变 β_1 个百分点；
- β_2：BP 相同时，市值增加 1%，对应收益约改变 $0.01\beta_2$ 个百分点；
- 这里的系数反映控制另一变量后的条件均值关系。

线性回归的基本假设

1. **模型设定**：模型能够正确描述因变量的条件均值；
2. **零条件均值**：$\mathbb{E}(\varepsilon \mid X) = 0$；
3. **无完全共线性**：解释变量没有精确线性关系；
4. **同方差性**：$\mathrm{Var}(\varepsilon \mid X) = \sigma^2$；
5. **误差不相关**：不同观测的误差之间不相关；
6. **正态性**：误差服从正态分布时，可在小样本下进行精确的 t 和 F 检验。

零条件均值和满列秩保证 OLS 无偏；再满足同方差、误差不相关时，OLS 是最佳线性无偏估计。

回归中的常见数据特征与问题



前三图展示 X 与 Y 的关系；右下图展示两个解释变量的关系。

OLS 的几何解释

正规方程为

$$\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = 0,$$

即

$$\mathbf{X}^\top \mathbf{e} = 0.$$

- 残差向量与每一列解释变量正交；
- 含截距时，残差和为零；
- 拟合值是 $\mathbf{y}$ 在 $\mathbf{X}$ 列空间上的投影，残差与该空间正交。

为什么拟合值是正交投影?

当 $\mathbf{X}$ 满列秩时，OLS 系数为

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

将它代入拟合值 $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$:

$$\hat{\mathbf{y}} = \underbrace{\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top}_{\mathbf{H}} \mathbf{y} = \mathbf{H}\mathbf{y}.$$

- $\mathbf{H}$ 是投影到 $\mathbf{X}$ 列空间的**正交投影矩阵**;
- 列空间就是 $\mathbf{X}$ 各列的所有线性组合。

平方和分解

含截距的回归中：

$$SST = SSR + SSE,$$

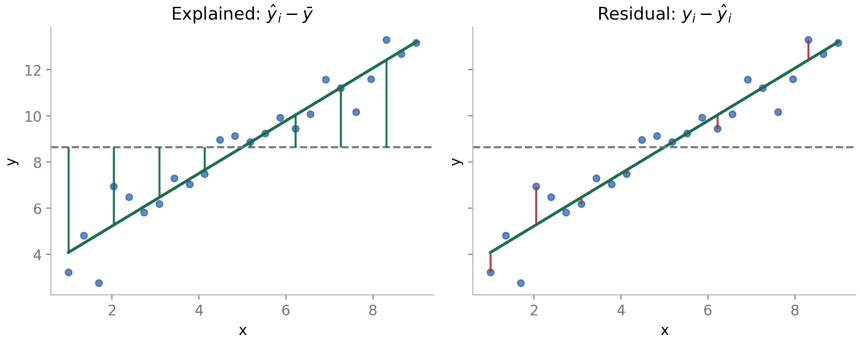
$$SST = \sum_i (y_i - \bar{y})^2,$$

$$SSR = \sum_i (\hat{y}_i - \bar{y})^2,$$

$$SSE = \sum_i (y_i - \hat{y}_i)^2.$$

回归解释的变异与残差变异共同构成总变异。

解释变异与残差变异



对每个观测，都有 $y_i - \bar{y} = (\hat{y}_i - \bar{y}) + (y_i - \hat{y}_i)$。含截距的 OLS 中，拟合值与残差正交，因此总平方和可分解为回归平方和与残差平方和。

判定系数 R^2

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}.$$

- 含截距且因变量有变异时，$0 \le R^2 \le 1$；
- 加入解释变量不会降低样本内 R^2；
- R^2 衡量样本内拟合程度，预测能力还需在新样本上评价；
- 股票单日收益受多种因素影响，横截面回归的 R^2 往往较低。

调整后的 R^2

$$\bar{R}^2 = 1 - (1 - R^2)\frac{n-1}{n-k-1}.$$

- 根据样本量和解释变量个数，对 R^2 作出调整；
- 新增变量若不能明显改善拟合，调整后的 R^2 可能下降；
- 调整后的 R^2 仍衡量样本内的拟合程度；
- 比较模型时应确保因变量、样本和截距设定一致。

整体 F 检验

对含 k 个斜率的模型，检验

$$H_0 : \beta_1 = \cdots = \beta_k = 0, \qquad H_1 : \text{至少一个斜率不为零.}$$

$$F = \frac{SSR/k}{SSE/(n-k-1)}.$$

当 H_0 成立且误差独立、同方差并服从正态分布时，$F \sim F(k, n-k-1)$。拒绝 H_0 不代表每个变量都显著；异方差下应采用相应的稳健联合检验。

单个系数的 t 检验

检验第 j 个系数：

$$H_0 : \beta_j = \beta_{j,0}, \qquad t = \frac{\hat{\beta}_j - \beta_{j,0}}{SE(\hat{\beta}_j)}.$$

- 标准误越大，系数估计越不精确；
- 共线性、噪声和有效样本量都会影响标准误；
- 置信区间同时反映系数的可能范围和估计精度；
- 显著性检验通常取 $\beta_{j,0} = 0$，考察该变量是否具有统计上的解释作用。

Python 示例：查看估计与检验结果

```
print(model.summary2().tables[1])
print("R2:", model.rsquared)
print("Adjusted R2:", model.rsquared_adj)
print("F, p:", model.fvalue, model.f_pvalue)
```

回归输出包括系数、标准误、t 值、p 值和置信区间。下面先按同方差假设解读结果，再通过残差诊断检验这一假设。

案例结果：控制规模后的回归系数

变量	系数	标准误	t	p	95% 区间
截距	3.023	0.418	7.226	< 0.001	[2.203, 3.843]
BP	-0.096	0.066	-1.453	0.146	[-0.225, 0.033]
对数市值	-0.132	0.031	-4.239	< 0.001	[-0.193, -0.071]

控制规模后，BP 系数为 -0.096，95% 置信区间包含零；对数市值系数为负且显著。表中采用通常的 OLS 标准误，下面进一步检查同方差假设。

案例结果：整体检验与单个系数检验

指标	结果
R^2	0.004
调整 R^2	0.003
整体 $F(2, 5223)$	9.742
整体 p	< 0.001
BP 系数的 p	0.146

整体显著与单个变量显著

整体检验拒绝 BP 和市值的系数同时为零，但 BP 的单个系数检验不显著。模型仅解释约 0.4% 的收益变异：统计显著性与拟合程度是两个不同的方面。

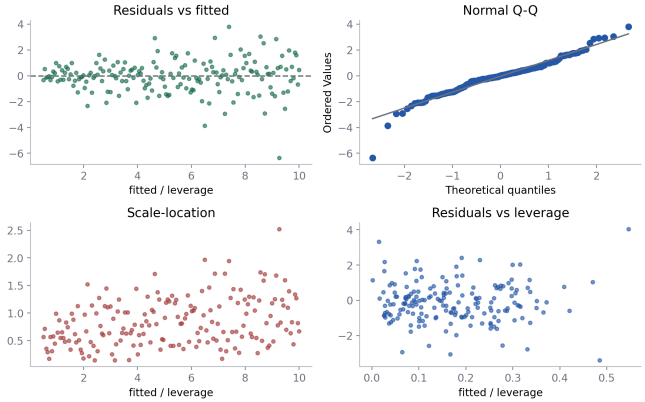
回归诊断与修正

残差分析、异常观测与模型修正

回归诊断的主要内容

1. **模型设定**：遗漏非线性项、交互项或重要变量；
2. **异方差**：残差的离散程度随拟合值变化；
3. **正态性**：残差厚尾或强偏态，影响小样本推断；
4. **误差相关**：不同时点或同一组内的观测相关，使普通标准误失真；
5. **异常与影响点**：少数观测显著改变系数；
6. **共线性**：系数对样本扰动十分敏感。

四幅常用诊断图



残差–拟合值图用于识别曲线趋势和异方差；Q–Q 图用于考察正态性；尺度–位置图显示残差的离散程度；残差–杠杆图用于识别强影响点。

异常值、高杠杆点与强影响点

异常值 观测值明显偏离拟合值，残差较大；

高杠杆点 从解释变量的取值看，该观测远离样本中心；

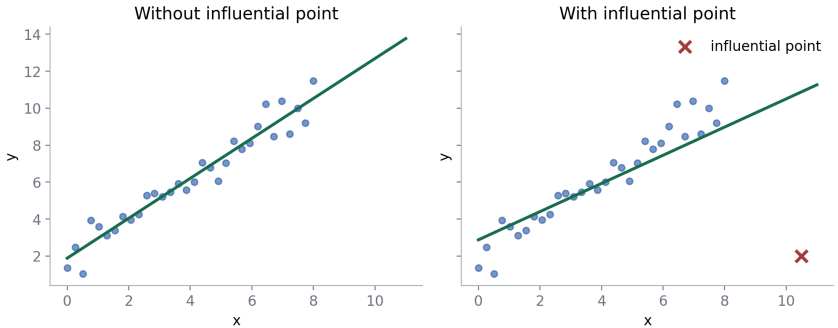
强影响点 删除该观测会明显改变拟合结果。

常用诊断包括学生化残差、杠杆值、Cook 距离与 DFFITS。

异常观测的判断

高杠杆点和大残差同时出现时，观测往往对回归有较大影响。是否剔除还取决于数据是否有误，以及该观测是否属于研究对象。

强影响点对回归直线的影响



图中两条回归线分别由包含和剔除该观测的样本估计得到，斜率的明显变化表明该点具有较强影响。真实的极端观测可能包含有用信息，判断时需要结合实际背景。

残差正态性的诊断

- 正态性假设针对给定解释变量时的误差分布，主要用于小样本下的精确 t 和 F 检验；
- 残差 Q–Q 图将样本分位数与正态分布分位数比较，偏离参考直线可提示偏态或厚尾；
- Shapiro–Wilk 和 Jarque–Bera 检验可辅助判断，需结合图形和样本量解释；
- OLS 系数无偏不要求误差正态，也不要求解释变量服从正态分布。

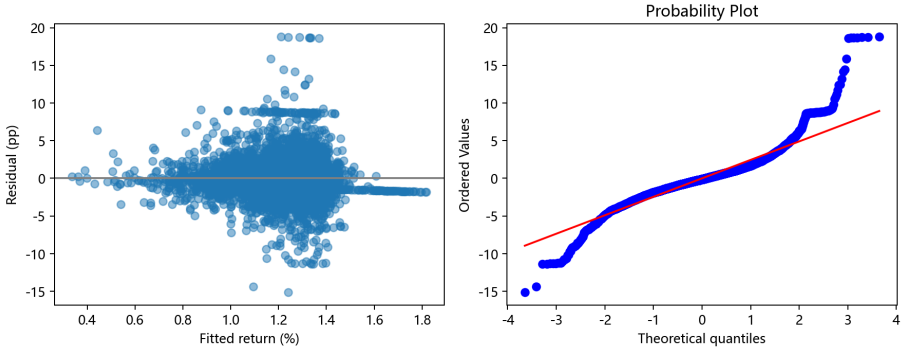
诊断对象

回归诊断考察模型的残差。解释变量的直方图描述该变量自身的分布，不能代替残差诊断。

Python 示例：残差图与影响点诊断

```
fig, axes = plt.subplots(1, 2, figsize=(10, 4))
axes[0].scatter(model.fittedvalues, model.resid, alpha=0.5)
axes[0].axhline(0, color="gray")
axes[0].set(xlabel="Fitted return (%)", ylabel="Residual (pp)")
stats.probplot(model.resid, dist="norm", plot=axes[1])
plt.tight_layout()
influence = model.get_influence()
diag = influence.summary_frame()[
    ["standard_resid", "hat_diag", "cooks_d", "dffits"]
]
print(diag.sort_values("cooks_d", ascending=False).head())
```

案例结果：多元回归的残差图



左图考察残差的离散程度是否随拟合值变化；右图比较残差分布与正态分布，尤其关注两端的偏离。残差的单位为百分点，图形判断可与后面的异方差检验结合。

变量变换：以市值为例

公司市值通常右偏：多数股票市值较小，少数股票市值很大。变量变换可以改变取值尺度，使主体分布和相对差异更易观察。

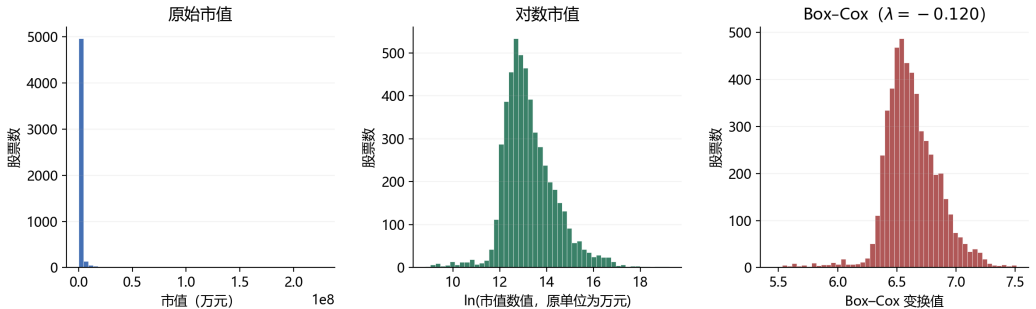
设 $x > 0$ 为以万元计的市值数值，比较以下三种尺度：

$$x, \qquad \log x, \qquad B_\lambda(x) = \begin{cases} (x^\lambda - 1)/\lambda, & \lambda \neq 0, \\ \log x, & \lambda = 0. \end{cases}$$

- 对数变换是 Box–Cox 在 $\lambda = 0$ 时的特例；
- 本例用同一组有效市值数据估计 λ，不缩尾、不标准化；
- 三种尺度均保留股票市值的大小顺序，但改变取值之间的距离。

变量变换：三种市值尺度的分布比较

2024-03-28，5242 只市值为正且有限的股票；三图使用同一组观测，每图分为 50 个等宽区间。



原始尺度中，少数大市值股票使横轴范围很宽；对数和 Box–Cox 变换压缩了较大取值之间的距离，使主体分布更易观察。三图的横轴均为线性刻度，但代表不同的变量尺度。

三种市值尺度的含义

尺度	数值的含义	距离的含义
原始市值 x	单位为万元，直接表示金额	相差 1 表示相差 1 万元
对数市值 $\log x$	以万元计的数值取自然对数	差值为 $\log(x_2/x_1)$，对应市值比率
Box–Cox	由 λ 决定的幂变换尺度	差值不直接对应金额或固定比率，需按变换公式解释

- 对数市值相差 $\log 2$，表示较大市值为较小市值的 2 倍；市值增加 1%，对数市值约增加 0.01；
- 原始市值与变换值的横轴数值不能直接比较，变换值也不是标准化分数；
- 分布更对称不代表回归更好。此处展示尺度变化，收益回归仍使用对数市值。

变量变换与系数解释

- 股票收益率可为负值，不满足 Box–Cox 变换的正值条件；
- 对数收益 $\log(1+r)$ 中，r 以小数表示，且须满足 $r > -1$；
- 因变量变换后，回归解释的是新尺度上的变化，系数单位也随之改变；
- 本例以原始收益率为因变量，用稳健标准误处理异方差对推断的影响。

异方差：检验与后果

异方差指

$$\mathrm{Var}(\varepsilon_i \mid X_i)$$

随 X_i 改变。

- 在零条件均值假设下，OLS 系数仍无偏，但通常不再具有最小方差；
- 通常的标准误公式不再适用，进而影响 t 和 F 检验；
- Breusch–Pagan 检验考察残差平方与解释变量的关系；
- White 检验在辅助回归中加入平方项和交叉项，可检验更一般的异方差。

Python 示例：异方差检验与稳健标准误

```python
from statsmodels.stats.diagnostic import het_breuschpagan

lm, lm_p, fvalue, f_p = het_breuschpagan(
    model.resid, model.model.exog
)
robust = model.get_robustcov_results(
    cov_type="HC3", use_t=True
)
print("Breusch-Pagan p:", lm_p)
print(robust.summary())
```

Breusch–Pagan 检验的原假设为同方差。HC3 是一种异方差稳健标准误，其计算允许误差方差随观测变化，仍以观测之间的误差不相关为前提。

案例结果：普通标准误与 HC3

变量	系数	普通标准误	HC3 标准误	HC3 p
截距	3.023	0.418	0.365	< 0.001
BP	-0.096	0.066	0.051	0.062
对数市值	-0.132	0.031	0.027	< 0.001

Breusch–Pagan 检验的 $p < 0.001$，拒绝同方差假设。HC3 保持系数估计不变，BP 的标准误由 0.066 调整为 0.051，p 值降至 0.062，在 5% 水平下仍不显著。稳健标准误可能增大，也可能减小。

加权最小二乘法

当各观测的误差方差 σ_i^2 不同时，可按其倒数加权，最小化

$$\sum_{i=1}^{n} w_i (y_i - \mathbf{x}_i^\top \beta)^2, \qquad w_i \propto \frac{1}{\sigma_i^2}.$$

解为

$$\hat{\beta}_{WLS} = (X^\top W X)^{-1} X^\top W y.$$

误差方差较小的观测获得较大权重，从而提高估计效率。

WLS 与异方差稳健标准误

- HC3：使用 OLS 估计系数，修正标准误及相应的区间估计和检验；
- WLS：根据误差方差加权拟合，权重设定正确时可提高估计效率；
- 市值加权侧重大市值股票，与按误差方差倒数加权具有不同含义；
- 本例不预设误差方差的具体形式，采用 OLS 估计和 HC3 标准误。

WLS 也可以配合稳健标准误，以减轻权重设定不准确对统计推断的影响。

残差相关与时间序列数据

- Durbin–Watson（DW）统计量用于诊断一阶残差自相关，使用时需满足相应的模型条件；
- Breusch–Godfrey（BG）检验可检验指定阶数以内的序列相关；
- 面板数据还可能存在同一股票内相关和同一期横截面相关；
- 忽略误差之间的相关性会使普通标准误不可靠，但仅改变标准误的计算方法不会改变 OLS 系数。

常见处理方法包括 HAC（Newey–West）标准误、聚类标准误和广义最小二乘法（GLS）。

横截面与时间序列中的误差相关

- 单日股票数据属于横截面，股票代码的排列次序不具有时间含义；
- DW 和 BG 用于有时间顺序的残差，自相关阶数取决于数据频率和模型；
- HC3 适用于异方差；HAC 同时考虑异方差与序列相关；聚类标准误允许组内误差相关；
- 逐日 BP 回归系数组成时间序列，后面将用 HAC 标准误检验其平均值。

多重共线性

多重共线性是解释变量之间存在很强的线性关系：

$$VIF_j = \frac{1}{1 - R_j^2},$$

其中 R_j^2 来自用其他解释变量回归 X_j。

- 多个变量包含相近的信息，难以分别估计各自的作用；
- 系数标准误增大，估计的符号和大小可能对样本变化较敏感；
- VIF 越大，说明该变量与其他解释变量的线性关系越强；
- 可结合专业知识合并或删减变量，也可采用主成分回归、岭回归等方法。

Python 示例：计算方差膨胀因子

```python
from statsmodels.stats.outliers_influence import variance_inflation_factor

X = model.model.exog
vif = pd.Series(
    [variance_inflation_factor(X, j)
     for j in range(X.shape[1])],
    index=model.model.exog_names,
)
print(vif)
```

由模型的设计矩阵计算各列的 VIF。共线性分析关注 BP 和对数市值，通常不解释常数项的 VIF。

案例结果：方差膨胀因子

解释变量	VIF
BP	1.003
对数市值	1.003

BP 和对数市值的 VIF 均接近 1，说明两个解释变量之间的线性关系较弱，本模型没有明显的多重共线性。

回归诊断与模型改进

1. 核查数据：变量单位、日期对应、缺失值和异常记录；
2. 检查模型：残差是否存在曲线趋势，是否需要非线性项或交互项；
3. 修正推断：存在异方差或误差相关时，采用相应的稳健标准误；
4. 改进估计：误差方差结构明确时，可采用加权最小二乘法；
5. 检查稳定性：比较不同样本期及强影响点处理前后的系数。

回归诊断的目的，是判断模型能否充分描述数据，以及区间估计和检验是否可信。

回归练习：逐日横截面回归

独立完成数据整理、逐日估计与结果分析

从单日回归到逐日回归

控制公司规模后，BP 与次日收益的关系是否随日期变化?

- 将前面的单日回归扩展到 2024 年第一季度，每个交易日估计一个模型；
- 每日以股票为观测单位，以当日 BP 和对数市值解释次日收益；
- 将逐日的系数、检验结果和样本量按日期排列，分析关系的方向与稳定性；
- 最后检验平均 BP 系数是否显著异于零。

将每日回归结果汇总成表，并绘制样本量、BP 系数和 t 值随日期变化的折线图，比较不同日期的估计结果。

第一步：读取并对齐季度数据

1. 读取 2024-01-01 至 2024-03-31 的沪深股票数据，字段为 PB、总市值、收盘价和复权因子；
2. 将日期按先后排序，检查重复日期和重复股票代码；
3. 以收盘价数据的完整交易日序列为基准，按日期和股票代码对齐四个字段；
4. 保留缺失值，后续按各日回归所需变量筛选有效股票。

用表格列出各字段的日期范围、交易日数、股票数和缺失值比例，检查是否存在日期或股票代码无法匹配的情况。

第二步：构造 BP、规模与次日收益

设 $P^*_{i,t}$ 为收盘价乘以复权因子，$MV_{i,t}$ 为总市值：

$$BP_{i,t} = \frac{1}{PB_{i,t}}, \qquad Size_{i,t} = \log MV_{i,t}, \qquad r_{i,t+1} = 100\left(\frac{P^*_{i,t+1}}{P^*_{i,t}} - 1\right).$$

- $t+1$ 指完整交易日序列中的下一个交易日，不是下一个自然日；
- BP 和规模取 t 日的值，收益由 t 日至 $t+1$ 日的价格计算；
- 收益率以百分比表示；区间最后一个交易日没有后续价格，不参与回归。

选取几只股票，将相邻交易日的价格、BP、规模和次日收益列成表。手工计算其中一条收益率，核对数值及对应日期。

第三步：整理逐日回归样本

1. 将数据整理为长表，每行对应“一只股票在一个交易日”的观测；
2. 保留因子日期、收益日期、股票代码、BP、对数市值和次日收益六列；
3. 每日保留 BP 为正、市值和两日价格为正，且回归变量均为有限值的股票；
4. 本练习使用原始 BP，暂不缩尾或标准化，也不按行业筛选。

检查长表的前几行，并统计各日有效股票数 n_t。本练习仅对至少有 30 只有效股票、且设计矩阵满列秩的日期进行估计；其余日期记录原因。

第四步：逐日估计同一个回归模型

对每个有效交易日，分别估计含截距的等权 OLS 回归：

$$r_{i,t+1} = \alpha_t + \beta_t BP_{i,t} + \gamma_t \log MV_{i,t} + \varepsilon_{i,t+1}.$$

1. 取出当天的有效股票，按上式估计截距、BP 系数和规模系数；
2. 用 HC3 异方差稳健标准误，计算 BP 系数的 t 值、p 值和 95% 置信区间；
3. 对其他日期重复相同步骤，保持变量定义、模型形式和标准误方法一致。

先估计 2024-03-28 的模型，与前面单日案例核对，再逐日估计。β_t 表示控制规模后，BP 每增加 1，次日平均收益改变多少个百分点。

第五步：保存逐日结果并绘制样本量图

将各日估计结果整理成一张表，每行对应一个有效回归日期：

类别	记录内容
日期与样本	因子日期、收益日期、有效股票数 n_t
系数估计	截距 $\hat{\alpha}_t$、BP 系数 $\hat{\beta}_t$、规模系数 $\hat{\gamma}_t$
BP 系数推断	HC3 标准误、t 值、p 值、95% 置信区间
拟合程度	R_t^2

每日有效样本量

以因子日期为横轴、n_t 为纵轴绘制折线图。若样本量明显下降，检查当日哪些变量缺失，以及哪些筛选条件使股票被排除。

第六步：绘制系数与显著性的时间序列

BP 系数及置信区间

以因子日期为横轴、$\hat{\beta}_t$（百分点）为纵轴绘制折线图，标出 95% HC3 置信区间和零参考线，观察系数的正负、波动大小及估计精度。

BP 系数的 t 值

以因子日期为横轴、HC3 t 值为纵轴绘制折线图，标出 0、$+2$、-2 参考线。± 2 便于观察显著性的大致变化，具体判断仍以 p 值为准。

- 比较系数的正负变化，统计显著的日期是否集中在某一时段；
- 系数波动较大的日期，可结合样本量图检查股票样本是否发生明显变化。

第七步：汇总并检验平均 BP 系数

设共有 T 个有效回归日期，计算

$$\overline{\beta} = \frac{1}{T}\sum_{t=1}^{T}\hat{\beta}_t, \qquad H_0 : \mathbb{E}(\hat{\beta}_t) = 0.$$

1. 汇总系数均值、标准差、正值比例，以及 $|t_t|$ 的均值和 $p_t < 0.05$ 的日期比例；
2. 将按日期排序的 BP 系数作为因变量，估计只有截距的回归；截距估计值即为平均系数；
3. 使用滞后 5 个交易日的 HAC 标准误，给出均值检验的 t 值、p 值和 95% 置信区间。

将有效日期数、汇总统计量和 HAC 均值检验结果列成表。逐日检验考察各日的 BP 系数，均值检验考察样本期内的平均关系。

回归结果的整理与分析

- 保存整理后的股票数据，说明日期范围、变量定义和有效样本的筛选条件；
- 汇总逐日回归结果，列出系数统计量与 HAC 均值检验结果；
- 绘制每日样本量、BP 系数及置信区间、BP 系数 t 值的折线图。

结果分析

结合系数均值和时间序列图，说明控制规模后 BP 与次日收益的关系及其随时间的变化。根据 HAC 检验判断平均系数是否显著异于零，并讨论样本期和数据范围对结论的限制。

平均系数不显著，表示当前样本不足以支持非零的平均关系；收益预测能力还需在新的样本期检验。

数据中性化

组内去均值与回归残差化

行业内去均值

不同行业的 BP 水平可能不同。若希望比较一只股票相对于同行的位置，可减去所在行业的平均 BP：

$$BP_i^{\text{demean}} = BP_i - \overline{BP}_{g(i)}.$$

- $g(i)$ 表示股票 i 所属的行业，均值在同一天、同一行业内计算；
- 正值表示高于同行平均水平，负值表示低于同行平均水平；
- 处理后，每个行业的均值为零，但行业之间的波动大小仍可能不同；
- 这里只消除了行业均值差异，没有控制公司规模。

Python 示例：匹配行业信息

```
print("平均系数、HAC标准误、p: ", mean_fit.params.iloc[0],
      mean_fit.bse.iloc[0], mean_fit.pvalues.iloc[0])

# %% 行业中性化的数据准备：直接复用 utils
from utils.utils import _get_industries, industry_neutral

industry = _get_industries("l1_name", date)["l1_name"].rename("industry")
factor_cross = bp.to_frame().join(industry)
factor_cross = factor_cross.replace([np.inf, -np.inf], np.nan)
factor_cross = factor_cross.loc[factor_cross.bp > 0]
```

按日期匹配股票所属行业，将 BP 整理为“日期 × 股票”的表。行业内去均值使用 BP 和行业信息，缺失行业的股票不参与计算。

Python 示例：行业内去均值

```
bp_matrix = pd.DataFrame([industry_cross.bp], index=[pd.Timestamp(date)])
neutralizer = industry_neutral("l1_name")
```

- `standardize=False` 表示只减去同行均值，不除以标准差；
- `iloc[0]` 取出单日的去均值结果；
- 去均值后，各行业 BP 的平均值在计算精度内为零。

组内去均值与类别虚拟变量

若只控制一个类别变量，并在模型中包含截距：

$$f_i = \alpha + \sum_{g=2}^{G} \gamma_g D_{ig} + u_i,$$

则残差等于观测值减去所属组均值：

$$\hat{u}_i = f_i - \bar{f}_{g(i)}.$$

因此，只控制类别变量时，回归取残差等价于“组内去均值”。若还需加入连续变量、交互项或采用加权估计，则应建立相应的回归模型。

行业内标准化

在去均值的基础上，再除以所在行业当天的标准差：

$$BP_i^{\text{industry z}} = \frac{BP_i - \overline{BP}_{g(i)}}{s_{g(i)}}.$$

- 数值表示该股票的 BP 高于或低于同行均值多少个标准差；
- 行业内有波动时，处理后的行业均值为零、标准差为一；
- 此处标准差采用 `ddof=0`；标准差为零的行业，处理结果记为零；
- 行业内标准化统一了各行业的尺度，但尚未控制公司规模。

Python 示例：行业内标准化

```
industry_cross["bp_demean"] = neutralizer(bp_matrix, standardize=False).iloc[0]
print(industry_cross.groupby("industry")["bp_demean"].mean())
```

`standardize=True` 表示在去均值后除以行业内标准差。去均值和标准化均以原始 BP 为基础，分别得到两种处理结果。

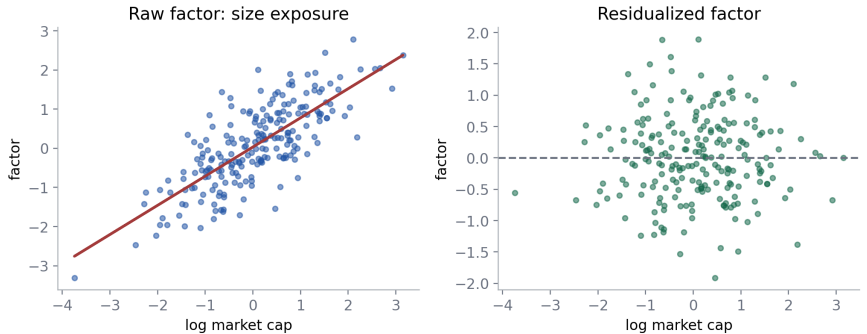
回归中性化

设待处理的因子为 f，行业、规模等控制变量组成矩阵 Z：

$$f = Z\gamma + u, \qquad f^{\text{neutral}} = \hat{u} = f - Z\hat{\gamma}.$$

- Z 可包含行业虚拟变量、对数市值等；
- 残差是原始因子中无法由这些控制变量线性解释的部分；
- 在同一拟合样本内，残差与 Z 的列空间正交；
- 中性化结果取决于控制变量、函数形式、权重和时间截面。

中性化前后



模拟数据中，原始因子与对数市值存在明显的线性关系。取回归残差后，两者在拟合样本中的线性相关为零，这是最小二乘正交性的结果。

Python 示例：行业与规模中性化

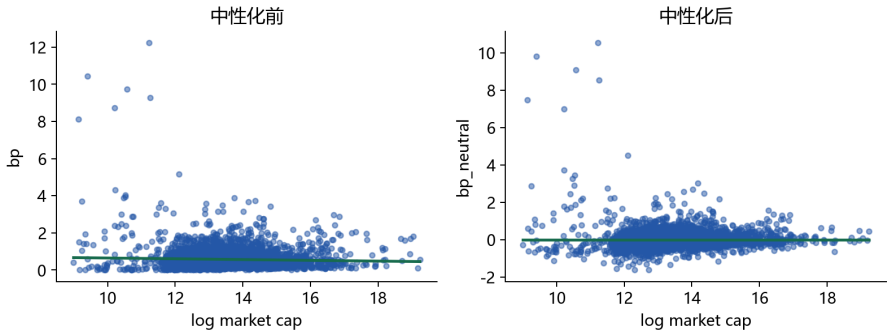
```
print(industry_cross.groupby("industry")["bp_industry_z"].agg(
    ["mean", lambda x: x.std(ddof=0)]))

# %% 加入市值：不按次日收益是否缺失筛选中性化样本
neutral_cross = industry_cross.join(log_mv).dropna(subset=["log_mv"]).copy()

# %% TODO 9c：单日行业与规模回归中性化
```

在 BP、行业和市值完整的样本上，将原始 BP 对行业虚拟变量和对数市值回归，所得残差即为行业与规模中性化后的 BP。

案例结果：行业与规模中性化



在 5195 只行业信息完整的股票中，中性化前后 BP 与对数市值的样本相关系数由 -0.044 降至约 0。残差满足最小二乘的正交性质；中性化后的收益预测能力仍需另行检验。

中性化结果的解释

- 中性化剔除控制变量能够线性解释的部分，非线性关系和交互作用仍可能保留；
- 某些行业或类别的样本过少，会使估计不稳定；
- 过度中性化可能删除因子本来希望捕捉的经济信息；
- 残差与控制变量的样本线性相关为零，不等于统计独立；
- 中性化后的因子可从分布、与控制变量的相关性及收益预测表现等方面评价。

中性化与控制变量回归的联系

在同一样本和同一组控制变量 Z 下，分别将 y 与 BP 对 Z 回归，得到残差 $\tilde{y}$ 与 $\widetilde{BP}$：

$$\hat{\beta}_{BP} = \frac{\widetilde{BP}^{\top}\tilde{y}}{\widetilde{BP}^{\top}\widetilde{BP}}.$$

- 它等于完整回归中 BP 的 OLS 系数：控制变量后的关系可用残差之间的关系理解；
- 两种计算必须使用相同的样本、控制变量和权重；
- 对残差再次缩尾、标准化或改变样本后，应重新解释系数与标准误。

BP 因子的 IC 评价

用横截面相关系数评价因子

BP 因子的分析流程



将当日 BP 与下一交易日收益按股票代码对齐，分别进行回归和相关分析。原始 BP 与中性化 BP 可分别评价，以观察行业和规模对结果的影响。

方差分析、回归、中性化与 IC

- Part 2：同日的行业平均 PB 是否不同？
- 前面的回归练习：控制市值后，BP 与下一日收益有何关系？
- 中性化：从 BP 中减去行业和规模能线性解释的部分。
- IC：当日因子高低是否对应下一日收益高低？

本例的分析对象

回归和 IC 分析使用原始 BP；中性化分析考察行业、规模与 BP 的关系。中性化后的预测能力需另行评价。

IC 与 Rank IC

因子 IC 衡量同一批股票的 t 期因子值与 $t+1$ 期收益之间的相关程度：

$$IC_t = \mathrm{corr}(f_t, r_{t+1}).$$

- **普通 IC**：通常使用 Pearson 相关系数；
- **Rank IC**：通常使用 Spearman 秩相关系数；
- 普通 IC 刻画线性关联，Rank IC 刻画单调关联，对极端值通常较不敏感；
- 每个日期均使用因子值和下一期收益同时有效的股票计算。

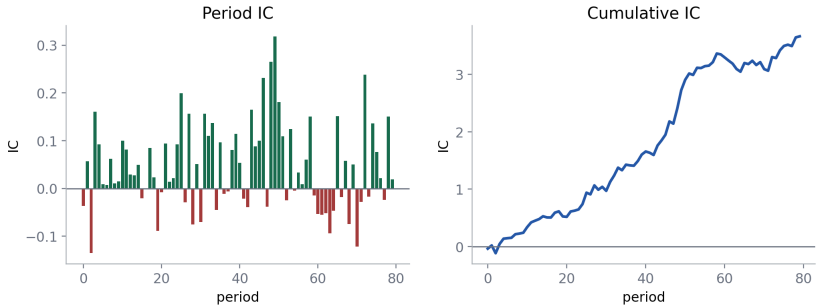
Python 示例：逐日计算 IC 与 Rank IC

```
print(neutral_cross[["bp", "bp_neutral", "log_mv"]].corr())
print(neutral_cross.groupby("industry")["bp_neutral"].mean())

# %% TODO 10: IC 与 Rank IC；不额外要求市值完整
rows = {}
for day, g in panel.groupby("trade_date"):
```

IC 的有效样本由 BP 和次日收益共同确定，因此样本量可能与需要市值数据的多元回归不同。

IC 序列的评价



图为模拟 IC 序列。均值反映总体相关方向，标准差反映日间波动，ICIR $\overline{IC}/s(IC)$ 衡量均值相对于波动的大小。累计 IC 用于观察相关性的累积方向，与累计收益含义不同。

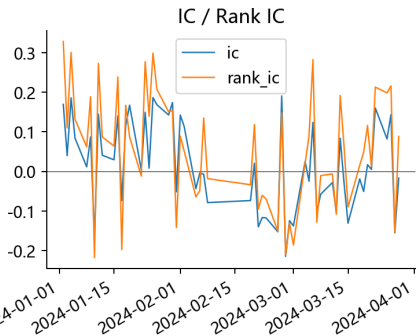
Python 示例：汇总与绘制 IC 序列

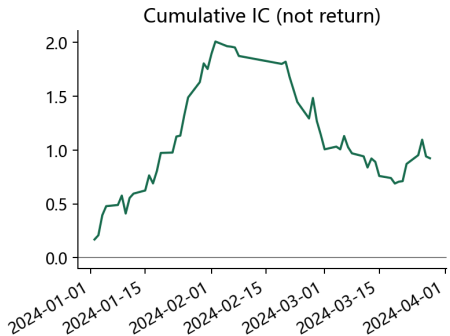
```
                "rank_ic": g.bp.corr(g.return_next, method="spearman")}
ic = pd.DataFrame.from_dict(rows, orient="index").sort_index()

# %% TODO 11：汇总与绘图
valid_ic = ic.ic.dropna()
summary = pd.Series({"mean_ic": valid_ic.mean(), "std_ic": valid_ic.std(ddof=1),
                     "positive_rate": valid_ic.gt(0).mean(),
                     "ic_ir": valid_ic.mean() / valid_ic.std(ddof=1)})
print(summary)
```

ICIR 为均值除以标准差，此处未年化；累计 IC 不是累计收益率。

案例结果：逐日 IC 与累计 IC





共 57 个有效交易日；平均 IC 为 0.016，标准差 0.112，正值比例 54.4%，ICIR=0.145。累计 IC 是相关系数的累加，不是投资组合累计收益。

案例分析的主要结论

- 单日回归：控制规模后，BP 系数为 -0.096；按 5% 显著性水平，普通和 HC3 检验均未拒绝系数为零的假设；
- 回归诊断：存在异方差，采用 HC3 后标准误和检验结果有所变化；
- 跨期结果：57 日平均 BP 系数为 0.073，HAC 检验的 p 值为 0.505，平均关系不显著；
- 相关分析：平均 IC 为 0.016，日间波动较大，BP 与次日收益的关系较弱。

案例结论限于当前样本期。将分析用于收益预测时，还需核实财务信息的可得日期、退市股票覆盖情况，并在新的样本期检验。

本节小结

- 回归描述因变量的条件均值，不能仅凭系数判断因果关系；
- OLS 最小化残差平方和，区间估计和假设检验以相应的模型假设为基础；
- R^2 衡量拟合优度，F 检验考察整体解释作用，t 检验考察单个系数；
- 诊断时应区分模型设定、异方差、观测相关、强影响点和共线性问题；
- 稳健标准误修正区间估计和检验；WLS 按误差方差的倒数加权估计系数；
- 回归中性化利用残差剔除线性关系；IC 和 Rank IC 分别衡量线性与单调关联；
- 逐日分析揭示关系的时间变化，样本外检验用于评价预测的稳定性。

课后练习：盈利市值比与股票收益

盈利市值比 $EP = 1/PE(TTM)$，其中 TTM 表示最近十二个月。参照 BP 案例，分析 EP 与下一交易日收益的关系：

1. 读取 `pe_ttm`，计算 EP，整理有效样本并说明取值范围；
2. 估计 EP 的一元回归和加入对数市值的多元回归，解释回归系数；
3. 绘制残差图，检查异方差和强影响点，比较普通与 HC3 标准误；
4. 在 BP 与 EP 的共同有效样本上，比较回归结果、逐日 IC 与 Rank IC；
5. 考察缩尾或行业与规模中性化后，EP 与收益的关系有何变化。

提交代码、结果图表及简要分析。分析应结合系数大小、估计精度和统计检验，说明结果的实际含义。