第三章：数据处理及分析

Part 3：回归分析

Lianghai Xiao

https://github.com/styluck/mlb

本章结构

Part 1 描述性统计、分布估计与数据标准化

Part 2 方差分析

Part 3 回归分析

回归分析：研究变量之间的数量关系。

学习目标

- 建立一元与多元线性回归模型，并解释回归系数；
- 理解最小二乘、平方和分解、R^2、F 检验和 t 检验；
- 理解线性回归的基本假设及其对估计和检验的影响；
- 通过残差图和统计检验进行回归诊断；
- 区分稳健标准误、加权最小二乘与变量变换的作用；
- 掌握回归中性化，并用回归系数评价 BP 因子。

案例：账面市值比与股票收益

股票的账面市值比与下一交易日收益是否存在关系？

$$BP = \frac{1}{PB} = \frac{\text{公司净资产}}{\text{公司总市值}}.$$

- 在净资产为正时，BP 越高，每元市值对应的账面净资产越多；
- BP 较高的股票，下一交易日的平均收益是否也较高？
- 考虑公司规模后，这种关系是否仍然存在？

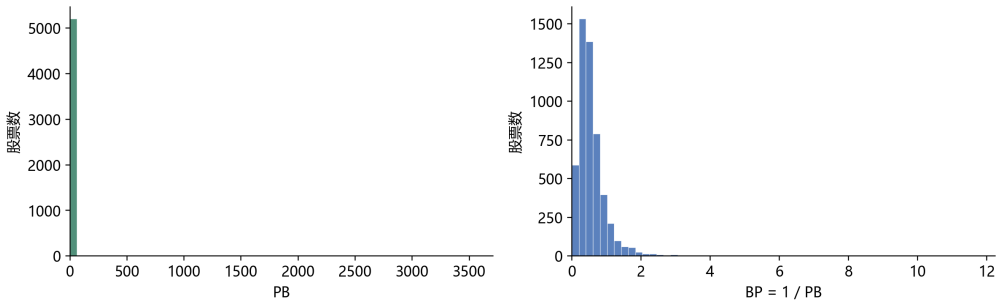
上一节用方差分析比较各行业的平均 PB，本节研究估值指标与后续收益之间的数量关系。

从行业比较到回归分析

- **方差分析**：按行业分组，比较各组的平均水平；
- **一元回归**：研究 BP 变化时，下一交易日收益的平均水平如何变化；
- **多元回归**：同时考虑 BP 与公司规模，分析控制规模后 BP 与收益的关系。

同一交易日的 PB 与 BP 分布

2024-03-28，沪深市场 5,226 只有效股票的 PB 与 BP 分布。



倒数变换压缩较大的 PB；接近零的 PB 则对应较大的 BP。

线性回归模型

回归方程、回归系数与残差

一元线性回归

一元线性回归用一个解释变量 X 描述因变量 Y 的平均变化规律：

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i.$$

β_0 截距。在零条件均值假设下，表示 $X = 0$ 时 Y 的平均水平；

β_1 斜率。X 每增加一个单位，Y 的平均水平改变 β_1 个单位；

ε_i 未被 X 解释的个体差异与随机误差。

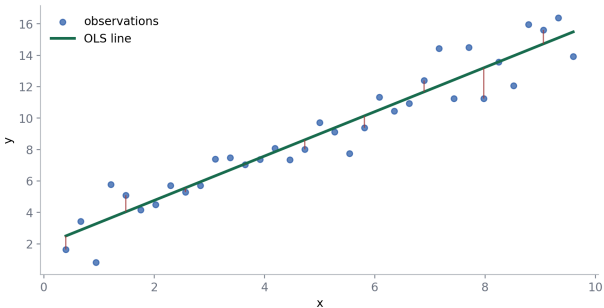
这里的“线性”指对参数线性，加入 X^2 等项仍属于线性模型。

观测值、拟合值与残差

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i,$$
$$e_i = Y_i - \hat{Y}_i.$$

残差是观测值与拟合值之差，即图中沿**纵轴方向的差值**。

残差是不可观测误差 ε_i 的样本估计。



回归分析的用途

描述关系 分析在给定解释变量时，Y 的平均水平如何变化；

预测 根据解释变量的取值估计新观测的因变量；

因果 分析改变 X 对 Y 的影响，需要研究设计和相应的识别假设。

最小二乘估计与统计推断

参数估计、拟合优度与假设检验

最小二乘法

选择截距和斜率，使观测值与拟合值之间的残差平方和最小：

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg\min_{\beta_0,\beta_1} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2 .$$

- 每个残差都先平方，正负残差不会相互抵消；
- 残差越大的观测，对目标函数的影响越大。

Python 示例：导入程序包

```python
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm
import statsmodels.formula.api as smf
from scipy import stats
from statsmodels.stats.diagnostic import het_breuschpagan
from statsmodels.stats.outliers_influence import variance_inflation_factor
from data_io.io_framework import load_data
```

Python 示例：读取单日数据

```
date, next_date = "2024-03-28", "2024-03-29"
pb = load_data("pb", date, date).loc[date]
bp = (1 / pb).rename("bp")
close = load_data("close", date, next_date)
adj = load_data("adj_factor", date, next_date)
price = close * adj
return_next = (100 * (price.loc[next_date] / price.loc[date] - 1)).rename("return_next")
```

以 2024-03-28 的 BP 为解释变量，以 2024-03-29 的收益率为因变量。收益率的单位为百分比。

Python 示例：整理回归样本

```
single = pd.concat([bp, return_next], axis=1)
single = single.replace([np.inf, -np.inf], np.nan)
simple_cross = single.loc[single.bp > 0].dropna().copy()
```

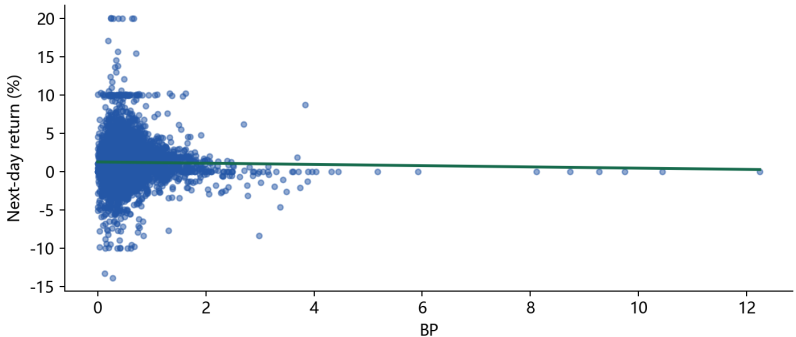
每行对应一只股票。样本包含 BP 为正、BP 与次日收益均无缺失的股票，解释变量采用原始 BP。

Python 示例：一元回归估计

```
simple = smf.ols("return_next ~ bp", data=simple_cross).fit()
print(simple.summary())
```

斜率表示 BP 每增加 1，预测次日收益改变多少个百分点。

BP 与下一交易日收益



5226 只股票的一元回归斜率为 -0.081，即 BP 每增加 1，拟合的次日收益下降 0.081 个百分点。散点较为分散，BP 对单日收益的解释程度较低。

多元线性回归

$$Y_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_k X_{ik} + \varepsilon_i.$$

- β_j 是在**其他解释变量保持不变**时，X_j 增加一个单位对应的条件均值变化；
- 类别变量可通过虚拟变量进入模型；
- 加入交互项，可以描述一个变量的斜率如何随另一个变量变化；
- 加入 X^2、$\log X$ 等项可以描述曲线关系，模型对参数仍然是线性的。

矩阵形式

对 n 个观测、k 个解释变量：

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

其中 $\mathbf{X}$ 通常包含一列常数，因此共有 $k+1$ 个参数。

- $\mathbf{y} \in \mathbb{R}^n$；
- $\mathbf{X} \in \mathbb{R}^{n \times (k+1)}$；
- $\boldsymbol{\beta} \in \mathbb{R}^{k+1}$；
- $\boldsymbol{\varepsilon} \in \mathbb{R}^n$。

多元回归的最小二乘解

多元回归同样使残差平方和最小：

$$\hat{\boldsymbol{\beta}} = \arg\min_{\boldsymbol{\beta}} \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2.$$

若设计矩阵满列秩，则

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Python 示例：构造规模变量

```
mv = load_data("total_mv", date, date).loc[date]
log_mv = np.log(mv.where(mv > 0)).rename("log_mv")
cross = simple_cross.join(log_mv).dropna().copy()
```

用总市值的自然对数衡量公司规模。比较一元与多元回归时，均使用 BP、收益和市值完整的股票。

Python 示例：多元回归估计

```
model = smf.ols("return_next ~ bp + log_mv", data=cross).fit()
# 市值缺失可能改变样本；比较系数时另拟合一个同样本的一元模型。
simple_same = smf.ols("return_next ~ bp", data=cross).fit()
print("一元、多元样本数：", len(simple_cross), len(cross))
print("同样本 BP 系数：", simple_same.params.bp, model.params.bp)
```

在同一样本上分别估计一元和多元回归，比较加入规模变量前后的 BP 系数。

案例数据：单日回归的样本与变量

因子日期：2024-03-28；收益日期：2024-03-29；有效股票数：5226。

样本范围	股票数
BP、收益与市值均有效的股票	5226

- `bp`：原始账面市值比；
- `log_mv`：当日总市值的自然对数；
- `return_next`：下一交易日复权收盘收益，单位为百分比。

多元回归系数的含义

$$r_{i,t+1} = \beta_0 + \beta_1 BP_{i,t} + \beta_2 \log MV_{i,t} + \varepsilon_i.$$

- β_1：市值相同时，BP 增加 1，对应收益改变 β_1 个百分点；
- β_2：BP 相同时，市值增加 1%，对应收益约改变 $0.01\beta_2$ 个百分点；

OLS 的几何解释

正规方程为

$$\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = 0,$$

即

$$\mathbf{X}^\top \mathbf{e} = 0.$$

- 残差向量与每一列解释变量正交；
- 含截距时，残差和为零；
- 拟合值是 $\mathbf{y}$ 在 $\mathbf{X}$ 列空间上的投影，残差与该空间正交。

为什么拟合值是正交投影?

当 $\mathbf{X}$ 满列秩时，OLS 系数为

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

将它代入拟合值 $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$:

$$\hat{\mathbf{y}} = \underbrace{\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top}_{\mathbf{H}} \mathbf{y} = \mathbf{H}\mathbf{y}.$$

- $\mathbf{H}$ 是投影到 $\mathbf{X}$ 列空间的**正交投影矩阵**;
- 列空间就是 $\mathbf{X}$ 各列的所有线性组合。

平方和分解

含截距的回归中：

$$SST = SSR + SSE,$$

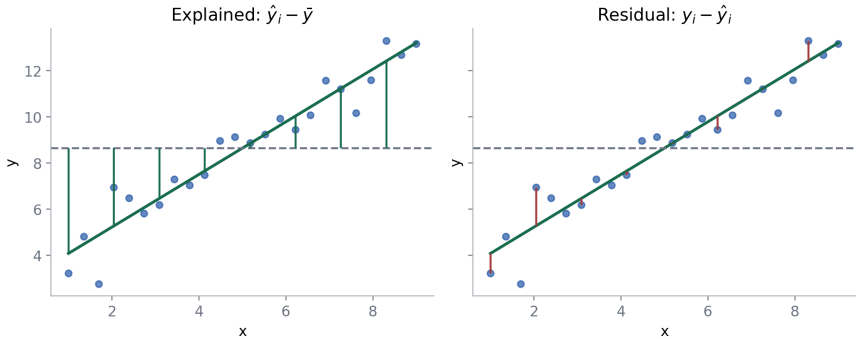
$$SST = \sum_i (y_i - \bar{y})^2,$$

$$SSR = \sum_i (\hat{y}_i - \bar{y})^2,$$

$$SSE = \sum_i (y_i - \hat{y}_i)^2.$$

回归解释的变异与残差变异共同构成总变异。

解释变异与残差变异



对每个观测，都有 $y_i - \bar{y} = (\hat{y}_i - \bar{y}) + (y_i - \hat{y}_i)$。含截距的 OLS 中，拟合值与残差正交，总平方和因此可分解为回归平方和与残差平方和。

判定系数 R^2

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}.$$

- 含截距且因变量有变异时，$0 \leq R^2 \leq 1$；
- 加入解释变量不会降低样本内 R^2；
- R^2 越大，模型解释的样本内因变量变异越多。

调整后的 R^2

$$\bar{R}^2 = 1 - (1 - R^2)\frac{n-1}{n-k-1}.$$

- 根据样本量和解释变量个数，对 R^2 作出调整；
- 新增变量若不能明显改善拟合，调整后的 R^2 可能下降。

整体 F 检验

对含 k 个斜率的模型，检验

$$H_0 : \beta_1 = \cdots = \beta_k = 0, \qquad H_1 : \text{至少一个斜率不为零.}$$

$$F = \frac{SSR/k}{SSE/(n-k-1)}.$$

在经典正态线性模型下，H_0 成立时 $F \sim F(k, n-k-1)$。$p < 0.05$ 时，在 5% 水平拒绝所有斜率同时为零。

单个系数的 t 检验

检验第 j 个系数：

$$H_0 : \beta_j = \beta_{j,0}, \qquad t = \frac{\hat{\beta}_j - \beta_{j,0}}{SE(\hat{\beta}_j)}.$$

- 标准误越大，系数估计越不精确；
- 检验系数是否为零时，取 $\beta_{j,0} = 0$；
- 在经典正态线性模型下，H_0 成立时 $t \sim t_{n-k-1}$。

Python 示例：查看估计与检验结果

```
print(model.summary2().tables[1])
print("R2:", model.rsquared)
print("Adjusted R2:", model.rsquared_adj)
print("F, p:", model.fvalue, model.f_pvalue)
```

输出系数、标准误、t 值、p 值、置信区间及模型拟合指标。

控制规模后的回归系数

变量	系数	标准误	t	p	95% 区间
截距	3.023	0.418	7.226	< 0.001	[2.203, 3.843]
BP	-0.096	0.066	-1.453	0.146	[-0.225, 0.033]
对数市值	-0.132	0.031	-4.239	< 0.001	[-0.193, -0.071]

控制规模后，BP 系数为 -0.096，$p = 0.146$，不显著；对数市值系数为负且显著。

整体检验与单个系数检验

指标	结果
R^2	0.004
调整 R^2	0.003
整体 $F(2, 5223)$	9.742
整体 p	< 0.001
BP 系数的 p	0.146

整体显著与单个变量显著

整体检验拒绝 BP 和市值的系数同时为零，但 BP 的单个系数检验不显著。模型仅解释约 0.4% 的收益变异：统计显著性与拟合程度是两个不同的方面。

回归诊断与修正

线性回归的基本假设

1. **模型设定**：模型能够正确描述因变量的条件均值；
2. **零条件均值**：$\mathbb{E}(\varepsilon \mid X) = 0$；
3. **无完全共线性**：设计矩阵满列秩；
4. **同方差性**：$\mathrm{Var}(\varepsilon \mid X) = \sigma^2$；
5. **误差不相关**：不同观测的误差之间不相关；
6. **正态性**：误差服从正态分布时，可在小样本下进行精确的 t 和 F 检验。

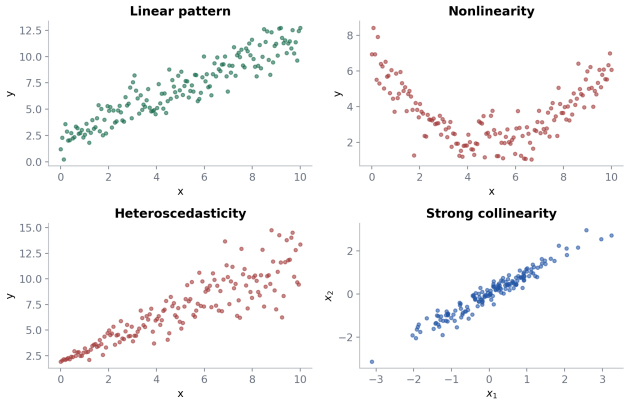
零条件均值和满列秩保证 OLS 无偏；再满足同方差、误差不相关时，OLS 是最佳线性无偏估计。

回归诊断的主要内容

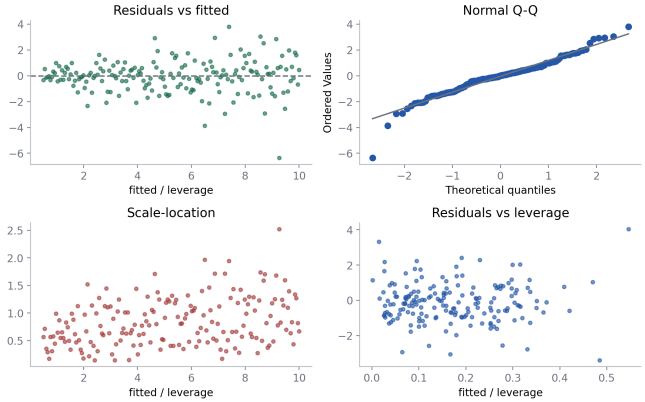
检查模型是否合适、估计与检验是否可靠，为模型改进提供依据。

1. 回归方程是否遗漏曲线趋势或重要变量；
2. 误差是否存在非正态、异方差或相关性；
3. 少数观测或解释变量之间的高度相关是否影响估计。

回归中的常见数据特征与问题



常用诊断图



残差–拟合值图用于识别曲线趋势和异方差；Q–Q 图用于考察正态性；尺度–位置图显示残差的离散程度；残差–杠杆图用于识别强影响点。

函数形式的检查与调整

观察残差是否围绕零随机分布，重点寻找系统的曲线或分组趋势。

- 残差呈 U 形或倒 U 形：考虑加入平方项等非线性项；
- 不同组别呈现不同趋势：考虑组别虚拟变量或交互项；
- 因变量与解释变量的关系更接近相对变化：可考虑对数等变量变换。

变量变换：以市值为例

公司市值通常右偏。对数和 Box–Cox 变换可以压缩大市值，使主体分布更易观察。

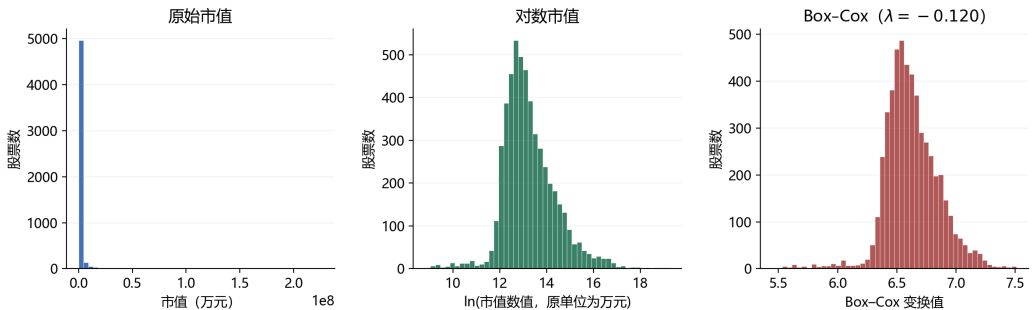
设 $x > 0$ 为以万元计的市值数值，比较以下三种尺度：

$$x, \qquad \log x, \qquad B_\lambda(x) = \begin{cases} (x^\lambda - 1)/\lambda, & \lambda \neq 0, \\ \log x, & \lambda = 0. \end{cases}$$

- 对数变换是 Box–Cox 在 $\lambda = 0$ 时的特例；
- 三种尺度保留大小顺序，改变取值之间的距离。

变量变换：三种市值尺度的分布比较

2024-03-28，5242 只股票；三图使用同一组市值数据。



原始市值右尾很长；对数和 Box–Cox 变换后，主体分布更集中。

三种市值尺度的含义

尺度	数值的含义	距离的含义
原始市值 x	单位为万元，直接表示金额	相差 1 表示相差 1 万元
对数市值 $\log x$	以万元计的数值取自然对数	差值为 $\log(x_2/x_1)$，对应市值比率
Box–Cox	由 λ 决定的幂变换尺度	差值不直接对应金额或固定比率，需按变换公式解释

- 对数市值相差 $\log 2$，表示较大市值为较小市值的 2 倍；
- 市值增加 1%，对数市值约增加 0.01。

变量变换与系数解释

- 解释变量取对数：市值增加 1%，收益率约改变 0.01β 个百分点；
- 因变量变换后，系数描述变换后尺度上的平均变化；
- 对数收益为 $\log(1+r)$，其中 $r > -1$，收益率以小数表示。

残差正态性的诊断

检查误差分布是否接近正态，为 t、F 检验提供依据，尤其是在小样本中。

- 用残差 Q–Q 图观察：点越接近直线，与正态分布越相符；
- 尾部明显偏离参考线，提示偏态或厚尾；
- 若偏离明显，先检查异常观测和模型设定。

异常值、高杠杆点与强影响点

异常值 观测值明显偏离拟合值，残差较大；

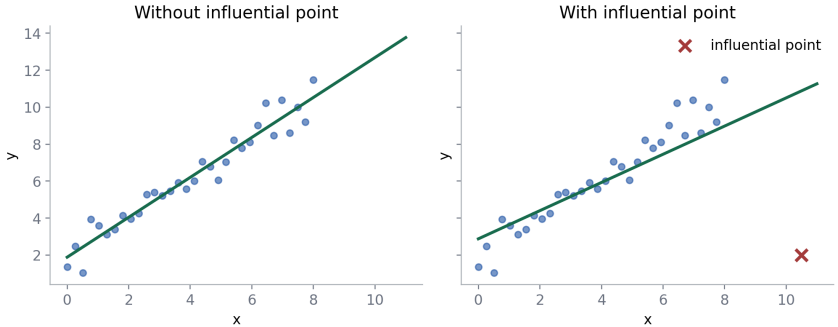
高杠杆点 从解释变量的取值看，该观测远离样本中心；

强影响点 删除该观测会明显改变拟合结果。

常用诊断包括学生化残差、杠杆值、Cook 距离与 DFFITS。

高杠杆值与大残差同时出现时，重点检查该观测的 Cook 距离。

强影响点对回归直线的影响

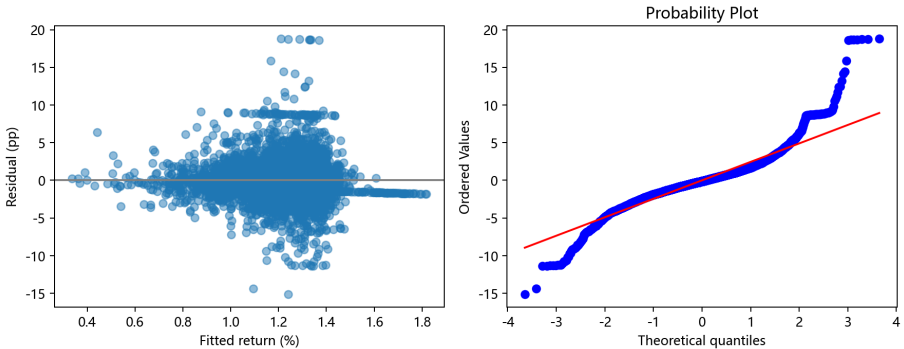


剔除该观测后，回归直线的斜率明显改变，表明它对拟合结果有较强影响。

Python 示例：残差图与影响点诊断

```
fig, axes = plt.subplots(1, 2, figsize=(10, 4))
axes[0].scatter(model.fittedvalues, model.resid, alpha=0.5)
axes[0].axhline(0, color="gray")
axes[0].set(xlabel="Fitted return (%)", ylabel="Residual (pp)")
stats.probplot(model.resid, dist="norm", plot=axes[1])
plt.tight_layout()
influence = model.get_influence()
diag = influence.summary_frame()[
    ["standard_resid", "hat_diag", "cooks_d", "dffits"]
]
print(diag.sort_values("cooks_d", ascending=False).head())
```

多元回归的残差图



左图提示异方差；右图尾部明显偏离正态参考线。

异方差：检验与后果

异方差指误差的条件方差随解释变量改变：

$$\mathrm{Var}(\varepsilon_i \mid \mathbf{X}) = \sigma_i^2.$$

- 异方差会使常规标准误不准确，影响置信区间及显著性检验；
- Breusch–Pagan 检验：H_0 为同方差，$p < 0.05$ 时在 5% 水平拒绝同方差；
- HC3 稳健标准误：保持 OLS 系数不变，调整标准误及相应的检验和置信区间。

Python 示例：异方差检验与稳健标准误

```python
from statsmodels.stats.diagnostic import het_breuschpagan

lm, lm_p, fvalue, f_p = het_breuschpagan(
    model.resid, model.model.exog
)
robust = model.get_robustcov_results(
    cov_type="HC3", use_t=True
)
print("Breusch-Pagan p:", lm_p)
print(robust.summary())
```

`lm_p` 检验同方差；`robust.summary()` 给出采用 HC3 标准误的系数检验。

常规 OLS 标准误与 HC3 标准误

变量	系数	常规 OLS 标准误	HC3 标准误	HC3 p
截距	3.023	0.418	0.365	< 0.001
BP	-0.096	0.066	0.051	0.062
对数市值	-0.132	0.031	0.027	< 0.001

Breusch–Pagan 检验 $p < 0.001$，拒绝同方差。采用 HC3 后，BP 的标准误由 0.066 降至 0.051，系数检验的 p 值由 0.146 降至 0.062，仍未达到 5% 显著水平。

加权最小二乘法

若误差方差 σ_i^2 已知或可合理估计，可按其倒数加权，最小化

$$\sum_{i=1}^{n} w_i (y_i - \mathbf{x}_i^\top \beta)^2, \qquad w_i \propto \frac{1}{\sigma_i^2}.$$

解为

$$\hat{\beta}_{WLS} = (X^\top W X)^{-1} X^\top W y.$$

误差方差较小的观测获得较大权重，从而提高估计效率。

WLS 与异方差稳健标准误

- HC3：保持 OLS 系数不变，调整标准误；
- WLS：按误差方差的倒数加权，重新估计系数；
- 本案例采用 OLS 系数和 HC3 标准误。

残差相关与时间序列数据

不同观测的误差存在关联时，常规标准误也可能不准确。

- Durbin–Watson（DW）统计量用于诊断一阶残差自相关；
- Breusch–Godfrey（BG）检验可检验指定阶数以内的序列相关；
- 面板数据可能存在同一股票内相关和同一期横截面相关。

横截面与时间序列中的误差相关

- 单日股票数据属于横截面；逐日回归系数组成时间序列；
- HC3 适用于异方差；HAC 同时考虑异方差与序列相关；聚类标准误允许组内误差相关；
- 逐日 BP 回归系数组成时间序列，后面将用 HAC 标准误检验其平均值。

多重共线性

多重共线性涉及解释变量之间的关系，主要影响系数估计的精度。可用方差膨胀因子衡量：

$$VIF_j = \frac{1}{1 - R_j^2},$$

其中 R_j^2 是以 X_j 为因变量、其余解释变量为自变量的辅助回归判定系数。

- 变量信息重叠，使系数标准误增大、估计不稳定；
- VIF 越大，说明该变量与其他解释变量的线性关系越强；
- 可结合专业知识合并或删减变量，或改用主成分回归、岭回归等方法。

Python 示例：计算方差膨胀因子

```
from statsmodels.stats.outliers_influence import variance_inflation_factor

X = model.model.exog
vif = pd.Series(
    [variance_inflation_factor(X, j)
     for j in range(X.shape[1])],
    index=model.model.exog_names,
)
print(vif)
```

由模型的设计矩阵计算各列的 VIF。共线性分析关注 BP 和对数市值，通常不解释常数项的 VIF。

方差膨胀因子

解释变量	VIF
BP	1.003
对数市值	1.003

BP 和对数市值的 VIF 均接近 1，说明两个解释变量之间的线性关系较弱，本模型没有明显的多重共线性。

回归诊断与模型改进

诊断现象	需要检查的问题	常见处理
残差呈曲线趋势	函数形式或遗漏变量	调整变量、非线性项或交互项
少数观测影响较大	数据错误或特殊样本	核查背景，比较含与不含该点的估计
残差离散程度变化	异方差	HC3；方差结构明确时可用 WLS
误差随时间或组别相关	序列相关或组内相关	HAC、聚类标准误或相应模型
解释变量高度相关	多重共线性	结合研究目的调整变量或采用正则化

回归练习：逐日横截面回归

独立完成数据整理、逐日估计与结果分析

从单日回归到逐日回归

控制公司规模后，BP 与次日收益的关系是否随日期变化?

- 将前面的单日回归扩展到 2024 年第一季度，每个交易日估计一个模型；
- 每日以股票为观测单位，以当日 BP 和对数市值解释次日收益；
- 将逐日的系数、检验结果和样本量按日期排列，分析关系的方向与稳定性；
- 最后检验平均 BP 系数是否显著异于零。

第一步：读取并对齐季度数据

1. 读取 2024 年第一季度的 PB、总市值、收盘价和复权因子；
2. 以收盘价的交易日序列为基准，按日期与股票代码对齐；
3. 列出各字段的日期范围、股票数和缺失比例。

第二步：构造 BP、规模与次日收益

设 $P^*_{i,t}$ 为收盘价乘以复权因子，$MV_{i,t}$ 为总市值：

$$BP_{i,t} = \frac{1}{PB_{i,t}}, \qquad Size_{i,t} = \log MV_{i,t}, \qquad r_{i,t+1} = 100\left(\frac{P^*_{i,t+1}}{P^*_{i,t}} - 1\right).$$

- $t+1$ 指下一个交易日；
- BP 和规模取 t 日的值，收益由 t 日至 $t+1$ 日的价格计算；
- 收益率以百分比表示。

第三步：整理逐日回归样本

1. 整理成长表，每行对应一只股票在一个交易日的观测；
2. 保留因子日期、收益日期、股票代码、BP、对数市值和次日收益；
3. 筛选 BP 为正且回归变量有效的股票，统计每日样本量 n_t。

第四步：逐日估计同一个回归模型

对每个有效交易日，分别估计含截距的等权 OLS 回归：

$$r_{i,t+1} = \alpha_t + \beta_t BP_{i,t} + \gamma_t \log MV_{i,t} + \varepsilon_{i,t+1}.$$

1. 逐日估计截距、BP 系数和规模系数；
2. 用 HC3 标准误计算 BP 系数的检验与 95% 置信区间；
3. 先复现 2024-03-28 的结果，再扩展到整个季度。

第五步：保存逐日结果并绘制样本量图

将各日估计结果整理成一张表，每行对应一个有效回归日期：

类别	记录内容
日期与样本	因子日期、收益日期、有效股票数 n_t
系数估计	截距 $\hat{\alpha}_t$、BP 系数 $\hat{\beta}_t$、规模系数 $\hat{\gamma}_t$
BP 系数推断	HC3 标准误、t 值、p 值、95% 置信区间
拟合程度	R_t^2

以因子日期为横轴，绘制每日有效样本量 n_t。

第六步：绘制系数与显著性的时间序列

以因子日期为横轴，绘制两幅时间序列图：

- BP 系数 $\hat{\beta}_t$（百分点）：标出 95% HC3 置信区间和零线；
- HC3 t 值：标出 0、$+2$、-2 参考线。

观察系数的方向、波动大小，以及显著的日期是否集中出现。

第七步：汇总并检验平均 BP 系数

设共有 T 个有效回归日期，计算

$$\overline{\beta} = \frac{1}{T}\sum_{t=1}^{T}\hat{\beta}_t, \qquad H_0 : \mathbb{E}(\hat{\beta}_t) = 0.$$

1. 汇总系数均值、标准差、正值比例，以及 $|t_t|$ 的均值和 $p_t < 0.05$ 的日期比例；
2. 将按日期排序的 BP 系数作为因变量，估计只有截距的回归；截距估计值即为平均系数；
3. 采用 HAC 标准误（最大滞后阶数为 5），报告均值检验和 95% 置信区间。

结果整理与解释

- 提交数据、逐日回归结果和汇总表；
- 绘制每日样本量、BP 系数及区间、t 值三幅图；
- 结合系数方向、时间变化和 HAC 均值检验，解释 BP 与次日收益的关系。

数据中性化

组内去均值与回归残差化

为什么需要中性化?

某品牌的眼霜历史投放数据中，**35–44 岁女性占 80%**，其余年龄、性别人群合计只占 20%。这些数据反映的偏好，可能较多地来自历史上主要触达的人群。

- 模型可能过度依赖年龄、性别，把“历史上主要向谁投放”与“谁有护肤需求”混在一起；
- 即使删除年龄、性别，浏览关键词、成分偏好等代理特征仍可能间接反映这些信息。

若研究目的是比较**控制年龄、性别后的需求差异**，可将某个需求评分对这些变量回归，取残差，表示高于或低于同类人群预期水平的部分。

中性化的本质：回归法

中性化的通用做法是**回归取残差**，分三步：

1. **确定变量**：待中性化的因子作为因变量 f，需要排除的影响（行业、规模等）作为自变量；
2. **线性回归**：估计 $f = Z\gamma + u$，得到拟合值 $\hat{f} = Z\hat{\gamma}$；
3. **计算残差**：$f^{\text{neutral}} = f - \hat{f}$，即实际值减去预测值。

行业内去均值

不同行业的 BP 水平可能不同。若希望比较一只股票相对于同行的位置，可减去所在行业的平均 BP：

$$BP_i^{\text{demean}} = BP_i - \overline{BP}_{g(i)}.$$

- $g(i)$ 表示股票 i 所属的行业，均值在同一天、同一行业内计算；
- 正值表示高于同行平均水平，负值表示低于同行平均水平；
- 处理后，每个行业的均值为零。

Python 示例：匹配行业信息

```
from utils.utils import _get_industries, _industry_on_date, industry_neutral

industry = _get_industries("l1_name", date)["l1_name"].rename("industry")
factor_cross = bp.to_frame().join(industry)
factor_cross = factor_cross.replace([np.inf, -np.inf], np.nan)
factor_cross = factor_cross.loc[factor_cross.bp > 0]
print("当日未匹配行业的股票数：", factor_cross.industry.isna().sum())
industry_cross = factor_cross.dropna().copy()
bp_matrix = pd.DataFrame([industry_cross.bp], index=[pd.Timestamp(date)])
neutralizer = industry_neutral("l1_name")
```

按日期匹配行业，将 BP 整理为“日期 × 股票”的表。

Python 示例：行业内去均值

```
industry_cross["bp_demean"] = neutralizer(bp_matrix, standardize=False).iloc[0]
print(industry_cross.groupby("industry")["bp_demean"].mean())
```

- `standardize=False` 表示只减去同行均值，不除以标准差；
- `iloc[0]` 取出单日的去均值结果；
- 去均值后，各行业 BP 的平均值在计算精度内为零。

组内去均值与类别虚拟变量

用含截距与 $G-1$ 个组别指标的等权 OLS：

$$f_i = \alpha + \sum_{g=2}^{G} \gamma_g D_{ig} + u_i,$$

则残差等于观测值减去所属组均值：

$$\hat{u}_i = f_i - \bar{f}_{g(i)}.$$

因此，**只控制类别变量的等权回归，取残差等价于组内去均值。**

均值方差法：去均值与标准化

对同一天、同一行业内的因子值，分两步处理：

- **组内去均值**：$f_i - \bar{f}_{g(i)}$，等价于前页的回归残差；
- **组内标准化**：再除以组内标准差 $(f_i - \bar{f}_{g(i)})/s_{g(i)}$，统一各组的波动尺度。

去均值调整组间平均水平，标准化进一步统一组间尺度。

行业内标准化

在去均值的基础上，再除以所在行业当天的标准差：

$$BP_i^{\text{industry z}} = \frac{BP_i - \overline{BP}_{g(i)}}{s_{g(i)}}.$$

- 数值表示该股票的 BP 高于或低于同行均值多少个标准差；
- 行业内有波动时，处理后的行业均值为零、标准差为一；

Python 示例：行业内标准化

```
industry_cross["bp_industry_z"] = neutralizer(bp_matrix).iloc[0]
print(industry_cross.groupby("industry")["bp_industry_z"].agg(
    ["mean", lambda x: x.std(ddof=0)]))
```

默认 `standardize=True`，在去均值后除以行业内标准差。

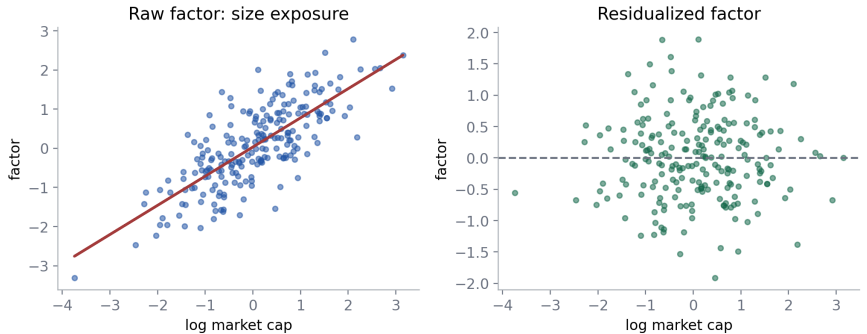
回归中性化

设待处理的因子为 f，行业、规模等控制变量组成矩阵 Z：

$$f = Z\gamma + u, \qquad f^{\text{neutral}} = \hat{u} = f - Z\hat{\gamma}.$$

- Z 可包含行业虚拟变量、对数市值等；
- 残差保留原始因子中未被控制变量线性解释的部分；
- OLS 残差与 Z 的各列正交。

中性化前后



模拟数据中，取回归残差后，因子与对数市值的样本线性相关降为零。

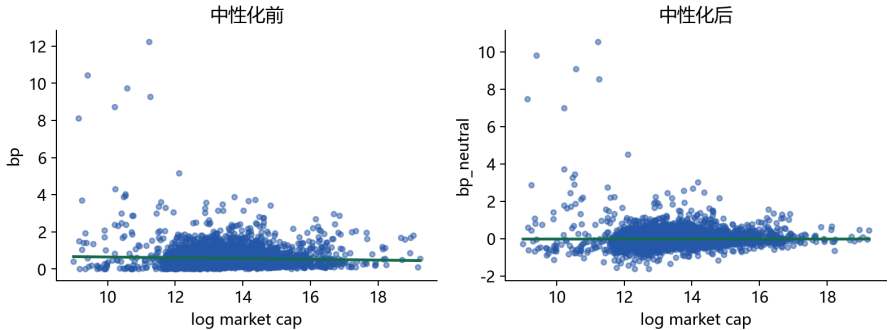
Python 示例：行业与规模中性化

```
neutral_cross = industry_cross.join(log_mv).dropna(subset=["log_mv"]).copy()

# %% TODO 9c: 单日行业与规模回归中性化
neutral_fit = smf.ols("bp ~ log_mv + C(industry)", data=neutral_cross).fit()
neutral_cross["bp_neutral"] = neutral_fit.resid
print(neutral_cross[["bp", "bp_neutral", "log_mv"]].corr())
print(neutral_cross.groupby("industry")["bp_neutral"].mean())
```

在 BP、行业和市值完整的样本上，将原始 BP 对行业虚拟变量和对数市值回归，所得残差即为行业与规模中性化后的 BP。

行业与规模中性化



5195 只股票中，中性化后 BP 与对数市值的样本相关系数由 -0.044 降至约 0。

中性化与控制变量回归的联系

在同一样本和同一组控制变量 Z 下，分别将 y 与 BP 对 Z 回归，得到残差 $\tilde{y}$ 与 $\widetilde{BP}$：

$$\hat{\beta}_{BP} = \frac{\widetilde{BP}^{\top}\tilde{y}}{\widetilde{BP}^{\top}\widetilde{BP}}.$$

- 它等于完整回归中 BP 的 OLS 系数；
- 控制变量后的关系，可以用两组残差之间的关系理解。

案例分析的主要结论

- 单日回归：BP 系数为 -0.096，HC3 检验 $p = 0.062$，在 5% 水平下不显著；
- 回归诊断：存在异方差，采用 HC3 调整标准误；
- 逐日回归：57 日平均 BP 系数为 0.073，HAC 检验 $p = 0.505$，平均关系不显著。

本节小结

- 回归描述因变量的条件均值，OLS 最小化残差平方和；
- R^2 衡量拟合优度，F 检验考察整体解释作用，t 检验考察单个系数；
- 用残差图和统计检验发现问题，选择相应的改进方法；
- 稳健标准误修正区间估计和检验；WLS 按误差方差的倒数加权估计系数；
- 回归中性化利用残差剔除线性关系，行业中性化是其常见应用；
- 逐日回归揭示关系的时间变化，HAC 检验评价平均系数。

课后练习：行业中性化前后的逐日回归对比

承接逐日回归练习，两组模型每日使用**相同的有效股票样本**，比较行业中性化前后的关系。

1. 每日将 BP 对行业指标回归，取残差作为行业中性化 BP；
2. 分别用原始 BP 和中性化 BP，配合对数市值解释次日收益；
3. 比较两组系数统计量、HC3 区间和 HAC 均值检验，绘制叠加图。

提交代码、结果图表及简要分析。具体数据处理与输出要求见 framework。