第四章 图像数据处理及分析

Lianghai Xiao

https://github.com/styluck/mlb

作业邮箱：alswfx@126.com

目录

- 数据特征的提取与描述
  - 主成分分析
  - 因子分析

- 数据分类的分析方法
  - 聚类分析
  - 判别分析
  - 支持向量机

流程图

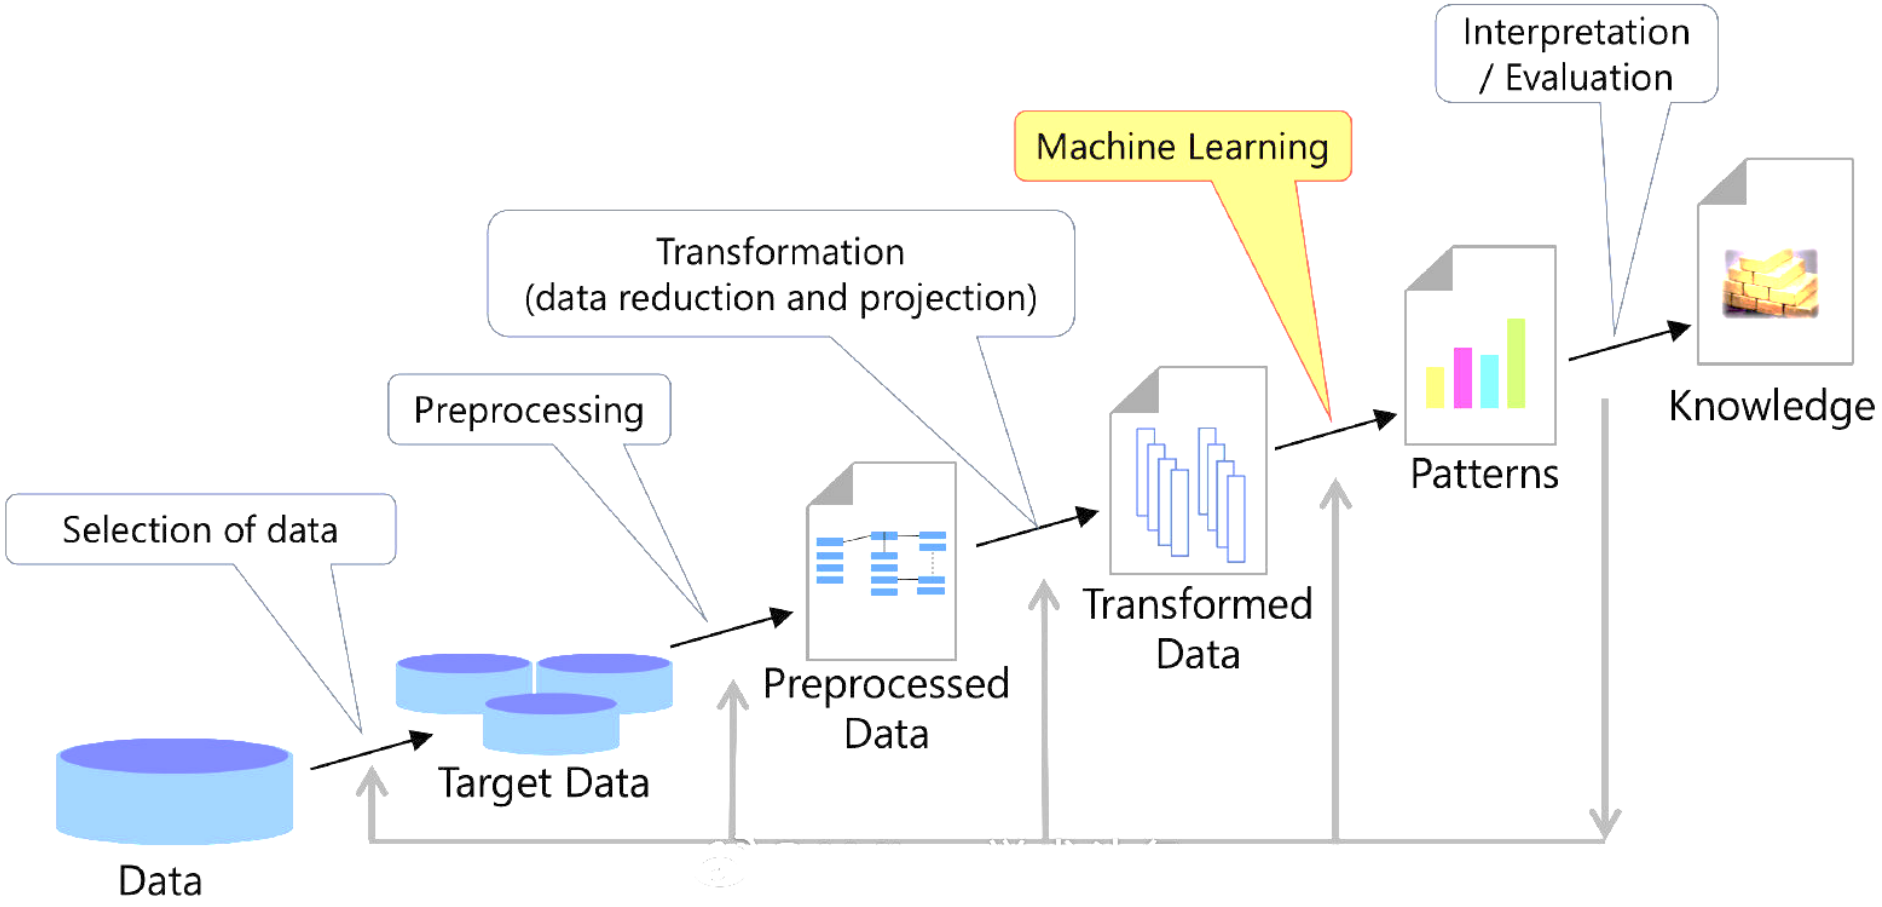
Interpretation
/ Evaluation
Machine Learning
Transformation
(data reduction and projection)
Preprocessing
Selection of data
Knowledge
Patterns
Transformed
Data
Preprocessed
Data
Target Data
Data

流程图

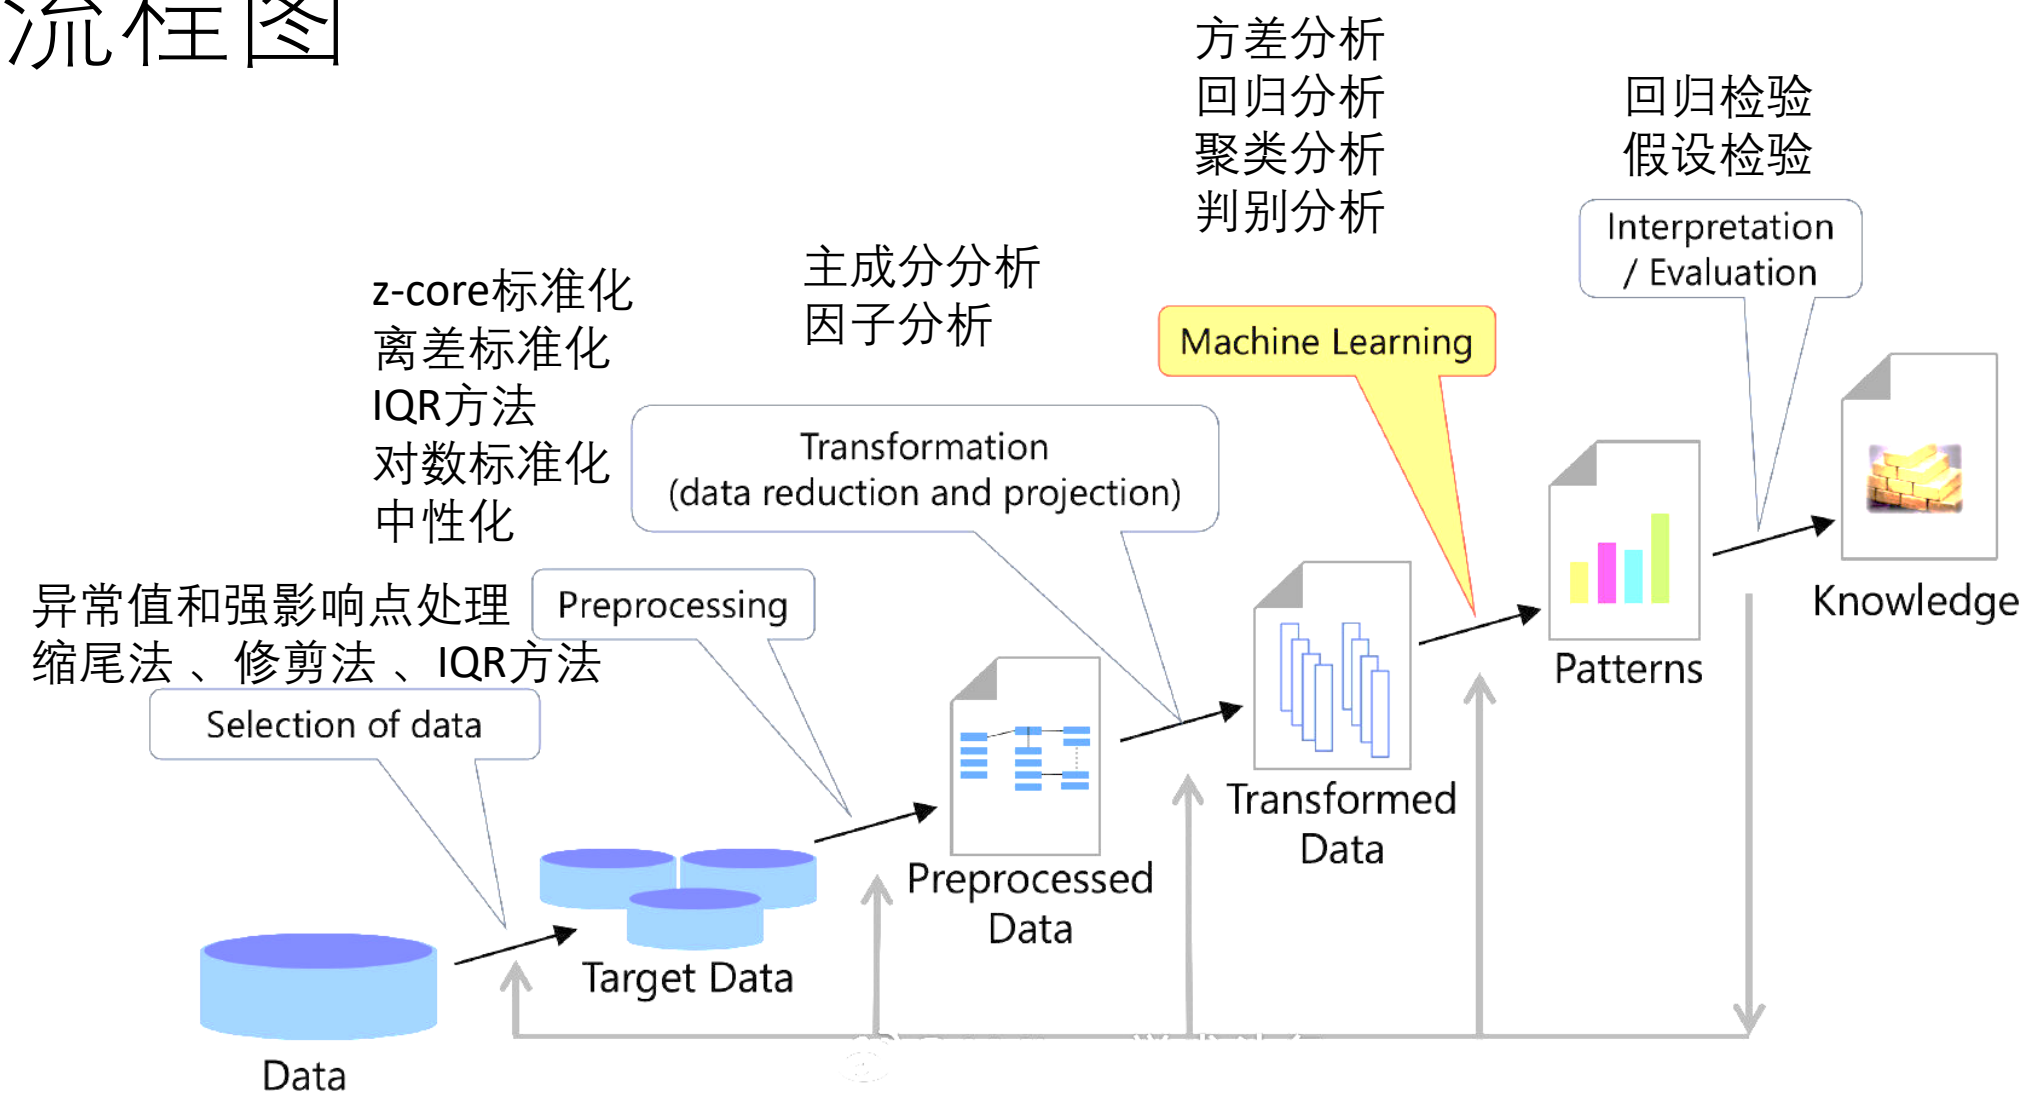
方差分析
回归分析
聚类分析
判别分析
回归检验
假设检验
Interpretation / Evaluation
z-core标准化
离差标准化
IQR方法
对数标准化
中性化
主成分分析
因子分析
Machine Learning
Transformation (data reduction and projection)
异常值和强影响点处理
缩尾法 、修剪法 、IQR方法
Preprocessing
Selection of data
Knowledge
Patterns
Transformed Data
Preprocessed Data
Target Data
Data

图像的预处理

- **去除噪声**
  - **均值滤波：**计算图像中每个像素点邻域内像素的平均值来代替该像素点的原始值。
  - 去除图像中的颗粒噪声，但会使图像边缘变得模糊。
  - **中值滤波：**将像素点邻域内的像素值进行排序，然后用中间值（中值）来替换该像素点的原始值。
  - 去除椒盐噪声方面效果显著，能够在一定程度上保留图像的边缘和细节。

图像的预处理

- **去除噪声**
  - **高斯滤波：** 认为像素点的邻域像素对其影响是符合高斯分布的。离中心像素越近的像素点，其权重越大；离得越远，权重越小。在滤波过程中，每个像素点的值是其邻域像素值的加权平均，权重由高斯函数确定。
  - 对于去除高斯噪声效果较好， 但也会对图像的边缘有一定的模糊作用，不过通常比均值滤波的模糊程度要小。
  - **小波去噪：** 基于小波变换将图像分解为不同尺度和方向的小波系数，通过设定阈值，将小于阈值的小波系数置零或进行收缩处理，然后再进行小波逆变换得到去噪后的图像。
  - 可以根据图像的特点选择合适的小波基函数进行分解，对多种类型的噪声都有较好的去除效果，并且能够在一定程度上保留图像的细节和特征，但阈值的选择比较关键。

图像的预处理

- **归一化**
  - **离差标准化**（归一化）
  - 计算公式为：

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

  - 将图像的像素值从原始范围线性映射到一个新的范围，比如将像素值从 [0, 255] 映射到 [0, 1]。
  - **Z-score 标准化**
  - 计算公式为：

$$Z = \frac{X - \mu}{\sigma}$$

  - 使处理后的图像数据均值为 0，标准差为 1。这样可以使不同数据集在同一尺度下进行比较和处理。

图像的预处理

- **归一化**
  - **RGB 与灰度转换**
  - 将彩色图像（RGB 颜色空间）转换为灰度图像。使用NTSC 公式将RGB 值转换为灰度:
    - 灰度 = 0.299 ·(红色) + 0.587 (绿色) + 0.114 ·(蓝色)。
  - 此公式可非常准确地反映一般人对红色、绿色和蓝色光源的相对感知。

主成分分析

主成分分析

- 尽管收集和分析大量的多变量数据可以为我们提供宝贵的信息资源，但这同时也加大了数据收集的工作负担。
- 主成分分析（Principal Component Analysis，简称 PCA）的主要目的是在尽可能保留原始数据信息的情况下，对高维数据进行降维处理。
- 在一个有多个变量（如身高、体重、血压等）的数据集中，这些变量之间可能存在相关性。主成分分析可以找到一组新的、相互无关的变量（主成分）来代替原始变量。

主成分分析

- 主成分分析的目的：
  - **降维**：在许多实际应用中，原始数据集可能包含大量特征，但其中许多特征可能是冗余的或高度相关的。PCA可以减少特征的数量，同时保留大部分信息。
  - **可视化**：通过将多维数据映射到较低维度（通常是二维或三维），PCA可以帮助我们更直观地理解数据。
  - **噪声过滤**：PCA可以去除数据中的噪声，因为它只保留最重要的变化模式。
  - **数据恢复**：PCA常用于特征提取，以恢复缺失的数据。

监督学习和无监督学习

- 在监督学习中，我们有一个包含输入特征（X）和对应的目标输出（y）的训练数据集。模型通过学习输入和输出之间的映射关系，以便在给定新的输入时能够预测输出。
- 无监督学习是在没有给定明确的目标输出的情况下，让模型自动从数据中发现模式和结构。也就是说，数据集中只有输入特征X，没有对应的y。
- PCA是一种**无监督学习方法**，它不依赖于数据的类别标签，旨在找到数据中方差最大的方向，以这些方向作为新的特征空间，从而实现降维。

监督学习和无监督学习

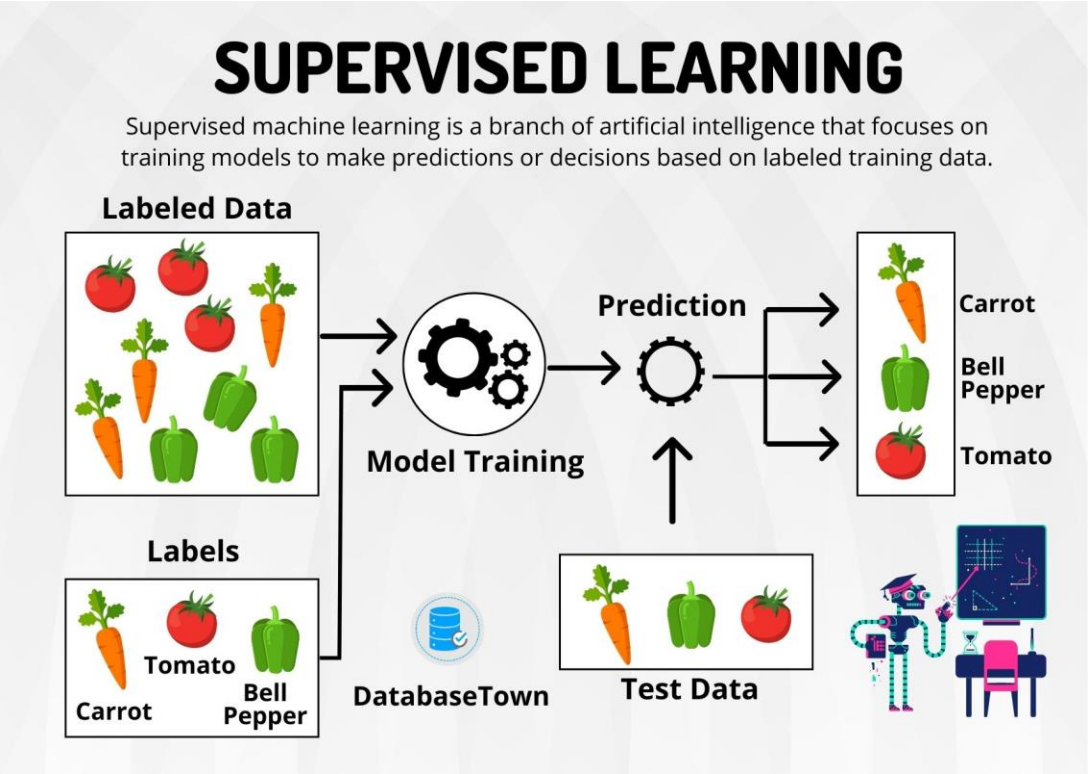
SUPERVISED LEARNING
Supervised machine learning is a branch of artificial intelligence that focuses on training models to make predictions or decisions based on labeled training data.
Labeled Data
Labels
Tomato
Carrot
Bell Pepper
Model Training
Prediction
Carrot
Bell Pepper
Tomato
DatabaseTown
Test Data

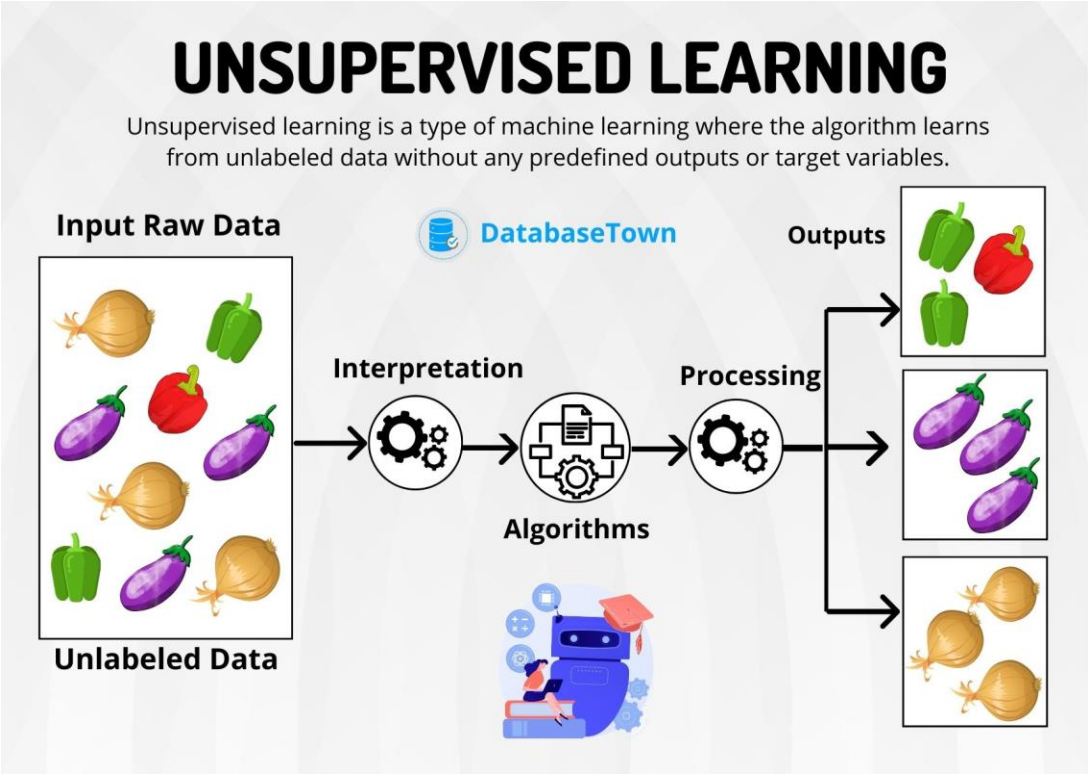
UNSUPERVISED LEARNING
Unsupervised learning is a type of machine learning where the algorithm learns from unlabeled data without any predefined outputs or target variables.
Input Raw Data
DatabaseTown
Outputs
Interpretation
Processing
Algorithms
Unlabeled Data

监督学习和无监督学习

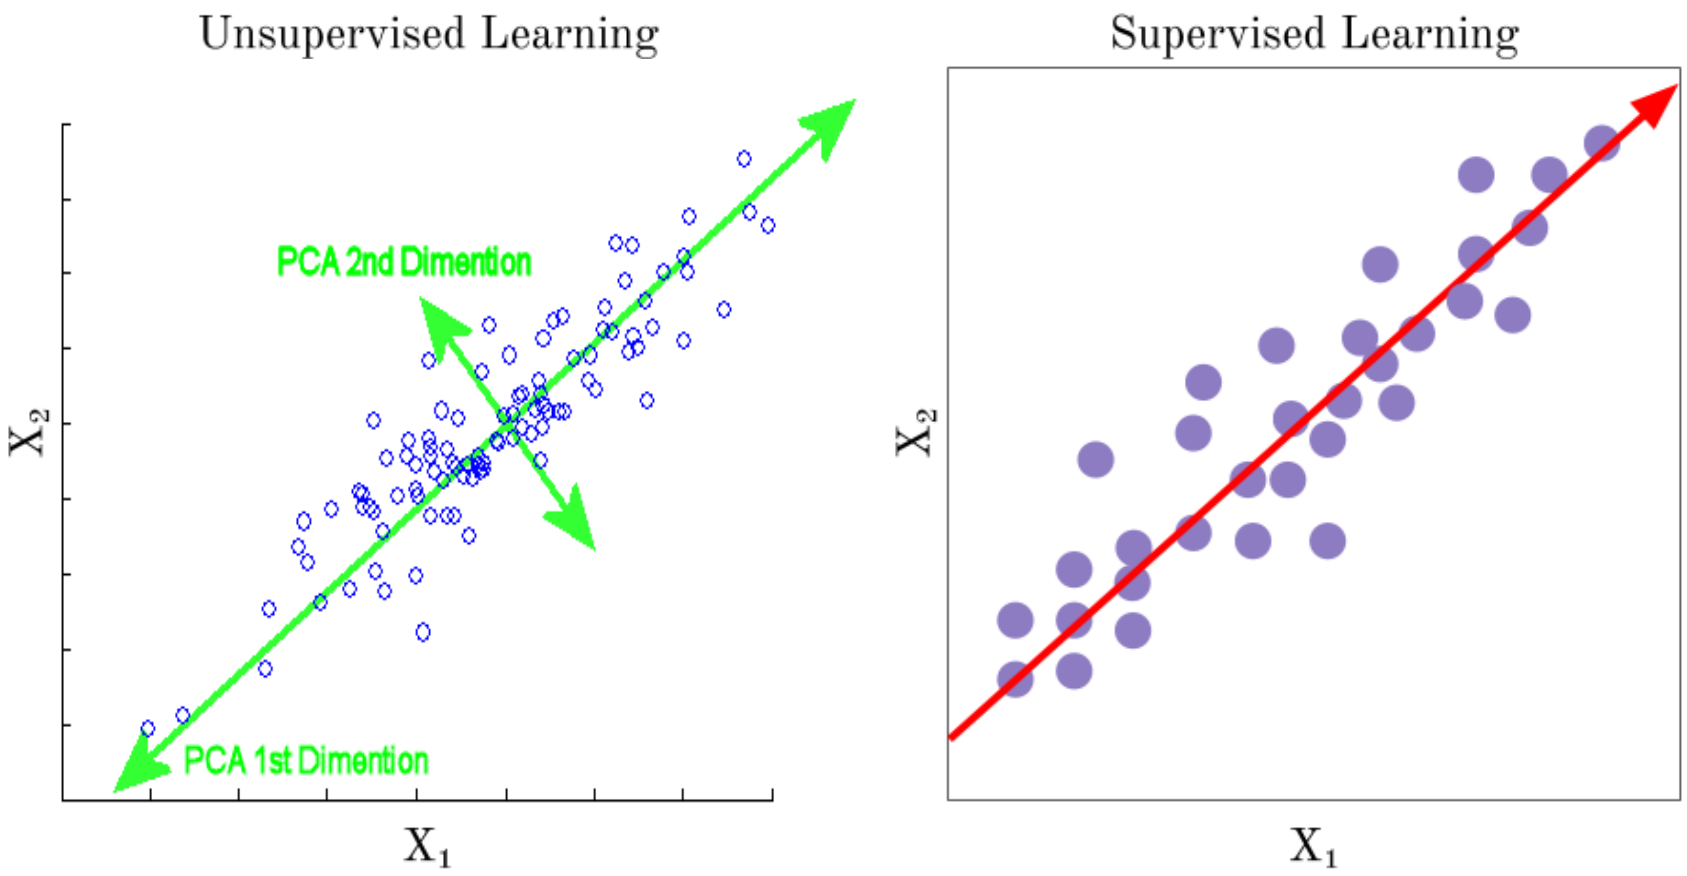
Unsupervised Learning
PCA 2nd Dimention
PCA 1st Dimention
X_2
X_1
Supervised Learning
X_2
X_1

主成分分析

- PCA的数学定义：一个正交化线性变换，把数据变换到一个新的坐标系统中，使得这一数据的任何投影的第一大差异性在第一个坐标（称为第一主成分）上，第二大差异性在第二个坐标（第二主成分）上，依次类推。

PCA优化目标

- PCA推导有两种主要思路：
  1.最大化数据投影后的的方差（让数据更分散）
  2.最小化投影造成的损失

- 采用第一种思路完成推导过程，下图中旋转的是新坐标轴，每个数据点在改坐标轴上垂直投影，最佳的坐标轴为数据投影后的数据之间距离最大。

主成分分析的优化目标

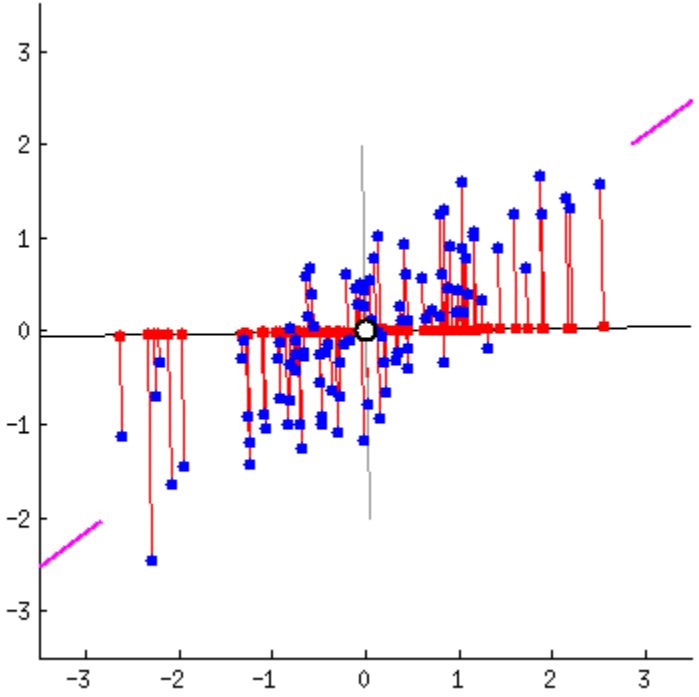

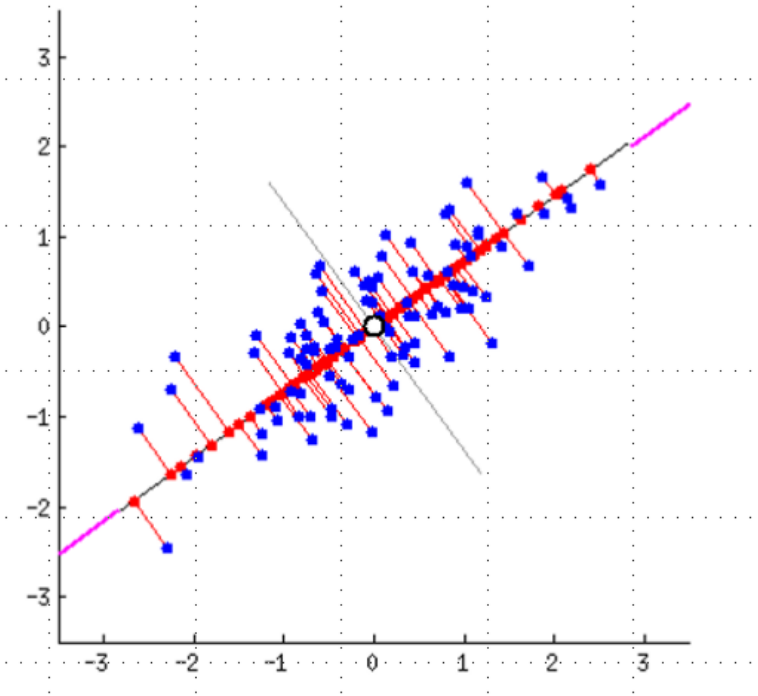

主成分分析的优化目标

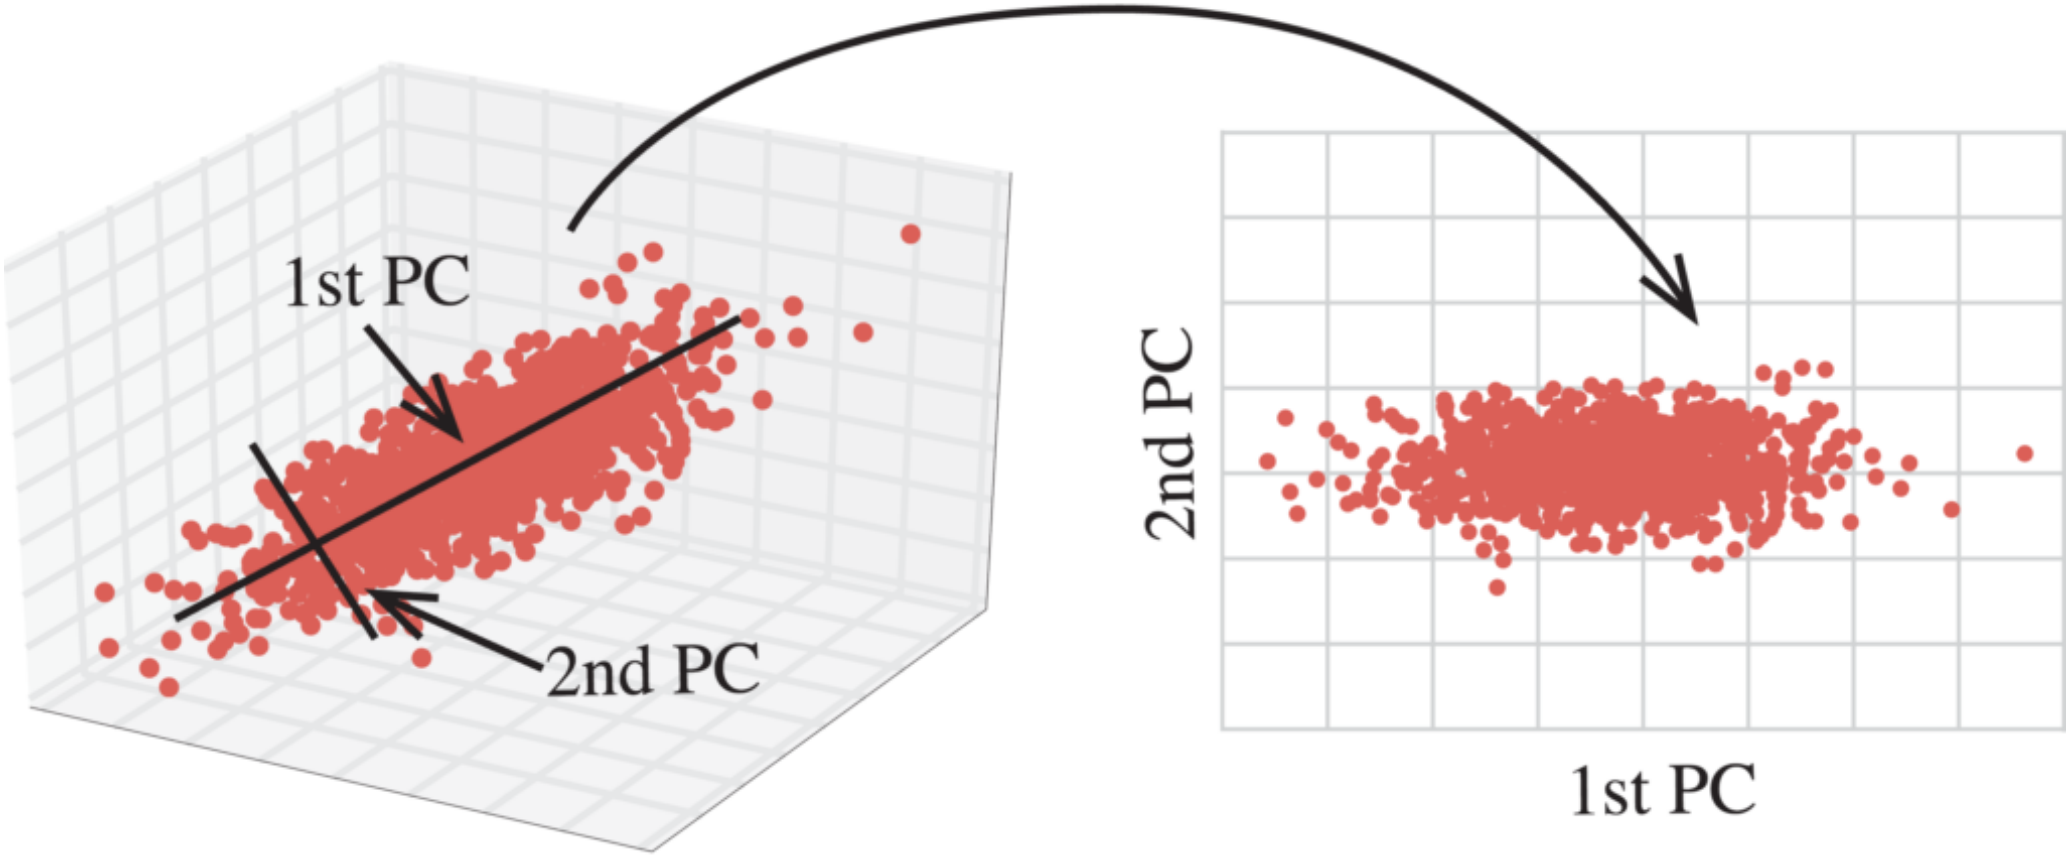

PCA推导

- PCA的目标是找到一组新的正交基 $\{u_1, u_2, \cdots, u_k\}$（从$m$维下降到$k$维），使得数据点在该正交基构成的平面上投影后，数据间的距离最大，即数据间的方差最大。
- 如果数据在每个正交基上投影后的方差最大，那么同样满足在正交基所构成的平面上投影距离最大。

PCA推导

- 设正交基 u_j， 数据点x_i在该基底上的投影距离为 $x_i u_j$， 所以所有数据在该基底上投影的方差J_j 为：

$$J_j = \frac{1}{n}\sum_{i=1}^{n}\left(x_i u_j - x_{center} u_j\right)^2$$

- 由于在数据运算之前对数据 x 进行0均值初始化，上式可写作

$$J_j = \frac{1}{n}\sum_{i=1}^{n}\left(x_i u_j\right)^2$$

$$= \frac{1}{n}\sum_{i=1}^{n}\left(u_j^T x_i^T \cdot x_i u_j\right) = u_j^T \cdot \frac{1}{n}\sum_{i=1}^{n}\left(x_i^T x_i\right) \cdot u_j$$

PCA推导

- 写成矩阵形式，有

$$J_j = \frac{1}{n} u_j^T X^T X u_j$$

- 则优化问题为

$$\max_{u_j} J_j = \frac{1}{n} u_j^T X^T X u_j$$
$$s.t. \quad u_j^T u_j = 1$$

PCA推导

- 只提取一个主成分：

$$\max_{u_j} J_j = \frac{1}{n} u_j^T X^T X u_j$$
$$s.t. \quad u_j^T u_j = 1$$

- 提取k个主成分：

$$\max_{U_k} J_k = \frac{1}{n} tr(U_k^T X^T X U_k)$$
$$s.t. \quad U_k^T U_k = I_k$$

主成分分析

- 如何得到包含最大差异性的主成分方向？

- 通过计算数据矩阵的协方差矩阵，然后得到协方差矩阵的特征值特征向量，**选择特征值最大(即方差最大)的k个特征所对应的特征向量组成的矩阵。**这样就可以将数据矩阵转换到新的空间当中，实现数据特征的降维。

- 两种实现方法：基于特征值分解协方差矩阵实现PCA算法、基于SVD分解协方差矩阵实现PCA算法。

特征值分解

- 如果一个向量v是矩阵A的特征向量，将一定可以表示成下面的形式：

$$Av = \lambda v$$

- 其中，λ是特征向量v对应的特征值，一个矩阵的一组特征向量是一组正交向量。
- 对于矩阵A，有一组特征向量v，将这组向量进行正交化单位化，就能得到一组正交单位向量。特征值分解就是将矩阵A分解为如下式：

$$A = V\Sigma V^{-1}$$

- 其中，V是矩阵A的特征向量组成的矩阵，Σ则是一个对角阵，对角线上的元素就是特征值。

SVD分解

- 奇异值分解是一个能适用于任意矩阵的一种分解的方法，对于任意矩阵X总是存在一个奇异值分解：
  - $X = W\Sigma U^T$
- 设X是一个$m \times n$的矩阵，那么得到的U是一个$m \times m$的方阵，U里面的正交向量被称为左奇异向量。
- Σ是一个$m \times n$的矩阵，Σ除了对角线其它元素都为0，对角线上的元素称为奇异值。
- 一般来讲，算法会将Σ上的值按从大到小的顺序排列。

主成分分析

- 输入：数据集 $X = \{x_1, x_2, \dots, x_n\} \in R^{n \times m}$，需要从$m$维降到$k$维。
- 1) 去平均值(即去中心化)，即每一位特征减去各自的平均值。
- 2) 计算协方差矩阵$\frac{1}{n} X^\top X$，这里除或不除样本数量n或$n-1$,对求出的特征向量没有影响。
- 3) 用特征值分解方法求协方差矩阵$\frac{1}{n} X^\top X$的特征值与特征向量。
- 4) 对特征值从大到小排序，选择其中最大的k个。然后将其对应的k个特征向量分别作为行向量组成特征向量矩阵U。
- 5) 将数据转换到k个特征向量构建的新空间中，即$Y = XU$。

主成分分析

- 数据集 $X = \{x_1, x_2, \dots, x_n\} \in R^{n\times m}$,其行为数据样本，列为数据类别，并经过了去平均值处理。则X的奇异值分解为
  - $X = W\Sigma U^T$
- 据此，

$$\begin{aligned} Y &= XU \\ &= W\Sigma U^\top U \\ &= W\Sigma \end{aligned}$$

- 我们可以利用U_k把 X 映射到一个只应用前面k个向量的低维空间中去：
  - $Y = XU_k = W\Sigma U^\top U_\mathrm{k} = \mathrm{W}\Sigma_k$

选择降维后的维度K(主成分的个数)

- average squared projection error

$$\frac{1}{m}\sum_{i=1}^{m}\left\|x^{(i)} - x_{approx}^{(i)}\right\|^2$$

- total variation in the data

$$\frac{1}{m}\sum_{i=1}^{m}\left\|x^{(i)}\right\|^2$$

选择降维后的维度K(主成分的个数)

- 选择不同的K值，然后用下面的式子不断计算，选取能够满足下列式子条件的最小K值即可。

$$\frac{\frac{1}{m}\sum_{i=1}^{m}\left\|x^{(i)}-x_{approx}^{(i)}\right\|^2}{\frac{1}{m}\sum_{i=1}^{m}\left\|x^{(i)}\right\|^2}\leq t$$

- 还可以用SVD分解时产生的S矩阵来表示

$$1-\frac{\sum_{i=1}^{k}S_{ii}}{\sum_{i=1}^{n}S_{ii}}\leq t$$

ALS算法

- PCA（主成分分析）中的ALS算法实际上是指交替最小二乘法（Alternating Least Squares），它是一种用于矩阵分解的优化方法，尤其在推荐系统中被广泛应用。
- ALS通常用于处理用户-商品评分矩阵，通过矩阵分解来预测缺失的评分，从而生成个性化推荐。

因子分析

因子分析简介

- 子分析起源于 20 世纪初, K. 皮尔逊 (Pearson) 和 C. 斯皮尔 曼 (Spearman) 等学者为定义和测定智力所作的努力，主要是 由对心理测量学有兴趣的科学家们培育和发展了因子分析。
- 因子分析常用于对不能直接观测的变量, 例如智力, 音乐能力, 爱国主义, 消费者态度等等, 进行推断, 这类变量称为隐变量.
- **隐变量**（latent variable）是指不能直接观测到的变量，但是可以从一组可观测变量的相关关系中导出。

因子分析简介

- 例如我们知道**虚弱**所表达的状况，但是无法测量。我们认为它 可以通过比如力量、重量、速度、平衡性等其他方面的测量（可 观测变量）来确定. 因此隐变量“虚弱”应该可以通过这些可测量的量来表示.
- 因子分析中称**隐变量为因子** (Factor).
- 个体在一个或多个因子上取值的变化可以影响可观测变量中的 多个变量 (某个变量子集), 从而导致该子集内变量之间高度相 关.

因子分析的分类

- 因子分析常包括探索性因子分析(Exploratory FA) 和验证性因子分析(Confirmatory FA) 两类.
- **探索性因子分析**常用来降维, 降维的方式是试图用少数几个潜 在的, 不可观测的随机变量（因子）来描述原始变量间的协方 差关系. “探索性”是指在没有对可观测变量之间，以及可观 测变量与因子之间的线性关系赋予任何结构，而只指定隐变量 (latent variables) 的个数.
- **验证性因子分析**则常用来研究一个假设的因子模型对一组新的样本拟合程度如何，其允许对模型中的参数进行限制.

因子分析应用：词嵌入

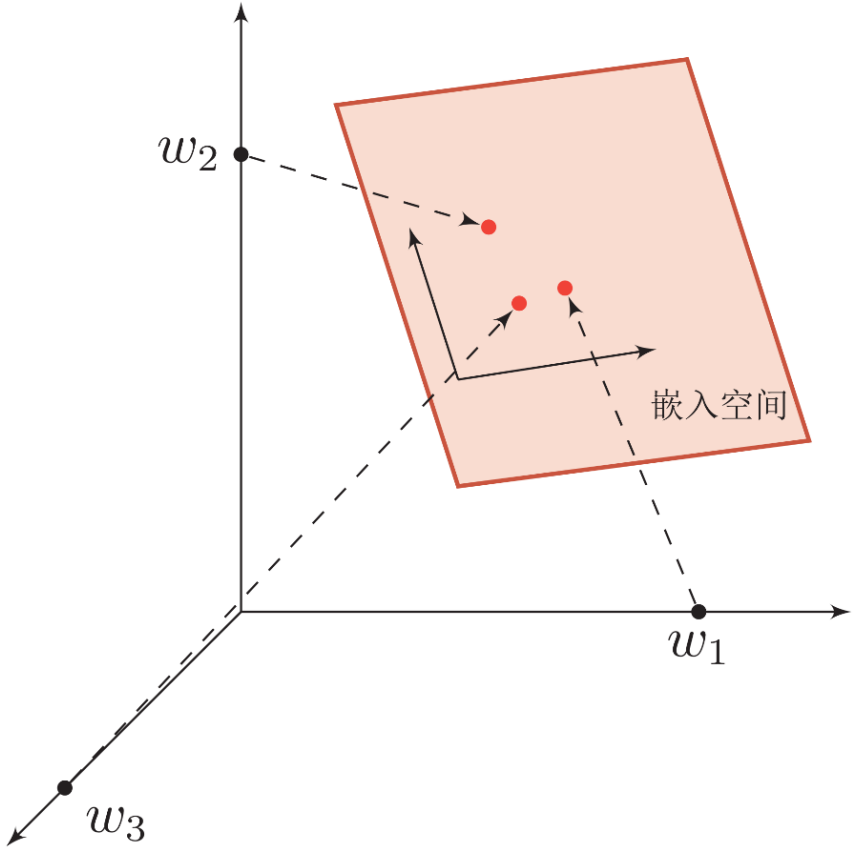
w_2
w_1
w_3
嵌入空间

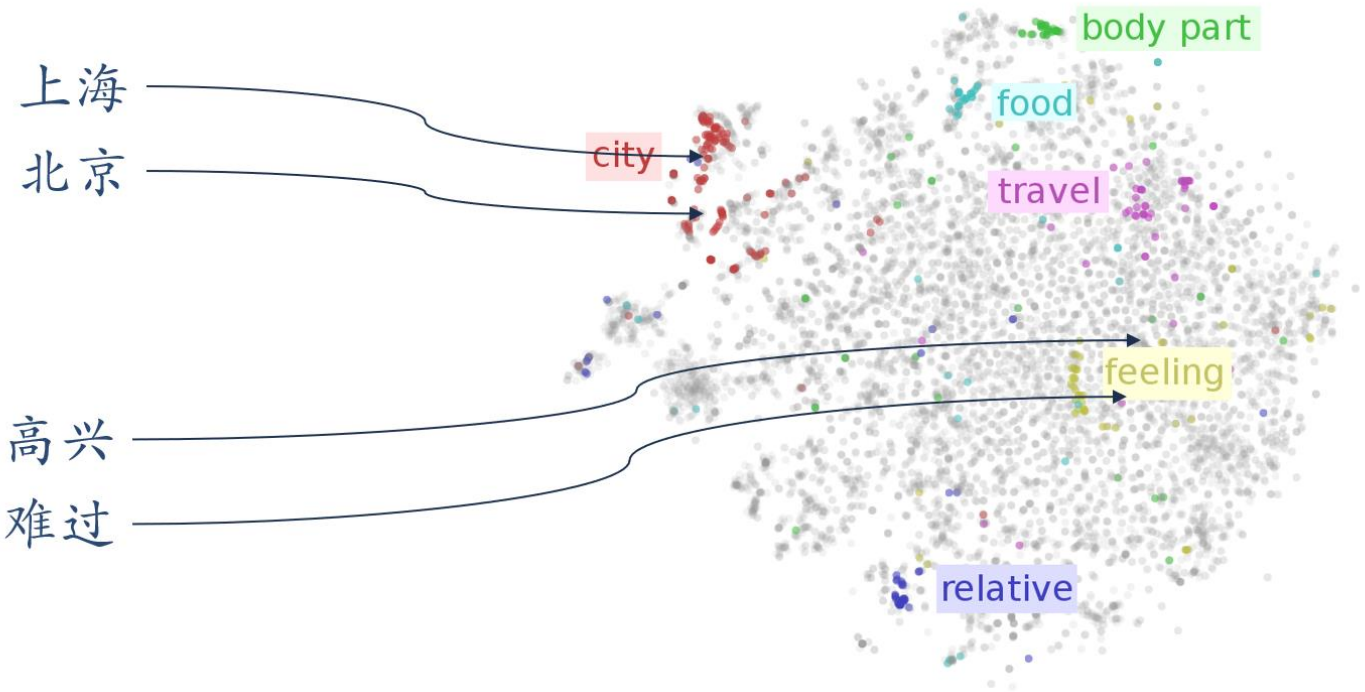
上海
北京
高兴
难过
city
body part
food
travel
feeling
relative

EFA vs CFA

Exploratory FA

因子个数未知
载荷模式未知
（例如所有的因子在所有变量）
可以不是可识别的
因子是不相关的

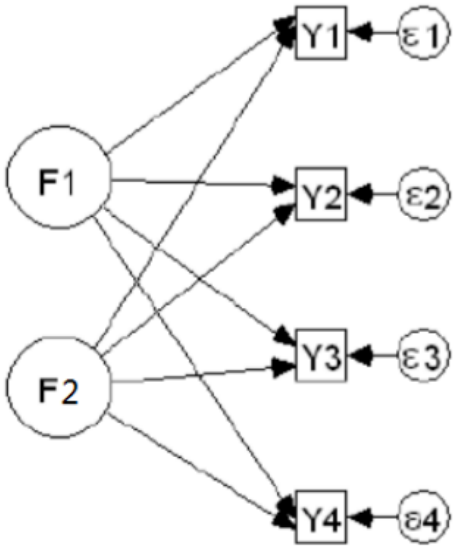

Exploratory FA

Confirmatory FA

因子个数根据理论来设置
载荷模式由理论决定
(e.g. $Y_1 = l_1 F_1 + \epsilon$)
一般是可识别的
因子可以是相关的

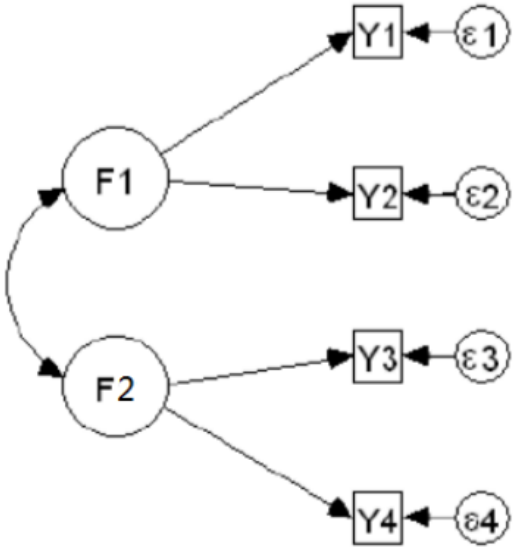

Confirmatory FA

Example: 验证性因子分析

- 一家市场研究公司希望了解消费者如何选择光顾哪家商店

- 随机对光顾每家商店的消费者进行了包含 $80(p = 80)$ 道问题 的问卷调查
- 市场研究人员提出假设 消费者的选择是基于几个潜在的因子: <u>商店人员的友好程度, 消费者服务水平, 商店气氛, 产品种类, 产品质量和一般的价格水平</u>
- 因子分析使用 80 个问题的响应值之间的相关性来决定 80 个变 量是否可以分为 6 组, 每组分别反映所假设的一个因子.

正交因子模型

- $X = (X_1, \ldots, X_p)'$ 为 p 维观测变量, 其均值和协方差矩阵分别 为 μ 和 Σ.
- 因子分析模型假定 X 可以表示为 m个公共因子 (common factors) $F_1, \ldots, F_m$ 和 p 个特殊因子 (unique factors) $\epsilon_1, \ldots, \epsilon_p$ 的 线性组合

$$
\begin{aligned}
X_1 - \mu_1 &= l_{11}F_1 + l_{12}F_2 + \cdots + l_{1m}F_m + \epsilon_1 \\
X_2 - \mu_2 &= l_{21}F_1 + l_{22}F_2 + \cdots + l_{2m}F_m + \epsilon_2 \\
&\vdots \\
X_p - \mu_p &= l_{p1}F_1 + l_{p2}F_2 + \cdots + l_{pm}F_m + \epsilon_p
\end{aligned}
$$

- 其中 l_{ij} 称为第 i 个变量在第 j 个因子上的因子负荷 (factor loading).

正交因子模型

- 表达成矩阵形式: $X_{p\times 1} = \mu + L_{p\times m}F + \epsilon$, L 称为因子负荷阵. 上述模型和线性模型形式非常相像, 但是注意右边每个量我们均不能直接观测到, 即公共因子和特殊因子均为随机变量且不能直接观测到. 因此需要假定一些结构才能进行推断.
- 正交因子模型假设包括:

$$(1). \quad E\mathbf{F} = 0, \quad Var(\mathbf{F}) = E(\mathbf{F}\mathbf{F}') = I_m$$

$$(2). \quad E\boldsymbol{\epsilon} = 0, \quad Var(\boldsymbol{\epsilon}) = E(\boldsymbol{\epsilon}\boldsymbol{\epsilon}') = \Psi = diag\{\psi_1, \ldots, \psi_p\}$$

$$(3). \quad cov(\mathbf{F}, \boldsymbol{\epsilon}) = 0$$

正交因子模型

- 在正交因子模型假设下，有

$$Cov(X_i, F_j) = l_{ij};$$

$$\Sigma = Var(\mathbf{X}) = Var(\mathbf{LF} + \boldsymbol{\epsilon}) = \mathbf{LL}' + \Psi$$

$$\sigma_{ii} = Var(X_i) = \sum_{j=1}^{m} l_{ij}^2 + \psi_i := h_i^2 + \psi_i$$

$$\sigma_{ij} = cov(X_i, X_j) = \sum_{k=1}^{m} l_{ik} l_{jk}, i \neq j$$

正交因子模型

- 方差 σ_{ii} 由两部分构成: 由 m 个公共因子贡献的部分,
- h_{2i} , 称为共性或**共性方差**(communality);
- 由公共因子不能解释 (由特 殊因子解释) 的部分称为特殊方差 (uniqueness, specific variance).
- 由协方差结构假设, 正交因子模型假定了 $p(p + 1)/2$ 个方差参数可以通过 $pm + p$ 个参数表达.

因子旋转

- 出于降维的需要，我们常常希望 m 要比 p 小得多, 这样分解式 $\Sigma = LL' + \Psi$ 通常只能近似成立. 一般来说, m 选取得越小, 上述近似效果就越差, 即因子模型拟合得越不理想. 拟合得太差的因子模型是没有什么实际意义的.
- 注意：公共因子 F 和负荷阵 L 不唯一: 对任意正交矩阵 T 有

$$X - \boldsymbol{\mu} = \mathbf{LF} + \epsilon = (\mathbf{LT})(\mathbf{T}'\mathbf{F}) + \boldsymbol{\epsilon} = \mathbf{L}^*\mathbf{F}^* + \boldsymbol{\epsilon}$$

- L^* , F^* 满足正交因子模型的所有假设. 因此因子负荷阵
  - $L^* = LT$ 和 L
- 在解释协方差 Σ 时候是等价的.

因子旋转

- 由正交矩阵的性质, 称正交变换 LT, $T'F$ 为因子旋转. 在合适 的准则下对因子负荷阵 L 进行旋转, 以期得到更易解释的结果.
- 旋转的目的是使每个变量在一个因子上的负荷量尽可能高，而在其他因子上的负荷量尽可能低，这样每个因子代表的含义就更加清晰。

参数估计

- 对可观测变量 X, 假设我们有一组样本: $x_1, \ldots, x_n$
- 由 $\Sigma = LL' + \Psi$ 结构, 需要估计 L 和 Ψ 当 L 和 Ψ 被估计出来后, 使用线性模型理论可得因子 F 的估 计 (称为因子得分).
- 记 S 为样本协方差矩阵, 则 S 为 Σ 的估计. 于是首先我们需要研究 p 个变量之间是否存在足够大的相关以进行因子分析. 如 果 S 的非对角元都约为零, 则特殊因子方差 ψ_i 占控制地位, 因 此此时我们不能识别公共因子.

参数估计

- 常见的估计方法包括
  - 主成分法
  - 迭代主因子法
  - 最大似然法 (假设正态)
- 第一种方法对方差关注更多, 后两种方法关注如何使用公共因 子的波动来描述观测性状之间的相关性.

主成分法(The principal component method)

- 由 Σ 的非负定性, 可以得到正交分解

$$\Sigma = \lambda_1 \mathbf{e}_1 \mathbf{e}_1' + \cdots + \lambda_p \mathbf{e}_p \mathbf{e}_p := \mathbf{e} \Lambda \mathbf{e}'$$

- 其中 $\lambda_1 \geq \cdots \geq \lambda_p \geq 0$ 为特征根, $e_1, \ldots, e_p$ 为相应的特征向量
- 记 $Y = e'(X - \mu)$, 则 Y 为总体主成分，有

$$\mathbf{X} - \boldsymbol{\mu} = \mathbf{e}\mathbf{Y} = \sum_{j=1}^{m} \mathbf{e}_j Y_j + \sum_{j=m+1}^{p} \mathbf{e}_j Y_j$$

$$:= \mathbf{L}\mathbf{F} + \boldsymbol{\epsilon},$$

- 其中 $\mathbf{L} = [\sqrt{\lambda_1}\mathbf{e}_1, \ldots, \sqrt{\lambda_m}\mathbf{e}_m]$, $\mathbf{F} = (Y_1/\sqrt{\lambda_1}, \ldots, Y_m/\sqrt{\lambda_m})'$,
  $\boldsymbol{\epsilon} = \sum_{j=m+1}^{p} \mathbf{e}_j Y_j$.

主成分法

- 可以验证正交因子模型的假设条件 (1) 和 (3) 成立, 但是 (2) 未 必成立.
- 相应地,

$$\Sigma = \mathbf{LL}' + Var(\boldsymbol{\epsilon})$$

- 若特殊因子 ϵ 对协方差的贡献很小, 则 $\Sigma \approx LL'$, 从而对协方 差的一个良好近似为

$$\Sigma \approx \mathbf{LL}' + diag\{\psi_1, \ldots, \psi_p\}$$

- 其中 $\psi_i = \sigma_{ii} - \sum_{j=1}^{m} l_{ij}^2 = \sigma_{ii} - h_i^2, i = 1, \ldots, p.$

主成分法

- 使用样本数据 $x_1, \ldots, x_n$ 估计上述参数. 记 $(\hat{\lambda}_i, \hat{\mathbf{e}}_j), j = 1, \ldots, p$ 样本协方差矩阵 S 的特征根和特征向量对, 且 $\hat{\lambda}_1 \geq \cdots \geq \hat{\lambda}_p \geq 0.$

- 因子模型的主成分解:

$$\hat{\mathbf{L}} = [\sqrt{\hat{\lambda}_1}\hat{\mathbf{e}}_1, \ldots, \sqrt{\hat{\lambda}_m}\hat{\mathbf{e}}_m],$$

$$\hat{\Psi} = diag(\mathbf{S} - \hat{\mathbf{L}}\hat{\mathbf{L}}') = diag\{\hat{\psi}_1, \ldots, \hat{\psi}_p\}, \hat{\psi}_i = s_{ii} - \sum_{j=1}^{m} \hat{l}_{ij}$$

因子个数 m的确定

- 在一些问题里, 因子个数 m 是事先取定的
- 若 m 不能事先取定, 则可以基于不同 m 下拟合的模型结果来 寻找 “最好” 的 m, 使得:

$$\mathbf{S} - (\hat{\mathbf{L}}\hat{\mathbf{L}}' + \hat{\Psi})$$

- 有较小的非对角元. 类似主成分个数的选择方法, 选择 m 使得

$$\frac{\sum_{i=1}^{m} \hat{\lambda}_i}{\hat{\lambda}_1 + \cdots \hat{\lambda}_p}$$

- 较大.
- 基于相关系数矩阵分析时候, 选择特征根大于 1 的个数.

迭代主因子法(Iterated principal factor method)

- 迭代主因子法是对主成分方法的修正. 我们通过样本相关系数矩阵 R 来说明. 同样的过程也可以用于样本协方差矩阵.
- 由于总体相关系数矩阵 $\rho = LL' + \Psi$, 因此 $\rho - \Psi = LL'$. 对角 元 $\rho_{ii} = h_{2i} + \psi_i = 1$.
- 从而若 Ψ 已知, 则可对 $\rho - \Psi$ 进行矩阵分解得到 L; 有了 L 后 可以由 $\Psi = \rho - LL'$ 得到 Ψ.
- 因此, 使用样本相关系数矩阵 R 代替 ρ, 使用 Ψ 的一个初始估 计代替, 则可以迭代求解 $\hat{\mathbf{L}}, \hat{\Psi}$ 此即为迭代主因子法.

迭代主因子法

- 1.若我们有 ψ_i 的估计 ψ^*_i , 则使用 $1-\psi^*_i = h^{*2}_i$ 代替 $\rho_{ii} = 1$ 后, 得到一个 " 缩减" 的样本相关系数矩阵

$$\mathbf{R}_r = \begin{pmatrix} h_1^{*2} & r_{12} & \cdots & r_{1p} \\ r_{21} & h_2^{*2} & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & h_p^{*2} \end{pmatrix}$$

- 2.对 m 个因子, 类似主成分方法将 R_r 因子化得到

$$\mathbf{R}_r \approx \mathbf{L}_r^* \mathbf{L}_r^{*\prime}$$

- 3.其中 L_r^* 由 R_r 的前 m 个特征根和特征向量构成. 有了 L_r^*后, 更新 Ψ 的估计为 $\Psi^* = diag\{\mathbf{R} - \mathbf{L}_r^* \mathbf{L}_r^{*\prime}\}$
- 重复上面 1-2 步直至满足收敛准则.

迭代主因子法

- 特殊方差 ψ_i(或共性方差 h^2_i) 的常用初始估计有如下几种:

- 取 $\psi_i^* = 1/r^{ii}$, 其中 r^{ii} 为 R^{-1} 的第 i 个对角元, 此时 $h_i^{*2} = 1 - \psi_i^*$ 为 X_i 和其它 $p-1$ 个变量间的样本负相关系数的平方. 这种初始估计方法最常用.

- 取 $h_i^{*2} = \max_{j \neq i} |r_{ij}|$, 此时 $\psi^* = 1 - h_i^{*2}$

- 取 $h_i^{*2} = 1$, 此时 $\psi^* = 0$, 得到的 $\mathbf{L}_r^*$ 为主成分解.

迭代主因子法

- 对主因子法, 需要注意
  - 缩减的相关系数矩阵 $\mathbf{R}_r$ 未必总是正定的, 因此其一些特征根可能是负的
  - 主因子方法的结果对因子个数 m 比较敏感, 不同 m 下得到的结果可能差异较大.
  - 如果 m 太大, 一些共性方差估计 h_i^{*2} 可能会大于 1.

最大似然方法

假定 $\mathbf{F} \sim N_m(0, I_m), \boldsymbol{\epsilon} \sim N_p(0, \Psi)$ 且两者相互独立. 从而 $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \mathbf{L}\mathbf{L}' + \Psi)$.

记 $l(\boldsymbol{\mu}, \mathbf{L}, \Psi)$ 为对数似然函数, 因此

$$
\begin{aligned}
(\hat{\boldsymbol{\mu}}, \hat{\mathbf{L}}, \hat{\Psi}) &= \arg\max l(\boldsymbol{\mu}, \mathbf{L}, \Psi) \\
&= \arg\max \Big\{ -\frac{n}{2} log|\mathbf{L}\mathbf{L}' + \Psi| \\
&\qquad - \frac{1}{2}\sum_{i=1}^{n}(\mathbf{x}_i - \boldsymbol{\mu})'(\mathbf{L}\mathbf{L}' + \Psi)^{-1}(\mathbf{x}_i - \boldsymbol{\mu}) \Big\}
\end{aligned}
$$

最大似然方法

计算得到 $\hat{\boldsymbol{\mu}} = \bar{\mathbf{x}}$, $\hat{\mathbf{L}}, \hat{\Psi}$ 满足

$$\begin{cases} \hat{\Sigma}\hat{\Psi}^{-1}\hat{\mathbf{L}} = \hat{\mathbf{L}}(I_m + \hat{\mathbf{L}}'\hat{\Psi}^{-1}\hat{\mathbf{L}}) \\ \hat{\Psi} = diag(\hat{\Sigma} - \hat{\mathbf{L}}\hat{\mathbf{L}}') \end{cases}$$

其中 $\hat{\Sigma} = \frac{1}{n}\sum_{i=1}^{n}(\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})'$.

由于对 $\hat{\mathbf{L}}$ 的解不唯一 (对任意正交阵 T, $\hat{\mathbf{L}}T$ 也满足等式), 因此为了得到唯一解, 常常附加计算上的限制条件

$$\hat{\mathbf{L}}'\hat{\Psi}^{-1}\hat{\mathbf{L}} \text{ 为对角阵}$$

因子旋转

- 前面我们已经看到, 在正交因子模型下，对因子负荷阵乘以一 个正交矩阵 T 可以得到对协方差矩阵同样的逼近.
- 这意味着, 我们使用 $\hat{\mathbf{L}}$ 或 $\hat{\mathbf{L}}T$ 来估计因子负荷阵都是可以的, 其中 T 为任意正交矩阵.
- 估计的残差矩阵 $\mathbf{S}-\hat{\mathbf{L}}\hat{\mathbf{L}}'-\hat{\Psi}=\mathbf{S}-(\hat{\mathbf{L}}T)(\hat{\mathbf{L}}T)'-\hat{\Psi}$ 不变, 而且估计的特殊方差和共性方差均不变.
- 我们希望通过旋转因子来更好对结果进行解释: 使因子负荷的 平方两极分化, 要么接近 0, 要么接近 1.
- 因子旋转方法主要有正交旋转和斜交变换两类.

正交旋转方法 (Orthogonal rotation)

- 正交旋转方法使得旋转后的因子仍然保持独立性. 常用的正交旋转方法包括: varimax, quartimax等.

最大方差旋转法 (varimax)(Kaiser, 1958)

- 直观上使得 p 个变量在每个因子上负荷尽可能分散, 即在 每个因子上的负荷方差最大.
- 该方法简化因子负荷阵的列, 是最常用的因子旋转方法.

记 $\hat{\mathbf{L}}^* = (\hat{l}^*_{ij})$ 为旋转的因子负荷阵, 令 $l^*_{ij} = \hat{l}^*_{ij}/\hat{h}_i$, 以及

$$V = \sum_{j=1}^{m}\left[\frac{1}{p}\sum_{i=1}^{p}\left\{(l^*_{ij})^2 - \frac{1}{p}\sum_{i=1}^{p}(l^*_{ij})^2\right\}^2\right]$$

$$\propto \sum_{j=1}^{m}\left[\text{第}j\text{个因子 (刻度变换后) 载荷平方的方差}\right]$$

从而选择 T, 使得 V 达到最大.

最大四次方法 (quartimax)

- varimax 旋转方法会破坏 “overall” 因子: 每个变量在该 因子上都有高负荷.
- quartimax 旋转目的在于保留 “overall” 因子, 建立其它因子, 使得每个变量在至多一个 (其它) 因 子上有高负荷.
- 最大化

$$V = \sum_{j=1}^{p} \left[\frac{1}{m} \sum_{i=1}^{m} \left\{ (l_{ij}^*)^2 - \frac{1}{m} \sum_{i=1}^{m} (l_{ij}^*)^2 \right\}^2 \right]$$

- 可使得解释每个变量所需的因子最少。该方法简化变量 (因子负荷阵的行)。